

Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Gradient Noise

Д. КОРТУНОВ В. ПАСТУШЕНКО А. ДУБОВИЦКИЙ А. ШАДРИН

НИУ ВШЭ, Москва

Ваш SGD расходится на финансовых данных?

Одна строка причинной предобработки переводит его **0/8** $\rightarrow$ **8/8** сходимостей и роняет асимптотический $\|\nabla f\|^2$ в **133** $\times$. Линейные фильтры так не умеют, а Adam — не панацея. Какой фильтр выбрать — решают *два числа* ($\hat{\alpha}, \hat{H}$).

Постановка

Наблюдаемый ряд — сигнал плюс шум, $y_t = s_t + \xi_t$. Перед обучением весь ряд проходит через причинный фильтр F : $\tilde{y} = F(y)$, и уже из сглаженного ряда строятся признаки $\tilde{\phi}_t$. Обучаем прогнозную модель (AR(p)) минимизацией риска методом первого порядка

$$g_k = \frac{1}{|\mathcal{B}_k|} \sum_{t \in \mathcal{B}_k} \nabla_x \ell(x_k, \tilde{\phi}_t, c_t), \quad x_{k+1} = x_k - \eta \phi(g_k).$$

Признаки и обучающий таргет — из ряда $\tilde{y}$; качество же оценивается на holdout по исходному будущему значению y_t .

На финансовых рядах шум тяжёлохвостый (α -устойчивый, $\alpha < 2$, бесконечная дисперсия) и долготпамятный. Тогда базовые предпосылки теории сходимости SGD нарушаются.

Вопрос. Как тройка (тип шума) $\times$ (фильтр) $\times$ (оптимизатор) влияет на сходимость, и можно ли по диагностике ряда заранее выбрать удачную пару?

Четыре класса шума

- N1 гауссов белый (контроль)
- N2 розовый $1/f$ (долгая память)
- N3 α -устойчивый (тяжёлый хвост)
- N4 смешанный (хвост $\cap$ память)

Фильтры F_0 – F_4 (все причинные)

- F_0 без фильтрации (контроль)
- F_1 скользящее среднее (линейный)
- F_2 фильтр Калмана (линейный)
- F_3 вейвлет-порог (Добеши)
- F_4 причинная медиана (робастный)

Оптимизаторы: SGD, Clipped-SGD, Normalized-SGD, Adam, AdamW. Дизайн — два блока: А (SGD-семейство, N1/N3/N4; спасение сходимости) и В (Adam/AdamW, N2/N4; скорость).

Предпосылки и гипотезы


При $\alpha < 2$ второй момент градиентного шума бесконечен — редкие гигантские шаги не дают SGD стабилизироваться. Медиана устойчива к выбросам и может вернуть градиентному шуму конечную дисперсию — отсюда спасение. Линейные фильтры α -устойчивость не убирают; долгую память лечит спектральное разреживание (вейвлет) или адаптивный шаг (Adam).

- Гипотеза 1 (N3): медиана F_4 переводит SGD в сходящийся режим; линейные фильтры — нет.
- Гипотеза 2 (N2): для Adam/AdamW вейвлет F_3 ускоряет сходимость сильнее линейных фильтров.
- Гипотеза 3 (N4): ни один простой фильтр не снижает асимптотический уровень $\|\nabla f\|^2$.
- Гипотеза 4 (N1): фильтрация нейтральна, медиана чуть хуже среднего.

Эксперимент 1: тяжёлые хвосты ($\alpha=1.2$, SGD)

Без фильтра и с линейными F_1, F_2, F_3 — 0/8 сходимостей; причинная медиана F_4 — 8/8, асимптотический уровень $\|\nabla f\|^2$ ниже в 20–133 $\times$.


Задача	бин. F_0	бин. F_4	асимпт. F_0	асимпт. F_4
квадратичная	0/8	8/8	0.540	0.0050
логистическая	0/8	8/8	0.0658	0.00050
авторегрессия	8/8	8/8	0.0421	0.0021




F_0 и линейные фильтры застревают на асимптотическом уровне; F_4 уходит вниз на 1–2 порядка.

Долгая память, смешанный шум, гауссов контроль

N2, Adam: вейвлет F_3 ускоряет сходимость в 11.2 $\times$ (T_ε 562 $\rightarrow$ 50), Калман F_2 — 3.1 $\times$, линейные/медиана — нет.




N4: отношение асимптотических уровней $F_0/F_k \approx 1$ для всех фильтров — ни один простой фильтр не работает (гипотеза 3). N1: фильтрация нейтральна, F_4 слегка проигрывает среднему (гипотеза 4):



Эксперименты 2–3: калибровка и реальные ряды

Медиана по корзине из 9 инструментов: $\hat{\alpha} \approx 1.2, \hat{d} \approx 0.29$. На калиброванной синтетике спасение сходимости сохраняется (91–120 $\times$):



На реальных рядах (Adam); holdout MSE в формате лучший / F_0 :

Домен	согл. F_0	лучший	ускор.	holdout
фин. 15-мин	7/16	F_2	78 $\times$	0.528/0.522
фин. дневные	13/16	F_2	10 $\times$	0.634/0.626
сенсор ETT	16/16	F_1	2.1 $\times$	0.653/0.488
макро FRED	16/16	F_0	—	F_0 лучший

Фильтр помогает там, где шум тяжёлый, и нейтрален на «аккуратных» рядах.

Правило ($\hat{\alpha}, \hat{H}$) $\rightarrow$ фильтр

Режим ($\hat{\alpha}, \hat{H}$)	связка	основание
$\hat{\alpha} \approx 2, \hat{H} \approx 0.5$	F_0	теория+опыт
$\hat{\alpha} \approx 2, \hat{H} > 0.6$	F_3 +Adam	теория+опыт
$\hat{\alpha} < 1.9, \hat{H} \approx 0.5$	F_4 +SGD	теория+опыт
$\hat{\alpha} < 1.9, \hat{H} > 0.6$	F_4/F_2 , валид.	не проверено

F_2 +Adam для N4 — лишь кандидат, не проверенный напрямую (эвристика).

Выводы

- Робастная порядковая статистика (медиана) восстанавливает конечную дисперсию градиента — линейные фильтры этого не дают.
- Тяжёлый хвост сам по себе не повод фильтровать: если узкое место не в сходимости (гаусс, светлый хвост), лучший выбор — F_0 .
- На финансовых рядах фильтр ускоряет оптимизацию, но почти не меняет качество прогноза на holdout.
- Все четыре гипотезы подтвердились в проведённых экспериментах.
- Открытая проблема — смешанный режим N4.

Код и данные: github.com/Poogee/momo_proj