

Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Noise

Дмитрий Кортунوف
НИУ ВШЭ
Москва, Россия
dvkortunov@edu.hse.ru

Вадим Пастушенко
НИУ ВШЭ
Москва, Россия
vapastushenko@edu.hse.ru

Алексей Дубовицкий
НИУ ВШЭ
Москва, Россия
andubovitskiy@edu.hse.ru

Андрей Шадрин
НИУ ВШЭ
Москва, Россия
arshadrin@edu.hse.ru

Аннотация—Финансовые временные ряды содержат шум различной природы: гауссов, тяжёлохвостовый, коррелированный и их комбинации. Прямая подача таких данных в стандартные стохастические оптимизаторы нарушает базовые предположения теории сходимости. Мы исследуем альтернативный подход: перед оптимизацией применяется этап шумоподавления — скользящее среднее, фильтр Калмана, вейвлет-пороговая обработка или медианная фильтрация, — после чего ряд подаётся в SGD, Adam или AdamW. Основной вопрос: насколько выбор фильтра влияет на скорость сходимости и итоговое качество модели, и можно ли подобрать пару (фильтр, оптимизатор), устойчивую к нескольким типам шума одновременно?

Index Terms—шумоподавление, финансовые временные ряды, стохастическая оптимизация, фильтр Калмана, вейвлет-порог, медианная фильтрация, Adam, SGD, сходимость

I. Введение

В обучении на финансовых временных рядах стандартно фокусируются либо на выборе архитектуры модели, либо на модификациях оптимизатора. При этом сама структура входного шума часто остаётся «за кадром», хотя для финансовых данных именно она задаёт сложность обучения: тяжёлые хвосты, долгая память и выбросы нарушают предпосылки, при которых гарантируется стабильная работа классических стохастических методов.

В проекте мы рассматриваем шумоподавление не как вспомогательную технику визуализации, а как полноценную часть оптимизационного процесса. Гипотеза состоит в том, что правильная предобработка может существенно изменить свойства градиентного шума и тем самым ускорить сходимость без усложнения самого оптимизатора.

Эмпирически мы сравниваем матрицу (тип шума) $\times$ (фильтр) $\times$ (оптимизатор) на синтетических и реальных финансовых данных и получаем ответ на практический вопрос: когда предобработка действительно помогает, а когда её эффект минимален или даже вреден из-за пересглаживания полезного сигнала.

Ответ, который мы получаем на первых экспериментах: при тяжёлых хвостах меняет, и сильно. При гауссовом шуме — нет.

II. Постановка задачи

A. Наблюдательная модель

Наблюдаемый ряд $y_1, \dots, y_T \in \mathbb{R}$ описывается стандартной аддитивной моделью:

$$y_t = s_t + \xi_t, \quad (1)$$

где s_t — сигнал, ξ_t — шум. Рассматриваем четыре класса шума.

N1 — гауссов белый, $\xi_t \sim \mathcal{N}(0, \sigma^2)$. Это контрольный случай, при котором теория сходимости SGD работает в полную силу.

N2 — розовый ($1/f$): $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$ с гауссовыми инновациями η_j и коэффициентами FARIMA(0, d , 0), $d \in (0, 1/2)$. Дисперсия конечна, но корреляции убывают медленно.

N3 — тяжёлохвостовый, $\xi_t \sim S_\alpha(\sigma, 0, 0)$, $\alpha \in (1, 2)$. Моменты порядка $p \geq \alpha$ бесконечны. Именно этот режим наиболее близок к реальным финансовым данным.

N4 — смешанный: α -устойчивые инновации, пропущенные через $1/f$ -фильтр. Тяжёлые хвосты и долгая память присутствуют одновременно.

B. Целевые функции

Минимизируется $f : \mathbb{R}^d \rightarrow \mathbb{R}$ по параметрам $x \in \mathbb{R}^d$. Используем две задачи.

Квадратичная: при положительно определённой матрице $A \in \mathbb{R}^{d \times d}$ и векторе $b \in \mathbb{R}^d$

$$f(x) = \frac{1}{2} x^\top A x - b^\top x. \quad (2)$$

Минимум единственный: $x^* = A^{-1}b$. Задача удобна тем, что позволяет изолированно измерить влияние шума на сходимость, не путая его с нелинейностью ландшафта потерь.

Логистическая регрессия: при наборе $\{(\phi_t, c_t)\}_{t=1}^n$, где $\phi_t \in \mathbb{R}^d$ — лаговые признаки из ряда y , $c_t \in \{0, 1\}$ — метка,

$$f(x) = -\frac{1}{n} \sum_{t=1}^n [c_t \log \sigma(x^\top \phi_t) + (1 - c_t) \log(1 - \sigma(x^\top \phi_t))]. \quad (3)$$

Здесь шум из ряда попадает прямо в признаки и тем самым в градиент.

С. Авторегрессионная постановка

Для задачи краткосрочного прогноза используем причинную $AR(p)$ -модель. На шаге $t > p$ входом модели служит вектор последних p наблюдений

$$\phi_t = [\tilde{y}_{t-1}, \tilde{y}_{t-2}, \dots, \tilde{y}_{t-p}]^\top \in \mathbb{R}^p, \quad (4)$$

где $\tilde{y}$ — либо исходный ряд y , либо его фильтрованная версия после применения выбранного фильтра F .

Выходом модели является одношаговый прогноз следующего значения ряда

$$\hat{y}_t = x^\top \phi_t, \quad (5)$$

где $x \in \mathbb{R}^p$ — вектор авторегрессионных коэффициентов. Целевой переменной при обучении выступает истинное следующее наблюдение y_t , поэтому для каждого объекта имеем пару (ϕ_t, y_t) .

Соответствующая функция потерь берётся квадратичной:

$$f(x) = \frac{1}{n} \sum_{t=p+1}^{p+n} (x^\top \phi_t - y_t)^2. \quad (6)$$

В этой постановке фильтрация влияет прежде всего на входные признаки ϕ_t , а качество модели оценивается по тому, насколько точно по прошлым значениям восстанавливается следующее значение ряда.

Д. Фильтры и стохастический градиент

Перед оптимизацией ряд обрабатывается фильтром F : $\tilde{y} = F(y_1, \dots, y_T)$. Признаки строятся из $\tilde{y}$, минибатчевый градиент на итерации k :

$$g_k = \frac{1}{|\mathcal{B}_k|} \sum_{t \in \mathcal{B}_k} \nabla_x \ell(x_k, \tilde{\phi}_t, c_t). \quad (7)$$

Пять режимов предобработки. F0 — без фильтрации ($\tilde{y}_t = y_t$), контрольный вариант. F1 — скользящее среднее по w последним наблюдениям. F2 — фильтр Калмана с моделью случайного блуждания $s_t = s_{t-1} + w_t$; оптимален при гауссовом шуме [1]. F3 — вейвлет-пороговая обработка в базисе Добеши [3], [4]. F4 — причинная медиана по w последним наблюдениям; из всех рассматриваемых фильтров единственная устойчива к выбросам [6].

Все фильтры причинные: при вычислении $\tilde{y}_t$ используются только $y_1, \dots, y_t$.

Е. Оптимизаторы и метрики

Обновление имеет вид $x_{k+1} = x_k - \eta \phi(g_k)$. Рассматриваем: SGD ($\phi(g) = g$), Clipped-SGD ($\phi(g) = \min(1, \tau/\|g\|)g$), Adam [12] и AdamW [13].

Основная метрика — медианное время до ε -точности по 8 запускам:

$$T(\varepsilon; F, A, \mathcal{N}) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\}. \quad (8)$$

Дополнительно смотрим на бинарную сходимость (доля запусков, достигших 100-кратного снижения $\|\nabla f\|^2$) и на шумовой пол — медиану финального $\|\nabla f\|^2$ по последним 200 итерациям.

III. Обзор литературы

А. Фильтрация временных рядов

Фильтр Калмана [1] для финансовых приложений подробно разобран у Harvey [2]. Теория вейвлет-порогового шумоподавления восходит к работе Donoho и Johnstone [3]; базисы Добеши [4] стали стандартом практики. Медианную фильтрацию и её взвешенные обобщения систематически изложили Yin et al. [6].

В. Природа финансового шума

Cont [7] зафиксировал набор устойчивых эмпирических фактов для доходностей: тяжёлые хвосты, кластеризация волатильности, медленное убывание автокорреляций абсолютных значений. Мандельброт [8] предложил α -устойчивые распределения в качестве модели ещё в 1963 году. Şimşekli et al. [9] показали, что стохастический градиент при обучении нейросетей демонстрирует те же признаки — α -устойчивость с α заметно меньше двух.

С. Стохастическая аппроксимация при нестандартном шуме

Asymptotic-уровень: Anantharam и Borkar [10] исследуют стохастическую аппроксимацию при одновременно тяжёлом и долгозависимом шуме методом предельного ОДУ. Первые конечновременные гарантии при обоих эффектах сразу получены в недавней работе Chandak et al. [11]. Направление робастной оптимизации через обрезание градиентов развито у Gorbunov et al. [14] и Zhang et al. [15]; вероятностные гарантии для невыпуклого случая — у Cutkosky и Mehta [16].

Д. Место данной работы

Перечисленные работы либо анализируют поведение конкретного оптимизатора при заданном типе шума, либо изучают свойства фильтров как таковых. Совместное влияние выбора фильтра и оптимизатора при тяжёлохвостовом и коррелированном финансовом шуме эмпирически не измерялось. Открытого бенчмарка формата (фильтр $\times$ шум $\times$ оптимизатор) на финансовых рядах нам обнаружить не удалось.

IV. Эксперимент 1: синтетика

А. Дизайн

Полный факторный эксперимент: три задачи (квадратичная регрессия $d = 20$, логистическая классификация $d = 15$, авторегрессия $AR(5)$) на трёх типах шума (N1, N3 с $\alpha = 1.2$, N4), пяти оптимизаторах (SGD, Clipped-SGD, Normalized-SGD, Adam, AdamW) и пяти фильтрах (F0–F4). По 8 независимых запусков на каждую ячейку. Горизонт 2000 итераций, $\sigma = 0.5$. Гиперпараметры одинаковы для всех ячеек — никакого подбора под конкретный фильтр.

В. Что происходит при тяжёлых хвостах

При шуме N3 ($\alpha = 1.2$) SGD без фильтра не сходится ни в одном из 8 запусков на квадратичной и логистической задачах — $\|\nabla f\|^2$ застревает на шумовом полу и остаётся там, сколько бы итераций мы ни запускали. Фильтры F1, F2, F3 картину не меняют: для каждого из них результат тот же, 0/8. Единственный фильтр, который переводит задачу в сходящийся режим — причинная медиана F4: 8/8 на квадратичной и логистической задачах (табл. I).

Таблица I: Тяжёлохвостовый шум N3, SGD: бинарная сходимость и шумовой пол.

Задача	бин. F0	бин. F4	пол F0	пол F4	F0/F4
квадратичная	0/8	8/8	0.540	0.0050	108×
логистическая	0/8	8/8	0.0658	0.00050	133×
авторегрессия	8/8	8/8	0.0421	0.0021	20×

Для авторегрессионной задачи сходимость формально достигается и без фильтра — слишком большой начальный $\|\nabla f_0\|^2$. Но шумовой пол с F4 ниже в 20 раз.

На гауссовом контроле N1 всё ровно наоборот: F4 немного хуже F0, отношение шумовых полов 0.76–0.95. Это ожидаемо — медиана теряет немного точности на распределении, для которого оптимальна среднее.




Рис. 1: Шум N3, SGD, 8 сидов. Слева — шумовые полы F0–F4 (лог-шкала, полоса p10–p90). Справа — медианные кривые $\|\nabla f\|^2$: F0 и линейные фильтры застревают, F4 уходит вниз на 1–2 порядка.

С. Долгая память и адаптивные методы

При шуме N2 ($1/f$) с Adam и AdamW вейвлет-фильтр F3 ускоряет сходимость в 11.2 раза: $T(\varepsilon)$ падает со 562 итераций (F0) до 50 (F3). Фильтр Калмана даёт $3.1\times$. Площадь под кривой (AUC по $\log \|\nabla f\|^2$): F3 даёт -0.94 против -0.65 у F0.

На смешанном N4 и в ряде конфигураций с Adam на N2 разницы между F0 и фильтрами нет — Adam достаточно хорошо справляется с коррелированным градиентным шумом без дополнительного сглаживания.

V. Эксперимент 2: калибровка под реальные ряды

A. Откуда взялось $\alpha = 1.2$

Прежде чем интерпретировать синтетические результаты, стоит проверить, насколько $\alpha = 1.2$ соответствует

реальным финансовым данным. Мы оценили индекс хвоста $\hat{\alpha}$ методом Маккаллоха и показатель Хёрста $\hat{H}$ методом DFA для корзины из 9 инструментов (SPY, QQQ, AAPL, MSFT, JPM, EUR/USD, GBP/USD, BTC, ETH) за 2018–2025 гг. по дневным логдоходностям (источник: Yahoo Finance). Часть результатов приведена в табл. II.

Таблица II: Оценки тяжести хвоста и памяти для выборки инструментов.

Инструмент	$\hat{\alpha}$	$\hat{H}$
SPY	1.05	0.86
QQQ	1.07	0.82
JPM	1.12	0.79
EUR/USD	≈ 1.2	≈ 0.55
BTC	≈ 1.4	≈ 0.60

Медиана по корзине: $\hat{\alpha} = 1.21$, $\hat{d} = 0.29$. Выбранное в эксперименте 1 значение $\alpha = 1.2$ попадает в середину диапазона.

В. Эксперимент при $\hat{\alpha} = 1.21$

При синтетическом шуме, откалиброванном под медиану реальных данных (N3cal, $\hat{\alpha} = 1.21$), основной эффект сохраняется: шумовой пол SGD с F4 ниже F0 в 91 раз (квадратичная), 120 раз (логистическая), 17 раз (авторегрессия).

Для смешанного режима N4cal ($\hat{d} = 0.29$, $\hat{\alpha} = 1.21$) простые фильтры шумовой пол не снижают — отношение F0/F4 около единицы. По всей видимости, медиана видит единичные выбросы, но долгая память «растягивает» выброс по времени, и скользящее окно медианы его уже не захватывает.




Рис. 2: Синтетика, откалиброванная под реальные $\hat{\alpha}$ и $\hat{d}$. При тяжёлохвостовом N3cal разрыв F0/F4 сохраняется (91–120×). При смешанном N4cal разрыва нет.

VI. Эксперимент 3: реальные финансовые ряды

A. Дизайн

Корзина из 9 инструментов, разбиение 70/30, только причинные фильтры. Holdout — нефильтрованные будущие значения, одинаковые для всех фильтров. На каждой паре (фильтр, оптимизатор) обучается AR(5)-модель. Метрики: итераций до сходимости ($T(\varepsilon)$), бинарная сходимость, causal holdout MSE.

Таблица III: Реальные ряды, Adam: итерации до сходимости и holdout MSE.

Домен	T F0	согл. F0	T лучш.	ускор.	holdout
фин. 15-мин	4000	7/16	F2 52	78×	0.528/0.522
фин. дневные	554	13/16	F2 57	10×	0.634/0.626
сенсор ETT	43	16/16	F1 20	2.1×	0.65/0.49
макро FRED	20	16/16	F0 20	—	F0 лучший

V. Результаты

На 15-минутных доходностях (SPY, QQQ и др.) Adam без фильтра сходится в 7 прогонах из 16; медиана T упирается в потолок 4000 итераций. С фильтром Калмана (F2) сходятся все 16, за 52 итерации в среднем. Это примерно 78-кратное ускорение. Holdout MSE при этом практически не меняется: 0.528 против 0.522.

На дневных доходностях ускорение есть (примерно 10-кратное), но оно значительно скромнее. На сенсорных данных ETT фильтр ускоряет сходимость, однако снижает точность на holdout — очевидно, пересглаживает полезную структуру в ряде. На макроэкономических данных FRED лучший вариант — F0 без фильтра.

Общий вывод: фильтр помогает там, где шум тяжёлый и домен близок к финансовому. Там, где данные ведут себя «аккуратнее», фильтр в лучшем случае нейтрален.




Рис. 3: Эксперимент на реальных доменах (Adam). Слева — итерации до сходимости. Справа — causal holdout MSE. На 15-минутных доходностях разрыв между F0 и F2 хорошо виден.

VII. Как выбрать фильтр на практике

Выбор фильтра зависит от типа шума в данных, а тип шума можно оценить по обучающей части ряда до начала обучения. Две диагностические характеристики — индекс хвоста $\hat{\alpha}$ (метод Маккаллоха или Хилла) и показатель Хёрста $\hat{H}$ (DFA) — делят пространство на четыре случая:

- $\hat{\alpha} \approx 2$, $\hat{H} \approx 0.5$: шум близок к гауссовому белому — фильтрация скорее не нужна, F0.
- $\hat{\alpha} \approx 2$, $\hat{H} > 0.6$: долгая память при лёгком хвосте — вейвлет F3 с Adam.
- $\hat{\alpha} < 1.9$, $\hat{H} \approx 0.5$: тяжёлый хвост без памяти — причинная медиана F4 с SGD.
- $\hat{\alpha} < 1.9$, $\hat{H} > 0.6$: оба эффекта сразу — ни один простой фильтр пока не работает стабильно, пробуем F4+SGD и F2+Adam, смотрим по валидации.

Диагностика задаёт стартовый список из 2–3 кандидатов. Финальный выбор делается по causal walk-forward валидации: обучение на train-части, оценка на нефилтрованном holdout. Рекомендации из списка — не истина в последней инстанции, а отправная точка для поиска.

VIII. Проблемы и следующие шаги

В ходе работы мы столкнулись с двумя неожиданными ситуациями, которые изменили дизайн экспериментов.

Первая — артефакт заглядывания вперёд. Центрированная (не причинная) медиана давала ложный прирост в точности прогноза направления на 7 п.п. Когда мы заменили её на причинную медиану, эффект исчез. Это стандартная проблема look-ahead bias, но она легко проскальзывает при небрежной реализации. Теперь все фильтры в экспериментах строго причинные.

Вторая — смешанный режим N4. Ни один из простых фильтров не снижает там шумовой пол. Интуиция: медиана работает с отдельными выбросами, но долгая память превращает выброс в аномальный кластер, который в окно медианы не помещается. Что с этим делать — пока открытый вопрос.

Дальнейшие шаги: адаптивный фильтр с онлайн-диагностикой типа шума, расширение корзины инструментов.

IX. Заключение

Главное, что мы наблюдаем в первых экспериментах: при α -устойчивом шуме с $\alpha \approx 1.2$ SGD без фильтра не достигает целевой точности ни в одном из восьми запусков — и это не вопрос количества итераций, а вопрос наличия конечного предела. Причинная медиана переводит задачу в сходящийся режим (8/8) и снижает шумовой пол в 20–133 раза. Линейные фильтры этого не делают. Тот же эффект воспроизводится на реальных 15-минутных доходностях.

При гауссовом шуме и на дневных доходностях фильтр не помогает. Это не случайное исключение, а следствие того, что медиана оптимальна для тяжёлых хвостов, но проигрывает среднему там, где хвосты лёгкие.

Практическое следствие: перед обучением на финансовых данных имеет смысл оценить $\hat{\alpha}$ и $\hat{H}$ и выбирать фильтр исходя из этих оценок, а не запускать один и тот же конвейер на всех рядах без разбора.

Список литературы

- [1] R. E. Kalman, “A new approach to linear filtering and prediction problems,” J. Basic Eng., vol. 82, no. 1, pp. 35–45, 1960.
- [2] A. C. Harvey, Forecasting, Structural Time Series Models and the Kalman Filter. Cambridge: Cambridge Univ. Press, 1990.
- [3] D. L. Donoho and I. M. Johnstone, “Ideal spatial adaptation by wavelet shrinkage,” Biometrika, vol. 81, no. 3, pp. 425–455, 1994.
- [4] I. Daubechies, Ten Lectures on Wavelets. Philadelphia: SIAM, 1992.

- [5] S. Mallat, *A Wavelet Tour of Signal Processing*. San Diego: Academic Press, 1999.
- [6] L. Yin, R. Yang, M. Gabbouj, and Y. Neuvo, "Weighted median filters: a tutorial," *IEEE Trans. Circuits Syst. II*, vol. 43, no. 3, pp. 157–192, 1996.
- [7] R. Cont, "Empirical properties of asset returns: stylized facts and statistical issues," *Quant. Finance*, vol. 1, no. 2, pp. 223–236, 2001.
- [8] B. B. Mandelbrot, "The variation of certain speculative prices," *J. Business*, vol. 36, no. 4, pp. 394–419, 1963.
- [9] U. Şimşekli, L. Sagun, and M. Gürbüzbalaban, "A tail-index analysis of stochastic gradient noise in deep neural networks," in *Proc. ICML*, 2019, pp. 5827–5837.
- [10] V. Anantharam and V. S. Borkar, "Stochastic approximation with long-range dependent and heavy-tailed noise," *Queueing Syst.*, vol. 71, no. 1–2, pp. 221–242, 2012.
- [11] P. Chandak, A. Yadav, A. Özgür, and N. Bambos, "Heavy-Tailed and Long-Range Dependent Noise in Stochastic Approximation: A Finite-Time Analysis" *arXiv:2503.19648*, Mar. 2026.
- [12] D. P. Kingma and J. Ba, "Adam: a method for stochastic optimization," in *Proc. ICLR*, 2015.
- [13] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *Proc. ICLR*, 2019.
- [14] E. Gorbunov, M. Danilova, and A. Gasnikov, "Stochastic optimization with heavy-tailed noise via Accelerated Gradient Clipping," in *Proc. NeurIPS*, 2020.
- [15] J. Zhang, T. He, S. Sra, and A. Jadbabaie, "Why gradient clipping accelerates training: a theoretical justification for adaptivity," in *Proc. ICLR*, 2020.
- [16] A. Cukkosky and H. Mehta, "High-probability bounds for non-convex stochastic optimization with heavy tails," in *Proc. NeurIPS*, 2021.