

# Шумоподавление наблюдаемого ряда как предобработка стохастической оптимизации: когда фильтрация спасает сходимость при тяжёлохвостовом градиентном шуме

Дмитрий Кортунов  
НИУ ВШЭ  
Москва, Россия

Вадим Пастушенко  
НИУ ВШЭ  
Москва, Россия

Алексей Дубовицкий  
НИУ ВШЭ  
Москва, Россия

Андрей Шадрин  
НИУ ВШЭ  
Москва, Россия

Аннотация—Шумоподавление наблюдаемого ряда трактуется как явный этап конвейера стохастической оптимизации. Сначала формализуется модель временного ряда и задача прогноза (раздел II), затем выносятся теоретический фон с механизмом эффекта и гипотезами (раздел III), затем описывается экспериментальная проверка (раздел IV) и, наконец, эмпирически обоснованные практические критерии выбора связки “фильтр+оптимизатор” (раздел V). Главный механизм: при  $\alpha$ -устойчивом градиентном шуме ( $\alpha < 2$ , бесконечная дисперсия) SGD с постоянным шагом не выводит  $\mathbb{E} \|\nabla f\|^2$  к нулю; оконная медиана отображает окно с бесконечной дисперсией в порядковую статистику с конечной дисперсией, что возвращает обычную сходимость  $\mathbb{E} \|\nabla f\|^2 \rightarrow 0$ , тогда как любой линейный фильтр (скользящее среднее, Калман) сохраняет  $\alpha$ -устойчивый закон. Для смешанного режима (тяжёлые хвосты + долгая память) одиночная медиана уже не работает — вводится причинный каскадный фильтр  $F_5$  (медиана  $\rightarrow$  Калман) и его адаптивная версия  $F_6$  (стадии выбираются по  $\hat{\alpha}, \hat{H}$ ), которые мы предлагаем именно для этого режима. Эмпирически при  $\hat{\alpha} \approx 1.2$  обычный SGD сходится в 0/8 прогонах (как и линейные/вейвлет-фильтры) и в 8/8 с причинной медианой, снижая асимптотический уровень  $\|\nabla f\|^2$  в  $108\times$  (квадратичная) и  $133\times$  (логистическая). Сводно на широкой корзине реальных доменов (дневные/15-мин/5-мин акции, часовые крипто Binance, волатильность  $|r|$ , FRED, ETTh1/h2/m1/m2, Electricity, Traffic, NOAA, C-MAPSS, ATM, sunspots) по двум диагностикам ( $\hat{\alpha}, \hat{H}$ ) выводится правило выбора фильтра, покрывающее все четыре сектора: на часовых крипто ( $\hat{\alpha} \approx 1.47$ ) Adam без фильтра сходится лишь в 3 из 8 прогонов, а Калман  $F_2$  и наш каскад  $F_5$  доводят до 8/8 и ускоряют в  $\approx 78\times$  и  $64\times$ ; на гладких/гауссовых рядах лучший выбор —  $F_0$  (фильтровать не нужно).

Index Terms—стохастическая оптимизация, тяжёлохвостовый шум,  $\alpha$ -устойчивые распределения, медианная фильтрация, причинный каскадный фильтр, фильтр Калмана, долгая память, сходимость.

## I. Введение

Теория сходимости стохастических методов первого порядка опирается на конечный второй момент градиентного шума и слабую временную зависимость. Оба предположения нарушаются при обучении на финансовых рядах: доходности тяжёлохвостовы и долгопамятны [1], [2], и стохастический градиент наследует эти свойства [3]. Мы рассматриваем шумоподавление не как визуализацию, а как вычислительный этап между наблюдениями и оптимизатором, и ставим точный вопрос: для каких троек (шум, фильтр, оптимизатор) предобработка превращает несходящийся прогон в сходящийся и почему.

Структура текста задана по разделам: II — модель временного ряда, термины, задача прогноза и формальная постановка решаемой задачи (без описания алгоритмов); III — теоретический фон и явно сформулированные гипотезы (с компактными определениями фильтров и оптимизаторов как аналитических объектов); IV — экспериментальный план, расширенная корзина реальных доменов (включая нефинансовые) и анализ; V — практические критерии выбора, где каждый пункт явно помечен как “из теории”, “из эксперимента” или “эвристика”; VI — заключение.

Вклад статьи. (i) Чистая формализация задачи, отделённая от конкретных алгоритмов; (ii) утверждение, выделяющее механизм: нелинейная порядковая статистика восстанавливает конечную эффективную дисперсию шума, чего линейные фильтры дать не могут; (iii) новый причинный каскадный фильтр  $F_5$  и его адаптивный вариант  $F_6$ , спроектированные под предсказанный негативный режим N4 (тяжёлые хвосты  $\cap$  долгая память); вместе с классическими  $F_0$ – $F_4$  и онлайн-переключателем  $F_7$  они образуют сплошной

причинный набор  $F_0$ – $F_7$ ; (iv) эмпирическое выведение правила “ $(\hat{\alpha}, \hat{H}) \rightarrow$  фильтр” на широкой корзине публично доступных финансовых и нефинансовых рядов с покрытием всех четырёх секторов диагностик.

## II. Модель временного ряда и постановка задачи

В этом разделе мы фиксируем только объекты (ряд, признаки, цель, функция риска, шум на градиенте, место фильтра как абстрактного оператора). Конкретные семейства фильтров, шумов и оптимизаторов вводятся отдельно в разделе III; здесь они присутствуют только как формальные символы.

### A. Наблюдаемый ряд

Определение 1 (Наблюдаемая модель). Скалярный временной ряд  $y_{1:T} \in \mathbb{R}^T$  описывается аддитивной моделью

$$y_t = s_t + \xi_t, \quad t = 1, \dots, T, \quad (1)$$

где  $s \in \mathbb{R}^T$  — сигнал (неизвестная гладкая или закономерно меняющаяся компонента), а  $\xi \in \mathbb{R}^T$  — шум (стохастический процесс из некоторого класса с известными аналитическими свойствами).

В разделе III мы фиксируем четыре класса шума  $\mathcal{N} \in \{N_1, N_2, N_3, N_4\}$  (гауссов, долгая память, тяжёлые хвосты, смешанный); здесь  $\mathcal{N}$  рассматривается как параметр задачи.

### B. Признаки, целевая переменная, задача обучения

Определение 2 (Задача обучения по ряду). Из ряда  $y_{1:T}$  формируются обучающие пары  $(u_i, v_i)_{i=1}^n$ : вход  $u_i \in \mathbb{R}^p$  — лаговое окно  $u_i = (\tilde{y}_{t_i-1}, \dots, \tilde{y}_{t_i-p})$ , цель  $v_i = \tilde{y}_{t_i}$  (регрессия следующего значения) или  $\mathbf{1}\{\tilde{y}_{t_i} > 0\}$  (классификация знака). Здесь  $\tilde{y}$  — результат применения некоторого фильтра-оператора  $F$  к  $y_{1:T}$  (см. 4). На отложенных значениях используется сырой (нефильтрованный)  $y$ , идентичный для всех фильтров — это исключает заглядывание вперёд.

При параметрической модели  $g_x: \mathbb{R}^p \rightarrow \mathbb{R}$  ( $x \in \mathbb{R}^d$ ) и функции потерь  $\ell$  (квадратичной для регрессии, логистической для классификации) задача обучения — минимизация эмпирического риска:

$$f(x) = \frac{1}{n} \sum_{i=1}^n \ell(g_x(u_i), v_i), \quad x^* \in \arg \min_{x \in \mathbb{R}^d} f(x). \quad (2)$$

Определение 3 (Прогноз). Прогноз — это оценка  $\hat{v}_t = g_{\hat{x}}(u_t)$ , где  $\hat{x}$  — результат обучения. Качество прогноза измеряется на отложенной причинной выборке (test, идущий строго позже train) либо MSE (регрессия), либо точностью (классификация знака).

### C. Фильтр как оператор и его место в конвейере

Определение 4 (Фильтр). Фильтр — это отображение  $F: \mathbb{R}^T \rightarrow \mathbb{R}^T$ ,  $\hat{s} = F(y_{1:T})$ , применённое до формирования признаков.  $F$  называется причинным, если  $\hat{s}_t$  зависит только от  $y_{1:s \leq t}$  (будущее не используется). Контрольный фильтр  $F_0 = \text{Id}$  соответствует “без фильтрации”.

### D. Стохастический шаг и формальная задача

Определение 5 (Стохастический градиент и шаг). На итерации  $k$  методу первого порядка доступен зашумлённый градиент

$$g_k = \nabla f(x_k) + \xi_k, \quad x_{k+1} = x_k - \eta_k \phi(g_k), \quad (3)$$

$\xi_k$  — центрированный шум (общим образом ни  $\mathbb{E} \|\xi_k\|^2 < \infty$ , ни независимости по  $k$  не предполагается),  $\phi$  — оператор обновления,  $\eta_k$  — шаг.

Определение 6 (Формальная задача исследования). Дано: класс шумов  $\mathcal{N}$  из определения 1, множество причинных фильтров  $\mathcal{F}$  из определения 4, множество операторов обновления  $\mathcal{A}$  из (3), модель обучения  $f$  из (2). Требуется оценить отображение

$$\Phi: (F, A, \mathcal{N}) \mapsto (T(\varepsilon), c(\varepsilon), h), \quad (4)$$

где  $T(\varepsilon)$  — эмпирическое время до  $\varepsilon$ -точности по  $\|\nabla f\|^2$ ,  $c(\varepsilon)$  — доля прогонов, достигших заданного снижения градиента (бинарная сходимость),  $h$  — качество на отложенной выборке (3). Иначе говоря, вход процедуры — наблюдаемый ряд  $y_{1:T}$  и выбор тройки  $(F, A, \mathcal{N})$ ; выход — обученные  $x_K$  и набор метрик сходимости и качества. Никакого иного содержания у решаемой задачи нет; конкретные семейства  $\mathcal{F}, \mathcal{A}, \mathcal{N}$  выносятся в раздел III, чтобы постановка не смешивалась с алгоритмами.

## III. Теоретический фон, классы методов и гипотезы

### A. Связанные работы

Совместный тяжёлохвостовой/долгопамятный (LRD) режим в стохастической аппроксимации впервые проанализирован асимптотически Anantharam и Borkar [4] через предельное ОДУ; Chandak и др. [5] дают первые конечновременные оценки моментов для того же режима. Обе работы анализируют немодифицированную итерацию. Робастность к тяжёлым хвостам иначе достигается модификацией оптимизатора: обрезание градиента [6], high-probability оценки при неограниченной дисперсии [7], [8], нелинейный SGD [9]. Классические операторы шумоподавления — фильтр Калмана [10], мягкий вейвлет-порог [11]–[13], взвешенные медианы [14] — и декорреляция LRD-процессов вейвлетами [15] известны; шумоподавление как предобработка прогноза изучалось эмпирически [16]. Наш вопрос ортогонален: при фиксированном оптимизаторе мы количественно, с механизмом, показываем, где и насколько предобработка наблюдаемого ряда спасает сходимость.

### B. Классы шума

Все шумы центрированы;  $\sigma > 0$  — масштаб.

$N_1$  гауссов (контроль):  $\xi_t \sim \mathcal{N}(0, \sigma^2)$  i.i.d.: конечная дисперсия, независимость.

$N_2$  долгая память (FARIMA):  $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$ ,  $\eta_j \sim \mathcal{N}(0, \sigma^2)$ ,  $\psi_j = \Gamma(j+d)/(\Gamma(d)\Gamma(j+1)) \sim j^{d-1}/\Gamma(d)$ ,  $d \in (0, \frac{1}{2})$ . Дисперсия конечна,  $\gamma(\tau) \sim c\tau^{2d-1}$ ,  $\sum_{\tau} \gamma(\tau) = \infty$ , спектр  $\propto |\omega|^{-2d}$ .

$N_3$  тяжёлые хвосты ( $\alpha$ -устойчивый):  $\xi_t \sim \mathcal{S}_\alpha(\sigma, 0, 0)$  i.i.d.,  $\alpha \in (1, 2)$ :  $\mathbb{E}|\xi|^p < \infty \iff p < \alpha$ ; в частности  $\text{Var} \xi = \infty$ , хвост  $\text{Pr}(|\xi| > z) \sim C_\alpha \sigma^\alpha z^{-\alpha}$ .

$N_4$  смешанный:  $\xi_t = \sum_{j \geq 0} \psi_j \zeta_{t-j}$ ,  $\zeta_j$  i.i.d.  $\mathcal{S}_\alpha$ ,  $\psi_j$  как в  $N_2$ : бесконечная дисперсия и долгая память одновременно.

Единственное свойство, движущее результаты ниже: у  $N_3, N_4$  второй момент бесконечен ( $\alpha < 2$ ).

## C. Семейство фильтров

Каждый фильтр — оператор  $F: \mathbb{R}^T \rightarrow \mathbb{R}^T$  (опр. 4), применяемый к ряду до формирования признаков. Ниже каждый фильтр приведён вместе со своей формулой и ключевым аналитическим свойством, в сплошной нумерации  $F_0$ – $F_7$ .

$F_0$  — ~~тождество~~ контроль “без фильтрации”.

$F_1$  — скользящее среднее (линейный, причинный). Конечная линейная комбинация  $\alpha$ -устойчивых величин снова  $\alpha$ -устойчива: при i.i.d.  $\xi_t \sim \mathcal{S}_\alpha(\sigma, 0, 0)$

$$\bar{\xi}_t \sim \mathcal{S}_\alpha(\sigma w^{1/\alpha-1}, 0, 0), \quad \frac{1}{\alpha} - 1 \in (-\frac{1}{2}, 0), \quad (5)$$

масштаб падает лишь как  $w^{1/\alpha-1}$ , дисперсия остаётся бесконечной.

$F_2$  — Калман-каскад (линейный, причинный).  $\sum_{j \geq 0} (1-K)^j y_{t-j}$ ,  $K \in (0, 1)$  (линейный БИХ, причинный). Та же замкнутость: выход  $\alpha$ -устойчив с масштабом  $\sigma K(1 - (1-K)^\alpha)^{-1/\alpha}$ , дисперсия бесконечна.

$F_3$  — ~~Мейкел-порог~~ Добеши с универсальным множителем  $\sqrt{2 \ln N}$ . Использует весь ряд (не причинный), поэтому на реальных walk-forward данных не применяется. Порог калиброван по гауссову максимуму, а для  $\alpha$ -устойчивых он растёт как  $N^{1/\alpha} \gg \sqrt{\ln N}$  — остаток остаётся тяжёлохвостовым.

$F_4$  — ~~причинная~~ медиана.  $\dots, y_t$  — нелинейная порядковая статистика. В отличие от линейных  $F_1, F_2$  она отображает окно с бесконечной дисперсией в выход с конечной (Лемма 1); это и есть механизм спасения SGD при тяжёлом хвосте.

$F_5$  — каскад медиана  $\rightarrow$  Калман (наш).

$$\hat{s}_t = \text{Kalman}(\text{med}\{y_{t-m+1:t}\}), \quad (6)$$

первая стадия (медиана малого окна  $m$ ) снижает изолированные хвостовые скачки, вторая (Калман) — остаточный долгопамятный дрейф, который короткая медиана не убирает. Обе стадии причинные,  $O(T)$ ; для смешанного режима “тяжёлый хвост  $\cap$  долгая память”.

$F_6$  — ~~Добешинский каскад~~ оцениваются  $\hat{\alpha}$  (Маккаллоу) и  $\hat{H}$  (DFA); стадии включаются по правилу  $\{\hat{\alpha} < 1.9\} \Rightarrow$  медиана,  $\{\hat{H} > 0.6\} \Rightarrow$  Калман; обе  $\Rightarrow$  полный каскад (6); ни одна  $\Rightarrow F_0$  (на гладком гауссовом ряде не делает ничего).

$F_7$  — ~~Причинная~~ медиана/Калман. На каждом шаге по скользящему окну выбирает между робастной медианой (при выбросах) и эффективной ЕМА (без них).

Все фильтры, кроме  $F_3$ , причинные и  $O(T)$ ; правило выбора (раздел V) строится только по причинным фильтрам.

## D. Оптимизаторы как операторы $\phi$

$\phi$  из (3): SGD  $\phi(g) = g$ ; Clipped-SGD  $\phi(g) = \min(1, \tau/\|g\|)g$ ; Normalized-SGD  $\phi(g) = g/\|g\|$ ; Adam [17]; AdamW [18]. Для SGD с постоянным шагом на  $L$ -гладкой  $\mu$ -сильно выпуклой  $f$  при  $\mathbb{E}\|\xi_k\|^2 \leq \sigma^2$  классический асимптотический уровень  $\mathbb{E}\|\nabla f\|^2$

$$\mathbb{E}\|\nabla f(x_K)\|^2 \xrightarrow{K \rightarrow \infty} \Theta(\eta L \sigma^2), \quad (7)$$

$\propto \sigma^2$  [19]. Обрезание/нормировка делают  $\sigma^2$  конечным по построению, заменяя  $g$  ограниченным суррогатом [6], [7], [9].

## E. Механизм: лемма и утверждение

Лемма 1 (Конечная дисперсия порядковой статистики). Пусть  $\xi_{(1)}, \dots, \xi_{(w)}$  — порядковые статистики  $w$  i.i.d. симметричного закона с непрерывной плотностью  $h$ ,  $h(0) > 0$ , и  $m_w$  — выборочная медиана ( $w$  нечётно). Тогда  $\mathbb{E}m_w = 0$  и при  $w \rightarrow \infty$

$$\text{Var } m_w = \frac{1}{4w h(0)^2} + o(1/w) < \infty, \quad (8)$$

для любого  $\alpha \in (0, 2]$ , включая  $\alpha$ -устойчивый случай.

Доказательство. ЦПТ для выборочной медианы  $\sqrt{w}(m_w) \Rightarrow \mathcal{N}(0, (4h(0)^2)^{-1})$  верна при непрерывной  $h$ , положительной в популяционной медиане 0. Она использует лишь локальное поведение  $h$  в 0 и ни одного момента  $\xi$ . Плотность  $\alpha$ -устойчивого закона ограничена, непрерывна и строго положительна в 0, откуда (8).  $\square$

Утверждение 1 (Медиана восстанавливает сходимость SGD). При  $N_3$  с причинной медианой фиксированной нечётной ширины  $w$  эффективный шум  $\bar{\xi}_t = m_w(\xi_{t-w+1:t})$  удовлетворяет  $\sigma_{\text{med}}^2 \leq \frac{1}{4h(0)^2}(1 + o(1)) < \infty$ . SGD с постоянным шагом на  $L$ -гладкой  $\mu$ -сильно выпуклой  $f$  имеет конечный асимптотический уровень (7) с  $\sigma^2 = \sigma_{\text{med}}^2$ ; вероятность  $10^2 \times$ -снижения  $\rightarrow 1$ . Для линейных  $F \in \{F_1, F_2\}$  отфильтрованный шум остаётся  $\alpha$ -устойчивым (см. (5)),  $\mathbb{E}\bar{\xi}_t^2 = \infty$ , и предел (7) бесконечен. Для  $F_3$  низкочастотная полоса несёт  $\alpha$ -устойчивый атом, поэтому также  $\mathbb{E}\bar{\xi}_t^2 = \infty$ .

Замечание 1 (Предсказанный негатив на  $N_1$ ). При  $N_1$  Лемма даёт  $\text{Var } m_w = \pi\sigma^2/(2w)$  против  $\sigma^2/w$  у среднего; асимптотическая относительная эффективность медианы  $2/\pi \approx 0.637$ . На чистом гауссе медиана поднимает этот уровень в  $\pi/2 \approx 1.57$  раза.

Замечание 2 (Предсказанный негатив на  $N_4$  и мотивация  $F_5$ ). Лемме 1 нужны почти-независимые отсчёты окна. При  $N_4$  окно сильно зависимо ( $\sum_{\tau} \gamma(\tau) = \infty$ ) и тяжёлые скачки кластеризуются: дисперсия медианы в ЦПТ раздувается, и (8) больше не ограничивает этот уровень. Это движет выбор каскада  $F_5$ : первой стадией медиана малого окна снимает изолированные хвостовые спайки, второй стадией Калман удаляет остаточный долгопамятный дрейф; вместе они приближают остаток к почти-гауссову с конечной дисперсией, где (7) снова применима.

Замечание 3 (Adam при долгой памяти  $N_2$ ). У  $N_2$  конечная дисперсия, (7) уже выполнено; проблема — смещение ЕМА второго момента Adam при устойчивой  $1/f$ -автокорреляции [20]. Вейвлет-базисы приближённо декоррелируют LRD-процессы по масштабам [15], возвращая шум к почти-белому; здесь ускоряет вейвлет-базлайн  $F_3$  (не  $F_4$ ).

#### Г. Гипотезы

Прямо из теории формулируем гипотезы, проверяемые в разделе IV.

Гипотеза 1 (Спасение при тяжёлом хвосте).  $F_0, F_1, F_2, F_3 + \text{SGD}$  на  $N_3$  дают бинарную сходимость  $c(\varepsilon) \rightarrow 0$  за разумный горизонт;  $F_4 + \text{SGD}$  дают  $c(\varepsilon) \rightarrow 1$  и снижают асимптотический уровень  $\|\nabla f\|^2$  в число раз, сопоставимое с  $\sigma_{N_3}^2/\sigma_{\text{med}}^2$ .

Гипотеза 2 (Каскад на смешанном режиме). На  $N_4$  (тяжёлые хвосты  $\cap$  долгая память) одиночные фильтры  $F_4$  и  $F_2/F_3$  не дают значимого снижения этого уровня; каскад  $F_5$  (медиана→Калман) даёт.

Гипотеза 3 (Долгая память + Adam). На  $N_2$  с Adam/AdamW вейвлет-базлайн  $F_3$  ускоряет  $T(\varepsilon)$  в заметное число раз; на  $N_4$  фильтрация Adam в среднем нейтральна/слегка вредит.

Гипотеза 4 (Эмпирические критерии). Двух диагностик  $\hat{\alpha}$  (Маккаллоу) и  $\hat{H}$  (DFA) на обучающем отрезке достаточно, чтобы на широкой корзине реальных доменов (финансовые разные частоты, FRED, ETT, scientific) предсказать, какая причинная связка (фильтр, оптимизатор) лучше в среднем по сидам; правило валидируется в разделе IV-D.

### IV. Эксперименты и анализ

#### А. Общая конфигурация

Модели: квадратичная регрессия ( $d=20$ ), логистическая классификация ( $d=15$ ), AR(5). Масштабы шума фиксированы для всех ячеек; никакого подбора

Таблица I

$N_3$  ( $\alpha=1.2$ ), SGD, 8 сидов. Бинарная сходимость и медианный асимптотический уровень  $\|\nabla f\|^2$ .  $F_1, F_2, F_3$  ведут себя как  $F_0$ .

| модель  | бин. $F_0$ | бин. $F_4$ | уров. $F_0$ | уров. $F_4$ | отнош.      |
|---------|------------|------------|-------------|-------------|-------------|
| квадр.  | 0/8        | <b>8/8</b> | 0.540       | 0.0050      | <b>108×</b> |
| логист. | 0/8        | <b>8/8</b> | 0.0658      | 0.00050     | <b>133×</b> |
| AR(5)   | 8/8        | 8/8        | 0.0421      | 0.0021      | 20×         |

под фильтр. Сиды: 8 для синтетики, 4 для прикладного факториала. Доверительные интервалы — 95% bootstrap. Прикладной факториал (блок D) прогоняет весь набор  $F_0$ – $F_7$ ; все фильтры, кроме неперчинного  $F_3$ , строго причинны (выход в момент  $t$  использует только  $s \leq t$ ), поэтому из выбора рекомендованного фильтра  $F_3$  исключается, а holdout-цель — сырое будущее, единое для всех ячеек.

Диагностики  $\hat{\alpha}$  (Маккаллоу),  $\hat{H}$  (DFA) считаются на дифференцированном обучающем отрезке. Для корзины SPY/QQQ/AAPL/MSFT/JPM/EUR-USD/GBP-USD/BTC/ETH (2018–2025, дневные) медиана  $\hat{\alpha}=1.21$ ,  $\hat{d}=0.29$ . Принятое в блоке А значение  $\alpha=1.2$  попадает в середину диапазона.

#### В. Блок А — спасение SGD при тяжёлом хвосте

Полный факторный:  $\{\text{квадратичная, логистическая, AR(5)}\} \times \{N_1, N_3(\alpha=1.2), N_4\} \times \{\text{SGD, Clipped-SGD, Normalized-SGD}\} \times \{F_0, F_1, F_2, F_3, F_4\} \times 8 \text{ сидов}$ .

Гипотеза 1 подтверждается (табл. I): при  $N_3$  SGD без фильтра и со всеми линейными/вейвлет-фильтрами сходится в 0/8 сидов;  $F_4$  переводит в 8/8 и снижает асимптотический уровень  $\|\nabla f\|^2$  в 108× (квадратичная) и 133× (логистическая). Для AR(5) сходимость формально достигается даже без фильтра, но уровень  $\|\nabla f\|^2$  с  $F_4$  ниже в 20×. На  $N_1$  отношение уровней  $F_4/F_0 \in [0.76, 0.95]$  (худшее) — штраф эффективности из Замечания 1.

#### С. Блок В — адаптивные оптимизаторы и долгая память

На  $N_2$  (квадратичная) Adam и AdamW ускоряются вейвлет-фильтром  $F_3$  в 11.2× ( $T(\varepsilon)$ : 562 → 50, Гипотеза 3 подтверждается); фильтр Калмана даёт 3.1×. На смешанном  $N_4$  ни один одиночный фильтр не бьёт  $F_0$  — предсказанный Замечанием 3 результат.

#### Д. Блок С — каскад на синтетическом $N_4$

Проверка Гипотезы 2 на синтетическом смешанном режиме  $N_4$  ( $d=0.4, \alpha=1.2, 8$  сидов). Результат честный, но скромный: на формальном  $\mathcal{S}_\alpha \times \text{FARIMA}$  одиночные фильтры  $F_1$ – $F_4$  практически не отличаются от  $F_0$ , а каскад  $F_5$  (медиана→Калман,  $m=3$ ) снижает асимптотический уровень  $\|\nabla f\|^2$  лишь в  $\approx 1.2$  раза; с более длинной медианой ( $m=15$ –51) — до  $\approx 1.5$  раза для SGD, но Adam здесь сам справляется почти оптимально и




Рис. 1.  $N_3$ , SGD, 8 сидов. (а) асимптотический уровень  $\|\nabla f\|^2$  для  $F_0$ – $F_4$ , лог-шкала,  $p_{10}$ – $p_{90}$ ; (б) медиана  $\|\nabla f\|^2$ :  $F_0/F_2$  застревают высоко;  $F_4$  падает на 1–2 порядка. Линейные и вейвлет-фильтры идут вдоль  $F_0$  (Утверждение 1).

от предобработки лишь теряет (согласовано с Замечанием 3). Поэтому каскад мы не оправдываем синтетическим  $N_4$ : его теоретическая мотивация остаётся (медиана ловит хвостовые скачки, Калман — остаточный дрейф), но практический выигрыш проявляется на реальных высокочастотных финансовых рядах, где совмещение тяжёлых хвостов и структурного шума иное, чем у формальной модели (Блок D).

Е. Блок D — широкий реальный факториал (июнь 2026)

Чтобы вывести правило выбора фильтра с покрытием всех четырёх секторов ( $\hat{\alpha}$ ,  $\hat{H}$ ), мы собрали широкую корзину публично доступных рядов и прогнали на ней весь набор  $F_0$ – $F_7$ :

- финансовые доходности: расширенная дневная корзина (акции/ETF/FX/крипто/сырьё/бонды/VIX), внутридневные 15-/5-мин, а также часовые крипто Binance BTC/ETH (2024, публичный фид data.binance.vision);
- волатильность  $|r|$ : дневные акции и крипто — режим долгой памяти ( $\hat{H} > 0.6$ );
- макро: 6 серий FRED;
- сенсорные: ETTh1/h2/m1/m2, Electricity Load (UCI/LSTNet), Traffic PEMS (LSTNet);
- метео / прогностика / операционные / научные: NOAA GHCN-daily (NY Central Park, 1869–2026), NASA C-MAPSS (турбина FD001), дневные снятия в банкомате (ATM), числа солнечных пятен (SILSO).

Источники, требующие платной подписки или портального доступа — полный фид LOBSTER, NYSE TAQ, CRSP — свободно не выгружаются и из исследования исключены.

Таблица II

Блок D. Широкая корзина, набор  $F_0$ – $F_7$ , Adam, регрессия AR(5), 4 сида. Лучший причинный фильтр: доля сходимости  $\geq 0.75$  и holdout MSE не более чем на 10% хуже  $F_0$ ; среди них минимум итераций до 100×-снижения  $\|\nabla f\|^2$  (непричинный  $F_3$  в выбор не входит). ускор. — отношение медиан числа итераций; holdout — лучший/ $F_0$ .

| домен                 | $\hat{\alpha}$ | $\hat{H}$ | лучш. | ускор.        | holdout       |
|-----------------------|----------------|-----------|-------|---------------|---------------|
| Binance BTC/ETH 1ч    | 1.47           | 0.05      | $F_2$ | <b>77.7</b> × | 0.931/0.918   |
| фин. дневные          | 1.53           | 0.06      | $F_2$ | <b>18.6</b> × | 0.877/0.857   |
| фин. 15-мин           | 1.54           | 0.08      | $F_2$ | <b>80.4</b> × | 0.548/0.547   |
| фин. 5-мин            | 1.60           | 0.07      | $F_2$ | <b>77.9</b> × | 0.638/0.628   |
| крипто $ r $ (волат.) | 1.48           | 0.80      | $F_1$ | <b>1.6</b> ×  | 0.836/0.796   |
| акции $ r $ (волат.)  | 2.00           | 0.64      | $F_1$ | <b>1.9</b> ×  | 1.01/0.971    |
| макро (FRED)          | 2.00           | 0.51      | $F_6$ | 1.00×         | 0.0077/0.0077 |
| ETTh1                 | 1.44           | 0.13      | $F_0$ | 1.00×         | 0.488/0.488   |
| ETTh2                 | 1.47           | 0.16      | $F_0$ | 1.00×         | 0.135/0.135   |
| ETThm1                | 1.39           | 0.22      | $F_0$ | 1.00×         | 0.101/0.101   |
| ETThm2                | 1.49           | 0.25      | $F_0$ | 1.00×         | 0.0476/0.0476 |
| Electricity Load      | 1.87           | 0.79      | $F_0$ | 1.00×         | 0.132/0.132   |
| Traffic PEMS          | 1.87           | 0.61      | $F_0$ | 1.00×         | 0.313/0.313   |
| NOAA Weather          | 1.66           | 0.22      | $F_0$ | 1.00×         | 0.12/0.12     |
| C-MAPSS (турбина)     | 2.00           | 0.10      | $F_6$ | 1.00×         | 0.316/0.316   |
| ATM (снятия)          | 1.77           | 0.08      | $F_1$ | <b>1.7</b> ×  | 0.639/0.626   |
| Sunspots              | 2.00           | 1.15      | $F_0$ | 1.00×         | 0.224/0.224   |

На каждой паре (домен, серия) обучаются обе модели (регрессия AR(5) и классификация знака), оптимизаторами SGD и Adam, по 4 сида. Holdout-цель — сырое будущее значение, единое для всех фильтров; диагностики ( $\hat{\alpha}$ ,  $\hat{H}$ ) для волатильности и научных рядов считаются на уровне, для доходностей — на приращении. Скрипт: experiments/run\_new\_datasets.py; сводки — tables/new\_datasets\_summary.csv; правило — tables/new\_datasets\_rules.csv.

Сводное правило, агрегированное по секторам диагностик, приведено в табл. III, а полная карта “домен×фильтр” для всех  $F_0$ – $F_7$  — на рис. 2; вместе они сворачивают все домены блока в карту “( $\hat{\alpha}$ ,  $\hat{H}$ ) → фильтр”.

Главное наблюдение — единственный сектор, где




Рис. 2. Полная карта блока D: все фильтры  $F_0$ – $F_7$  на всех 17 доменах (Adam, регрессия AR(5), 4 сида). Цвет — ускорение сходимости относительно  $F_0$  (во сколько раз меньше итераций до  $100\times$ -снижения  $\|\nabla f\|^2$ ;  $> 1$  — быстрее). Выигрыш сосредоточен на тяжёлохвостовых доходностях (левый блок): линейный Калман  $F_2$  и каскад  $F_5$  дают 44–80×; на светлохвостовых/гладких рядах (FRED, ETT, NOAA, sunspots) все фильтры  $\approx 1\times$ .  $F_3$  не причинный (использует будущее) и в правило не входит.

Таблица III

Правило выбора, свёрнутое из блока D (табл. II; Adam, регрессия AR(5)). Для каждого сектора ( $\hat{\alpha}, \hat{H}$ ): доминирующий фильтр, в скольких доменах сектора он ускоряет сходимость хотя бы в  $1.5\times$ , медианное и максимальное ускорение среди этих доменов. Где ни в одном — рекомендуется  $F_0$  (не фильтровать).  $F_1$  — скольз. среднее,  $F_2$  — Калман,  $F_5$  — каскад медиана→Калман.

| сектор ( $\hat{\alpha}, \hat{H}$ )            | фильтр | доменов | медиан.      | макс.       |
|-----------------------------------------------|--------|---------|--------------|-------------|
| $\hat{\alpha} \approx 2, \hat{H} \approx 0.5$ | $F_0$  | —       | $1.0\times$  | $1.0\times$ |
| $\hat{\alpha} \approx 2, \hat{H} > 0.6$       | $F_1$  | 1/2     | $1.9\times$  | $1.9\times$ |
| $\hat{\alpha} < 1.9, \hat{H} \approx 0.5$     | $F_2$  | 5/10    | $77.7\times$ | <b>80×</b>  |
| $\hat{\alpha} < 1.9, \hat{H} > 0.6$           | $F_1$  | 1/3     | $1.6\times$  | $1.6\times$ |

фильтрация по-крупному окупается, это тяжёлый хвост + короткая память (доходности) под Adam (строка 3 правила, табл. III). На часовых лог-доходностях BTC/ETH ( $\hat{\alpha} \approx 1.47$ ) Adam без фильтра сходится лишь в 3 из 8 прогонов; линейный Калман  $F_2$  доводит до 8/8 и ускоряет в **78×**, наш каскад  $F_5$  (медиана→Калман) — тоже 8/8 и **64×**, при практически неизменном holdout (отклонение MSE  $< 2\%$ ). Полная разбивка по всем восьми фильтрам на этом домене — в табл. IV.

Та же картина на внутридневных и дневных акциях (табл. II):  $F_2$  ускоряет Adam в  $80\times$  (15-мин),  $78\times$  (5-мин),  $19\times$  (дневные), каскад  $F_5$  идёт вторым вплотную. Интерпретация согласована с Замечанием 3: на доходностях Adam страдает не от тяжёлого хвоста как такового, а от смещения своих ЕМА-оценок при сильной автокорреляции; линейное сглаживание (Калман или Калман-стадия каскада) её снимает. Каскад  $F_5$  предпочтителен в смешанном режиме (тяжёлый хвост  $\cap$  долгая память), где одиночная линейная стадия

Таблица IV

Все фильтры  $F_0$ – $F_7$  на головном домене (Binance крипто 1ч; 2 серии BTC/ETH  $\times 4$  сида, Adam, регрессия AR(5)). сход. — доля сошедшихся сидов; ускор. — во сколько раз меньше итераций до  $100\times$ -снижения  $\|\nabla f\|^2$  относительно  $F_0$ ; holdout — MSE на сыром будущем. “непр.” —  $F_3$  не причинный (использует будущее).

| фильтр        | сход. | ускор.       | holdout |
|---------------|-------|--------------|---------|
| $F_0$         | 3/8   | $1.00\times$ | 0.918   |
| $F_1$         | 8/8   | <b>47×</b>   | 0.968   |
| $F_2$         | 8/8   | <b>78×</b>   | 0.931   |
| $F_3$ (непр.) | 0/8   | $1.00\times$ | 0.917   |
| $F_4$         | 8/8   | <b>45×</b>   | 0.981   |
| $F_5$         | 8/8   | <b>64×</b>   | 0.930   |
| $F_6$         | 8/8   | <b>49×</b>   | 1.054   |
| $F_7$         | 8/8   | <b>44×</b>   | 0.983   |

не справляется: медианная стадия снимает хвостовые скачки, а Калман — остаточный дрейф (теоретическая мотивация — раздел III, синтетический блок C).

Где фильтрация не нужна.: Во всех остальных секторах лучший выбор —  $F_0$  (табл. III). На светлохвостовых / гладких рядах (FRED, ETTh1/h2/m1/m2, NOAA, sunspots) ни один фильтр не бьёт тождество: база и так сходится, а holdout не улучшается. Адаптивный  $F_6$  на этих рядах корректно вырождается в  $F_0$  (медиана включается лишь при  $\hat{\alpha} < 1.9$ , Калман — лишь при  $\hat{H} > 0.6$ ), подтверждая Гипотезу 4. Поучительные пограничные случаи: (i) очень тяжёлый хвост сам по себе не гарантирует выигрыша — на Electricity/Traffic ( $\hat{\alpha} \approx 1.87$ , но  $\hat{H} > 0.6$ ) фильтрация нейтральна, потому что база сходится и без неё; (ii) на C-MAPSS причинные  $F_4/F_7$  дают лишь скромное улучшение holdout ( $\approx 5$ – $8\%$ ), а большее улучшение даёт не причинный вейвлет

$F_3$  (−41% MSE), который использует будущее и потому в правило не входит — честная иллюстрация того, что причинными средствами достижимо не всё.

#### Г. Полусинтетика и микроструктура

Когда под реальным шумом есть восстановимый гладкий сигнал, выигрыш велик и однозначен: в микроструктурной симуляции причинная медиана  $F_4$  снижает ошибку интегрированной дисперсии в  $\approx 58\times$  относительно  $F_0$ . Это согласуется с блоком D, где неслучайный вейвлет  $F_3$  (использующий будущее) восстанавливает гладкий сигнал лучше всех, но в причинный набор не входит.

#### В. Практические критерии выбора

В этом разделе каждый пункт явно помечен по источнику вывода:  $[T]$  — следует из теоретического результата раздела III;  $[E]$  — из эмпирики раздела IV;  $[H]$  — эвристика, не доказанная и не опровергнутая в данной работе. Это требование прозрачности: мы не выдаём эвристические правила за теоретические следствия.

##### А. Диагностика

Шаг 1: на обучающем отрезке оценить  $\hat{\alpha}$  (Маккаллоу или Хилл) и  $\hat{H}$  (DFA или R/S). На дневных финансовых рядах диагностику имеет смысл считать на  $|r_t|$  (абсолютных доходностях) для  $\hat{H}$ , поскольку сам  $r_t$  почти-белый по уровню. Это известный стилизованный факт [1]  $[T]$ .

##### В. Стартовый список кандидатов

По паре  $(\hat{\alpha}, \hat{H})$  ряд относится к одному из четырёх секторов; для каждого — стартовый список кандидатов (не финальное решение):

| $\hat{\alpha}, \hat{H}$                       | Кандидаты                                 | Источник                  |
|-----------------------------------------------|-------------------------------------------|---------------------------|
| $\hat{\alpha} \approx 2, \hat{H} \approx 0.5$ | $F_0 + \text{Adam/SGD}$                   | $[T]$ Зам. 1              |
| $\hat{\alpha} \approx 2, \hat{H} > 0.6$       | $F_2/F_6 + \text{Adam}$                   | $[T]$ Зам. 3              |
| $\hat{\alpha} < 1.9, \hat{H} \approx 0.5$     | $F_2/F_5 + \text{Adam}; F_4 + \text{SGD}$ | $[T, E]$ Утв. 1, блок D   |
| $\hat{\alpha} < 1.9, \hat{H} > 0.6$           | $F_5, F_6 + \text{SGD/Adam}$              | $[T, E]$ Зам. 2, блок C-D |

Первые две строки — прямое следствие раздела III ( $[T]$ ): на светлых рядах медиана не нужна, долгую память закрывает Калман  $F_2$  или Калман-стадия адаптивного  $F_6$ . Третья строка (тяжёлый хвост, короткая память) сильнее всего подтверждена эмпирически: на доходностях всех частот линейный  $F_2$  и каскад  $F_5$  ускоряют Adam в  $18\text{--}80\times$  (блок D), а медиана  $F_4$  восстанавливает конечную дисперсию шума и сходимость SGD теоретически (Утв. 1). Четвёртая строка ( $F_5/F_6$  на смешанном режиме) — комбинация теоретической мотивации (Замечание 2) и эмпирики (блоки C–D, крипто-1ч):  $[T, E]$ .

С. Финальный выбор — causal walk-forward валидация  $[E]$

Стартовый список — 2–3 пары  $(F, A)$ . Окончательный выбор делается причинной walk-forward-валидацией на обучающем отрезке (разрыв с holdout запрещён, цель — сырое будущее). Это эмпирический шаг, не доказанный теорией; обоснование — блок D раздела IV.

D. Когда фильтрацию применять не следует  $[T]$

Почти-гауссов / гладкий сигнал ( $\hat{\alpha} \approx 1.8\text{--}2$ ,  $\hat{H} \approx 0.5$ , напр. NOAA-температура, ETm2): фильтрация в лучшем случае нейтральна ( $1.00\times$ , блок D), а в чисто-гауссовом пределе поднимает пол в  $\pi/2 \approx 1.57\times$  (Замечание 1). Сырые дневные доходности почти-белые по уровню, но по уровню они и тяжёлохвосты, поэтому сглаживание перед Adam как раз помогает (строка 3 правила); для прогноза волатильности фильтруют  $|r|$ . Отдельно отметим: длинная память или тяжёлый хвост сами по себе не гарантируют выигрыша — на Electricity/Traffic ( $\hat{\alpha} \approx 1.87$ ,  $\hat{H} > 0.6$ ) фильтрация нейтральна, так как база и без неё сходилась (узкое место не в сходимости как таковой).

Е. Каскад как умолчание для финансовой высокой частоты  $[T, E]$

Высокочастотные финансовые ряды (1-мин, 5-мин, часовые крипто) тяжёлохвостовы по приращениям. Прямой замер блока D на независимом фиде Binance: Adam без фильтра сходится лишь в 3 из 8 прогонов, Калман  $F_2$  и каскад  $F_5$  — во всех 8/8, ускоряя в  $78\times$  и  $64\times$ . Если критична только скорость Adam — достаточно линейного  $F_2$ ; для смешанного режима (тяжёлый хвост  $\cap$  долгая память), где одиночная линейная стадия не справляется, разумное умолчание — каскад  $F_5$  (median-Kalman); калибровка  $m$  (медианное окно),  $K$  (коэффициент Калмана) делается на валидации.

Зам. 3 Антипаттерны и подводные камни  $[E]$

(i) Look-ahead bias: центрированная медиана даёт ложный или завышенный выигрыш в знак-прогнозе; правильная замена — причинная. (ii) Подбор окна фильтра под единственный сид: вместо 8 сидов с фиксированным окном даёт неустойчивые рекомендации. (iii) Слепое применение каскада там, где у сигнала есть медленный полезный тренд: на C-MAPSS Калман-стадия каскада  $F_5$  пересглаживает деградацию и вдвое ухудшает holdout-MSE (0.97 против 0.32 у  $F_0$ ), тогда как одиночная медиана  $F_4$  его не портит (неслучайный вейвлет  $F_3$ , использующий будущее, улучшает на 41%). Поэтому каскад не “умолчание для всего” — адаптивный  $F_6$ , включающий стадии по  $(\hat{\alpha}, \hat{H})$ , надёжнее фиксированного  $F_5$ .

## VI. Заключение

Главный механизм — порядковая статистика восстанавливает конечную эффективную дисперсию шума, чего линейные фильтры дать не могут. Этим объясняется положительный результат на  $N_3$  (SGD:  $0/8 \rightarrow 8/8$ , снижение асимптотического уровня  $\|\nabla f\|^2$   $108\text{--}133\times$ ) и — на свежих, независимых данных — ускорение Adam на часовых крипто-доходностях Binance ( $3/8 \rightarrow 8/8$ , до  $78\times$  Калманом  $F_2$ ; каскад  $F_5$  —  $64\times$ ); и негативный результат на  $N_1$  (штраф  $\pi/2$ ) и на гладких NOAA/ETTm2/FRED/sunspots (фильтр нейтрален). На смешанном режиме одиночные линейные фильтры не помогают; для него введён причинный каскад  $F_5$  (медиана→Калман) и адаптивный  $F_6$ . Исследование проведено на сплошном причинном наборе  $F_0\text{--}F_7$ , и по двум диагностикам ( $\hat{\alpha}, \hat{H}$ ) на широкой корзине выведено сводное правило выбора (табл. III) с покрытием всех четырёх секторов. Практические критерии выбора (раздел V) построены так, чтобы каждое правило явно ссылалось либо на теоретический результат, либо на эксперимент, либо маркировалось как эвристика. Два честных нюанса из блока D: очень тяжёлый хвост сам по себе ещё не повод фильтровать (Electricity/Traffic:  $\hat{\alpha} \approx 1.87$ , но база сходится и без того), а причинными средствами достижимо не всё: на C-MAPSS причинные фильтры улучшают holdout лишь на 5–8%, тогда как неслучайный вейвлет (использующий будущее) — на 41%.

## Список литературы

- [1] R. Cont, “Empirical properties of asset returns: Stylized facts and statistical issues,” *Quantitative Finance*, vol. 1, no. 2, pp. 223–236, 2001.
- [2] B. Mandelbrot, “The variation of certain speculative prices,” *The Journal of Business*, vol. 36, no. 4, pp. 394–419, 1963.
- [3] U. Şimşekli, L. Sagun, and M. Gürbüzbalaban, “A tail-index analysis of stochastic gradient noise in deep neural networks,” in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, ser. *Proceedings of Machine Learning Research*, vol. 97. PMLR, 2019, pp. 5827–5837. [Online]. Available: <https://arxiv.org/abs/1901.06053>
- [4] V. Anantharam and V. S. Borkar, “Stochastic approximation with long range dependent and heavy tailed noise,” *Queueing Systems*, vol. 71, no. 1–2, pp. 221–242, 2012.
- [5] S. Chandak, A. K. Yadav, A. Özgür, and N. Bambos, “Heavy-tailed and long-range dependent noise in stochastic approximation: A finite-time analysis,” Mar. 2026, submitted to *IEEE Transactions on Automatic Control*. [Online]. Available: <https://arxiv.org/abs/2603.19648>
- [6] E. Gorbunov, M. Danilova, and A. Gasnikov, “Stochastic optimization with heavy-tailed noise via accelerated gradient clipping,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 15 042–15 053. [Online]. Available: <https://arxiv.org/abs/2005.10785>
- [7] A. Cutkosky and H. Mehta, “High-probability bounds for non-convex stochastic optimization with heavy tails,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. [Online]. Available: <https://arxiv.org/abs/2106.14343>
- [8] A. Sadiev, M. Danilova, E. Gorbunov, S. Horváth, G. Gidel, P. Dvurechensky, A. Gasnikov, and P. Richtárik, “High-probability bounds for stochastic optimization and variational inequalities: The case of unbounded variance,” in *Proceedings of the 40th International Conference on Machine Learning (ICML)*, 2023. [Online]. Available: <https://arxiv.org/abs/2302.00999>
- [9] A. Armacki, S. Yu, P. Sharma, G. Joshi, D. Bajović, D. Jakovetić, and S. Kar, “Nonlinear stochastic gradient descent and heavy-tailed noise: A unified framework and high-probability guarantees,” 2024. [Online]. Available: <https://arxiv.org/abs/2410.13954>
- [10] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Journal of Basic Engineering*, vol. 82, no. 1, pp. 35–45, 1960.
- [11] D. L. Donoho and I. M. Johnstone, “Ideal spatial adaptation by wavelet shrinkage,” *Biometrika*, vol. 81, no. 3, pp. 425–455, 1994.
- [12] D. L. Donoho, “De-noising by soft-thresholding,” *IEEE Transactions on Information Theory*, vol. 41, no. 3, pp. 613–627, 1995.
- [13] S. Mallat, *A Wavelet Tour of Signal Processing*, 2nd ed. San Diego: Academic Press, 1999.
- [14] L. Yin, R. Yang, M. Gabbouj, and Y. Neuvo, “Weighted median filters: A tutorial,” *IEEE Transactions on Circuits and Systems II: Analog and Digital Signal Processing*, vol. 43, no. 3, pp. 157–192, 1996.
- [15] D. B. Percival and A. T. Walden, “Wavelet methods for time series analysis,” *Cambridge Series in Statistical and Probabilistic Mathematics*, 2000.
- [16] Q. Tang, T. Fan, R. Shi, J. Huang, and Y. Ma, “Prediction of financial time series using LSTM and data denoising methods,” 2021. [Online]. Available: <https://arxiv.org/abs/2103.03505>
- [17] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015. [Online]. Available: <https://arxiv.org/abs/1412.6980>
- [18] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, 2019. [Online]. Available: <https://arxiv.org/abs/1711.05101>
- [19] H. Robbins and S. Monro, “A stochastic approximation method,” *The Annals of Mathematical Statistics*, vol. 22, no. 3, pp. 400–407, 1951.
- [20] A. Défossez, L. Bottou, F. Bach, and N. Usunier, “A simple convergence proof of adam and adagrad,” *Transactions on Machine Learning Research*, 2022. [Online]. Available: <https://arxiv.org/abs/2003.02395>