

Шумоподавление наблюдаемого ряда как предобработка стохастической оптимизации: когда фильтрация спасает сходимость при тяжёлохвостовом градиентном шуме

Дмитрий Кортунов
НИУ ВШЭ
Москва, Россия

Вадим Пастушенко
НИУ ВШЭ
Москва, Россия

Алексей Дубовицкий
НИУ ВШЭ
Москва, Россия

Андрей Шадрин
НИУ ВШЭ
Москва, Россия

Аннотация—Шумоподавление наблюдаемого ряда рассматривается как явный этап конвейера стохастической оптимизации. Модель наблюдений $y_t = s_t + \xi_t$; фильтр F применяется до оптимизатора. Приводятся точный оператор и значимые аналитические свойства каждой модели шума, фильтра и оптимизатора и доказывается механизм эмпирического эффекта: при α -устойчивом градиентном шуме ($\alpha < 2$, бесконечная дисперсия) SGD с постоянным шагом не имеет конечного шумового пола и не сходится; оконная медиана отображает окно с бесконечной дисперсией в порядковую статистику с конечной дисперсией, что восстанавливает стандартный пол $O(\eta L \sigma^2)$, тогда как любой линейный фильтр (скользящее среднее, Калман) сохраняет α -устойчивый закон и бесконечную дисперсию. Эмпирически, при калиброванном по реальным рядам индексе хвоста $\hat{\alpha} \approx 1.2$, обычный SGD на квадратичной регрессии и логистической классификации сходится в 0/8 прогонах (как и с линейными и вейвлет-фильтрами) и в 8/8 с причинной медианой, снижая шумовой пол в $108\times$ и $133\times$; эффект сохраняется при калибровке ($91\times/120\times$) и на реальной причинной задаче (15-мин, $\approx 78\times$). Негативные зоны (чистый гауссов шум, долгопамятные смеси) предсказываются той же теорией и подтверждаются.

Index Terms—стохастическая оптимизация, тяжёлохвостовый шум, α -устойчивые распределения, медианная фильтрация, фильтр Калмана, вейвлет-порог, долгая память, сходимость.

I. Введение

Теория сходимости стохастических методов первого порядка опирается на конечный второй момент градиентного шума и, как правило, на слабую временную зависимость. Оба предположения нарушаются при обучении на финансовых рядах: доходности тяжёлохвостовы и долгопамятны [1], [2], и стохастический градиент наследует эти свойства [3]. Мы рассматриваем шумоподавление не как визуализацию, а как вычислительный этап между наблюдениями и оптимизатором, и ставим точный вопрос: для каких троек (шум, фильтр, оп-

тимизатор) предобработка превращает несходящийся прогон в сходящийся и почему. Вклад: (i) самодостаточный вывод оператора и значимых свойств каждого компонента; (ii) утверждение, выделяющее механизм — нелинейная порядковая статистика восстанавливает конечную эффективную дисперсию шума, чего линейные фильтры дать не могут; (iii) эмпирическое подтверждение с доверительными интервалами по сидам на синтетике, калиброванной синтетике и реальных причинных режимах, включая честно показанные режимы, где фильтрация не помогает.

II. Связанные работы

Совместный тяжёлохвостовый/долгопамятный (LRD) режим в стохастической аппроксимации впервые проанализирован асимптотически Anantharam и Borkar [4] через предельное ОДУ; Chandak и др. [5] дают первые конечновременные оценки моментов для того же режима. Обе работы анализируют немодифицированную итерацию. Робастность к тяжёлым хвостам иначе достигается модификацией оптимизатора: обрезание градиента [6], high-probability оценки при неограниченной дисперсии [7], [8], нелинейный SGD [9]. Классические операторы шумоподавления — фильтр Калмана [10], мягкий вейвлет-порог [11]–[13], взвешенные медианы [14] — и декорреляция LRD-процессов вейвлетами [15] известны; шумоподавление как предобработка прогноза изучалось эмпирически [16]. Наш вопрос ортогонален: при фиксированном оптимизаторе мы количественно, с механизмом, показываем, где и насколько предобработка наблюдаемого ряда спасает сходимость.

III. Постановка

A. Задача обучения

Пусть $x \in \mathbb{R}^d$ — параметры модели. Из наблюдаемого скалярного ряда $y_{1:T}$ формируются обучающие пары $(u_i, v_i)_{i=1}^n$, где вход $u_i \in \mathbb{R}^p$ — лаговое окно, цель v_i — следующее значение (или его знак для классификации). При модели g_x и потере ℓ (квадратичной для регрессии, логистической кросс-энтропии для классификации) минимизируется эмпирический риск

$$f(x) = \frac{1}{n} \sum_{i=1}^n \ell(g_x(u_i), v_i), \quad x^* \in \arg \min_{x \in \mathbb{R}^d} f(x). \quad (1)$$

B. Стохастический шаг и место фильтра

На итерации k методу доступен зашумлённый градиент

$$g_k = \nabla f(x_k) + \xi_k, \quad x_{k+1} = x_k - \eta_k \phi(g_k), \quad (2)$$

ξ_k — центрированный шум; не предполагаются ни $\mathbb{E} \|\xi_k\|^2 < \infty$, ни независимость по k . Модель наблюдений

$$y_t = s_t + \xi_t, \quad (3)$$

s — сигнал, ξ — шум. Фильтр — отображение $\hat{s} = F(y_{1:T})$, применяемое до оптимизатора (эквивалентно к инжектируемому в градиент шуму). Вход всей процедуры: $y_{1:T}$; выход: x_K и метрики сходимости/качества. Контроль — $F_0 = \text{Id}$. Таким образом F стоит строго между (3) и (2).

IV. Модели шума

Все шумы центрированы; $\sigma > 0$ — масштаб.

N1 гауссов (контроль): $\xi_t \sim \mathcal{N}(0, \sigma^2)$ i.i.d.: конечная дисперсия, независимость — режим классической теории.

N2 долгая память (FARIMA): $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$, $\eta_j \sim \mathcal{N}(0, \sigma^2)$, $\psi_j = \Gamma(j+d)/(\Gamma(d)\Gamma(j+1)) \sim j^{d-1}/\Gamma(d)$, $d \in (0, \frac{1}{2})$. Дисперсия конечна, но автоковариация $\gamma(\tau) \sim c\tau^{2d-1}$, $\sum_{\tau} \gamma(\tau) = \infty$: долгая память, спектр $\propto |\omega|^{-2d}$ (1/f-типа).

N3 тяжёлые хвосты (α -устойчивый): $\xi_t \sim \mathcal{S}_\alpha(\sigma, 0, 0)$ i.i.d., $\alpha \in (1, 2)$, $\mathbb{E} e^{i\theta\xi} = \exp(-\sigma^\alpha |\theta|^\alpha)$. Тогда $\mathbb{E} |\xi|^p < \infty \iff p < \alpha$; в частности $\mathbb{E} \xi = 0$, но $\text{Var} \xi = \infty$, хвост $\text{Pr}(|\xi| > z) \sim C_\alpha \sigma^\alpha z^{-\alpha}$.

N4 смешанный (тяжёлый + долгая память): $\xi_t = \sum_{j \geq 0} \psi_j \zeta_{t-j}$, ζ_j i.i.d. $\mathcal{S}_\alpha$, ψ_j как в N2: бесконечная дисперсия и долгая память одновременно.

Единственное свойство, движущее все результаты ниже: у N3/N4 второй момент бесконечен ($\alpha < 2$), у N1/N2 — конечен.

V. Фильтры

Пусть в (2) входит покоординатная последовательность шума $\xi_{1:T}$. Для каждого оператора — формула и значимое свойство.

A. F_0 тождество

$\hat{s}_t = y_t$; градиентный шум в точности ξ_t .

B. F_1 скользящее среднее (причинное, окно w)

$$\hat{s}_t = \frac{1}{w} \sum_{i=0}^{w-1} y_{t-i}. \quad (4)$$

Линеен и несмещён. Ключ — замкнутость: конечная линейная комбинация α -устойчивых α -устойчива. При i.i.d. $\xi_t \sim \mathcal{S}_\alpha(\sigma, 0, 0)$ свойство устойчивости даёт $\hat{\xi}_t \sim \mathcal{S}_\alpha(\sigma_w, 0, 0)$,

$$\sigma_w = \sigma \left(\sum_{i=0}^{w-1} w^{-\alpha} \right)^{1/\alpha} = \sigma w^{1/\alpha-1}. \quad (5)$$

Поскольку $1 < \alpha < 2$, $1/\alpha - 1 \in (-\frac{1}{2}, 0)$: масштаб падает лишь как $w^{1/\alpha-1}$, медленнее гауссова $w^{-1/2}$, а закон остаётся α -устойчивым с $\text{Var} \hat{\xi} = \infty$.

C. F_2 Калман (локальный уровень, причинный)

Состояние $s_t = s_{t-1} + w_t$, наблюдение $y_t = s_t + \varepsilon_t$; стационарный фильтр — экспоненциальная рекурсия

$$\hat{s}_t = (1 - K)\hat{s}_{t-1} + Ky_t = K \sum_{j \geq 0} (1 - K)^j y_{t-j}, \quad (6)$$

$K \in (0, 1)$ — стационарный коэффициент. Это линейный БИХ-оператор — бесконечная геометрическая смесь входов. По тому же аргументу замкнутости выход α -устойчив с масштабом $\sigma K(1 - (1 - K)^\alpha)^{-1/\alpha}$, снова с бесконечной дисперсией. Оптимален для гауссова s [10]; против тяжёлых хвостов бессилён.

D. F_3 мягкий вейвлет-порог

Анализ Добеши, мягкое пороговое отсечение детальных коэффициентов, обратное преобразование:

$$\hat{c} = \text{sgn}(c)(|c| - \lambda)_+, \quad \lambda = \hat{\sigma} \sqrt{2 \ln N}, \quad (7)$$

$\hat{\sigma} = \text{MAD}(c^{(\text{мелк})})/0.6745$ [11], [12]. Универсальный множитель $\sqrt{2 \ln N}$ — максимум N i.i.d. гауссовых отклонений; он неверного порядка для α -устойчивых экстремумов, чей максимум по N растёт как $N^{1/\alpha} \gg \sqrt{\ln N}$. Кроме того, порогуются только детальные полосы: тяжёлохвостовый всплеск даёт ненулевую массу в нетронутую низкочастотную (аппроксимирующую) полосу и переживает реконструкцию. Поэтому остаток после F_3 при N3 остаётся тяжёлохвостовым (бесконечная дисперсия).

E. F_4 причинная медиана (окно w)

$$\hat{s}_t = \text{med}\{y_{t-w+1}, \dots, y_t\}. \quad (8)$$

Единственный нелинейный фильтр, который мы оставляем; это порядковая статистика окна, отображающая окно с бесконечной дисперсией в выход с конечной. Исследование ограничено F_0 – F_4 ; на реальных данных применяются только причинные F_0, F_1, F_2, F_4 (без заглядывания вперёд).

VI. Оптимизаторы

Обновление (2) с ϕ : SGD $\phi(g) = g$ (постоянный шаг η); Clipped-SGD $\phi(g) = \min(1, \tau/\|g\|)g$; Normalized-SGD $\phi(g) = g/\|g\|$; Adam [17]; AdamW [18]. Значимый факт для SGD с постоянным шагом на L -гладкой μ -сильно выпуклой f — классическое тождество шумового пола: если $\mathbb{E}\|\xi_k\|^2 \leq \sigma^2$, то

$$\mathbb{E}\|\nabla f(x_K)\|^2 \xrightarrow{K \rightarrow \infty} \Theta(\eta L \sigma^2), \quad (9)$$

конечное плато $\propto \sigma^2$ [19]. Обрезание/нормировка заменяют g ограниченным суррогатом, делая σ^2 конечным по построению [6], [7], [9] — это путь со стороны оптимизатора. Наш объект — ортогональный путь предобработки через F .

VII. Метрики сходимости

Для каждой ячейки (модель, шум, оптимизатор, фильтр) — 8 фиксированных сидов и, с 95% bootstrap-CI по сидам: (i) бинарная сходимость — доля сидов, достигших $10^2 \times$ снижения $\|\nabla f\|^2$ за горизонт; (ii) $T(\varepsilon) = \min\{k : \|\nabla f(x_k)\|^2 \leq \varepsilon\}$; (iii) шумовой пол — $p_{10}/p_{50}/p_{90}$ хвостового $\|\nabla f\|^2$; (iv) наклон $\log\|g_k\|^2$ vs $\log k$ на последних 30% (> 0 : расходимость, ≈ 0 : пол, < 0 : ещё сходится); (v) $\text{AUC} = \overline{\log_{10}\|\nabla f\|^2}$; (vi) holdout (без смешения train/test); (vii) wall-clock с учётом стоимости фильтра.

VIII. Теоретические результаты

Выделим, почему оконная медиана спасает SGD, а линейные/вейвлет — нет. Берём N3: $\xi_t \sim \mathcal{S}_\alpha(\sigma, 0, 0)$ i.i.d., симметричный, с плотностью h , $h(0) > 0$.

Лемма 1 (Конечная дисперсия порядковой статистики). Пусть $\xi_{(1)}, \dots, \xi_{(w)}$ — порядковые статистики w i.i.d. выборок симметричного закона с непрерывной плотностью h , $h(0) > 0$, и m_w — выборочная медиана (w нечётно). Тогда $\mathbb{E}m_w = 0$ и при $w \rightarrow \infty$

$$\text{Var } m_w = \frac{1}{4w h(0)^2} + o(1/w) < \infty, \quad (10)$$

для любого $\alpha \in (0, 2]$, включая α -устойчивый случай с бесконечной дисперсией.

Доказательство. Симметрия даёт $\mathbb{E}m_w = 0$. ЦПТ для выборочной медианы $\sqrt{w}(m_w - \theta) \Rightarrow \mathcal{N}(0, (4h(\theta)^2)^{-1})$ верна при непрерывной h , положительной в популяционной медиане $\theta = 0$; она использует лишь локальное поведение h в 0 и ни одного момента ξ . Плотность α -устойчивого закона ограничена, непрерывна и строго положительна в 0, откуда (10); конечность не зависит от (бесконечной) дисперсии ξ . $\square$

Утверждение 1 (Медиана восстанавливает пол SGD). При N3 с причинной медианой (8) фиксированной нечётной ширины w эффективный шум $\tilde{\xi}_t = m_w(\xi_{t-w+1:t})$ удовлетворяет $\sigma_{\text{med}}^2 := \mathbb{E}\tilde{\xi}_t^2 \leq \frac{1}{4h(0)^2}(1 + o(1)) < \infty$. Следовательно SGD с постоянным шагом

на L -гладкой μ -сильно выпуклой f имеет конечный пол (9) с $\sigma^2 = \sigma_{\text{med}}^2$ и достигает его со стандартной скоростью; вероятность события $10^2 \times$ -снижения $\rightarrow 1$. Для любого линейного $F \in \{F_1, F_2\}$ отфильтрованный шум снова α -устойчив (разд. V), $\mathbb{E}\tilde{\xi}_t^2 = \infty$, (9) вырождена, конечного плато нет. Для F_3 остаток сохраняет α -устойчивую компоненту (нетронутая аппроксимирующая полоса, гауссов-калиброванный порог), значит также $\mathbb{E}\tilde{\xi}_t^2 = \infty$.

Доказательство. Лемма 1 равномерно по α ограничивает дисперсию оконной медианы; при фиксированном окне маргинальный второй момент $\leq (4h(0)^2)^{-1}(1 + o(1))$. С конечной эффективной дисперсией лемма о спуске для SGD с постоянным шагом после телескопирования даёт $\frac{1}{K} \sum_{k < K} \mathbb{E}\|\nabla f(x_k)\|^2 \leq \frac{2(f(x_0) - f^*)}{\eta K} + \eta L \sigma_{\text{med}}^2$ — пол (9); сильная выпуклость превращает среднее в плато последней итерации. Утверждения о линейных фильтрах — тождества замкнутости разд. V ((5) и аналог для Калмана): устойчивость α -устойчивого семейства сохраняется при конечных и геометрических линейных комбинациях, дисперсия остаётся бесконечной. Для F_3 мягкий порог детальных полос оставляет низкочастотную проекцию тяжёлохвостового атома, чей α -хвост не меняется. $\square$

Замечание 1 (Гауссов контроль — предсказанный негатив). При N1 та же Лемма даёт $\text{Var } m_w = (4wh(0)^2)^{-1} = \pi\sigma^2/(2w)$, тогда как у среднего σ^2/w ; асимптотическая относительная эффективность медианы $2/\pi \approx 0.637$. Фильтрация чистого гауссова шума поднимает пол в $\pi/2 \approx 1.57$: предобработку нельзя применять при $\alpha \approx 2$.

Замечание 2 (Смешанный N4 — предсказанный негатив). Лемме 1 нужны (почти) независимые отсчёты окна. При N4 окно сильно зависимо ($\sum_\tau \gamma(\tau) = \infty$) и тяжёлые скачки кластеризуются; дисперсия медианы в ЦПТ раздувается, и (10) больше не ограничивает пол. Медиана смешанный режим не спасает.

Замечание 3 (Adam при долгой памяти N2). У N2 конечная дисперсия, (9) уже выполнено; проблема — смещение ЕМА второго момента Adam при устойчивой $1/f$ -автокорреляции, нарушающей почти-независимость в оценках Adam [20]. Вейвлет-базисы приближённо декоррелируют LRD-процессы по масштабам [15], возвращая шум к почти-белому; поэтому здесь ускоряет F_3 (не F_4).

IX. Эксперименты

A. Конфигурация

Модели: квадратичная регрессия ($d=20$), логистическая классификация ($d=15$), AR(5). Масштабы шума фиксированы для всех фильтров/оптимизаторов; 8 сидов; заранее зарегистрировано, без отбора по сидам/окнам/метрике. Индексы хвоста оценены на подлинно реальных рядах (Маккаллоу $\hat{\alpha}$, DFA $\hat{H}$ по $|r|$):

Таблица I

N3 ($\alpha=1.2$), SGD, 8 сидов. Бинарная сходимость и медианный шумовой пол. $F_1/F_2/F_3$ ведут себя как F_0 (все 0/8).

модель	бин. F_0	бин. F_4	пол F_0	пол F_4	отнош.
квадр.	0/8	8/8	0.540	0.0050	108 ×
логист.	0/8	8/8	0.0658	0.00050	133 ×
AR(5)	8/8	8/8	0.0421	0.0021	20×

SPY $\hat{\alpha}=1.05$, $\hat{H}=0.86$ (виден обвал -11.6% 16.03.2020); медиана корзины $\hat{\alpha}=1.21$, $\hat{d}=0.29$.

B. Тяжёлые хвосты + SGD: спасает только медиана

Табл. I: при N3 ($\alpha=1.2$) обычный SGD и SGD с каждым линейным/вейвлет-фильтром сходятся в 0/8 сидов; причинная медиана — в 8/8 и снижает пол в 108× (квадратичная) и 133× (логистическая); для AR все ячейки сходятся, но пол с медианой в 20× ниже. На гауссовом контроле N1 отношение пола медианы 0.76–0.95 (< 1 : лёгкая потеря) — ровно штраф эффективности $\pi/2$. Рис. 1 — пол и медианные кривые $\|\nabla f\|^2$.

C. Калибровка под реальные хвосты

При измеренном $\hat{\alpha}=1.21$ эффект сохраняется: F_4 снижает пол SGD в 91× (квадр.), 120× (логист.), 17× (AR). При калиброванном смешанном хвосте ($\hat{d}=0.29$, $\hat{\alpha}=1.21$) выигрыш $\approx 1\times$ — предсказанный негатив N4 (Замечание 3).

D. Адаптивные оптимизаторы

На долгопамятном N2 (квадр.) вейвлет F_3 ускоряет Adam и AdamW одинаково в 11.2× ($T(\varepsilon)$: 562 $\rightarrow$ 50; F_2 3.1×); на смешанных/логистических ячейках ни один фильтр не бьёт F_0 — картина Замечания 4.

E. Применённый, строго причинный

Табл. II: на реальных 15-мин доходностях Adam без фильтра сходится лишь в $\approx 7/16$ прогонах (медиана $T=4000$, сар), и в 16/16 с причинным фильтром Калмана ($T \approx 52$, $\approx 78\times$) при неизменном holdout (0.528 vs 0.522); признаки — только прошлое, holdout-цель — сырое будущее, одинаковое для всех фильтров. Дневные: $\approx 10\times$. Честные негативы: сенсорный ряд ускоряется, но теряет holdout (пересглаживание); на near-white сырых дневных и на офлайн-фоллбэке макро лучший — F_0 .

F. Режимы с восстановимым сигналом

Когда под реальным шумом есть гладкий сигнал, выигрыш велик и однозначен: реальные доходности как шум плюс известный сигнал — вейвлет F_3 восстанавливает его с holdout-MSE в 8.1× ниже; в микроструктурной симуляции медиана снижает ошибку интегрированной дисперсии в $\approx 58\times$.

Таблица II

Применённое причинное обучение AR(5), Adam, реальные домены. T — медиана итераций до $10^2\times$ падения градиента (сар 4000).

домен	$T(F_0)$	сходл. F_0	лучший	ускор.
фин. 15-мин	4000	7/16	$F_2 \approx 52$	78 ×
фин. дневн.	554	13/16	$F_2 \approx 57$	10×
сенсор (ETT)	43	16/16	F_1 20	$2.1\times^\dagger$
макро (FRED)	20	16/16	F_0	—

† быстрее, но holdout-MSE хуже (честный негатив).

X. Заключение

Эффект механистичен, а не случаен: α -устойчивый градиентный шум убирает конечный второй момент, нужный SGD с постоянным шагом; линейные и вейвлет-фильтры сохраняют α -устойчивый закон, и лишь нелинейная порядковая статистика — оконная медиана — восстанавливает конечную эффективную дисперсию и, значит, стандартный шумовой пол. Это предсказывает (и эксперименты подтверждают с CI по сидам) и положительный режим (тяжёлые хвосты: 0/8 $\rightarrow$ 8/8, пол ниже 108–133×; реальные 15-мин: $\approx 78\times$), и негативные режимы (чистый гаусс: штраф $\pi/2$; долгопамятные смеси: выигрыша нет). Практическое правило следует прямо: оценить $\hat{\alpha}, \hat{H}$ на обучающем отрезке; применять причинную медиану только при тяжёлых хвостах и наличии восстановимого сигнала; не валидировать с заглядыванием вперёд.

Список литературы

- [1] R. Cont, “Empirical properties of asset returns: Stylized facts and statistical issues,” *Quantitative Finance*, vol. 1, no. 2, pp. 223–236, 2001.
- [2] B. Mandelbrot, “The variation of certain speculative prices,” *The Journal of Business*, vol. 36, no. 4, pp. 394–419, 1963.
- [3] U. Şimşekli, L. Sagun, and M. Gürbüzbalaban, “A tail-index analysis of stochastic gradient noise in deep neural networks,” in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, ser. *Proceedings of Machine Learning Research*, vol. 97. PMLR, 2019, pp. 5827–5837. [Online]. Available: <https://arxiv.org/abs/1901.06053>
- [4] V. Anantharam and V. S. Borkar, “Stochastic approximation with long range dependent and heavy tailed noise,” *Queueing Systems*, vol. 71, no. 1–2, pp. 221–242, 2012.
- [5] S. Chandak, A. K. Yadav, A. Özgür, and N. Bambos, “Heavy-tailed and long-range dependent noise in stochastic approximation: A finite-time analysis,” Mar. 2026, submitted to *IEEE Transactions on Automatic Control*. [Online]. Available: <https://arxiv.org/abs/2603.19648>
- [6] E. Gorbunov, M. Danilova, and A. Gasnikov, “Stochastic optimization with heavy-tailed noise via accelerated gradient clipping,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 15 042–15 053. [Online]. Available: <https://arxiv.org/abs/2005.10785>
- [7] A. Cutkosky and H. Mehta, “High-probability bounds for non-convex stochastic optimization with heavy tails,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. [Online]. Available: <https://arxiv.org/abs/2106.14343>
- [8] A. Sadiiev, M. Danilova, E. Gorbunov, S. Horváth, G. Gidel, P. Dvurechensky, A. Gasnikov, and P. Richtárik, “High-probability bounds for stochastic optimization and variational inequalities: The case of unbounded variance,” in *Proceedings of the 40th International Conference*

Предфильтрация спасает сходимость SGD при тяжёлохвостовом градиентном шуме (8 сидов)




Рис. 1. Тяжёлохвостовый N3, SGD, 8 сидов. (а) шумовой пол F_0 – F_4 по моделям (лог-шкала, p_{10} – p_{90}); (б) медиана $\|\nabla f(x_k)\|^2$: F_0/F_2 застревают высоко, причинная медиана F_4 падает на 1–2 порядка. Линейные и вейвлет-фильтры идут вдоль F_0 , как предсказывает Утверждение 1.

- on Machine Learning (ICML), 2023. [Online]. Available: <https://arxiv.org/abs/2302.00999>
- [9] A. Armacki, S. Yu, P. Sharma, G. Joshi, D. Bajović, D. Jakovetić, and S. Kar, “Nonlinear stochastic gradient descent and heavy-tailed noise: A unified framework and high-probability guarantees,” 2024. [Online]. Available: <https://arxiv.org/abs/2410.13954>
- [10] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Journal of Basic Engineering*, vol. 82, no. 1, pp. 35–45, 1960.
- [11] D. L. Donoho and I. M. Johnstone, “Ideal spatial adaptation by wavelet shrinkage,” *Biometrika*, vol. 81, no. 3, pp. 425–455, 1994.
- [12] D. L. Donoho, “De-noising by soft-thresholding,” *IEEE Transactions on Information Theory*, vol. 41, no. 3, pp. 613–627, 1995.
- [13] S. Mallat, *A Wavelet Tour of Signal Processing*, 2nd ed. San Diego: Academic Press, 1999.
- [14] L. Yin, R. Yang, M. Gabbouj, and Y. Neuvo, “Weighted median filters: A tutorial,” *IEEE Transactions on Circuits and Systems II: Analog and Digital Signal Processing*, vol. 43, no. 3, pp. 157–192, 1996.
- [15] D. B. Percival and A. T. Walden, “Wavelet methods for time series analysis,” *Cambridge Series in Statistical and Probabilistic Mathematics*, 2000.
- [16] Q. Tang, T. Fan, R. Shi, J. Huang, and Y. Ma, “Prediction of financial time series using LSTM and data denoising methods,” 2021. [Online]. Available: <https://arxiv.org/abs/2103.03505>
- [17] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015. [Online]. Available: <https://arxiv.org/abs/1412.6980>
- [18] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, 2019. [Online]. Available: <https://arxiv.org/abs/1711.05101>
- [19] H. Robbins and S. Monro, “A stochastic approximation method,” *The Annals of Mathematical Statistics*, vol. 22, no. 3, pp. 400–407, 1951.
- [20] A. Défossez, L. Bottou, F. Bach, and N. Usunier, “A simple convergence proof of adam and adagrad,” *Transactions on Machine Learning Research*, 2022. [Online]. Available: <https://arxiv.org/abs/2003.02395>