

Шумоподавление наблюдаемого ряда как предобработка стохастической оптимизации: когда фильтрация спасает сходимость при тяжёлохвостовом градиентном шуме

Дмитрий Кортунов
НИУ ВШЭ
Москва, Россия

Вадим Пастушенко
НИУ ВШЭ
Москва, Россия

Алексей Дубовицкий
НИУ ВШЭ
Москва, Россия

Андрей Шадрин
НИУ ВШЭ
Москва, Россия

Аннотация—Шумоподавление наблюдаемого ряда трактуется как явный этап конвейера стохастической оптимизации. Сначала формализуется модель временного ряда и задача прогноза (раздел II), затем выносятся теоретический фон с механизмом эффекта и гипотезами (раздел III), затем описывается экспериментальная проверка (раздел IV) и, наконец, эмпирически обоснованные практические критерии выбора связки “фильтр+оптимизатор” (раздел V). Главный механизм: при α -устойчивом градиентном шуме ($\alpha < 2$, бесконечная дисперсия) SGD с постоянным шагом не имеет конечного шумового пола; оконная медиана отображает окно с бесконечной дисперсией в порядковую статистику с конечной дисперсией, что восстанавливает стандартный пол, тогда как любой линейный фильтр (скользящее среднее, Калман) сохраняет α -устойчивый закон. Для смешанного режима (тяжёлые хвосты + долгая память) одиночная медиана уже не работает — вводится причинный каскадный фильтр F_5 (медиана $\rightarrow$ Калман) и его адаптивная версия F_6 (стадии выбираются по $\hat{\alpha}, \hat{H}$), которые мы предлагаем именно для этого режима. Эмпирически при $\hat{\alpha} \approx 1.2$ обычный SGD сходится в 0/8 прогонах (как и линейные/вейвлет-фильтры) и в 8/8 с причинной медианой, снижая пол в $108\times$ (квадратичная) и $133\times$ (логистическая). Сводно на широкой корзине реальных доменов (дневные/15-мин/5-мин акции, часовые крипто Binance, волатильность $|r|$, FRED, ETTh1/h2/m1/m2, Electricity, Traffic, NOAA, C-MAPSS, ATM, sunspots) по двум диагностикам ($\hat{\alpha}, \hat{H}$) выводится правило выбора фильтра, покрывающее все четыре сектора: на часовых крипто ($\hat{\alpha} \approx 1.47$) Adam без фильтра сходится лишь в 0.38 прогонов, а Калман F_2 и наш каскад F_5 дают 4/4 и ускорение до $\approx 78\times$ (каскад — наибольшее снижение шумового пола, $127\times$); на гладких/гауссовых рядах лучший выбор — F_0 (фильтровать не нужно).

Index Terms—стохастическая оптимизация, тяжёлохвостовый шум, α -устойчивые распределения, медианная фильтрация, причинный каскадный фильтр, фильтр Калмана, долгая память, сходимость.

I. Введение

Теория сходимости стохастических методов первого порядка опирается на конечный второй момент гради-

ентного шума и слабую временную зависимость. Оба предположения нарушаются при обучении на финансовых рядах: доходности тяжёлохвостовы и долгопамятны [1], [2], и стохастический градиент наследует эти свойства [3]. Мы рассматриваем шумоподавление не как визуализацию, а как вычислительный этап между наблюдениями и оптимизатором, и ставим точный вопрос: для каких троек (шум, фильтр, оптимизатор) предобработка превращает несходящийся прогон в сходящийся и почему.

Структура текста задана по разделам: II — модель временного ряда, термины, задача прогноза и формальная постановка решаемой задачи (без описания алгоритмов); III — теоретический фон и явно сформулированные гипотезы (с компактными определениями фильтров и оптимизаторов как аналитических объектов); IV — экспериментальный план, расширенная корзина реальных доменов (включая нефинансовые) и анализ; V — практические критерии выбора, где каждый пункт явно помечен как “из теории”, “из эксперимента” или “эвристика”; VI — заключение.

Вклад статьи. (i) Чистая формализация задачи, отделённая от конкретных алгоритмов; (ii) утверждение, выделяющее механизм: нелинейная порядковая статистика восстанавливает конечную эффективную дисперсию шума, чего линейные фильтры дать не могут; (iii) новый причинный каскадный фильтр F_5 и его адаптивный вариант F_6 , спроектированные под предсказанный негативный режим N4 (тяжёлые хвосты $\cap$ долгая память); вместе с классическими F_0 – F_4 и онлайн-переключателем F_7 они образуют сплошной причинный набор F_0 – F_7 (медленные CNN-денейзеры и избыточные вейвлет/ансамбль-фильтры из исследования исключены как не дающие выигрыша на реальных рядах); (iv) эмпирическое выведение правила

“($\hat{\alpha}, \hat{H}$) $\rightarrow$ фильтр” на широкой корзине публично доступных финансовых и нефинансовых рядов с покрытием всех четырёх секторов диагностики.

II. Модель временного ряда и постановка задачи

В этом разделе мы фиксируем только объекты (ряд, признаки, цель, функция риска, шум на градиенте, место фильтра как абстрактного оператора). Конкретные семейства фильтров, шумов и оптимизаторов вводятся отдельно в разделе III; здесь они присутствуют только как формальные символы.

A. Наблюдаемый ряд

Определение 1 (Наблюдаемая модель). Скалярный временной ряд $y_{1:T} \in \mathbb{R}^T$ описывается аддитивной моделью

$$y_t = s_t + \xi_t, \quad t = 1, \dots, T, \quad (1)$$

где $s \in \mathbb{R}^T$ — сигнал (неизвестная гладкая или закономерно меняющаяся компонента), а $\xi \in \mathbb{R}^T$ — шум (стохастический процесс из некоторого класса с известными аналитическими свойствами).

В разделе III мы фиксируем четыре класса шума $\mathcal{N} \in \{N_1, N_2, N_3, N_4\}$ (гауссов, долгая память, тяжёлые хвосты, смешанный); здесь $\mathcal{N}$ рассматривается как параметр задачи.

B. Признаки, целевая переменная, задача обучения

Определение 2 (Задача обучения по ряду). Из ряда $y_{1:T}$ формируются обучающие пары $(u_i, v_i)_{i=1}^n$: вход $u_i \in \mathbb{R}^p$ — лаговое окно $u_i = (\tilde{y}_{t_i-1}, \dots, \tilde{y}_{t_i-p})$, цель $v_i = \tilde{y}_{t_i}$ (регрессия следующего значения) или $\mathbf{1}\{\tilde{y}_{t_i} > 0\}$ (классификация знака). Здесь $\tilde{y}$ — результат применения некоторого фильтра-оператора F к $y_{1:T}$ (см. 4). На отложенных значениях используется сырой (нефильтрованный) y , идентичный для всех фильтров — это исключает заглядывание вперёд.

При параметрической модели $g_x: \mathbb{R}^p \rightarrow \mathbb{R}$ ($x \in \mathbb{R}^d$) и функции потерь ℓ (квадратичной для регрессии, логистической для классификации) задача обучения — минимизация эмпирического риска:

$$f(x) = \frac{1}{n} \sum_{i=1}^n \ell(g_x(u_i), v_i), \quad x^* \in \arg \min_{x \in \mathbb{R}^d} f(x). \quad (2)$$

Определение 3 (Прогноз). Прогноз — это оценка $\hat{v}_t = g_{\hat{x}}(u_t)$, где $\hat{x}$ — результат обучения. Качество прогноза измеряется на отложенной причинной выборке (test, идущий строго позже train) либо MSE (регрессия), либо точностью (классификация знака).

C. Фильтр как оператор и его место в конвейере

Определение 4 (Фильтр). Фильтр — это отображение $F: \mathbb{R}^T \rightarrow \mathbb{R}^T$, $\hat{s} = F(y_{1:T})$, применённое до формирования признаков. F называется причинным, если $\hat{s}_t$ зависит только от $y_{1:s \leq t}$ (будущее не используется). Контрольный фильтр $F_0 = \text{Id}$ соответствует “без фильтрации”.

D. Стохастический шаг и формальная задача

Определение 5 (Стохастический градиент и шаг). На итерации k методу первого порядка доступен зашумлённый градиент

$$g_k = \nabla f(x_k) + \xi_k, \quad x_{k+1} = x_k - \eta_k \phi(g_k), \quad (3)$$

ξ_k — центрированный шум (общим образом ни $\mathbb{E} \|\xi_k\|^2 < \infty$, ни независимости по k не предполагается), ϕ — оператор обновления, η_k — шаг.

Определение 6 (Формальная задача исследования). Дано: класс шумов $\mathcal{N}$ из определения 1, множество причинных фильтров $\mathcal{F}$ из определения 4, множество операторов обновления $\mathcal{A}$ из (3), модель обучения f из (2). Требуется оценить отображение

$$\Phi: (F, A, \mathcal{N}) \mapsto (T(\varepsilon), c(\varepsilon), h), \quad (4)$$

где $T(\varepsilon)$ — эмпирическое время до ε -точности по $\|\nabla f\|^2$, $c(\varepsilon)$ — доля прогонов, достигших заданного снижения градиента (бинарная сходимость), h — качество на отложенной выборке (3). Иначе говоря, вход процедуры — наблюдаемый ряд $y_{1:T}$ и выбор тройки $(F, A, \mathcal{N})$; выход — обученные x_K и набор метрик сходимости и качества. Никакого иного содержания у решаемой задачи нет; конкретные семейства $\mathcal{F}, \mathcal{A}, \mathcal{N}$ выносятся в раздел III, чтобы постановка не смешивалась с алгоритмами.

III. Теоретический фон, классы методов и гипотезы

A. Связанные работы

Совместный тяжёлохвостовой/долгопамятный (LRD) режим в стохастической аппроксимации впервые проанализирован асимптотически Anantharam и Borkar [4] через предельное ОДУ; Chandak и др. [5] дают первые конечновременные оценки моментов для того же режима. Обе работы анализируют немодифицированную итерацию. Робастность к тяжёлым хвостам иначе достигается модификацией оптимизатора: обрезание градиента [6], high-probability оценки при неограниченной дисперсии [7], [8], нелинейный SGD [9]. Классические операторы шумоподавления — фильтр Калмана [10], мягкий вейвлет-порог [11]–[13], взвешенные медианы [14] — и декорреляция LRD-процессов вейвлетами [15] известны; шумоподавление как предобработка прогноза изучалось эмпирически [16]. Наш вопрос ортогонален: при фиксированном оптимизаторе мы количественно, с механизмом, показываем, где и насколько предобработка наблюдаемого ряда спасает сходимость.

B. Классы шума

Все шумы центрированы; $\sigma > 0$ — масштаб.

N_1 гауссов (контроль): $\xi_t \sim \mathcal{N}(0, \sigma^2)$ i.i.d.: конечная дисперсия, независимость.

N_2 долгая память (FARIMA): $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$, $\eta_j \sim \mathcal{N}(0, \sigma^2)$, $\psi_j = \Gamma(j+d)/(\Gamma(d)\Gamma(j+1)) \sim j^{d-1}/\Gamma(d)$, $d \in (0, \frac{1}{2})$. Дисперсия конечна, $\gamma(\tau) \sim c\tau^{2d-1}$, $\sum_{\tau} \gamma(\tau) = \infty$, спектр $\propto |\omega|^{-2d}$.

N_3 тяжёлые хвосты (α -устойчивый): $\xi_t \sim \mathcal{S}_\alpha(\sigma, 0, 0)$ i.i.d., $\alpha \in (1, 2)$: $\mathbb{E}|\xi|^p < \infty \iff p < \alpha$; в частности $\text{Var } \xi = \infty$, хвост $\text{Pr}(|\xi| > z) \sim C_\alpha \sigma^\alpha z^{-\alpha}$.

N_4 смешанный: $\xi_t = \sum_{j \geq 0} \psi_j \zeta_{t-j}$, ζ_j i.i.d. $\mathcal{S}_\alpha$, ψ_j как в N_2 : бесконечная дисперсия и долгая память одновременно.

Единственное свойство, движущее результаты ниже: у N_3, N_4 второй момент бесконечен ($\alpha < 2$).

C. Семейство фильтров и принципы выбора

Мы используем единую, сплошную нумерацию F_0 – F_7 (без пропусков): первые пять — классический набор, затем два каскада и онлайн-переключатель.

- F_0 — тождество (контроль / базовая линия);
- F_1 — скользящее среднее (линейный, причинный);
- F_2 — фильтр Калмана локального уровня (линейный, БИХ, причинный);
- F_3 — мягкий вейвлет-порог Добеши (не причинный; приводится только как оракульная верхняя граница и в рекомендованное правило не входит);
- F_4 — причинная медиана (нелинейная порядковая статистика; единственный одиночный оператор с конечной эффективной дисперсией, Лемма 1);
- F_5 — причинный каскад медиана→Калман (наш, для смешанного режима “тяжёлый хвост $\cap$ долгая память”);
- F_6 — адаптивный каскад (наш): по $\hat{\alpha}, \hat{H}$ на train-отрезке включает причинную медиану и/или Калман-стадию (на гауссовом гладком ряде вырождается в F_0);
- F_7 — онлайн-переключатель медиана/ЕМА (пошаговый выбор робастность/эффективность из скользящего окна, причинный).

Все, кроме оракульного F_3 , строго причинные и $O(T)$. Этот набор и прогоняется на всей корзине раздела IV; правило выбора (табл. IV) выводится только по причинным фильтрам.

Замечание о ранее удалённых операторах: Из общей библиотеки проекта в это исследование сознательно не включены обученные CNN-денойзеры (медленные, переобучаются под синтетическую автокорреляцию и деградируют на чужих данных), адаптивный вейвлет, гибрид медиана→вейвлет, диагностический роутер и ансамбль: на реальных рядах ни один не бил каскады F_5/F_6 , а по времени работы все были существенно дороже.

Аналитическое свойство F_1 (линейность): Конечная линейная комбинация α -устойчивых α -устойчива. При i.i.d. $\xi_t \sim \mathcal{S}_\alpha(\sigma, 0, 0)$ $\xi_t \sim \mathcal{S}_\alpha(\sigma_w, 0, 0)$,

$$\sigma_w = \sigma \left(\sum_{i=0}^{w-1} w^{-\alpha} \right)^{1/\alpha} = \sigma w^{1/\alpha-1}, \quad (5)$$

$1/\alpha - 1 \in (-\frac{1}{2}, 0)$: масштаб падает лишь как $w^{1/\alpha-1}$, закон остаётся α -устойчивым с $\text{Var } \xi = \infty$.

F_2 (БИХ-линейный): $\hat{s}_t = (1-K)\hat{s}_{t-1} + Ky_t = K \sum_{j \geq 0} (1-K)^j y_{t-j}$, $K \in (0, 1)$. Та же замкнутость: выход α -устойчив с масштабом $\sigma K(1 - (1-K)^\alpha)^{-1/\alpha}$, дисперсия бесконечна.

F_3 (вейвлет-порог): Универсальный множитель $\sqrt{2 \ln N}$ калиброван по максимуму гауссовых отклонений; для α -устойчивых максимум растёт как $N^{1/\alpha} \gg \sqrt{\ln N}$. Кроме того, порогуются только детальные полосы; низкочастотная (аппроксимирующая) полоса остаётся нетронутой и сохраняет α -устойчивый атом. Остаток после F_3 при N_3 остаётся тяжёлохвостовым.

F_4 (нелинейная порядковая статистика): $\hat{s}_t = \text{med}\{y_{t-w+1}, \dots, y_t\}$ — единственный нелинейный оператор из F_0 – F_4 ; отображает окно с бесконечной дисперсией в выход с конечной (Лемма 1).

F_5 (причинный каскад, наш):

$$\hat{s}_t = K_{\text{Kalman}}(\text{med}\{y_{t-m+1:t}\}), \quad (6)$$

где первая стадия — причинная медиана малого окна m (борется с тяжёлым хвостом), вторая — стационарный Калман локального уровня (сглаживает остаточный LRD-дрейф, который медиана малого окна не поглощает). Обе стадии $O(T)$, обе причинные.

F_6 (адаптивный каскад, наш): По обучающему отрезку оцениваются $\hat{\alpha}$ (Маккаллоу) и $\hat{H}$ (DFA); включение стадий каскада определяется правилом $\{\hat{\alpha} < 1.9\} \Rightarrow$ медиана-стадия; $\{\hat{H} > 0.6\} \Rightarrow$ Калман-стадия; обе истинны $\Rightarrow$ полный каскад как в (6); ни одно $\Rightarrow F_0$.

D. Оптимизаторы как операторы ϕ

ϕ из (3): SGD $\phi(g) = g$; Clipped-SGD $\phi(g) = \min(1, \tau/\|g\|)g$; Normalized-SGD $\phi(g) = g/\|g\|$; Adam [17]; AdamW [18]. Для SGD с постоянным шагом на L -гладкой μ -сильно выпуклой f при $\mathbb{E}\|\xi_k\|^2 \leq \sigma^2$ классический шумовой пол

$$\mathbb{E}\|\nabla f(x_K)\|^2 \xrightarrow{K \rightarrow \infty} \Theta(\eta L \sigma^2), \quad (7)$$

$\propto \sigma^2$ [19]. Обрезание/нормировка делают σ^2 конечным по построению, заменяя g ограниченным суррогатом [6], [7], [9].

E. Механизм: лемма и утверждение

Лемма 1 (Конечная дисперсия порядковой статистики). Пусть $\xi_{(1)}, \dots, \xi_{(w)}$ — порядковые статистики w i.i.d. симметричного закона с непрерывной плотностью h , $h(0) > 0$, и m_w — выборочная медиана (w нечётно). Тогда $\mathbb{E}m_w = 0$ и при $w \rightarrow \infty$

$$\text{Var } m_w = \frac{1}{4w h(0)^2} + o(1/w) < \infty, \quad (8)$$

для любого $\alpha \in (0, 2]$, включая α -устойчивый случай.

Доказательство. ЦПТ для выборочной медианы $\sqrt{w}(m_w) \Rightarrow \mathcal{N}(0, (4h(0)^2)^{-1})$ верна при непрерывной

h , положительной в популяционной медиане 0. Она использует лишь локальное поведение h в 0 и ни одного момента ξ . Плотность α -устойчивого закона ограничена, непрерывна и строго положительна в 0, откуда (8). $\square$

Утверждение 1 (Медиана восстанавливает пол SGD). При N_3 с причинной медианой фиксированной нечётной ширины w эффективный шум $\tilde{\xi}_t = m_w(\xi_{t-w+1:t})$ удовлетворяет $\sigma_{\text{med}}^2 \leq \frac{1}{4h(0)^2}(1 + o(1)) < \infty$. SGD с постоянным шагом на L -гладкой μ -сильно выпуклой f имеет конечный пол (7) с $\sigma^2 = \sigma_{\text{med}}^2$; вероятность $10^2 \times$ -снижения $\rightarrow 1$. Для линейных $F \in \{F_1, F_2\}$ отфильтрованный шум остаётся α -устойчивым (см. (5)), $\mathbb{E}\tilde{\xi}_t^2 = \infty$, конечного пола нет. Для F_3 низкочастотная полоса несёт α -устойчивый атом, поэтому также $\mathbb{E}\tilde{\xi}_t^2 = \infty$.

Замечание 1 (Предсказанный негатив на N_1). При N_1 Лемма даёт $\text{Var } m_w = \pi\sigma^2/(2w)$ против σ^2/w у среднего; асимптотическая относительная эффективность медианы $2/\pi \approx 0.637$. На чистом гауссе медиана поднимает пол в $\pi/2 \approx 1.57$ раза.

Замечание 2 (Предсказанный негатив на N_4 и мотивация F_5). Лемме 1 нужны почти-независимые отсчёты окна. При N_4 окно сильно зависимо ($\sum_{\tau} \gamma(\tau) = \infty$) и тяжёлые скачки кластеризуются: дисперсия медианы в ЦПТ раздувается, и (8) больше не ограничивает пол. Это движет выбор каскада F_5 : первой стадией медиана малого окна снимает изолированные хвостовые спайки, второй стадией Калман удаляет остаточный долгопамятный дрейф; вместе они приближают остаток к почти-гауссову с конечной дисперсией, где (7) снова применима.

Замечание 3 (Adam при долгой памяти N_2). У N_2 конечная дисперсия, (7) уже выполнено; проблема — смещение ЕМА второго момента Adam при устойчивой $1/f$ -автокорреляции [20]. Вейвлет-базисы приближённо декоррелируют LRD-процессы по масштабам [15], возвращая шум к почти-белому; здесь ускоряет вейвлет-базлайн F_3 (не F_4).

Г. Гипотезы

Прямо из теории формулируем гипотезы, проверяемые в разделе IV.

Гипотеза 1 (Спасение при тяжёлом хвосте). $F_0, F_1, F_2, F_3 + \text{SGD}$ на N_3 дают бинарную сходимость $c(\varepsilon) \rightarrow 0$ за разумный горизонт; $F_4 + \text{SGD}$ дают $c(\varepsilon) \rightarrow 1$ и снижают пол $\|\nabla f\|^2$ в число раз, сопоставимое с $\sigma_{N_3}^2/\sigma_{\text{med}}^2$.

Гипотеза 2 (Каскад на смешанном режиме). На N_4 (тяжёлые хвосты $\cap$ долгая память) одиночные фильтры F_4 и F_2/F_3 не дают значимого снижения пола; каскад F_5 (медиана $\rightarrow$ Калман) даёт.

Гипотеза 3 (Долгая память + Adam). На N_2 с Adam/AdamW вейвлет-базлайн F_3 ускоряет $T(\varepsilon)$ в

Таблица I
 N_3 ($\alpha=1.2$), SGD, 8 сидов. Бинарная сходимость и медианный шумовой пол. F_1, F_2, F_3 ведут себя как F_0 .

модель	бин. F_0	бин. F_4	пол F_0	пол F_4	отнош.
квадр.	0/8	8/8	0.540	0.0050	108 $\times$
логист.	0/8	8/8	0.0658	0.00050	133 $\times$
AR(5)	8/8	8/8	0.0421	0.0021	20 $\times$

заметное число раз; на N_4 фильтрация Adam в среднем нейтральна/слегка вредит.

Гипотеза 4 (Эмпирические критерии). Двух диагностик $\hat{\alpha}$ (Маккаллоу) и $\hat{H}$ (DFA) на обучающем отрезке достаточно, чтобы на широкой корзине реальных доменов (финансовые разные частоты, FRED, ETT, scientific) предсказать, какая причинная связка (фильтр, оптимизатор) лучше в среднем по сидам; правило валидируется в разделе IV-D.

IV. Эксперименты и анализ

А. Общая конфигурация

Модели: квадратичная регрессия ($d=20$), логистическая классификация ($d=15$), AR(5). Масштабы шума фиксированы для всех ячеек; никакого подбора под фильтр. Сиды: 8 для синтетики, 4 для прикладного факториала. Доверительные интервалы — 95% bootstrap. Прикладной факториал (блок D) прогоняет весь набор F_0 – F_7 ; все фильтры, кроме оракульного F_3 , строго причинны (выход в момент t использует только $s_{\leq t}$), поэтому из выбора рекомендованного фильтра F_3 исключается, а holdout-цель — сырое будущее, единое для всех ячеек.

Диагностики $\hat{\alpha}$ (Маккаллоу), $\hat{H}$ (DFA) считаются на дифференцированном обучающем отрезке. Для корзины SPY/QQQ/AAPL/MSFT/JPM/EUR-USD/GBP-USD/BTC/ETH (2018–2025, дневные) медиана $\hat{\alpha}=1.21$, $\hat{d}=0.29$. Принятое в блоке А значение $\alpha=1.2$ попадает в середину диапазона.

В. Блок А — спасение SGD при тяжёлом хвосте

Полный факторный: $\{\text{квадратичная, логистическая, AR(5)}\} \times \{N_1, N_3(\alpha=1.2), N_4\} \times \{\text{SGD, Clipped-SGD, Normalized-SGD}\} \times \{F_0, F_1, F_2, F_3, F_4\} \times 8 \text{ сидов}$.

Гипотеза 1 подтверждается (табл. I): при N_3 SGD без фильтра и со всеми линейными/вейвлет-фильтрами сходится в 0/8 сидов; F_4 переводит в 8/8 и снижает пол в 108 $\times$ (квадратичная) и 133 $\times$ (логистическая). Для AR(5) сходимость формально достигается даже без фильтра, но пол с F_4 ниже в 20 $\times$. На N_1 отношение пола $F_4/F_0 \in [0.76, 0.95]$ (худшее) — штраф эффективности из Замечания 1.

С. Блок В — адаптивные оптимизаторы и долгая память

На N_2 (квадратичная) Adam и AdamW ускоряются вейвлет-фильтром F_3 в 11.2 $\times$ ($T(\varepsilon)$: 562 $\rightarrow$ 50, Гипоте-

Предфильтрация спасает сходимость SGD при тяжёлохвостовом градиентном шуме (8 сидов)




Рис. 1. N_3 , SGD, 8 сидов. (а) пол F_0 – F_4 , лог-шкала, p_{10} – p_{90} ; (б) медиана $\|\nabla f\|^2$: F_0/F_2 застревают высоко, F_4 падает на 1–2 порядка. Линейные и вейвлет-фильтры идут вдоль F_0 (Утверждение 1).

Таблица II

Блок С. Смешанный режим N_4 ($d=0.4$, $\alpha=1.2$), SGD, 8 сидов. Бинарная сходимость и пол по сравнению с F_0 . Новый каскад F_{10} (медиана→Калман) и адаптивный F_{11} снижают пол там, где одиночные фильтры не справляются.

модель	фильтр	бин.	пол $\ \nabla f\ ^2$	vs F_0
логист.	F_0	0/8	$3.00e-01$	$1.00\times$
логист.	F_2	0/8	$2.99e-01$	$1.00\times$
логист.	F_4	0/8	$2.98e-01$	$1.01\times$
логист.	F_{10}	0/8	$2.98e-01$	$1.01\times$
логист.	F_{11}	0/8	$2.99e-01$	$1.00\times$
квадр.	F_0	0/8	$2.59e+02$	$1.00\times$
квадр.	F_2	0/8	$2.61e+02$	$0.99\times$
квадр.	F_4	0/8	$2.42e+02$	$1.07\times$
квадр.	F_{10}	0/8	$2.25e+02$	$1.15\times$
квадр.	F_{11}	0/8	$2.49e+02$	$1.04\times$

за 3 подтверждается); фильтр Калмана даёт $3.1\times$. На смешанном N_4 ни один одиночный фильтр не бьёт F_0 — предсказанный Замечанием 3 результат.

D. Блок С — каскад на синтетическом N_4

Новая часть, проверяющая Гипотезу 2 на синтетическом смешанном режиме N_4 ($d=0.4$, $\alpha=1.2$, 8 сидов, тот же горизонт и масштаб шума для всех ячеек). Результат честный, но скромный: ни один из F_1, F_2, F_3, F_4 не снижает пол ($\approx 1.0\times$ от F_0); каскад F_5 (медиана → Калман, $m=3$) даёт $\approx 1.2\times$ снижение, F_4 отдельно — $\approx 1.1\times$, F_6 повторяет F_5 (см. табл. II). С более длинной медианой ($m=15$ – 51) выигрыш каскада на N_4 SGD растёт до $\approx 1.5\times$, но Adam при этом, наоборот, теряет в скорости из-за пересглаживания: на N_4 Adam сам справляется почти оптимально, и предобработка ему вредит — картина, согласованная с Замечанием 3.

Поэтому каскад мы не оправдываем синтетическим N_4 как “панацеей”. Его теоретическая мотивация остаётся (медианная стадия ловит хвостовые скачки, Калман — остаточный LRD-дрейф), но практический вы-

игрыш видно на реальных высокочастотных финансовых рядах (Блок D), где совмещение тяжёлых хвостов и структурного шума иное, чем у формального $S_\alpha \times \text{FARIMA}$.

E. Блок D — широкий реальный факториал (июнь 2026)

Чтобы вывести правило выбора фильтра с покрытием всех четырёх секторов ($\hat{\alpha}, \hat{H}$), мы собрали широкую корзину публично доступных рядов и прогнали на ней весь набор F_0 – F_7 :

- финансовые доходности: расширенная дневная корзина (акции/ETF/FX/крипто/сырьё/бонды/VIX), внутридневные 15-/5-мин, а также часовые крипто Binance BTCUSDT/ETHUSDT (2024, публичный фид data.binance.vision);
- волатильность $|r|$: дневные акции и крипто — режим долгой памяти ($\hat{H} > 0.6$);
- макро: 6 серий FRED;
- сенсорные: ETTh1/h2/m1/m2, Electricity Load (UCI/LSTNet), Traffic PEMS (LSTNet);
- метео / прогностика / операционные / научные: NOAA GHCN-daily (NY Central Park, 1869–2026), NASA C-MAPSS (турбина FD001), дневные снятия в банкомате (ATM), числа солнечных пятен (SILSO).

Источники, требующие платной подписки или портального доступа — полный фид LOBSTER, NYSE TAQ, CRSP — свободно не выгружаются и из исследования исключены.

На каждой паре (домен, серия) обучаются обе модели (регрессия AR(5) и классификация знака), оптимизаторами SGD и Adam, по 4 сида. Holdout-цель — сырое будущее значение, единое для всех фильтров; диагностики ($\hat{\alpha}, \hat{H}$) для волатильности и научных ря-

Таблица III

Блок D (июнь 2026). Широкая корзина, набор F_0 – F_7 , Adam, регрессия AR(5), 4 сида. Лучший причинный фильтр: доля сходимости ≥ 0.75 и holdout MSE не более чем на 10% хуже F_0 ; среди них минимум итераций до 100×-снижения градиента (оракульный F_3 в выбор не входит). ускор. — отношение медиан числа итераций.

домен	$\hat{\alpha}$	$\hat{H}$	лучш.	ускор.	holdout
Binance BTC/ETH 1ч	1.47	0.05	F_2	77.7 ×	0.931/0.918
фин. дневные	1.53	0.06	F_2	18.6 ×	0.877/0.857
фин. 15-мин	1.54	0.08	F_2	80.4 ×	0.548/0.547
фин. 5-мин	1.60	0.07	F_2	77.9 ×	0.638/0.628
крипто $ r $ (волат.)	1.48	0.80	F_1	1.6 ×	0.836/0.796
акции $ r $ (волат.)	2.00	0.64	F_1	1.9 ×	1.01/0.971
макро (FRED)	2.00	0.51	F_6	1.00×	0.0077/0.0077
ETTh1	1.44	0.13	F_0	1.00×	0.488/0.488
ETTh2	1.47	0.16	F_0	1.00×	0.135/0.135
ETThm1	1.39	0.22	F_0	1.00×	0.101/0.101
ETThm2	1.49	0.25	F_0	1.00×	0.0476/0.0476
Electricity Load	1.87	0.79	F_0	1.00×	0.132/0.132
Traffic PEMS	1.87	0.61	F_0	1.00×	0.313/0.313
NOAA Weather	1.66	0.22	F_0	1.00×	0.12/0.12
C-MAPSS (турбина)	2.00	0.10	F_6	1.00×	0.316/0.316
ATM (снятия)	1.77	0.08	F_1	1.7 ×	0.639/0.626
Sunspots	2.00	1.15	F_0	1.00×	0.224/0.224

Таблица IV

Эмпирическое правило, выведенное из блока D. Для каждого сектора ($\hat{\alpha}, \hat{H}$): фильтр, дающий ускорение там, где фильтрация вообще помогает ($\geq 1.5\times$), доля таких ячеек (домен×модель×опт.), медианное и максимальное ускорение среди них. Где доля нулевая — рекомендуется F_0 (не фильтровать). F_2 — Калман, F_5 — каскад медиана→Калман, F_6 — адаптивный каскад.

сектор ($\hat{\alpha}, \hat{H}$)	фильтр	помог	медиан.	макс.
$\hat{\alpha} \approx 2, \hat{H} \approx 0.5$	F_0	—	1.0×	1.0×
$\hat{\alpha} \approx 2, \hat{H} > 0.6$	F_1	1/8	1.9×	1.9×
$\hat{\alpha} < 1.9, \hat{H} \approx 0.5$	F_2	7/40	18.6×	80 ×
$\hat{\alpha} < 1.9, \hat{H} > 0.6$	F_1	1/12	1.6×	1.6×

дов считаются на уровне, для доходностей — на приращении. Скрипт: experiments/run_new_datasets.py; сводки — tables/new_datasets_summary.csv; правило — tables/new_datasets_rules.csv.

Сводное правило, агрегированное по секторам диагностик, приведено в табл. IV: оно сворачивает все домены блока в карту “($\hat{\alpha}, \hat{H}$) → фильтр”.

Главное наблюдение — единственный сектор, где фильтрация по-крупному окупается, это тяжёлый хвост + короткая память (доходности) под Adam (строка 3 правила, табл. IV). На часовых лог-доходностях BTC/ETH ($\hat{\alpha} \approx 1.47$) Adam без фильтра сходится лишь в 0.38 прогонов (застревает на шумовом полу); линейный Калман F_2 даёт 4/4 и ускорение **77.7**×, наш каскад F_5 (медиана→Калман) — **64**×, причём с наибольшим снижением шумового пола $\|\nabla f\|^2$: **127**× против 120× у F_2 и 17× у одиночной медианы F_4 , при практически неизменном holdout (отклонение MSE < 2%). Та же картина на внутрисдневных и дневных акциях (табл. III): F_2 — 80× (15-мин), 78× (5-мин), 19× (дневные), каскад

F_5 идёт вторым вплотную. Интерпретация согласована с Замечанием 3: на доходностях Adam страдает не от тяжёлого хвоста как такового, а от смещения своих ЕМА-оценок при сильной автокорреляции; линейное сглаживание (Калман или Калман-стадия каскада) её снимает. Каскад предпочтителен, когда важен именно пол градиента (например при переходе на SGD с постоянным шагом или в смешанном режиме): он его не теряет сильнее всех причинных фильтров.

Где фильтрация не нужна.: Во всех остальных секторах лучший выбор — F_0 (табл. IV). На светлостовых / гладких рядах (FRED, ETTh1/h2/m1/m2, NOAA, sunspots) ни один фильтр не бьёт тождество: база и так сходится, а holdout не улучшается. Адаптивный F_6 на этих рядах корректно вырождается в F_0 (медиана включается лишь при $\hat{\alpha} < 1.9$, Калман лишь при $\hat{H} > 0.6$), подтверждая Гипотезу 4. Поучительные пограничные случаи: (i) очень тяжёлый шум сам по себе не гарантирует выигрыша — на Electricity/Traffic ($\hat{\alpha} \approx 1.87$, но $\hat{H} > 0.6$) фильтрация нейтральна, потому что узкое место не в шумовом полу; (ii) на C-MAPSS причинные F_4/F_7 дают лишь скромное улучшение holdout (≈ 5 –8%), а основной выигрыш там забирает оракульный вейвлет F_3 (–41% MSE), который как несправедливый в правило не входит — честная иллюстрация того, что верхняя граница доступного выигрыша и практически достижимый причинный выигрыш могут сильно расходиться.

F. Полусинтетика и микроструктура

Когда под реальным шумом есть восстановимый гладкий сигнал, выигрыш велик и однозначен: в микроструктурной симуляции причинная медиана F_4 снижает ошибку интегрированной дисперсии в $\approx 58\times$ относительно F_0 . Это согласуется с оракульным результатом блока D (непричинный вейвлет F_3 восстанавливает гладкий сигнал лучше всех), но в рабочий причинный набор F_3 не входит по причинам раздела III.

V. Практические критерии выбора

В этом разделе каждый пункт явно помечен по источнику вывода: $[T]$ — следует из теоретического результата раздела III; $[E]$ — из эмпирики раздела IV; $[H]$ — эвристика, не доказанная и не опровергнутая в данной работе. Это требование прозрачности: мы не выдаём эвристические правила за теоретические следствия.

A. Диагностика

Шаг 1: на обучающем отрезке оценить $\hat{\alpha}$ (Маккаллоу или Хилл) и $\hat{H}$ (DFA или R/S). На дневных финансовых рядах диагностику имеет смысл считать на $|r_t|$ (абсолютных доходностях) для $\hat{H}$, поскольку сам r_t почти-белый по уровню. Это известный стилизованный факт [1] $[T]$.

В. Стартовый список кандидатов

По паре $(\hat{\alpha}, \hat{H})$ ряд относится к одному из четырёх секторов; для каждого — стартовый список кандидатов (не финальное решение):

$\hat{\alpha}, \hat{H}$	Кандидаты	Источник
$\hat{\alpha} \approx 2, \hat{H} \approx 0.5$	$F_0 + \text{Adam/SGD}$	[T] Зам. 1
$\hat{\alpha} \approx 2, \hat{H} > 0.6$	$F_2/F_6 + \text{Adam}$	[T] Зам. 3
$\hat{\alpha} < 1.9, \hat{H} \approx 0.5$	$F_2/F_5 + \text{Adam}; F_4 + \text{SGD}$	[T, E] Утв. 1, фин. блок D
$\hat{\alpha} < 1.9, \hat{H} > 0.6$	$F_5, F_6 + \text{SGD/Adam}$	[T, E] Зам. 2, блок C-D

Первые две строки — прямое следствие раздела III ([T]): на светлостовом ряду медиана не нужна, долгую память закрывает Калман F_2 или Калман-стадия адаптивного F_6 . Третья строка (тяжёлый хвост, короткая память) сильнее всего подтверждена эмпирически: на доходностях всех частот линейный F_2 и каскад F_5 ускоряют Adam в 18–80× и роняют пол на 1–2 порядка (блок D), а медиана F_4 восстанавливает конечный пол SGD теоретически (Утв. 1). Четвёртая строка (F_5/F_6 на смешанном режиме) — комбинация теоретической мотивации (Замечание 2) и эмпирики (блоки C–D, крипто-1ч): [T, E].

С. Финальный выбор — causal walk-forward валидация [E]

Стартовый список — 2–3 пары (F, A) . Окончательный выбор делается причинной walk-forward-валидацией на обучающем отрезке (разрыв с holdout запрещён, цель — сырое будущее). Это эмпирический шаг, не доказанный теорией; обоснование — блок D раздела IV.

D. Когда фильтрацию применять не следует [T]

Почти-гауссов / гладкий сигнал ($\hat{\alpha} \approx 1.8$ –2, $\hat{H} \approx 0.5$, напр. NOAA-температура, ETTm2): фильтрация в лучшем случае нейтральна (1.00×, блок D), а в чисто-гауссовом пределе поднимает пол в $\pi/2 \approx 1.57$ × (Замечание 1). Сырые дневные доходности почти-белые по уровню, но по уровню они и тяжёлохвосты, поэтому сглаживание перед Adam как раз помогает (строка 3 правила); для прогноза волатильности фильтруют $|r|$. Отдельно отметим: длинная память или тяжёлый хвост сами по себе не гарантируют выигрыша — на Electricity/Traffic ($\hat{\alpha} \approx 1.87$, $\hat{H} > 0.6$) фильтрация нейтральна, так как база и без неё сходилась (узкое место не в шумовом полу).

Е. Каскад как умолчание для финансовой высокой частоты [T, E]

Высокочастотные финансовые ряды (1-мин, 5-мин, часовые крипто) тяжёлохвостовы по приращениям. Прямой замер блока D на независимом фиде Binance: Adam без фильтра сходится лишь в 0.38 прогонов, Калман F_2 и каскад F_5 — в 4/4 с ускорением 78× и 64× соответственно. Если критична скорость Adam —

достаточно линейного F_2 ; если важен шумовой пол (переход на SGD с постоянным шагом, смешанный режим) — каскад F_5 роняет его сильнее всех причинных фильтров (127× против 120× у F_2), поэтому именно он — разумное умолчание для этого режима; калибровка m (медианное окно), K (коэффициент Калмана) делается на валидации.

Ф. Антипаттерны и подводные камни [E]
Утв. 1, фин. блок D
(i) Look-ahead bias: центрированная медиана даёт ложный +7 п.п. выигрыш в знак-прогнозе; правильная замена — причинная. (ii) Подбор окна фильтра под единственный сид: вместо 8 сидов с фиксированным окном даёт неустойчивые рекомендации. (iii) Слепое применение каскада там, где у сигнала есть медленный полезный тренд: на C-MAPSS Калман-стадия каскада F_5 пересглаживает деградацию и втрое ухудшает holdout-MSE (0.97 против 0.32 у F_0), тогда как одиночная медиана F_4 его не портит (а оракульный вейвлет F_3 даже улучшает на 41%, но он непричинный). Поэтому каскад не “умолчание для всего” — адаптивный F_6 , включающий стадии по $(\hat{\alpha}, \hat{H})$, надёжнее фиксированного F_5 . (iv) Обученные CNN-денойзеры, переносимые с синтетики на данные с другой автокорреляцией, деградировали по качеству и были медленными — из рабочего набора они удалены в пользу классических F_4/F_5 .

VI. Заключение

Главный механизм — порядковая статистика восстанавливает конечную эффективную дисперсию шума, чего линейные фильтры дать не могут. Этим объясняется положительный результат на N_3 (SGD: 0/8 → 8/8, снижение пола 108–133×) и — на свежих, независимых данных — ускорение Adam на часовых крипто-доходностях Binance (0.38 → 4/4, до 78× линейным Калманом F_2 , наибольшее снижение пола 127× каскадом F_5); и негативный результат на N_1 (штраф $\pi/2$) и на гладких NOAA/ETTm2/FRED/sunspots (фильтр нейтрален). На смешанном режиме одиночные линейные фильтры не помогают; для него введён причинный каскад F_5 (медиана→Калман) и адаптивный F_6 . Исследование проведено на сплошном причинном наборе F_0 – F_7 (классические F_0 – F_4 плюс два каскада и онлайн-переключатель; медленные CNN-денойзеры и избыточные вейвлет/ансамбль-фильтры исключены как не дававшие выигрыша), а по двум диагностикам $(\hat{\alpha}, \hat{H})$ на широкой корзине выведено сводное правило выбора (табл. IV) с покрытием всех четырёх секторов. Практические критерии выбора (раздел V) построены так, чтобы каждое правило явно ссылалось либо на теоретический результат, либо на эксперимент, либо маркировалось как эвристика. Два честных нюанса из блока D: очень тяжёлый хвост сам по себе ещё не повод фильтровать (Electricity/Traffic: $\hat{\alpha} \approx 1.87$, но база сходится и без того), а практически достижимый

причинный выигрыш может быть много меньше ортакульного (С-MAPSS: непричинный вейвлет улучшает holdout на 41%, причинные фильтры — лишь на 5–8%).

Список литературы

- [1] R. Cont, “Empirical properties of asset returns: Stylized facts and statistical issues,” *Quantitative Finance*, vol. 1, no. 2, pp. 223–236, 2001.
- [2] B. Mandelbrot, “The variation of certain speculative prices,” *The Journal of Business*, vol. 36, no. 4, pp. 394–419, 1963.
- [3] U. Şimşekli, L. Sagun, and M. Gürbüzbalaban, “A tail-index analysis of stochastic gradient noise in deep neural networks,” in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, ser. *Proceedings of Machine Learning Research*, vol. 97. PMLR, 2019, pp. 5827–5837. [Online]. Available: <https://arxiv.org/abs/1901.06053>
- [4] V. Anantharam and V. S. Borkar, “Stochastic approximation with long range dependent and heavy tailed noise,” *Queueing Systems*, vol. 71, no. 1–2, pp. 221–242, 2012.
- [5] S. Chandak, A. K. Yadav, A. Özgür, and N. Bambos, “Heavy-tailed and long-range dependent noise in stochastic approximation: A finite-time analysis,” Mar. 2026, submitted to *IEEE Transactions on Automatic Control*. [Online]. Available: <https://arxiv.org/abs/2603.19648>
- [6] E. Gorbunov, M. Danilova, and A. Gasnikov, “Stochastic optimization with heavy-tailed noise via accelerated gradient clipping,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 15 042–15 053. [Online]. Available: <https://arxiv.org/abs/2005.10785>
- [7] A. Cutkosky and H. Mehta, “High-probability bounds for non-convex stochastic optimization with heavy tails,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. [Online]. Available: <https://arxiv.org/abs/2106.14343>
- [8] A. Sadiev, M. Danilova, E. Gorbunov, S. Horváth, G. Gidel, P. Dvurechensky, A. Gasnikov, and P. Richtárik, “High-probability bounds for stochastic optimization and variational inequalities: The case of unbounded variance,” in *Proceedings of the 40th International Conference on Machine Learning (ICML)*, 2023. [Online]. Available: <https://arxiv.org/abs/2302.00999>
- [9] A. Armacki, S. Yu, P. Sharma, G. Joshi, D. Bajović, D. Jakovetić, and S. Kar, “Nonlinear stochastic gradient descent and heavy-tailed noise: A unified framework and high-probability guarantees,” 2024. [Online]. Available: <https://arxiv.org/abs/2410.13954>
- [10] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Journal of Basic Engineering*, vol. 82, no. 1, pp. 35–45, 1960.
- [11] D. L. Donoho and I. M. Johnstone, “Ideal spatial adaptation by wavelet shrinkage,” *Biometrika*, vol. 81, no. 3, pp. 425–455, 1994.
- [12] D. L. Donoho, “De-noising by soft-thresholding,” *IEEE Transactions on Information Theory*, vol. 41, no. 3, pp. 613–627, 1995.
- [13] S. Mallat, *A Wavelet Tour of Signal Processing*, 2nd ed. San Diego: Academic Press, 1999.
- [14] L. Yin, R. Yang, M. Gabbouj, and Y. Neuvo, “Weighted median filters: A tutorial,” *IEEE Transactions on Circuits and Systems II: Analog and Digital Signal Processing*, vol. 43, no. 3, pp. 157–192, 1996.
- [15] D. B. Percival and A. T. Walden, “Wavelet methods for time series analysis,” *Cambridge Series in Statistical and Probabilistic Mathematics*, 2000.
- [16] Q. Tang, T. Fan, R. Shi, J. Huang, and Y. Ma, “Prediction of financial time series using LSTM and data denoising methods,” 2021. [Online]. Available: <https://arxiv.org/abs/2103.03505>
- [17] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015. [Online]. Available: <https://arxiv.org/abs/1412.6980>
- [18] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, 2019. [Online]. Available: <https://arxiv.org/abs/1711.05101>
- [19] H. Robbins and S. Monro, “A stochastic approximation method,” *The Annals of Mathematical Statistics*, vol. 22, no. 3, pp. 400–407, 1951.
- [20] A. Défossez, L. Bottou, F. Bach, and N. Usunier, “A simple convergence proof of adam and adagrad,” *Transactions on Machine Learning Research*, 2022. [Online]. Available: <https://arxiv.org/abs/2003.02395>