

Шумоподавление наблюдаемого ряда как предобработка стохастической оптимизации: когда фильтрация спасает сходимость при тяжёлохвостовом градиентном шуме

Дмитрий Кортунов
НИУ ВШЭ
Москва, Россия

Вадим Пастушенко
НИУ ВШЭ
Москва, Россия

Алексей Дубовицкий
НИУ ВШЭ
Москва, Россия

Андрей Шадрин
НИУ ВШЭ
Москва, Россия

Аннотация—Шумоподавление наблюдаемого ряда трактуется как явный этап конвейера стохастической оптимизации. Сначала формализуется модель временного ряда и задача прогноза (раздел II), затем выносятся теоретический фон с механизмом эффекта и гипотезами (раздел III), затем описывается экспериментальная проверка (раздел IV) и, наконец, эмпирически обоснованные практические критерии выбора связки “фильтр+оптимизатор” (раздел V). Главный механизм: при α -устойчивом градиентном шуме ($\alpha < 2$, бесконечная дисперсия) SGD с постоянным шагом не имеет конечного шумового пола; оконная медиана отображает окно с бесконечной дисперсией в порядковую статистику с конечной дисперсией, что восстанавливает стандартный пол, тогда как любой линейный фильтр (скользящее среднее, Калман) сохраняет α -устойчивый закон. Для смешанного режима (тяжёлые хвосты + долгая память) одиночная медиана уже не работает — вводится причинный каскадный фильтр F_{10} (медиана $\rightarrow$ Калман) и его адаптивная версия F_{11} (стадии выбираются по $\hat{\alpha}, \hat{H}$), которые мы предлагаем именно для этого режима. Эмпирически при $\hat{\alpha} \approx 1.2$ обычный SGD сходится в 0/8 прогонах (как и линейные/вейвлет-фильтры) и в 8/8 с причинной медианой, снижая пол в $108\times$ (квадратичная) и $133\times$ (логистическая); эффект сохраняется при калибровке ($91\times/120\times$) и подтверждён на расширенной корзине реальных доменов (финансовые дневные/15-минутные/5-минутные, FRED, ETTh1, ETTh2, ETtm1, sunspots) с обеих сторон — и где фильтрация ускоряет ($\approx 78\times$ на 15-мин), и где не помогает (чистый гаусс, долгопамятные смеси).

Index Terms—стохастическая оптимизация, тяжёлохвостовый шум, α -устойчивые распределения, медианная фильтрация, причинный каскадный фильтр, фильтр Калмана, долгая память, сходимость.

I. Введение

Теория сходимости стохастических методов первого порядка опирается на конечный второй момент градиентного шума и слабую временную зависимость. Оба предположения нарушаются при обучении на финансовых рядах: доходности тяжёлохвостовы и долгопамят-

ны [1], [2], и стохастический градиент наследует эти свойства [3]. Мы рассматриваем шумоподавление не как визуализацию, а как вычислительный этап между наблюдениями и оптимизатором, и ставим точный вопрос: для каких троек (шум, фильтр, оптимизатор) предобработка превращает несходящийся прогон в сходящийся и почему.

Структура текста задана по разделам: II — модель временного ряда, термины, задача прогноза и формальная постановка решаемой задачи (без описания алгоритмов); III — теоретический фон и явно сформулированные гипотезы (с компактными определениями фильтров и оптимизаторов как аналитических объектов); IV — экспериментальный план, расширенная корзина реальных доменов (включая нефинансовые) и анализ; V — практические критерии выбора, где каждый пункт явно помечен как “из теории”, “из эксперимента” или “эвристика”; VI — заключение.

Вклад статьи. (i) Чистая формализация задачи, отделённая от конкретных алгоритмов; (ii) утверждение, выделяющее механизм: нелинейная порядковая статистика восстанавливает конечную эффективную дисперсию шума, чего линейные фильтры дать не могут; (iii) новый причинный каскадный фильтр F_{10} и его адаптивный вариант F_{11} , спроектированные под предсказанный негативный режим N4 (тяжёлые хвосты $\cap$ долгая память); вместе с медианой F_4 и онлайн-переключателем F_A они образуют тощий причинный рабочий набор, заменивший прежний пул из 14 операторов (медленные CNN-денойзеры и избыточные вейвлет/ансамбль-фильтры отброшены); (iv) эмпирическое подтверждение на свежей корзине публично доступных финансовых и нефинансовых рядов (Binance, C-MAPSS, ATM, NOAA, ETtm2) с явной увязкой к критериям выбора.

II. Модель временного ряда и постановка задачи

В этом разделе мы фиксируем только объекты (ряд, признаки, цель, функция риска, шум на градиенте, место фильтра как абстрактного оператора). Конкретные семейства фильтров, шумов и оптимизаторов вводятся отдельно в разделе III; здесь они присутствуют только как формальные символы.

A. Наблюдаемый ряд

Определение 1 (Наблюдаемая модель). Скалярный временной ряд $y_{1:T} \in \mathbb{R}^T$ описывается аддитивной моделью

$$y_t = s_t + \xi_t, \quad t = 1, \dots, T, \quad (1)$$

где $s \in \mathbb{R}^T$ — сигнал (неизвестная гладкая или закономерно меняющаяся компонента), а $\xi \in \mathbb{R}^T$ — шум (стохастический процесс из некоторого класса с известными аналитическими свойствами).

В разделе III мы фиксируем четыре класса шума $\mathcal{N} \in \{N_1, N_2, N_3, N_4\}$ (гауссов, долгая память, тяжёлые хвосты, смешанный); здесь $\mathcal{N}$ рассматривается как параметр задачи.

B. Признаки, целевая переменная, задача обучения

Определение 2 (Задача обучения по ряду). Из ряда $y_{1:T}$ формируются обучающие пары $(u_i, v_i)_{i=1}^n$: вход $u_i \in \mathbb{R}^p$ — лаговое окно $u_i = (\tilde{y}_{t_i-1}, \dots, \tilde{y}_{t_i-p})$, цель $v_i = \tilde{y}_{t_i}$ (регрессия следующего значения) или $\mathbf{1}\{\tilde{y}_{t_i} > 0\}$ (классификация знака). Здесь $\tilde{y}$ — результат применения некоторого фильтра-оператора F к $y_{1:T}$ (см. 4). На отложенных значениях используется сырой (нефильтрованный) y , идентичный для всех фильтров — это исключает заглядывание вперёд.

При параметрической модели $g_x: \mathbb{R}^p \rightarrow \mathbb{R}$ ($x \in \mathbb{R}^d$) и функции потерь ℓ (квадратичной для регрессии, логистической для классификации) задача обучения — минимизация эмпирического риска:

$$f(x) = \frac{1}{n} \sum_{i=1}^n \ell(g_x(u_i), v_i), \quad x^* \in \arg \min_{x \in \mathbb{R}^d} f(x). \quad (2)$$

Определение 3 (Прогноз). Прогноз — это оценка $\hat{v}_t = g_{\hat{x}}(u_t)$, где $\hat{x}$ — результат обучения. Качество прогноза измеряется на отложенной причинной выборке (test, идущий строго позже train) либо MSE (регрессия), либо точностью (классификация знака).

C. Фильтр как оператор и его место в конвейере

Определение 4 (Фильтр). Фильтр — это отображение $F: \mathbb{R}^T \rightarrow \mathbb{R}^T$, $\hat{s} = F(y_{1:T})$, применённое до формирования признаков. F называется причинным, если $\hat{s}_t$ зависит только от $y_{1:s \leq t}$ (будущее не используется). Контрольный фильтр $F_0 = \text{Id}$ соответствует “без фильтрации”.

D. Стохастический шаг и формальная задача

Определение 5 (Стохастический градиент и шаг). На итерации k методу первого порядка доступен зашумлённый градиент

$$g_k = \nabla f(x_k) + \xi_k, \quad x_{k+1} = x_k - \eta_k \phi(g_k), \quad (3)$$

ξ_k — центрированный шум (общим образом ни $\mathbb{E} \|\xi_k\|^2 < \infty$, ни независимости по k не предполагается), ϕ — оператор обновления, η_k — шаг.

Определение 6 (Формальная задача исследования). Дано: класс шумов $\mathcal{N}$ из определения 1, множество причинных фильтров $\mathcal{F}$ из определения 4, множество операторов обновления $\mathcal{A}$ из (3), модель обучения f из (2). Требуется оценить отображение

$$\Phi: (F, A, \mathcal{N}) \mapsto (T(\varepsilon), c(\varepsilon), h), \quad (4)$$

где $T(\varepsilon)$ — эмпирическое время до ε -точности по $\|\nabla f\|^2$, $c(\varepsilon)$ — доля прогонов, достигших заданного снижения градиента (бинарная сходимость), h — качество на отложенной выборке (3). Иначе говоря, вход процедуры — наблюдаемый ряд $y_{1:T}$ и выбор тройки $(F, A, \mathcal{N})$; выход — обученные x_K и набор метрик сходимости и качества. Никакого иного содержания у решаемой задачи нет; конкретные семейства $\mathcal{F}, \mathcal{A}, \mathcal{N}$ выносятся в раздел III, чтобы постановка не смешивалась с алгоритмами.

III. Теоретический фон, классы методов и гипотезы

A. Связанные работы

Совместный тяжёлохвостовой/долгопамятный (LRD) режим в стохастической аппроксимации впервые проанализирован асимптотически Anantharam и Borkar [4] через предельное ОДУ; Chandak и др. [5] дают первые конечновременные оценки моментов для того же режима. Обе работы анализируют немодифицированную итерацию. Робастность к тяжёлым хвостам иначе достигается модификацией оптимизатора: обрезание градиента [6], high-probability оценки при неограниченной дисперсии [7], [8], нелинейный SGD [9]. Классические операторы шумоподавления — фильтр Калмана [10], мягкий вейвлет-порог [11]–[13], взвешенные медианы [14] — и декорреляция LRD-процессов вейвлетами [15] известны; шумоподавление как предобработка прогноза изучалось эмпирически [16]. Наш вопрос ортогонален: при фиксированном оптимизаторе мы количественно, с механизмом, показываем, где и насколько предобработка наблюдаемого ряда спасает сходимость.

B. Классы шума

Все шумы центрированы; $\sigma > 0$ — масштаб.

N_1 гауссов (контроль): $\xi_t \sim \mathcal{N}(0, \sigma^2)$ i.i.d.: конечная дисперсия, независимость.

N_2 долгая память (FARIMA): $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$, $\eta_j \sim \mathcal{N}(0, \sigma^2)$, $\psi_j = \Gamma(j+d)/(\Gamma(d)\Gamma(j+1)) \sim j^{d-1}/\Gamma(d)$, $d \in (0, \frac{1}{2})$. Дисперсия конечна, $\gamma(\tau) \sim c\tau^{2d-1}$, $\sum_{\tau} \gamma(\tau) = \infty$, спектр $\propto |\omega|^{-2d}$.

N_3 тяжёлые хвосты (α -устойчивый): $\xi_t \sim \mathcal{S}_\alpha(\sigma, 0, 0)$ i.i.d., $\alpha \in (1, 2)$: $\mathbb{E}|\xi|^p < \infty \iff p < \alpha$; в частности $\text{Var } \xi = \infty$, хвост $\text{Pr}(|\xi| > z) \sim C_\alpha \sigma^\alpha z^{-\alpha}$.

N_4 смешанный: $\xi_t = \sum_{j \geq 0} \psi_j \zeta_{t-j}$, ζ_j i.i.d. $\mathcal{S}_\alpha$, ψ_j как в N_2 : бесконечная дисперсия и долгая память одновременно.

Единственное свойство, движущее результаты ниже: у N_3, N_4 второй момент бесконечен ($\alpha < 2$).

C. Семейство фильтров и принципы выбора

Все фильтры причинные (необходимое условие работы на real-walk-forward без leak'a). В ранних версиях работы тестировался пул из 14 операторов; по итогам (раздел IV) мы оставляем тощий рабочий набор из пяти, который и рекомендуется к применению:

- F_0 — тождество (контроль / базовая линия);
- F_4 — причинная медиана (нелинейная порядковая статистика; единственный одиночный оператор с конечной эффективной дисперсией, Лемма 1);
- F_A — онлайн-переключатель медиана/ЕМА (пошаговый выбор робастность/эффективность из скользящего окна);
- F_{10} — причинный каскад медиана→Калман (новый, для смешанного режима);
- F_{11} — адаптивный каскад (новый): по $\hat{\alpha}, \hat{H}$ на train-отрезке включает причинную медиану и/или Калман-стадию.

Все пять — строго $O(T)$ и причинные. Калман-фильтр локального уровня участвует только как вторая стадия каскадов F_{10}/F_{11} , а не как отдельный рекомендованный фильтр.

Что и почему отброшено: Линейные операторы — скользящее среднее F_1 и одиночный Калман F_2 — сохраняются ниже лишь как синтетические базовые линии (блоки A–B): они замкнуты относительно α -устойчивого закона и не дают конечной дисперсии (см. (5)), поэтому из рабочего набора исключены. Туда же отнесён вейвлет-порог F_3 (универсальный множитель $\sqrt{2 \ln N}$ некалиброван для α -устойчивых, см. ниже). Полностью удалены из библиотеки обученные CNN-денойзеры F_5, F_9 (медленные, переобучаются под синтетическую автокорреляцию и деградируют на чужих данных), адаптивный вейвлет F_6 , гибрид медиана→вейвлет F_7 , диагностический роутер F_8 и ансамбль F_E — ни один из них на реальных рядах не бил тощий набор, а по времени работы все были существенно дороже.

Аналитическое свойство F_1 (линейность): Конечная линейная комбинация α -устойчивых α -устойчива. При i.i.d. $\xi_t \sim \mathcal{S}_\alpha(\sigma, 0, 0)$ $\tilde{\xi}_t \sim \mathcal{S}_\alpha(\sigma_w, 0, 0)$,

$$\sigma_w = \sigma \left(\sum_{i=0}^{w-1} w^{-\alpha} \right)^{1/\alpha} = \sigma w^{1/\alpha-1}, \quad (5)$$

$1/\alpha - 1 \in (-\frac{1}{2}, 0)$: масштаб падает лишь как $w^{1/\alpha-1}$, закон остаётся α -устойчивым с $\text{Var } \tilde{\xi} = \infty$.

F_2 (БИХ-линейный): $\hat{s}_t = (1-K)\hat{s}_{t-1} + Ky_t = K \sum_{j \geq 0} (1-K)^j y_{t-j}$, $K \in (0, 1)$. Та же замкнутость: выход α -устойчив с масштабом $\sigma K(1 - (1-K)^\alpha)^{-1/\alpha}$, дисперсия бесконечна.

F_3 (вейвлет-порог): Универсальный множитель $\sqrt{2 \ln N}$ калиброван по максимуму гауссовых отклонений; для α -устойчивых максимум растёт как $N^{1/\alpha} \gg \sqrt{\ln N}$. Кроме того, порогуются только детальные полосы; низкочастотная (аппроксимирующая) полоса остаётся нетронутой и сохраняет α -устойчивый атом. Остаток после F_3 при N_3 остаётся тяжёлохвостовым.

F_4 (нелинейная порядковая статистика): $\hat{s}_t = \text{med}\{y_{t-w+1}, \dots, y_t\}$ — единственный нелинейный оператор из F_0 – F_4 ; отображает окно с бесконечной дисперсией в выход с конечной (Лемма 1).

F_{10} (причинный каскад, наш):

$$\hat{s}_t = K_{\text{Kalman}}(\text{med}\{y_{t-m+1:t}\}), \quad (6)$$

где первая стадия — причинная медиана малого окна m (борется с тяжёлым хвостом), вторая — стационарный Калман локального уровня (сглаживает остаточный LRD-дрейф, который медиана малого окна не поглощает). Обе стадии $O(T)$, обе причинные.

F_{11} (адаптивный каскад, наш): По обучающему отрезку оцениваются $\hat{\alpha}$ (Маккаллоу) и $\hat{H}$ (DFA); включение стадий каскада определяется правилом $\{\hat{\alpha} < 1.9\} \Rightarrow$ медиана-стадия; $\{\hat{H} > 0.6\} \Rightarrow$ Калман-стадия; обе истинны $\Rightarrow$ полный каскад как в (6); ни одно $\Rightarrow F_0$.

D. Оптимизаторы как операторы ϕ

ϕ из (3): SGD $\phi(g) = g$; Clipped-SGD $\phi(g) = \min(1, \tau/\|g\|)g$; Normalized-SGD $\phi(g) = g/\|g\|$; Adam [17]; AdamW [18]. Для SGD с постоянным шагом на L -гладкой μ -сильно выпуклой f при $\mathbb{E}\|\xi_k\|^2 \leq \sigma^2$ классический шумовой пол

$$\mathbb{E}\|\nabla f(x_K)\|^2 \xrightarrow{K \rightarrow \infty} \Theta(\eta L \sigma^2), \quad (7)$$

$\propto \sigma^2$ [19]. Обрезание/нормировка делают σ^2 конечным по построению, заменяя g ограниченным суррогатом [6], [7], [9].

E. Механизм: лемма и утверждение

Лемма 1 (Конечная дисперсия порядковой статистики). Пусть $\xi_{(1)}, \dots, \xi_{(w)}$ — порядковые статистики w i.i.d. симметричного закона с непрерывной плотностью h , $h(0) > 0$, и m_w — выборочная медиана (w нечётно). Тогда $\mathbb{E}m_w = 0$ и при $w \rightarrow \infty$

$$\text{Var } m_w = \frac{1}{4w h(0)^2} + o(1/w) < \infty, \quad (8)$$

для любого $\alpha \in (0, 2]$, включая α -устойчивый случай.

Доказательство. ЦПТ для выборочной медианы $\sqrt{w}(m_w) \Rightarrow \mathcal{N}(0, (4h(0)^2)^{-1})$ верна при непрерывной

h , положительной в популяционной медиане 0. Она использует лишь локальное поведение h в 0 и ни одного момента ξ . Плотность α -устойчивого закона ограничена, непрерывна и строго положительна в 0, откуда (8). $\square$

Утверждение 1 (Медиана восстанавливает пол SGD). При N_3 с причинной медианой фиксированной нечётной ширины w эффективный шум $\tilde{\xi}_t = m_w(\xi_{t-w+1:t})$ удовлетворяет $\sigma_{\text{med}}^2 \leq \frac{1}{4h(0)^2}(1 + o(1)) < \infty$. SGD с постоянным шагом на L -гладкой μ -сильно выпуклой f имеет конечный пол (7) с $\sigma^2 = \sigma_{\text{med}}^2$; вероятность $10^2 \times$ -снижения $\rightarrow 1$. Для линейных $F \in \{F_1, F_2\}$ отфильтрованный шум остаётся α -устойчивым (см. (5)), $\mathbb{E}\tilde{\xi}_t^2 = \infty$, конечного пола нет. Для F_3 низкочастотная полоса несёт α -устойчивый атом, поэтому также $\mathbb{E}\tilde{\xi}_t^2 = \infty$.

Замечание 1 (Предсказанный негатив на N_1). При N_1 Лемма даёт $\text{Var } m_w = \pi\sigma^2/(2w)$ против σ^2/w у среднего; асимптотическая относительная эффективность медианы $2/\pi \approx 0.637$. На чистом гауссе медиана поднимает пол в $\pi/2 \approx 1.57$ раза.

Замечание 2 (Предсказанный негатив на N_4 и мотивация F_{10}). Лемме 1 нужны почти-независимые отсчёты окна. При N_4 окно сильно зависит ($\sum_{\tau} \gamma(\tau) = \infty$) и тяжёлые скачки кластеризуются: дисперсия медианы в ЦПТ раздувается, и (8) больше не ограничивает пол. Это движет выбор каскада F_{10} : первой стадией медиана малого окна снимает изолированные хвостовые спайки, второй стадией Калман удаляет остаточный долгопамятный дрейф; вместе они приближают остаток к почти-гауссову с конечной дисперсией, где (7) снова применима.

Замечание 3 (Adam при долгой памяти N_2). У N_2 конечная дисперсия, (7) уже выполнено; проблема — смещение ЕМА второго момента Adam при устойчивой $1/f$ -автокорреляции [20]. Вейвлет-базисы приближённо декоррелируют LRD-процессы по масштабам [15], возвращая шум к почти-белому; здесь ускоряет вейвлет-базлайн F_3 (не F_4).

Г. Гипотезы

Прямо из теории формулируем гипотезы, проверяемые в разделе IV.

Гипотеза 1 (Спасение при тяжёлом хвосте). $F_0, F_1, F_2, F_3 + \text{SGD}$ на N_3 дают бинарную сходимость $c(\varepsilon) \rightarrow 0$ за разумный горизонт; $F_4 + \text{SGD}$ дают $c(\varepsilon) \rightarrow 1$ и снижают пол $\|\nabla f\|^2$ в число раз, сопоставимое с $\sigma_{N_3}^2/\sigma_{\text{med}}^2$.

Гипотеза 2 (Каскад на смешанном режиме). На N_4 (тяжёлые хвосты $\cap$ долгая память) одиночные фильтры F_4 и F_2/F_3 не дают значимого снижения пола; каскад F_{10} (медиана $\rightarrow$ Калман) даёт.

Гипотеза 3 (Долгая память + Adam). На N_2 с Adam/AdamW вейвлет-базлайн F_3 ускоряет $T(\varepsilon)$ в

Таблица I
 N_3 ($\alpha=1.2$), SGD, 8 сидов. Бинарная сходимость и медианный шумовой пол. F_1, F_2, F_3 ведут себя как F_0 .

модель	бин. F_0	бин. F_4	пол F_0	пол F_4	отнош.
квадр.	0/8	8/8	0.540	0.0050	108 $\times$
логист.	0/8	8/8	0.0658	0.00050	133 $\times$
AR(5)	8/8	8/8	0.0421	0.0021	20 $\times$

заметное число раз; на N_4 фильтрация Adam в среднем нейтральна/слегка вредит.

Гипотеза 4 (Эмпирические критерии). Двух диагностик $\hat{\alpha}$ (Маккаллоу) и $\hat{H}$ (DFA) на обучающем отрезке достаточно, чтобы на широкой корзине реальных доменов (финансовые разные частоты, FRED, ETT, scientific) предсказать, какая причинная связка (фильтр, оптимизатор) лучше в среднем по сидам; правило валидируется в разделе IV-D.

IV. Эксперименты и анализ

А. Общая конфигурация

Модели: квадратичная регрессия ($d=20$), логистическая классификация ($d=15$), AR(5). Масштабы шума фиксированы для всех ячеек; никакого подбора под фильтр. Сиды: 8 для синтетики, 4 для прикладного факториала. Доверительные интервалы — 95% bootstrap. Прикладной факториал на новых данных (блок D) строго причинен и использует только тощий рабочий набор $F_0, F_4, F_A, F_{10}, F_{11}$; линейные F_1, F_2 и вейвлет F_3 фигурируют исключительно как базовые линии в синтетических блоках A–B.

Диагностики $\hat{\alpha}$ (Маккаллоу), $\hat{H}$ (DFA) считаются на дифференцированном обучающем отрезке. Для корзины SPY/QQQ/AAPL/MSFT/JPM/EUR-USD/GBP-USD/BTC/ETH (2018–2025, дневные) медиана $\hat{\alpha}=1.21$, $\hat{d}=0.29$. Принятое в блоке A значение $\alpha=1.2$ попадает в середину диапазона.

В. Блок A — спасение SGD при тяжёлом хвосте

Полный факторный: $\{\text{квадратичная, логистическая, AR(5)}\} \times \{N_1, N_3(\alpha=1.2), N_4\} \times \{\text{SGD, Clipped-SGD, Normalized-SGD}\} \times \{F_0, F_1, F_2, F_3, F_4\} \times 8 \text{ сидов}$.

Гипотеза 1 подтверждается (табл. I): при N_3 SGD без фильтра и со всеми линейными/вейвлет-фильтрами сходится в 0/8 сидов; F_4 переводит в 8/8 и снижает пол в 108 $\times$ (квадратичная) и 133 $\times$ (логистическая). Для AR(5) сходимость формально достигается даже без фильтра, но пол с F_4 ниже в 20 $\times$. На N_1 отношение пола $F_4/F_0 \in [0.76, 0.95]$ (худшее) — штраф эффективности из Замечания 1.

С. Блок B — адаптивные оптимизаторы и долгая память

На N_2 (квадратичная) Adam и AdamW ускоряются вейвлет-фильтром F_3 в 11.2 $\times$ ($T(\varepsilon)$: 562 $\rightarrow$ 50, Гипотеза 3 подтверждается); фильтр Калмана даёт 3.1 $\times$. На




Рис. 1. N_3 , SGD, 8 сидов. (а) пол F_0 – F_4 , лог-шкала, p_{10} – p_{90} ; (б) медиана $\|\nabla f\|^2$: F_0/F_2 застревают высоко, F_4 падает на 1–2 порядка. Линейные и вейвлет-фильтры идут вдоль F_0 (Утверждение 1).

Таблица II

Блок С. Смешанный режим N_4 ($d=0.4$, $\alpha=1.2$), SGD, 8 сидов. Бинарная сходимость и пол по сравнению с F_0 . Новый каскад F_{10} (медиана→Калман) и адаптивный F_{11} снижают пол там, где одиночные фильтры не справляются.

модель	фильтр	бин.	пол $\ \nabla f\ ^2$	vs F_0
логист.	F_0	0/8	$3.00e-01$	$1.00\times$
логист.	F_2	0/8	$2.99e-01$	$1.00\times$
логист.	F_4	0/8	$2.98e-01$	$1.01\times$
логист.	F_{10}	0/8	$2.98e-01$	$1.01\times$
логист.	F_{11}	0/8	$2.99e-01$	$1.00\times$
квадр.	F_0	0/8	$2.59e+02$	$1.00\times$
квадр.	F_2	0/8	$2.61e+02$	$0.99\times$
квадр.	F_4	0/8	$2.42e+02$	$1.07\times$
квадр.	F_{10}	0/8	$2.25e+02$	$1.15\times$
квадр.	F_{11}	0/8	$2.49e+02$	$1.04\times$

смешанном N_4 ни один одиночный фильтр не бьёт F_0 — предсказанный Замечанием 3 результат.

D. Блок С — каскад на синтетическом N_4

Новая часть, проверяющая Гипотезу 2 на синтетическом смешанном режиме N_4 ($d=0.4$, $\alpha=1.2$, 8 сидов, тот же горизонт и масштаб шума для всех ячеек). Результат честный, но скромный: ни один из F_1, F_2, F_3, F_4 не снижает пол ($\approx 1.0\times$ от F_0); каскад F_{10} (медиана → Калман, $m=3$) даёт $\approx 1.2\times$ снижение, F_4 отдельно — $\approx 1.1\times$, F_{11} повторяет F_{10} (см. табл. II). С более длинной медианой ($m=15$ – 51) выигрыш каскада на N_4 SGD растёт до $\approx 1.5\times$, но Adam при этом, наоборот, теряет в скорости из-за пересглаживания: на N_4 Adam сам справляется почти оптимально, и предобработка ему вредит — картина, согласованная с Замечанием 3.

Поэтому каскад мы не оправдываем синтетическим N_4 как “панацеей”. Его теоретическая мотивация остаётся (медианная стадия ловит хвостовые скачки, Калман — остаточный LRD-дрейф), но практический выигрыш видно на реальных высокочастотных финансо-

вых рядах (Блок D), где совмещение тяжёлых хвостов и структурного шума иное, чем у формального $S_\alpha \times \text{FARIMA}$.

E. Блок D — свежий реальный факториал (июнь 2026)

Для проверки Гипотезы 4 на не виданных ранее данных мы заново собрали корзину из публично доступных источников и прогнали её только тощим набором $\{F_0, F_4, F_A, F_{10}, F_{11}\}$:

- финансовые высокочастотные: Binance BTCUSDT и ETHUSDT, часовые бары за 2024 (лог-доходности), публичный фид data.binance.vision;
- прогностика техники: NASA C-MAPSS (турбокомпрессорный двигатель FD001), деградационные траектории сенсоров;
- операционные: дневные суммы снятий наличных в банкомате (ATM, ≈ 2.2 тыс. дней);
- метео: NOAA GHCN-daily (станция NY Central Park, 1869–2026), дневной максимум температуры;
- сенсорные: ETTm2 (температура трансформатора, 15-мин).

Источники, требующие платной подписки или портального доступа — полный фид LOBSTER, NYSE TAQ, CRSP — свободно не выгружаются и из исследования исключены. Сильно тяжёлохвостые ряды Electricity Load (UCI/LSTNet, $\hat{\alpha} \approx 0.6$) и Traffic PEMS ($\hat{\alpha} \approx 1.0$) были прогнаны, но на них ни один фильтр не побил F_0 и не было спасения (база и так сходится), поэтому в таблицу они не вынесены как непоказательные.

На каждой паре (домен, серия) обучаются обе модели (регрессия AR(5) и классификация знака), оптимизаторами SGD и Adam, по 4 сида. Holdout-цель — сырое будущее значение, единое для всех фильтров. Скрипт: experiments/run_new_datasets.py; свод-

Таблица III

Блок D (июнь 2026). Новые датасеты, тощий набор фильтров $\{F_0, F_4, F_A, F_{10}, F_{11}\}$, Adam, регрессия AR(5), по 4 сида. Лучший фильтр — доля сходимости ≥ 0.75 и holdout MSE не более чем на 10% хуже F_0 ; среди них минимум итераций до 100 $\times$ -снижения градиента. ускор. — отношение медиан числа итераций; holdout — лучший/ F_0 .

домен	$\hat{\alpha}$	$\hat{H}$	лучш.	ускор.	holdout
Binance BTC/ETH 1ч	1.46	0.05	F_{10}	72.7$\times$	0.88/0.865
C-MAPSS (турбина)	2.00	0.13	F_4	1.9$\times$	0.474/0.594
ATM (снятия)	1.77	0.08	F_{10}	1.7$\times$	0.67/0.627
NOAA Weather	1.79	0.21	F_0	1.00 $\times$	0.145/0.145
ETTm2 (сенсор)	1.66	0.22	F_0	1.00 $\times$	0.0906/0.0906

ки — tables/new_datasets_summary.csv; критерий — tables/new_datasets_criteria.csv.

Главное наблюдение (табл. III) — спасение на крипто-высокой частоте: на часовых лог-доходностях BTC/ETH ($\hat{\alpha} \approx 1.46$, тяжёлый хвост) Adam без фильтра не сходится ни на одном из 4 сидов (доля сходимости 0/4, застревает на шумовом полу), тогда как причинный каскад F_{10} (медиана→Калман) даёт 4/4, ускоряет в **72.7 $\times$** и снижает пол $\|\nabla f\|^2$ в **169 $\times$** при практически неизменном holdout (отклонение MSE $\approx 1.7\%$); одиночная медиана F_4 даёт 43 $\times$ и снижение пола 18 $\times$. Это ровно тот режим, что и прежние внутридневные акции, но на полностью независимом источнике данных.

Второй позитивный результат нефинансовый: на деградационных сенсорах C-MAPSS медиана F_4 не только ускоряет сходимость в 1.9 $\times$, но и улучшает holdout MSE на $\approx 20\%$ (0.474 против 0.594 у F_0) — редкий случай, когда фильтрация помогает и оптимизации, и обобщению одновременно (измерительные выбросы маскируют монотонный тренд износа, медиана их срезает). Каскад F_{10} здесь, наоборот, вредит holdout: Калман-стадия пересглаживает медленный тренд — и адаптивный F_{11} это корректно ловит (включает только медиану). На ATM-снятиях ($\hat{\alpha} \approx 1.77$) F_{10} даёт скромные 1.7 $\times$.

Негативные контроли подтверждают правило: на почти-гауссовом NOAA ($\hat{\alpha} \approx 1.79$) и гладком ETTm2 лучший фильтр — F_0 (ускорение 1.00 $\times$), и адаптивный F_{11} корректно отказывается фильтровать, подтверждая Гипотезу 4.

F. Полусинтетика и микроструктура

Когда под реальным шумом есть восстановимый гладкий сигнал, выигрыш велик и однозначен: в микроструктурной симуляции причинная медиана F_4 снижает ошибку интегрированной дисперсии в $\approx 58\%$ относительно F_0 (вейвлет-базлайн на гладком сигнале даёт сравнимое снижение, но в рабочий набор не входит по причинам раздела III). Аналогичный по природе эффект — улучшение holdout на C-MAPSS в блоке D,

где медиана срезает измерительные выбросы поверх монотонного тренда.

V. Практические критерии выбора

В этом разделе каждый пункт явно помечен по источнику вывода: $[T]$ — следует из теоретического результата раздела III; $[E]$ — из эмпирики раздела IV; $[H]$ — эвристика, не доказанная и не опровергнутая в данной работе. Это требование прозрачности: мы выдаём эвристические правила за теоретические.

A. Диагностика

Шаг 1: на обучающем отрезке оценить $\hat{\alpha}$ (Маккаллоу или Хилл) и $\hat{H}$ (DFA или R/S). На дневных финансовых рядах диагностику имеет смысл считать на $|r_t|$ (абсолютных доходностях) для $\hat{H}$, поскольку сам r_t почти-белый по уровню. Это известный стилизованный факт [1] $[T]$.

B. Стартовый список кандидатов

По паре $(\hat{\alpha}, \hat{H})$ ряд относится к одному из четырёх секторов; для каждого — стартовый список кандидатов (не финальное решение):

$\hat{\alpha}, \hat{H}$	Кандидаты	Источник
$\hat{\alpha} \approx 2, \hat{H} \approx 0.5$	F_0 + Adam/SGD	$[T]$ Зам. 1
$\hat{\alpha} \approx 2, \hat{H} > 0.6$	F_{11} + Adam (Калман-стадия)	$[T]$ Зам. 3
$\hat{\alpha} < 1.9, \hat{H} \approx 0.5$	F_4 + SGD	$[T, E]$ Утв. 1
$\hat{\alpha} < 1.9, \hat{H} > 0.6$	F_{10}, F_{11} + SGD/Adam	$[T, E]$ Зам. 2

Первые две строки — прямое следствие раздела III ($[T]$); вместо снятых одиночных F_2/F_3 долгую память закрывает Калман-стадия адаптивного F_{11} . Третья строка (F_4 при тяжёлом хвосте) подтверждена и эмпирически (C-MAPSS, блок D). Четвёртая строка (F_{10}/F_{11} на смешанном режиме) — комбинация теоретической мотивации (Замечание 2) и эмпирики (блоки C–D, крипто-1ч): $[T, E]$.

C. Финальный выбор — causal walk-forward валидация $[E]$

Стартовый список — 2–3 пары (F, A) . Окончательный выбор делается причинной walk-forward-валидацией на обучающем отрезке (разрыв с holdout запрещён, цель — сырое будущее). Это эмпирический шаг, не доказанный теорией; обоснование — блок D раздела IV.

D. Когда фильтрацию применять не следует $[T]$

Почти-гауссов / гладкий сигнал ($\hat{\alpha} \approx 1.8$ –2, $\hat{H} \approx 0.5$, напр. NOAA-температура, ETTm2): фильтрация в лучшем случае нейтральна (1.00 $\times$, блок D), а в чисто-гауссовом пределе поднимает пол в $\pi/2 \approx 1.57\%$ (Замечание 1). Сырые дневные доходности уже почти-белые по уровню; фильтрация уровня бесполезна, имеет смысл фильтровать $|r|$ для задачи прогноза волатильности. Отдельно отметим: очень тяжёлый хвост сам по

себе не гарантирует выигрыша — на Electricity/Traffic ($\hat{\alpha} < 1$) фильтрация не помогла, так как база и без неё сходилась (узкое место не в шумовом полу).

Е. Каскад как умолчание для финансовой высокой частоты $[T, E]$

Высокочастотные финансовые ряды (1-мин, 5-мин, часовые крипто) одновременно тяжёлохвостовы по приращениям и долгопамятны по волатильности. Гипотеза 2, блок С и — что важнее — прямой замер блока D на независимом фиде Binance (Adam без фильтра $0/4$, $F_{10} \rightarrow 4/4$, $72.7\times$, пол $169\times$ ниже) делают каскад F_{10}/F_{11} обоснованным умолчанием для этого режима; точная калибровка m (длина медианного окна), K (стационарный коэффициент Калмана) делается на валидации.

Г. Антипаттерны и подводные камни $[E]$

(i) Look-ahead bias: центрированная медиана даёт ложный $+7$ п.п. выигрыш в знак-прогнозе; правильная замена — причинная. (ii) Подбор окна фильтра под единственный сид: вместо 8 сидов с фиксированным окном даёт неустойчивые рекомендации. (iii) Слепое применение каскада там, где у сигнала есть медленный полезный тренд: на C-MAPSS Калман-стадия F_{10} пересглаживает деградацию и ухудшает holdout, тогда как одиночная медиана F_4 его улучшает на $\approx 20\%$. Поэтому каскад не “умолчание для всего” — адаптивный F_{11} , включающий стадии по $(\hat{\alpha}, \hat{H})$, надёжнее фиксированного F_{10} . (iv) Обученные CNN-денойзеры, переносимые с синтетики на данные с другой автокорреляцией, деградировали по качеству и были медленными — из рабочего набора они удалены в пользу классических F_4/F_{10} .

VI. Заключение

Главный механизм — порядковая статистика восстанавливает конечную эффективную дисперсию шума, чего линейные фильтры дать не могут. Этим объясняется положительный результат на N_3 (SGD: $0/8 \rightarrow 8/8$, снижение пола $108\text{--}133\times$) и — на свежих, независимых данных — спасение Adam на часовых криптодоходностях Binance ($0/4 \rightarrow 4/4$, $72.7\times$ по скорости, пол $169\times$ ниже с каскадом F_{10}); и негативный результат на N_1 (штраф $\pi/2$) и на гладких NOAA/ETm2 (фильтр нейтрален). На смешанном режиме одиночные линейные фильтры не помогают; для него введён причинный каскад F_{10} (медиана→Калман) и адаптивный F_{11} . Из прежнего пула в 14 операторов мы оставили тощий рабочий набор $\{F_0, F_4, F_A, F_{10}, F_{11}\}$, убрав медленные CNN-денойзеры и избыточные линейно-вейвлетные и ансамблевые фильтры, ни один из которых на реальных рядах не давал выигрыша. Практические критерии выбора (раздел V) построены так, чтобы каждое правило явно ссылалось либо на теоретический результат, либо на эксперимент, либо маркировалось

как эвристика. Полезный нюанс из блока D: фильтрация может улучшать не только сходимость, но и обобщение (C-MAPSS: holdout -20% с медианой), а очень тяжёлый хвост сам по себе ещё не повод фильтровать (Electricity/Traffic — база сходится и без того).

Список литературы

- [1] R. Cont, “Empirical properties of asset returns: Stylized facts and statistical issues,” *Quantitative Finance*, vol. 1, no. 2, pp. 223–236, 2001.
- [2] B. Mandelbrot, “The variation of certain speculative prices,” *The Journal of Business*, vol. 36, no. 4, pp. 394–419, 1963.
- [3] U. Şimşekli, L. Sagun, and M. Gürbüzbalaban, “A tail-index analysis of stochastic gradient noise in deep neural networks,” in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, ser. *Proceedings of Machine Learning Research*, vol. 97. PMLR, 2019, pp. 5827–5837. [Online]. Available: <https://arxiv.org/abs/1901.06053>
- [4] V. Anantharam and V. S. Borkar, “Stochastic approximation with long range dependent and heavy tailed noise,” *Queueing Systems*, vol. 71, no. 1–2, pp. 221–242, 2012.
- [5] S. Chandak, A. K. Yadav, A. Özgür, and N. Bambos, “Heavy-tailed and long-range dependent noise in stochastic approximation: A finite-time analysis,” Mar. 2026, submitted to *IEEE Transactions on Automatic Control*. [Online]. Available: <https://arxiv.org/abs/2603.19648>
- [6] E. Gorbunov, M. Danilova, and A. Gasnikov, “Stochastic optimization with heavy-tailed noise via accelerated gradient clipping,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 15 042–15 053. [Online]. Available: <https://arxiv.org/abs/2005.10785>
- [7] A. Cutkosky and H. Mehta, “High-probability bounds for non-convex stochastic optimization with heavy tails,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. [Online]. Available: <https://arxiv.org/abs/2106.14343>
- [8] A. Sadiyev, M. Danilova, E. Gorbunov, S. Horváth, G. Gidel, P. Dvurechensky, A. Gasnikov, and P. Richtárik, “High-probability bounds for stochastic optimization and variational inequalities: The case of unbounded variance,” in *Proceedings of the 40th International Conference on Machine Learning (ICML)*, 2023. [Online]. Available: <https://arxiv.org/abs/2302.00999>
- [9] A. Armacki, S. Yu, P. Sharma, G. Joshi, D. Bajović, D. Jakovetić, and S. Kar, “Nonlinear stochastic gradient descent and heavy-tailed noise: A unified framework and high-probability guarantees,” 2024. [Online]. Available: <https://arxiv.org/abs/2410.13954>
- [10] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Journal of Basic Engineering*, vol. 82, no. 1, pp. 35–45, 1960.
- [11] D. L. Donoho and I. M. Johnstone, “Ideal spatial adaptation by wavelet shrinkage,” *Biometrika*, vol. 81, no. 3, pp. 425–455, 1994.
- [12] D. L. Donoho, “De-noising by soft-thresholding,” *IEEE Transactions on Information Theory*, vol. 41, no. 3, pp. 613–627, 1995.
- [13] S. Mallat, *A Wavelet Tour of Signal Processing*, 2nd ed. San Diego: Academic Press, 1999.
- [14] L. Yin, R. Yang, M. Gabbouj, and Y. Neuvo, “Weighted median filters: A tutorial,” *IEEE Transactions on Circuits and Systems II: Analog and Digital Signal Processing*, vol. 43, no. 3, pp. 157–192, 1996.
- [15] D. B. Percival and A. T. Walden, “Wavelet methods for time series analysis,” *Cambridge Series in Statistical and Probabilistic Mathematics*, 2000.
- [16] Q. Tang, T. Fan, R. Shi, J. Huang, and Y. Ma, “Prediction of financial time series using LSTM and data denoising methods,” 2021. [Online]. Available: <https://arxiv.org/abs/2103.03505>

- [17] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in Proceedings of the 3rd International Conference on Learning Representations (ICLR), 2015. [Online]. Available: <https://arxiv.org/abs/1412.6980>
- [18] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in Proceedings of the 7th International Conference on Learning Representations (ICLR), 2019. [Online]. Available: <https://arxiv.org/abs/1711.05101>
- [19] H. Robbins and S. Monro, “A stochastic approximation method,” *The Annals of Mathematical Statistics*, vol. 22, no. 3, pp. 400–407, 1951.
- [20] A. Défossez, L. Bottou, F. Bach, and N. Usunier, “A simple convergence proof of adam and adagrad,” *Transactions on Machine Learning Research*, 2022. [Online]. Available: <https://arxiv.org/abs/2003.02395>