

Шумоподавление наблюдаемого ряда как предобработка

стохастической оптимизации

когда фильтрация спасает сходимость при тяжёлохвостовом градиентном шуме

Д. КОРТУНОВ В. ПАСТУШЕНКО А. ДУБОВИЦКИЙ А. ШАДРИН *НИУ ВШЭ*

Задача

Наблюдаемый скалярный ряд — сигнал плюс шум:

$$y_t = s_t + \xi_t, \qquad t = 1, \dots, T.$$

Из ряда строятся пары (лаговое окно $\rightarrow$ следующее значение); обучается модель g_x минимизацией риска $f(x) = \frac{1}{n} \sum_i \ell(g_x(u_i), v_i)$ методом первого порядка

$$g_k = \nabla f(x_k) + \xi_k, \qquad x_{k+1} = x_k - \eta_k \phi(g_k).$$

На финансовых рядах шум **тяжёлохвостый** (α -устойчивый, $\alpha < 2$, бесконечная дисперсия) и **долгопамятный**. Тогда у SGD с постоянным шагом $\mathbb{E}\|\nabla f\|^2$ *не стремится к нулю*.

Вопрос. Для каких троек (шум, фильтр, оптимизатор) предобработка превращает несходящийся прогон в сходящийся — и почему?

Фильтр как этап конвейера

Фильтр $F: \mathbb{R}^T \rightarrow \mathbb{R}^T$, $\hat{s} = F(y)$, применяется *до* формирования признаков — оптимизатор видит сглаженный ряд. Сплошной причинный набор F_0 – F_7 :

F_0	тождество $\hat{s}_t = y_t$
F_1	скользящее среднее (лин.)
F_2	Калман лок. уровня (лин.)
F_3	вейвлет-порог (не прич.)
F_4	причинная медиана
F_5	каскад медиана→Калман
F_6	адаптивный каскад
F_7	онлайн медиана/ЕМА

Механизм

Лемма. Выборочная медиана окна из w i.i.d. симметричных величин имеет

$$\mathrm{Var}\, m_w = \frac{1}{4w\,h(0)^2} + o(1/w) < \infty$$

для *любого* $\alpha \in (0, 2]$. Медиана отображает окно с бесконечной дисперсией в выход с **конечной** — это и есть спасение SGD.

Линейные фильтры не помогают: F_1, F_2 замкнуты относительно α -устойчивого закона,

$$\bar{\xi}_t \sim \mathcal{S}_\alpha(\sigma\, w^{1/\alpha-1}, 0, 0), \quad \mathrm{Var}\, \bar{\xi} = \infty.$$

Смешанный режим (тяжёлый хвост $\cap$ долгая память): одиночной медианы мало. Каскад

$$\hat{s}_t = \mathrm{Kalman}\big(\mathrm{med}\{y_{t-m+1}, \dots, y_t\}\big)$$

— медиана снимает хвостовые скачки, Калман убирает остаточный дрейф. Адаптивный F_6 включает стадии по диагностикам $(\hat{\alpha}, \hat{H})$.


Эксперимент

Синтетика (α =1.2, SGD, 8 сидов): без фильтра и с линейными — 0/8; причинная медиана F_4 — **8/8**, уровень $\|\nabla f\|^2$ ниже в 108–133×.

Реальные данные: широкая корзина из **17** публичных доменов — крипто Binance (1ч), акции (дн./15м/5м), волатильность $|r|$, FRED,

ETTh1/h2/m1/m2, Electricity, Traffic, NOAA, C-MAPSS, ATM, sunspots. Для каждого ряда считаются $\hat{\alpha}$ (Маккаллок) и $\hat{H}$ (DFA); связка (фильтр, оптимизатор) сравнивается с F_0 по числу итераций до сходимости и по holdout на *сыром* будущем.

Результаты: карта домен × фильтр



Ускорение сходимости Adam относительно F_0 (Adam, пергрессия AR(5)). Выигрыш **сосредоточен на тяжёлохвостовых доходностях** (левый блок): Калман F_2 ускоряет до **80×**, каскад F_5 — **64×**. На головном домене (крипто 1ч) F_0 сходится лишь в 3/8 прогонов, F_2 и F_5 — во всех 8/8. На светлохвостовых/гладких рядах (FRED, ETT, NOAA, sunspots) все фильтры $\approx 1\times$ — фильтровать не нужно.

Правило выбора $(\hat{\alpha}, \hat{H}) \rightarrow$ фильтр

сектор $(\hat{\alpha}, \hat{H})$	фильтр	доменов	макс.
$\hat{\alpha}\approx 2, \hat{H}\approx 0.5$	F_0	—	1×
$\hat{\alpha}\approx 2, \hat{H}>0.6$	F_1	1/2	1.9×
$\hat{\alpha}<1.9, \hat{H}\approx 0.5$	F_2	5/10	80×
$\hat{\alpha}<1.9, \hat{H}>0.6$	F_5, F_6	1/3	1.6×

По двум диагностикам на обучающем отрезке выбирается стартовая связка; финальный выбор — причинной walk-forward валидацией.

Выводы

- Нелинейная порядковая статистика (медиана) восстанавливает **конечную** эффективную дисперсию шума — чего линейные фильтры дать не могут.
- Каскад F_5 и адаптивный F_6 закрывают смешанный режим “тяжёлый хвост $\cap$ долгая память”.
- Тяжёлый хвост сам по себе *не* повод фильтровать: если узкое место не в сходимости, лучший выбор — F_0 .
- Правило по $(\hat{\alpha}, \hat{H})$ предсказывает связку (фильтр, оптимизатор) на широкой корзине реальных доменов.

Код и данные: github.com/Poogee/momo_proj