

Beyond Gaussian Noise: сходимость стохастических оптимизаторов при коррелированном и тяжёлохвостовом финансовом градиентном шуме

Project Proposal · НИУ ВШЭ · 26 апреля 2026 г.

Кортунов Д., Пастушенко В., Дубовицкий А., Шадрин А.

Аннотация. Большая часть теории сходимости стохастических методов оптимизации опирается на то, что градиентный шум имеет конечную дисперсию и независим по итерациям. На финансовых данных это очевидно не так: доходности активов давно известны как тяжёлохвостовые и с долгой памятью, и градиенты, посчитанные на таких данных, наследуют эти свойства. Мы хотим разобраться, насколько это на самом деле мешает обучению. Подмешиваем к градиенту шум разных типов (от обычного гауссова до смеси α -устойчивого с долгой памятью) и смотрим, как с этим справляются SGD, Adam, Clipped-SGD и Normalized-SGD на синтетике и на реальных финансовых рядах. Параллельно оцениваем индекс хвоста и показатель Хёрста у самих градиентов во время обучения, чтобы понять, действительно ли реальный шум попадает в наши модельные режимы.

1. О чём проект

В обучении нейросетей по умолчанию используют Adam, и теоретические гарантии для него обычно предполагают, что шум градиента ограничен по дисперсии и независим. На финансовых данных оба предположения ломаются. Хочется понять, что в этом случае происходит на практике.

Идея простая: фиксируем четыре оптимизатора, фиксируем четыре параметрических класса градиентного шума и смотрим, как меняются кривые сходимости. Часть экспериментов делаем на синтетических задачах (квадратичная и логистическая регрессия), куда шум подмешиваем сами, часть — на реальных финансовых временных рядах, где собираем полученный градиент и оцениваем его статистики. Дальше сопоставляем наблюдаемое поведение с тем, что говорит теория для каждого из четырёх методов.

2. Постановка

Минимизируем L -гладкую (в общем случае невыпуклую) функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$. На итерации k алгоритм получает стохастический градиент

$$g_k = \nabla f(x_k) + \xi_k,$$

где ξ_k — центрированный шум. В отличие от стандартного сеттинга мы не накладываем ни ограниченности $\mathbb{E}\|\xi_k\|^2$, ни независимости ξ_k от прошлых итераций.

Для ξ_k рассматриваем четыре класса. Первый — белый гауссов $\xi_k \sim \mathcal{N}(0, \sigma^2 I)$ как контроль. Второй — розовый ($1/f$) шум: $\xi_k = \sum_{j \geq 0} \psi_j \eta_{k-j}$ с гауссовыми η_j и коэффициентами FARIMA(0, d , 0), $d \in (0, 1/2)$; спектральная плотность ведёт себя как f^{-2d} , есть долгая память, дисперсия конечна. Третий — тяжёлохвостовой: $\xi_k \sim S_\alpha(\sigma, 0, 0)$ покомпонентно, $\alpha \in (1, 2)$, конечен только p -й момент при $p < \alpha$. Четвёртый, самый интересный, — смешанный: $\xi_k = \sum_{j \geq 0} \psi_j \zeta_{k-j}$, где ζ_j уже не гауссовы, а α -устойчивые i.i.d., а ψ_j по-прежнему задают $1/f$ -спектр. Это режим, в котором тяжёлые хвосты и долговременная зависимость присутствуют одновременно.

Сравниваем стандартные оптимизаторы с обновлением $x_{k+1} = x_k - \eta_k \varphi(g_k)$:

— SGD: $\varphi(g) = g$;

- Adam [1]: $\varphi(g_k) = m_k / (\sqrt{v_k} + \varepsilon)$;
- Clipped-SGD: $\varphi(g) = \min(1, \tau/\|g\|)g$;
- Normalized-SGD with momentum [2]: $\varphi(g_k) = m_k / \|m_k\|$;
- и другие (см. §«Обзор литературы»).

Главная величина — эмпирическая $T(\varepsilon; A, \mathcal{N}) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\}$, сколько итераций нужно методу A при шуме $\mathcal{N}$, чтобы дойти до малого градиента.

3. Метрики

Что считаем по результатам экспериментов:

- кривая сходимости $\mathbb{E}\|\nabla f(x_k)\|^2$ от номера итерации (медиана и 90-й перцентиль по нескольким десяткам запусков), чтобы видеть и типичное поведение, и разброс;
- итоговое качество модели на отложенной выборке для реальных задач;
- индекс хвоста и показатель Хёрста собранного во время обучения градиентного шума: на синтетике это проверка, что генератор работает; на реальных данных это сам по себе результат.

Возможен и отрицательный исход — например, окажется, что на тестовых финансовых задачах все четыре метода ведут себя примерно одинаково. Это тоже нормальный результат, и тогда содержательной частью становится сама диагностика градиента и обоснование, почему теоретические различия не проявились.

4. Обзор литературы

Литературу удобно разбить на несколько групп.

Тяжёлохвостовой градиентный шум как явление. Şimşekli, Sagun, Gürbüzbalaban [3] эмпирически показали, что градиентный шум в нейросетях не гауссов, а α -устойчивый. Дальше Gürbüzbalaban, Şimşekli, Zhu [4] заметили, что даже при гауссовых данных стационарное распределение итераций SGD само получается тяжёлохвостовым, а Battash и Lindenbaum [5] добавили, что у разных параметров сети индексы хвоста могут заметно различаться. С этих работ начался интерес к тому, что классические условия на шум во многих практических задачах нарушаются. Ссылки: [arxiv 1901.06053](#), [2006.04740](#), [2303.02749](#).

Сходимость с обрезанием и нормировкой. Zhang, He, Sra и Jadbabaie [6] ввели условие (L_0, L_1) -гладкости и показали, что при нём обрезание градиента ускоряет обучение. Параллельная работа Zhang и др. [7] формализует наблюдение, что Adam эквивалентен покоординатному обрезанию. Главный для нас результат получили Gorbunov, Danilova и Gasnikov [8]: первые high-probability оценки для Clipped-SGD при ограниченном $(1 + \alpha)$ -моменте шума; в [9] эти оценки доведены до оптимальных. У клиппинга, впрочем, есть обратная сторона: Koloskova, Hendrikx, Stich [10] показали, что обрезание вносит неустраняемое смещение, и сходимость к точному оптимуму без дополнительных условий не гарантирована. Альтернатива — нормировка: Cutkosky и Mehta [2] для Normalized-SGD с моментумом, а Hübler, Fatkhullin, He [11] и Liu, Zhou [12] недавно показали, что нормированные методы достигают оптимальной скорости при тяжёлом шуме вообще без обрезания. Ссылки: [1905.11881](#), [1912.03194](#), [2005.10785](#), [2302.05437](#), [2305.01588](#), [2002.03305](#), [2410.13849](#), [2412.19529](#).

Adam и его сходимость. Оригинальная статья Kingma и Ba [1] не предполагала тяжёлых хвостов. Reddi, Kale и Kumar [13] показали, что Adam может расходиться даже на простой выпуклой задаче, и предложили AMSGrad. Чистое доказательство сходимости Adam (для ограниченных градиентов) есть у Défossez и др. [14] — это тот baseline, относительно которого мы будем смотреть на деградацию. Loshchilov и Hutter [15] уточнили, как правильно прикрывать к Adam регуляризацию весов (AdamW). Ссылки: [1412.6980](#), [1904.09237](#), [2003.02395](#), [1711.05101](#).

Другие способы бороться с шумом. Помимо обрезания и нормировки есть несколько отдельных линий. Методы уменьшения дисперсии (SVRG [16], SAG [17], SAGA [18]) периодически используют полный градиент или хранят историю прошлых градиентов как *control variate*; они отлично работают для конечных сумм, но в их анализе тоже стоит предположение конечной дисперсии, поэтому с *heavy-tailed* шумом они скорее всего работать не будут — это само по себе можно проверить. Усреднение траектории по Поляку и Юдицкому [19] и его современный вариант SWA [20] уменьшают разброс итераций задним числом. Lookahead [21] периодически интерполирует медленные веса к быстрым, что тоже работает как сглаживание. SAM [22] ищет плоские минимумы, что должно делать обучение устойчивее к шуму. На другом конце спектра — методы для больших батчей: линейное масштабирование шага у Goyal и др. [23] просто снижает дисперсию градиента увеличением батча. Lion [24] использует знак моментума и идеологически близок к Normalized-SGD. В распределённом сеттинге используют робастные агрегации (медиана, *trimmed mean*) — Yin и др. [25]; они напрямую мотивированы тяжёлыми хвостами и Byzantine-устойчивостью. Подробнее эти методы мы в основной части не разбираем, но они образуют тот контекст, в котором наш бенчмарк имеет смысл. Ссылки на оригиналы: [1309.2388](#), [1407.0202](#), [1803.05407](#), [1907.08610](#), [2010.01412](#), [1706.02677](#), [2302.06675](#), [1803.01498](#).

Финансовые данные и коррелированный шум. Каноническая работа Cont [26] перечисляет одиннадцать «стилизированных фактов» финансовых доходностей, среди которых тяжёлые хвосты, кластеризация волатильности и долгая память абсолютных доходностей. Mandelbrot [27] ещё в 1963 году предлагал моделировать цены α -устойчивыми распределениями. Sirignano и Cont [28] недавно обучили глубокую сеть на больших объёмах данных стакана, что показывает реалистичность задачи. Vivarelli и Mannella [29] — одна из немногих работ, которая ослабляет независимость шума в анализе SGD. И главное для нас: Chandak, Yadav, Özgür, Vambos [30] (март 2026) — единственная известная нам работа, которая разбирает стохастическую аппроксимацию одновременно при тяжёлом и долговременно-зависимом шуме. Они работают в общем фреймворке стохастической аппроксимации без привязки к конкретным оптимизаторам и без α -устойчивых LRD-инноваций. Ссылки: [Cont 2001](#), [Mandelbrot 1963](#), [1803.06917](#), [2306.05300](#), [2603.19648](#).

Что во всём этом ландшафте уже сделано, а что нет. Тяжёлохвостовой шум разобран хорошо, но почти всегда в предположении независимости. Коррелированный гауссов шум разобран чуть-чуть. Одновременно тяжёлый и коррелированный — только в работе Chandak et al., и то для общей стохастической аппроксимации, без сравнения конкретных оптимизаторов и без финансовых данных. Эмпирического сравнения четырёх популярных методов на одних и тех же финансовых задачах с диагностикой полученного градиентного шума, насколько мы видим, никто не делал. Это и хочется заполнить.

5. План работ

Работа естественно разбивается на несколько этапов. Сначала генератор шума: четыре класса (N1–N4), плюс тесты, что обратные оценки индекса хвоста и показателя Хёрста дают то, что было заложено. Затем имплементация четырёх оптимизаторов в едином API на PyTorch со смок-тестами на квадратичной задаче. Потом синтетический эксперимент: квадратичная и логистическая задача при четырёх типах шума, кривые сходимости и $T(\varepsilon)$ по нескольким десяткам запусков; цель — воспроизвести известные результаты для *baseline*-методов и убедиться, что наши имплементации ведут себя ожидаемо. После этого реальные финансовые временные ряды: обучаем небольшие модели, собираем градиенты по ходу обучения, оцениваем у них $\hat{\alpha}$ и $\hat{H}$, сравниваем оптимизаторы по качеству на валидации. На последнем этапе — анализ результатов, оформление графиков и отчёта.

Если что-то пойдёт не по плану, у нас есть запас: либо упростить реальный эксперимент до более ручного режима с меньшими моделями, либо сократить набор синтетических задач. Этапы по времени получаются неравномерно — синтетика и реальные данные занимают по две недели, остальное по одной–полторы.

6. Outcomes

По итогу должны получиться численные результаты сравнения четырёх оптимизаторов в нескольких режимах шума: кривые сходимости с разбросом, оценки индекса хвоста и показателя Хёрста для реальных финансовых задач, и общие наблюдения о том, в каком из режимов какой метод ведёт себя лучше. Параллельно с этим — открытый код, которым можно воспроизвести наши эксперименты, и письменный отчёт.

7. Литература

- [1] D. P. Kingma и J. Ba, «Adam: A Method for Stochastic Optimization», в *International Conference on Learning Representations (ICLR)*, 2015. [Онлайн]. Доступно на: <https://arxiv.org/abs/1412.6980>
- [2] A. Cutkosky и H. Mehta, «Momentum Improves Normalized SGD», в *International Conference on Machine Learning (ICML)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/2002.03305>
- [3] U. Şimşekli, L. Sagun, и M. Gürbüzbalaban, «A Tail-Index Analysis of Stochastic Gradient Noise in Deep Neural Networks», в *Proceedings of the 36th International Conference on Machine Learning (ICML)*, в PMLR, vol. 97. 2019, сс. 5827–5837. [Онлайн]. Доступно на: <https://arxiv.org/abs/1901.06053>
- [4] M. Gürbüzbalaban, U. Şimşekli, и L. Zhu, «The Heavy-Tail Phenomenon in SGD», в *International Conference on Machine Learning (ICML)*, 2021. [Онлайн]. Доступно на: <https://arxiv.org/abs/2006.04740>
- [5] B. Battash и O. Lindenbaum, «Revisiting the Noise Model of Stochastic Gradient Descent», в *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2024. [Онлайн]. Доступно на: <https://arxiv.org/abs/2303.02749>
- [6] J. Zhang, T. He, S. Sra, и A. Jadbabaie, «Why Gradient Clipping Accelerates Training: A Theoretical Justification for Adaptivity», в *International Conference on Learning Representations (ICLR)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/1905.11881>
- [7] J. Zhang и др., «Why are Adaptive Methods Good for Attention Models?», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/1912.03194>
- [8] E. Gorbunov, M. Danilova, и A. Gasnikov, «Stochastic Optimization with Heavy-Tailed Noise via Accelerated Gradient Clipping», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/2005.10785>
- [9] T. D. Nguyen, A. Ene, и H. L. Nguyen, «High Probability Convergence of Clipped-SGD Under Heavy-tailed Noise», *arXiv preprint arXiv:2302.05437*, 2023, [Онлайн]. Доступно на: <https://arxiv.org/abs/2302.05437>
- [10] A. Koloskova, H. Hendrikx, и S. U. Stich, «Revisiting Gradient Clipping: Stochastic Bias and Tight Convergence Guarantees», в *International Conference on Machine Learning (ICML)*, 2023. [Онлайн]. Доступно на: <https://arxiv.org/abs/2305.01588>
- [11] F. Hübler, I. Fatkhullin, и N. He, «From Gradient Clipping to Normalization for Heavy Tailed SGD», в *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2025. [Онлайн]. Доступно на: <https://arxiv.org/abs/2410.13849>
- [12] Z. Liu и Z. Zhou, «Nonconvex Stochastic Optimization under Heavy-Tailed Noises: Optimal Convergence without Gradient Clipping», в *International Conference on Learning Representations (ICLR)*, 2025. [Онлайн]. Доступно на: <https://arxiv.org/abs/2412.19529>
- [13] S. J. Reddi, S. Kale, и S. Kumar, «On the Convergence of Adam and Beyond», в *International Conference on Learning Representations (ICLR)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1904.09237>
- [14] A. Défossez, L. Bottou, F. Bach, и N. Usunier, «A Simple Convergence Proof of Adam and Adagrad», *Transactions on Machine Learning Research (TMLR)*, 2022, [Онлайн]. Доступно на: <https://arxiv.org/abs/2003.02395>
- [15] I. Loshchilov и F. Hutter, «Decoupled Weight Decay Regularization», в *International Conference on Learning Representations (ICLR)*, 2019. [Онлайн]. Доступно на: <https://arxiv.org/abs/1711.05101>
- [16] R. Johnson и T. Zhang, «Accelerating Stochastic Gradient Descent using Predictive Variance Reduction», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2013.
- [17] M. Schmidt, N. Le Roux, и F. Bach, «Minimizing Finite Sums with the Stochastic Average Gradient», *Mathematical Programming*, т. 162, сс. 83–112, 2017, [Онлайн]. Доступно на: <https://arxiv.org/abs/1309.2388>
- [18] A. Defazio, F. Bach, и S. Lacoste-Julien, «SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2014. [Онлайн]. Доступно на: <https://arxiv.org/abs/1407.0202>
- [19] B. T. Polyak и A. B. Juditsky, «Acceleration of Stochastic Approximation by Averaging», *SIAM Journal on Control and Optimization*, т. 30, вып. 4, сс. 838–855, 1992.
- [20] P. Izmailov, D. Podoprikin, T. Garipov, D. Vetrov, и A. G. Wilson, «Averaging Weights Leads to Wider Optima and Better Generalization», в *Conference on Uncertainty in Artificial Intelligence (UAI)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1803.05407>

- [21] M. R. Zhang, J. Lucas, G. Hinton, и J. Ba, «Lookahead Optimizer: k Steps Forward, 1 Step Back», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2019. [Онлайн]. Доступно на: <https://arxiv.org/abs/1907.08610>
- [22] P. Foret, A. Kleiner, H. Mobahi, и B. Neyshabur, «Sharpness-Aware Minimization for Efficiently Improving Generalization», в *International Conference on Learning Representations (ICLR)*, 2021. [Онлайн]. Доступно на: <https://arxiv.org/abs/2010.01412>
- [23] P. Goyal и др., «Accurate, Large Minibatch SGD: Training ImageNet in 1 Hour», *arXiv preprint arXiv:1706.02677*, 2017, [Онлайн]. Доступно на: <https://arxiv.org/abs/1706.02677>
- [24] X. Chen и др., «Symbolic Discovery of Optimization Algorithms», *arXiv preprint arXiv:2302.06675*, 2023, [Онлайн]. Доступно на: <https://arxiv.org/abs/2302.06675>
- [25] D. Yin, Y. Chen, K. Ramchandran, и P. Bartlett, «Byzantine-Robust Distributed Learning: Towards Optimal Statistical Rates», в *International Conference on Machine Learning (ICML)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1803.01498>
- [26] R. Cont, «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues», *Quantitative Finance*, т. 1, вып. 2, сс. 223–236, 2001, doi: [10.1080/713665670](https://doi.org/10.1080/713665670).
- [27] B. Mandelbrot, «The Variation of Certain Speculative Prices», *Journal of Business*, т. 36, вып. 4, сс. 394–419, 1963, [Онлайн]. Доступно на: <http://www.e-m-h.org/Mand63.pdf>
- [28] J. Sirignano и R. Cont, «Universal Features of Price Formation in Financial Markets: Perspectives from Deep Learning», *Quantitative Finance*, т. 19, вып. 9, сс. 1449–1459, 2019, [Онлайн]. Доступно на: <https://arxiv.org/abs/1803.06917>
- [29] M. Vivarelli и R. Mannella, «Correlated Noise in Epoch-Based Stochastic Gradient Descent: Implications for Weight Variances», *arXiv preprint arXiv:2306.05300*, 2024, [Онлайн]. Доступно на: <https://arxiv.org/abs/2306.05300>
- [30] S. Chandak, A. K. Yadav, A. Özgür, и N. Bambos, «Heavy-Tailed and Long-Range Dependent Noise in Stochastic Approximation: A Finite-Time Analysis», в *arXiv preprint arXiv:2603.19648*, 2026. [Онлайн]. Доступно на: <https://arxiv.org/abs/2603.19648>