

Beyond Gaussian Noise: сходимость стохастических оптимизаторов при коррелированном и тяжёлохвостовом финансовом градиентном шуме

Project Proposal · НИУ ВШЭ · 26 апреля 2026 г.

Кортунов Д., Пастушенко В., Дубовицкий А., Шадрин А.

Аннотация. Стандартные оценки сходимости SGD и Adam предполагают, что градиентный шум имеет ограниченную дисперсию и независим по итерациям. На финансовых данных оба предположения нарушаются: доходности активов тяжёлохвостовы и обладают долговременной памятью, и градиенты, посчитанные на таких данных, наследуют эти свойства. Мы хотим эмпирически проверить, как четыре популярных оптимизатора (SGD, Adam, Clipped-SGD, Normalized-SGD) ведут себя при разных типах градиентного шума — от белого гауссова до смешанного α -устойчивого с $1/f$ -корреляцией — на синтетических задачах и на реальных финансовых рядах (S&P 500, LOBSTER). По итогам должны получиться кривые сходимости, оценки индекса хвоста $\hat{\alpha}$ и показателя Хёрста $\hat{H}$ полученного шума, и короткая таблица «когда какой оптимизатор лучше брать».

1. Описание проекта

Если коротко: мы берём четыре оптимизатора, четыре типа шума и смотрим, кто как сходится. Мотивация — большинство практиков в quant-finance по умолчанию обучают модели Adam’ом, при том что финансовые данные заведомо ломают предположения, при которых для Adam доказывают сходимость. Хочется понять, насколько это плохо на практике, и есть ли оптимизаторы, которые в этом сеттинге ведут себя стабильнее.

Конкретно делаем две вещи:

1. **Синтетика.** Берём простую задачу (квадратичная и логистическая регрессия), искусственно подмешиваем к градиенту шум четырёх типов (см. §2) и смотрим, насколько быстро падает $\|\nabla f\|$.
2. **Реальные данные.** Учим небольшие модели (MLP, LSTM) предсказывать знак дневной доходности S&P 500 и спред в LOBSTER NASDAQ. Параллельно собираем сами градиенты g_k во время обучения и оцениваем у них $\hat{\alpha}$ (по методу McCulloch / Hill) и $\hat{H}$ (по R/S-статистике и DFA), чтобы проверить, действительно ли финансовые градиенты соответствуют нашей синтетической модели.

2. Формальная постановка

Минимизируем L -гладкую функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$, в общем случае невыпуклую. На итерации k доступен стохастический градиент

$$g_k = \nabla f(x_k) + \xi_k,$$

где ξ_k — центрированный шум. Предположения ограниченности $\mathbb{E}\|\xi_k\|^2$ и независимости ξ_k не накладываем.

Шум ξ_k моделируем одним из четырёх классов:

- **N1 (белый гауссов):** $\xi_k \sim \mathcal{N}(0, \sigma^2 I)$, i.i.d. — контроль.
- **N2 (розовый, $1/f$):** $\xi_k = \sum_{j \geq 0} \psi_j \eta_{k-j}$, η_j гауссовы i.i.d., ψ_j задают FARIMA(0, d , 0) с $d \in (0, 1/2)$. Спектр $S(f) \sim f^{-2d}$, долгая память, конечная дисперсия.
- **N3 (тяжёлохвостовой):** $\xi_k \sim S_\alpha(\sigma, 0, 0)$ покомпонентно, $\alpha \in (1, 2)$. Конечен только p -й момент при $p < \alpha$.

- **N4 (смешанный, главный):** $\xi_k = \sum_{j \geq 0} \psi_j \zeta_{k-j}$, ζ_j — α -устойчивые i.i.d., ψ_j задают $1/f$ -спектр. Тяжёлый и коррелированный.

Сравниваем четыре оптимизатора с обновлением $x_{k+1} = x_k - \eta_k \varphi(g_k)$:

1. SGD: $\varphi(g) = g$.
2. Adam [1]: $\varphi(g_k) = m_k / (\sqrt{v_k} + \varepsilon)$.
3. Clipped-SGD: $\varphi(g) = \min(1, \tau/\|g\|)g$.
4. Normalized-SGD with momentum [2]: $\varphi(g_k) = m_k / \|m_k\|$.

Главная величина, которую мы измеряем — эмпирическая $T(\varepsilon; A, \mathcal{N}) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\}$.

3. Метрики

Что считаем по итогам экспериментов:

- **Кривая сходимости** $\mathbb{E}\|\nabla f(x_k)\|^2$ от k (медиана и 90-й перцентиль по 50 запускам).
- **Финальный лосс / Sharpe** на out-of-sample части финансовых данных.
- **Восстановление $\hat{\alpha}$ и $\hat{H}$** собранного градиентного шума: должны совпасть с инжестированными значениями на синтетике; на реальных данных — собственно интересный результат.

Возможен отрицательный исход: например, обнаружится, что для S&P 500 все четыре оптимизатора ведут себя примерно одинаково, и тогда наш вклад — это сама диагностика и обоснование, *почему* так получилось (например, $\hat{\alpha} \approx 1.95$, то есть данные оказались «почти гауссовы» на уровне градиента).

4. Обзор литературы

Литературу удобно разбить на четыре группы.

4.1. Тяжёлохвостовой градиентный шум

Şimşekli, Sagun, Gürbüzbalaban [3] (ICML 2019) эмпирически показали, что градиентный шум в нейросетях не гауссов, а α -устойчивый. Это базовая работа, с которой начинается весь сюжет. Gürbüzbalaban, Şimşekli, Zhu [4] (ICML 2021) дальше показали, что даже при гауссовых данных *сами итерации* SGD имеют тяжёлохвостовое стационарное распределение. Battash, Lindenbaum [5] (AISTATS 2024) уточнили, что разные параметры сети имеют разные индексы хвоста — важно, как именно оценивать $\hat{\alpha}$.

Ссылки: [arxiv 1901.06053](#), [2006.04740](#), [2303.02749](#).

4.2. Сходимость с обрезанием и нормировкой

Zhang, He, Sra, Jadbabaie [6] (ICLR 2020) дали условие (L_0, L_1) -гладкости, при котором обрезание ускоряет сходимость. Zhang et al. [7] (NeurIPS 2020) показали, что Adam — это по сути покоординатное обрезание. Gorbunov, Danilova, Gasnikov [8] (NeurIPS 2020) получили первые high-probability оценки для Clipped-SGD при ограниченном $(1 + \alpha)$ -моменте шума — это наш основной теоретический baseline. Nguyen et al. [9] (2023) уточнили эти оценки до time-optimal. Koloskova, Hendrikx, Stich [10] (ICML 2023), наоборот, показали, что у clipping есть неустранимое смещение — это важный caveat. Cutkosky, Mehta [2] (ICML 2020) — стандартная работа по Normalized-SGD. Hübler, Fatkhullin, He [11] (AISTATS 2025) и Liu, Zhou [12] (ICLR 2025) показали, что Normalized-SGD достигает оптимальной скорости при тяжёлом шуме *без* обрезания — значит у нас есть прямой соперник Clipped-SGD.

Ссылки: [1905.11881](#), [1912.03194](#), [2005.10785](#), [2302.05437](#), [2305.01588](#), [2002.03305](#), [2410.13849](#), [2412.19529](#).

4.3. Сходимость Adam

Kingma, Ba [1] (ICLR 2015) — оригинальная статья. Reddi, Kale, Kumar [13] (ICLR 2018, best paper) показали, что Adam может расходиться даже на простой выпуклой задаче, и предложили AMSGrad. Défossez et al. [14] (TMLR 2022) дали наиболее чистое доказательство сходимости Adam при ограниченных градиентах — это baseline, от которого мы будем мерить деградацию.

Ссылки: [1412.6980](#), [1904.09237](#), [2003.02395](#).

4.4. Финансовый контекст и коррелированный шум

Cont [15] (Quantitative Finance 2001) — канонический список «стилизированных фактов» финансовых рядов: тяжёлые хвосты, кластеризация волатильности, долгая память. Mandelbrot [16] (1963) — исторический аргумент в пользу α -устойчивых распределений. Sirignano, Cont [17] (2019) — глубокое обучение на LOB-данных, показывает, что задача реалистичная. Vivarelli, Mannella [18] (2024) — одна из немногих работ про SGD с коррелированным шумом. И самое главное: Chandak, Yadav, Özgür, Bambos [19] (arXiv 2603.19648, *март 2026*) — единственная нам известная работа, где разбирается стохастическая аппроксимация одновременно при тяжёлом и долговременно-зависимом шуме. Они работают в общем фреймворке SA, без специализации на конкретные оптимизаторы и без α -устойчивых LRD-инноваций — ровно то, что мы хотим конкретизировать.

Ссылки: [Cont 2001](#), [Mandelbrot 1963](#), [1803.06917](#), [2306.05300](#), [2603.19648](#).

4.5. Где наш проект на этом ландшафте

Тяжёлохвостовой шум разобран хорошо, но всегда в предположении независимости. Коррелированный гауссов шум — разобран чуть-чуть. Одновременно тяжёлый и коррелированный — только Chandak et al., и то без привязки к конкретным оптимизаторам и финансовым данным. Эмпирического сравнения SGD / Adam / Clipped-SGD / Normalized-SGD на одних и тех же финансовых задачах с диагностикой $\hat{\alpha}$, $\hat{H}$ полученного градиента — нет. Это и заполняем.

5. План работ

Разбиваем работу на пять этапов; каждый занимает 1–2 недели.

1. **Генератор шума.** Реализуем четыре класса (N1–N4), пишем тесты на восстановление $\hat{\alpha}$ и $\hat{H}$.
2. **Оптимизаторы.** Реализуем четыре оптимизатора в едином API на PyTorch, прогоняем smoke-test на квадратичной задаче.
3. **Синтетический эксперимент.** Решаем квадратичную и логистическую задачу при четырёх типах шума, строим кривые сходимости, считаем $T(\epsilon)$ и 95-й перцентиль. Цель — воспроизвести известные результаты [8], [11], [12].
4. **Реальный эксперимент.** MLP/LSTM на S&P 500 (1990–2020) и LOBSTER NASDAQ. Собираем градиенты, оцениваем $\hat{\alpha}$ и $\hat{H}$, сравниваем оптимизаторы по test loss и Sharpe.
5. **Анализ и сборка.** Рисуем графики, пишем шпаргалку «наблюдаемое $\hat{\alpha}$, $\hat{H} \rightarrow$ что брать», оформляем отчёт.

6. Outcomes

Что должно получиться:

- Код (PyTorch, открытый репозиторий с фиксированными seed'ами).
- Таблица 4×4 : оптимизатор $\times$ тип шума, по каждой ячейке — $T(\epsilon)$, 95-й перцентиль $\|\nabla f\|^2$.
- Кривые сходимости и оценки $\hat{\alpha}$, $\hat{H}$ для финансовых задач.
- Шпаргалка на одну страницу: при каких диагностических признаках использовать какой оптимизатор.

- Письменный отчёт (≈ 10 страниц).

7. Возможные развития проекта

Если останется время или для будущих этапов:

1. **L_p -Adam.** В оригинальной статье Adam’a Kingma & Ba [1] в §7.1 выписали обобщение со степенным моментом $v_t \propto |g_t|^p$ и обновлением $m_t/v_t^{1/p}$, но сразу перешли к пределу $p \rightarrow \infty$ (Adamax). Промежуточный режим $p \in (1, 2)$ почти не исследован. *Гипотеза*: оптимально брать $p \approx \alpha$, потому что только при $p < \alpha$ конечен момент. Можно сделать ablation по $p \in \{1.1, 1.3, 1.5, 1.7, 2.0\}$ + адаптивная онлайн-оценка $\hat{p}_t$ через Hill-estimator.
2. **Доказательство для N4.** Применить noise-averaging аргумент [19] к одному из четырёх оптимизаторов и попробовать получить оценку вида $\mathbb{E}\|\nabla f\|^2 = O(K^{-r(\alpha, H)})$ для смешанного режима. Резерв: если в общем виде не получится — доказать для квадратичного случая.
3. **RL-сеттинг.** Перенос на обучение с подкреплением для портфельной оптимизации. Reward в финансовом RL такой же тяжёлохвостовой, как доходности; сравнить PPO+Adam vs PPO+Clipped-SGD.
4. **Адаптивный τ для Clipped-SGD.** Вместо фиксированного порога — оценивать $\hat{\alpha}_k$ онлайн и подбирать τ_k из теоретически оптимальной формулы Gorbunov et al.
5. **Per-layer диагностика.** [5] показали, что у разных слоёв разные индексы хвоста. Можно использовать разные оптимизаторы (или разные τ) для разных слоёв.

8. Литература

- [1] D. P. Kingma и J. Ba, «Adam: A Method for Stochastic Optimization», в *International Conference on Learning Representations (ICLR)*, 2015. [Онлайн]. Доступно на: <https://arxiv.org/abs/1412.6980>
- [2] A. Cutkosky и H. Mehta, «Momentum Improves Normalized SGD», в *International Conference on Machine Learning (ICML)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/2002.03305>
- [3] U. Şimşekli, L. Sagun, и M. Gürbüzbalaban, «A Tail-Index Analysis of Stochastic Gradient Noise in Deep Neural Networks», в *Proceedings of the 36th International Conference on Machine Learning (ICML)*, в PMLR, vol. 97. 2019, сс. 5827–5837. [Онлайн]. Доступно на: <https://arxiv.org/abs/1901.06053>
- [4] M. Gürbüzbalaban, U. Şimşekli, и L. Zhu, «The Heavy-Tail Phenomenon in SGD», в *International Conference on Machine Learning (ICML)*, 2021. [Онлайн]. Доступно на: <https://arxiv.org/abs/2006.04740>
- [5] B. Battash и O. Lindenbaum, «Revisiting the Noise Model of Stochastic Gradient Descent», в *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2024. [Онлайн]. Доступно на: <https://arxiv.org/abs/2303.02749>
- [6] J. Zhang, T. He, S. Sra, и A. Jadbabaie, «Why Gradient Clipping Accelerates Training: A Theoretical Justification for Adaptivity», в *International Conference on Learning Representations (ICLR)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/1905.11881>
- [7] J. Zhang и др., «Why are Adaptive Methods Good for Attention Models?», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/1912.03194>
- [8] E. Gorbunov, M. Danilova, и A. Gasnikov, «Stochastic Optimization with Heavy-Tailed Noise via Accelerated Gradient Clipping», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/2005.10785>
- [9] T. D. Nguyen, A. Ene, и H. L. Nguyen, «High Probability Convergence of Clipped-SGD Under Heavy-tailed Noise», *arXiv preprint arXiv:2302.05437*, 2023, [Онлайн]. Доступно на: <https://arxiv.org/abs/2302.05437>
- [10] A. Koloskova, H. Hendrikx, и S. U. Stich, «Revisiting Gradient Clipping: Stochastic Bias and Tight Convergence Guarantees», в *International Conference on Machine Learning (ICML)*, 2023. [Онлайн]. Доступно на: <https://arxiv.org/abs/2305.01588>
- [11] F. Hübler, I. Fatkhullin, и N. He, «From Gradient Clipping to Normalization for Heavy Tailed SGD», в *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2025. [Онлайн]. Доступно на: <https://arxiv.org/abs/2410.13849>
- [12] Z. Liu и Z. Zhou, «Nonconvex Stochastic Optimization under Heavy-Tailed Noises: Optimal Convergence without Gradient Clipping», в *International Conference on Learning Representations (ICLR)*, 2025. [Онлайн]. Доступно на: <https://arxiv.org/abs/2412.19529>
- [13] S. J. Reddi, S. Kale, и S. Kumar, «On the Convergence of Adam and Beyond», в *International Conference on Learning Representations (ICLR)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1904.09237>
- [14] A. Défossez, L. Bottou, F. Bach, и N. Usunier, «A Simple Convergence Proof of Adam and Adagrad», *Transactions on Machine Learning Research (TMLR)*, 2022, [Онлайн]. Доступно на: <https://arxiv.org/abs/2003.02395>
- [15] R. Cont, «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues», *Quantitative Finance*, т. 1, вып. 2, сс. 223–236, 2001, doi: [10.1080/713665670](https://doi.org/10.1080/713665670).
- [16] B. Mandelbrot, «The Variation of Certain Speculative Prices», *Journal of Business*, т. 36, вып. 4, сс. 394–419, 1963, [Онлайн]. Доступно на: <http://www.e-m-h.org/Mand63.pdf>
- [17] J. Sirignano и R. Cont, «Universal Features of Price Formation in Financial Markets: Perspectives from Deep Learning», *Quantitative Finance*, т. 19, вып. 9, сс. 1449–1459, 2019, [Онлайн]. Доступно на: <https://arxiv.org/abs/1803.06917>
- [18] M. Vivarelli и R. Mannella, «Correlated Noise in Epoch-Based Stochastic Gradient Descent: Implications for Weight Variances», *arXiv preprint arXiv:2306.05300*, 2024, [Онлайн]. Доступно на: <https://arxiv.org/abs/2306.05300>
- [19] S. Chandak, A. K. Yadav, A. Özgür, и N. Bambos, «Heavy-Tailed and Long-Range Dependent Noise in Stochastic Approximation: A Finite-Time Analysis», в *arXiv preprint arXiv:2603.19648*, 2026. [Онлайн]. Доступно на: <https://arxiv.org/abs/2603.19648>