

Шумоподавление как предобработка: влияние типа фильтра на сходимость стохастических оптимизаторов на финансовых временных рядах

Project Proposal · НИУ ВШЭ · 26 апреля 2026 г.

Кортунов Д., Пастушенко В., Дубовицкий А., Шадрин А.

Аннотация. Финансовые временные ряды содержат шум различной природы: гауссов, тяжёлохвостовый, коррелированный и их комбинации. Прямая подача таких данных в стандартные стохастические оптимизаторы нарушает базовые предположения теории сходимости. Мы исследуем альтернативный подход: перед оптимизацией применяется этап шумоподавления — скользящее среднее, фильтр Калмана, вейвлет-пороговая обработка или медианная фильтрация, — после чего ряд подаётся в SGD, Adam или AdamW. Основной вопрос: насколько выбор фильтра влияет на скорость сходимости и итоговое качество модели, и можно ли подобрать пару (фильтр, оптимизатор), устойчивую к нескольким типам шума одновременно?

1. О чём проект

Классический пайплайн обучения модели на финансовых данных молчаливо предполагает, что доходности достаточно «чистые». На практике это не так: хвосты тяжёлые, есть долгая память, волатильность кластеризована. Один из практически мотивированных ответов — сначала убрать шум, а потом запускать оптимизатор на очищенном ряду. Такой подход широко применяется в индустрии, однако его систематического сравнения в контексте оптимизации нет.

Мы фиксируем четыре типа искусственно добавляемого шума и четыре метода шумоподавления, выбираем три стандартных оптимизатора и смотрим, как меняются кривые сходимости в матрице экспериментов (фильтр) $\times$ (тип шума) $\times$ (оптимизатор). Часть экспериментов синтетическая (квадратичная и логистическая регрессия), часть — на реальных финансовых рядах. По итогу хотим дать практическую рекомендацию: при каком типе шума какую пару (фильтр, оптимизатор) разумно использовать.

2. Постановка

Минимизируем L -гладкую функцию $f: \mathbb{R}^d \rightarrow \mathbb{R}$ по параметрам модели. Наблюдаемый временной ряд $y_1, \dots, y_T$ задаётся как

$$y_t = s_t + \xi_t,$$

где s_t — «сигнал» (истинное движение цены), а ξ_t — шум. Мы рассматриваем четыре класса шума.

N1 (гауссов белый): $\xi_t \sim \mathcal{N}(0, \sigma^2)$ — контрольный режим, соответствующий стандартным допущениям теории.

N2 (розовый, $1/f$): $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$ с гауссовыми η_j и FARIMA(0, d , 0)-весами, $d \in (0, 1/2)$; дисперсия конечна, но есть долгая память.

N3 (тяжёлохвостовый): $\xi_t \sim S_{\alpha(\sigma, 0, 0)}$ покомпонентно, $\alpha \in (1, 2)$; конечен только p -й момент при $p < \alpha$.

N4 (смешанный): $\xi_t = \sum_{j \geq 0} \psi_j \zeta_{t-j}$, где ζ_j i.i.d. α -устойчивые, а ψ_j задают $1/f$ -спектр; тяжёлые хвосты и долгая память присутствуют одновременно.

Перед подачей в оптимизатор ряд $y_1, \dots, y_T$ обрабатывается одним из четырёх фильтров.

F1 (скользящее среднее, MA): $\hat{s}_t = (1/w) \sum_{i=0}^{w-1} y_{t-i}$; простейший линейный фильтр, смещает ряд на $w/2$ шагов.

F2 (фильтр Калмана): предполагает линейную модель состояния $s_t = As_{t-1} + w_t$; оценивает $\hat{s}_t$ рекуррентно, оптимален при гауссовом шуме [1].

F3 (вейвлет-пороговая обработка): разложение по базису Добеши, жёсткое или мягкое пороговое отсечение коэффициентов детализации, обратное преобразование [2], [3]. Хорошо справляется с локальными всплесками (тяжёлые хвосты).

F4 (медианная фильтрация): $\hat{s}_t = \text{median}(y_{t-\frac{w}{2}}, \dots, y_{t+\frac{w}{2}})$; не требует гауссовости, устойчив к выбросам [4].

После фильтрации получаем очищенный ряд $\hat{s}_1, \dots, \hat{s}_T$, по которому считаем градиенты и запускаем один из трёх оптимизаторов:

- SGD с постоянным шагом: $x_{k+1} = x_k - \eta \nabla f(x_k)$;
- Adam [5]: адаптивный шаг с моментами первого и второго порядка;
- AdamW [6]: Adam с корректным L_2 -регуляризатором.

Главная величина — эмпирическое время до ε -точности $T(\varepsilon; F, A, \mathcal{N}) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\}$ для каждой тройки (фильтр F , оптимизатор A , тип шума $\mathcal{N}$).

3. Метрики

По итогам экспериментов вычисляем следующие характеристики.

Кривая сходимости $\mathbb{E}\|\nabla f(x_k)\|^2$ от номера итерации: медиана и 90-й перцентиль по нескольким десяткам независимых запусков. Это основной результат для синтетических задач.

Качество на отложенной выборке (MSE или log-правдоподобие) для задач прогнозирования на реальных финансовых рядах.

Степень подавления шума: SNR до и после фильтрации для каждой пары (фильтр, тип шума). Позволяет понять, насколько хорошо фильтр «подготовил» ряд.

Искажение структуры ряда: оценка показателя Хёрста $\hat{H}$ и, при необходимости, индекса хвоста $\hat{\alpha}$ — до и после фильтрации. Слишком агрессивный фильтр может убрать вместе с шумом полезный сигнал.

Отрицательный результат тоже содержателен: если окажется, что все пары (фильтр, оптимизатор) дают схожую сходимость на реальных данных, это само по себе говорит о низкой чувствительности оптимизатора к предобработке — что является практически важным выводом.

4. Обзор литературы

Фильтрация временных рядов. Фильтр Калмана [1] — классический байесовский метод оценки состояния при линейной гауссовой модели; активно применяется в финансах для сглаживания цен и скрытых компонент [7]. Вейвлет-методы шумоподавления были систематизированы Donoho и Johnstone [2], которые показали оптимальность мягкого порога в классе кусочно-гладких функций; базисы Добеши [8] наиболее распространены на практике. Общую теорию вейвлет-разложений временных рядов описывает Mallat [3]. Медианная фильтрация и её обобщения разобраны у Yin и др. [4]; она устойчива к выбросам там, где линейные фильтры

дают утечку. Скользящее среднее — простейший базовый случай; его свойства в контексте финансовых рядов обсуждают Hamilton [9] и Tsay [10].

Природа финансового шума. Cont [11] перечисляет одиннадцать «стилизированных фактов» финансовых доходностей — тяжёлые хвосты, кластеризация волатильности, долгая память абсолютных доходностей. Mandelbrot [12] ещё в 1963 году предлагал моделировать цены α -устойчивыми распределениями. Şimşekli, Sagun и Gürbüzbalaban [13] эмпирически показали, что градиентный шум при обучении нейросетей не гауссов, а близок к α -устойчивому. Chandak, Yadav, Özgür и Bambos [14] (март 2026) — единственная известная нам работа, в которой одновременно разбирается тяжёлохвостовый и долговременно-зависимый шум в стохастической аппроксимации.

Стохастические оптимизаторы. Kingma и Ba [5] предложили Adam, обоснование его сходимости при ограниченных градиентах дано у Défossez и др. [15]. Reddi, Kale и Kumar [16] показали, что Adam может расходиться на выпуклых задачах, и предложили AMSGrad. Loshchilov и Hutter [6] уточнили, как правильно совмещать Adam с L_2 -регуляризацией. Классическая теория SGD изложена у Robbins и Monro [17]; современный анализ сходимости при тяжёлом шуме — у Gorbunov, Danilova и Gasnikov [18].

Что ещё не сделано. Сравнения вида (тип фильтра) $\times$ (тип шума) $\times$ (оптимизатор) в единой постановке на финансовых данных нам не встречалось. Большинство работ либо предполагают чистые данные, либо модифицируют оптимизатор, но не предобработку. Мы хотим заполнить этот пробел и дать практическую матрицу рекомендаций.

5. План работ

Работа разбивается на несколько последовательных этапов.

Этап 1 (1 неделя): генератор шума. Реализуем четыре класса N1–N4; проверяем оценки индекса хвоста и показателя Хёрста — убеждаемся, что обратные оценки дают то, что было заложено.

Этап 2 (1 неделя): реализация фильтров. Пишем F1–F4 с единым API: вход — сырой ряд, выход — очищенный. Тестируем на синтетике с известным $\hat{\alpha}$ и $\hat{H}$: смотрим SNR до/после и степень сохранения структуры.

Этап 3 (1 неделя): имплементация оптимизаторов. SGD, Adam, AdamW в едином API на PyTorch; смок-тесты на квадратичной задаче без шума.

Этап 4 (2 недели): синтетический эксперимент. Квадратичная и логистическая задача, матрица $4 \times 4 \times 3$ (шум $\times$ фильтр $\times$ оптимизатор), несколько десятков запусков каждой конфигурации, кривые сходимости и оценки $T(\epsilon)$.

Этап 5 (2 недели): реальные финансовые ряды. Берём дневные и внутридневные данные по нескольким активам, применяем ту же матрицу (фильтр, оптимизатор), обучаем небольшую модель прогнозирования, сравниваем по MSE и log-правдоподобию на валидации.

Этап 6 (1 неделя): анализ, графики, отчёт.

Запасной вариант: если реальный эксперимент окажется слишком трудоёмким, упрощаем модели до линейной регрессии и сокращаем список активов.

6. Outcomes

По итогу ожидаем получить матрицу результатов сходимости и качества для всех комбинаций (фильтр, тип шума, оптимизатор); оценки SNR и степени искажения структуры ряда для каждого фильтра; практическую таблицу рекомендаций «при каком шуме какую пару использовать»; открытый воспроизводимый код и письменный отчёт.

7. Литература

- [1] R. E. Kalman, «A New Approach to Linear Filtering and Prediction Problems», *Journal of Basic Engineering*, т. 82, вып. 1, сс. 35–45, 1960, doi: [10.1115/1.3662552](https://doi.org/10.1115/1.3662552).
- [2] D. L. Donoho и I. M. Johnstone, «Ideal Spatial Adaptation by Wavelet Shrinkage», *Biometrika*, т. 81, вып. 3, сс. 425–455, 1994, doi: [10.1093/biomet/81.3.425](https://doi.org/10.1093/biomet/81.3.425).
- [3] S. Mallat, *A Wavelet Tour of Signal Processing*, 2nd изд. San Diego: Academic Press, 1999.
- [4] L. Yin, R. Yang, M. Gabbouj, и Y. Neuvo, «Weighted Median Filters: A Tutorial», *IEEE Transactions on Circuits and Systems II: Analog and Digital Signal Processing*, т. 43, вып. 3, сс. 157–192, 1996, doi: [10.1109/82.486465](https://doi.org/10.1109/82.486465).
- [5] D. P. Kingma и J. Ba, «Adam: A Method for Stochastic Optimization», в *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015. [Онлайн]. Доступно на: <https://arxiv.org/abs/1412.6980>
- [6] I. Loshchilov и F. Hutter, «Decoupled Weight Decay Regularization», в *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, 2019. [Онлайн]. Доступно на: <https://arxiv.org/abs/1711.05101>
- [7] A. C. Harvey, *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge: Cambridge University Press, 1990. doi: [10.1017/CBO9781107049994](https://doi.org/10.1017/CBO9781107049994).
- [8] I. Daubechies, *Ten Lectures on Wavelets*. Philadelphia: Society for Industrial, Applied Mathematics, 1992. doi: [10.1137/1.9781611970104](https://doi.org/10.1137/1.9781611970104).
- [9] J. D. Hamilton, *Time Series Analysis*. Princeton: Princeton University Press, 1994.
- [10] R. S. Tsay, *Analysis of Financial Time Series*, 3rd изд. Hoboken: John Wiley & Sons, 2010. doi: [10.1002/9780470644560](https://doi.org/10.1002/9780470644560).
- [11] R. Cont, «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues», *Quantitative Finance*, т. 1, вып. 2, сс. 223–236, 2001, doi: [10.1080/713665670](https://doi.org/10.1080/713665670).
- [12] B. Mandelbrot, «The Variation of Certain Speculative Prices», *The Journal of Business*, т. 36, вып. 4, сс. 394–419, 1963, doi: [10.1086/294632](https://doi.org/10.1086/294632).
- [13] U. Şimşekli, L. Sagun, и M. Gürbüzbalaban, «A Tail-Index Analysis of Stochastic Gradient Noise in Deep Neural Networks», в *Proceedings of the 36th International Conference on Machine Learning (ICML)*, в *Proceedings of Machine Learning Research*, vol. 97. PMLR, 2019, сс. 5827–5837. [Онлайн]. Доступно на: <https://arxiv.org/abs/1901.06053>
- [14] Y. Chandak, P. Yadav, A. Özgür, и N. Bambos, «Stochastic Approximation with Heavy-Tailed and Long-Range Dependent Noise». [Онлайн]. Доступно на: <https://arxiv.org/abs/2603.19648>
- [15] A. Défossez, L. Bottou, F. Bach, и N. Usunier, «A Simple Convergence Proof of Adam and Adagrad», *Transactions on Machine Learning Research*, 2022, [Онлайн]. Доступно на: <https://arxiv.org/abs/2003.02395>
- [16] S. J. Reddi, S. Kale, и S. Kumar, «On the Convergence of Adam and Beyond», в *Proceedings of the 6th International Conference on Learning Representations (ICLR)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1904.09237>
- [17] H. Robbins и S. Monro, «A Stochastic Approximation Method», *The Annals of Mathematical Statistics*, т. 22, вып. 3, сс. 400–407, 1951, doi: [10.1214/aoms/1177729586](https://doi.org/10.1214/aoms/1177729586).
- [18] E. Gorbunov, M. Danilova, и A. Gasnikov, «Stochastic Optimization with Heavy-Tailed Noise via Iterative Differentially Private Clipping», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020, сс. 15042–15053. [Онлайн]. Доступно на: <https://arxiv.org/abs/2005.10785>