

Beyond Gaussian Noise: Сходимость стохастических оптимизаторов при коррелированном и тяжёлохвостовом финансовом градиентном шуме

Project Proposal

НИУ ВШЭ, ФКН – Методы оптимизации в машинном обучении

26 апреля 2026 г.

Кортунов Д. dvkortunov@edu.hse.ru Пастушенко В. vapastushenko@edu.hse.ru Дубовицкий А. andubovitskiy@edu.hse.ru Шадрин А. arshadrin@edu.hse.ru

Аннотация. Стандартный анализ сходимости SGD, Adam и их модификаций опирается на два предположения: ограниченная дисперсия стохастического градиента и его независимость по итерациям. Финансовые данные (доходности активов, реализованная волатильность, объёмы) систематически нарушают оба: эмпирически наблюдаются тяжёлые хвосты (α -устойчивого типа, $\alpha < 2$) и долговременная память ($1/f$ -спектр абсолютных доходностей). Мы эмпирически исследуем, как такой градиентный шум влияет на сходимость четырёх популярных оптимизаторов — SGD, Adam, Clipped-SGD, Normalized-SGD — при обучении на финансовых временных рядах. Цель проекта: построить воспроизводимый бенчмарк «оптимизатор $\times$ тип шума» на синтетических и реальных данных, измерить индекс хвоста $\hat{\alpha}$ и показатель Хёрста $\hat{H}$ полученного градиентного шума, и сформулировать практические рекомендации по выбору оптимизатора для квантового ML. *Сверх нормы:* теоретический анализ и эксперименты с L_p -обобщением Adam (см. §«Возможные развития проекта»).

1. Описание проекта

1.1. Мотивация и контекст

Современная теория стохастической оптимизации в основном строится в одном из двух режимов: (а) ограниченной дисперсии $\mathbb{E}\|g - \nabla f\|^2 \leq \sigma^2$ при независимых выборках мини-батчей, (б) тяжёлых хвостов с ограниченным $(1 + \alpha)$ -моментом, $\alpha \in (0, 1]$, но всё ещё с независимыми выборками. Финансовые временные ряды одновременно нарушают оба предположения: доходности имеют тяжёлые хвосты с показателем $\alpha \approx 1.5\text{--}1.9$ (Sirignano & Cont, 2019 [1]), а абсолютные доходности и реализованная волатильность демонстрируют долговременную память со спектром мощности $S(f) \sim f^{-\beta}$, $\beta \in (0.3, 0.9)$ (так называемый «розовый» или $1/f$ -шум, Lux & Marchesi, 1999 [2]). Когда такие данные подаются в обучение нейросетевой модели (forecasting, market making, RL для портфельной оптимизации), полученный стохастический градиент наследует обе эти патологии.

При этом большинство практиков в квантовом ML используют Adam с настройками по умолчанию, не задумываясь о применимости его теоретических гарантий (Kingma & Ba, 2015 [3]). Известно, что Adam может расходиться даже на простых выпуклых задачах при определённых распределениях градиентов (Reddi et al., 2018 [4]). Для тяжёлых хвостов Clipped-SGD и Normalized-SGD имеют строго лучшие гарантии (Gorbunov et al., 2020 [5]; Hübler et al., 2025 [6]), но эти результаты получены в предположении независимости шума, которое нарушено для $1/f$ -корреляций.

1.2. Конкретная задача

Мы хотим закрыть два конкретных пробела:

1. **Эмпирический пробел.** Систематического сравнения SGD/Adam/Clipped-SGD/Normalized-SGD на одних и тех же финансовых задачах при контролируемом типе шума (белый гауссов / розовый / α -устойчивый / смешанный) на сегодня нет. Существующие работы либо проверяют один оптимизатор [7], либо изолированно тестируют новый алгоритм на синтетике [5], [6], [8]. Мы строим единый воспроизводимый бенчмарк.
2. **Практический пробел.** Для квантовых ML-задач выработать таблицу рекомендаций «тип задачи (диагностика $\hat{\alpha}$, $\hat{H}$) $\rightarrow$ оптимизатор + threshold τ » с обоснованием. Сейчас практики в quant-finance используют Adam с настройками по умолчанию вне зависимости от того, какой режим шума на самом деле наблюдается.

Сверх нормы: теоретический анализ для одного из четырёх оптимизаторов в смешанном режиме N4 (опираясь на noise-averaging аргумент [9]) и эмпирический ablation L_p -Adam-семейства [3]. Эти задачи описаны в §«Возможные развития проекта» и не входят в баллы за обязательную часть.

2. Формальная постановка задачи

2.1. Целевая функция

Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R}$ — L -гладкая, в общем случае невыпуклая целевая функция (loss нейросетевой модели на финансовых данных). На k -й итерации алгоритм наблюдает стохастический градиент

$$g_k = \nabla f(x_k) + \xi_k,$$

где ξ_k — центрированный градиентный шум. В отличие от классического сеттинга, мы *не предполагаем* ни ограниченности второго момента, ни σ -алгебраической независимости ξ_k от $\xi_{k-1}, \xi_{k-2}, \dots$

2.2. Модель шума

Рассматриваем три параметрических класса шума:

- (N1) **Белый гауссов:** $\xi_k \sim \mathcal{N}(0, \sigma^2 I)$, i.i.d. (контрольный режим).
- (N2) **Розовый ($1/f$):** $\xi_k = \sum_{j=0}^{\infty} \psi_j \eta_{k-j}$, где $\eta_j \sim \mathcal{N}(0, \sigma^2 I)$ i.i.d., а коэффициенты FARIMA(0, d , 0) $\psi_j \sim j^{d-1}/\Gamma(d)$ при $d \in (0, 1/2)$. Спектральная плотность $S(f) \sim f^{-2d}$ (долгая память, конечная дисперсия).
- (N3) **Тяжёлохвостовой (α -устойчивый):** $\xi_k \sim S_{\alpha}(\sigma, 0, 0)$ покомпонентно, $\alpha \in (1, 2)$. $\mathbb{E}|\xi_k|^p < \infty$ только для $p < \alpha$.
- (N4) **Смешанный (главный для финансов):** $\xi_k = \sum_{j=0}^{\infty} \psi_j \zeta_{k-j}$, где $\zeta_j \sim S_{\alpha}$, ψ_j задаёт $1/f$ -спектр (FARIMA с α -устойчивыми инновациями).

2.3. Оптимизаторы

Сравниваем четыре алгоритма с обновлением $x_{k+1} = x_k - \eta_k \varphi(g_k)$:

1. **SGD:** $\varphi(g) = g$.
2. **Adam:** $\varphi(g_k) = m_k / (\sqrt{v_k} + \varepsilon)$ с экспоненциальными моментами m_k, v_k (см. [3]).
3. **Clipped-SGD:** $\varphi(g) = \min(1, \tau/\|g\|)g$ с порогом $\tau > 0$.
4. **Normalized-SGD with momentum:** $\varphi(g_k) = m_k / \|m_k\|$, где $m_k = \beta m_{k-1} + (1 - \beta)g_k$ (см. [10]).

2.4. Постановка цели

Для каждой комбинации (оптимизатор A) $\times$ (модель шума $\mathcal{N}$) изучить:

$$T(\varepsilon; A, \mathcal{N}) := \min \left\{ K : \mathbb{E} [\|\nabla f(x_K)\|^2] \leq \varepsilon \right\}$$

и его поведение по $\varepsilon, d, \sigma, \alpha, \beta$ (показатели тяжести/корреляции).

3. Метрики качества

Метрика	Описание	Тип
Empirical $T(\varepsilon)$	Число итераций до достижения $\ \nabla f\ \leq \varepsilon$ (медиана по 50 запускам).	количеств.
High-prob. bound	Эмпирический 95-й перцентиль $\ \nabla f(x_K)\ ^2$ vs. теоретическая верхняя оценка.	количеств.
Test loss / Sharpe	Качество получаемой модели на out-of-sample финансовых данных (для портфельных задач – Sharpe ratio).	количеств.
Tail-index recovery	Оценка $\hat{\alpha}$ градиентного шума по методу McCulloch / Hill после обучения; должна совпасть с инжектированным α .	диагност.
Dependence-test	Тест Ljung-Box и оценка показателя Хёрста H для $\ g_k\ $; проверка, что симулятор шума действительно даёт нужный $1/f$.	диагност.
Replicability	Все эксперименты воспроизводятся одной командой <code>make experiments</code> ; фиксированные seed, опубликованный код.	качеств.

Возможный отрицательный результат. Если для смешанного режима N4 никакая из четырёх настроек не даёт сходимости лучше, чем $O(K^{-\frac{\alpha-1}{\alpha}})$ (предсказание для независимого α -устойчивого шума), это будет *информативным* отрицательным результатом: он покажет, что $1/f$ -корреляция *не* замедляет существующие методы дополнительно. В этом случае мы документируем наблюдаемые перцентили и конкретные failure modes (например, Adam расходится для $\alpha < 1.7$ при FARIMA-корреляции с $d > 0.3$).

4. Обзор литературы

Ниже структурированный обзор по восьми направлениям, охватывающий 26 источников. Для каждой работы указана прямая ссылка на arXiv / DOI / PDF, чтобы можно было проверить релевантность независимо. Источники, отмеченные символом ★, — наиболее близкие к нашей постановке (тяжёлый и коррелированный шум) и определяют точное позиционирование проекта на ландшафте.

4.1. А. Тяжёлохвостовой градиентный шум в DL

Şimşekli, Sagun, Gürbüzbalaban (ICML 2019) [7] эмпирически продемонстрировали, что градиентный шум в нейросетях существенно тяжелее гауссова и хорошо описывается α -устойчивым распределением. Это *фундаментальная* работа, опровергающая привычное предположение CLT-аргумента о гауссовости шума.

arxiv.org/abs/1901.06053, код github.com/umutsimsekli/sgd_tail_index.

Gürbüzbalaban, Şimşekli, Zhu (ICML 2021) [11] доказали, что *даже при гауссовых данных* итерации SGD сходятся к тяжёлохвостовому стационарному распределению, причём индекс хвоста определяется отношением шага к размеру батча. Это аргумент, что тяжёлые хвосты – свойство *динамики* SGD, а не только данных.

arxiv.org/abs/2006.04740.

Nguyen, Şimşekli, Gürbüzbalaban, Richard (NeurIPS 2019) [12] получили оценку времени первого выхода SGD из бассейна локального минимума при α -устойчивом шуме. Мы можем напрямую переиспользовать формулы для предсказания, как часто SGD будет «выпрыгивать»

при разных α на финансовых данных.

arxiv.org/abs/1906.09069.

Battash, Lindenbaum (AISTATS 2024) [13] обновили эмпирический анализ: показали, что разные параметры сети имеют разные индексы хвоста и что нужен не один глобальный α , а покомпонентная модель. Методологически важно для нашего эксперимента (как *измерять α*).

arxiv.org/abs/2303.02749.

4.2. В. Сходимость с обрезанием градиентов

Zhang, He, Sra, Jadbabaie (ICLR 2020) [14] предложили условие (L_0, L_1) -гладкости и доказали, что Clipped-SGD имеет лучшую скорость сходимости, чем SGD, на функциях с переменной локальной кривизной. Базовая работа, обосновывающая использование клиппинга.

arxiv.org/abs/1905.11881.

Zhang, Karimireddy, Veit и др. (NeurIPS 2020) [15] показали, что adaptive-методы (Adam) эквивалентны покоординатному клиппингу, и дали первые тесные оценки на сходимость при тяжёлом шуме. Прямо обосновывает наш выбор сравнения Adam vs Clipped-SGD vs Normalized-SGD.

arxiv.org/abs/1912.03194.

Gorbunov, Danilova, Gasnikov (NeurIPS 2020) [5] получили первые high-probability bounds для ускоренного клиппированного SGD при ограниченном $(1 + \alpha)$ -моменте шума, $\alpha \in (0, 1]$. Это наш *основной* теоретический baseline для Clipped-SGD на α -стабильном шуме.

arxiv.org/abs/2005.10785, код github.com/eduardgorbunov/accelerated_clipping.

Koloskova, Hendrikx, Stich (ICML 2023) [16] показали, что клиппинг вносит неустранимое смещение, мешающее сходимости к точному оптимуму, и количественно охарактеризовали зависимость от порога τ . Критический caveat для нашего сравнения: Clipped-SGD не обязательно «лучше» даже при тяжёлом шуме.

arxiv.org/abs/2305.01588.

Nguyen, Ene, Nguyen (2023) [17] получили time-optimal high-probability bounds для Clipped-SGD при $\mathbb{E}\|g\|^p < \infty$, $p \in (1, 2]$. Это в точности тот режим, в который попадают финансовые доходности (типичный $\alpha \approx 1.7$), значит – прямо применимая теоретическая оценка.

arxiv.org/abs/2302.05437.

4.3. С. Сходимость Adam

Kingma, Ba (ICLR 2015) [3] – оригинальный Adam, обязательная ссылка для нашего benchmark.

arxiv.org/abs/1412.6980.

Reddi, Kale, Kumar (ICLR 2018, best paper) [4] показали расходимость Adam на простой выпуклой задаче и предложили AMSGrad. Прямо относится к нашему опасению, что Adam может расходиться при не-гауссовом финансовом шуме.

arxiv.org/abs/1904.09237.

Défossez, Bottou, Bach, Usunier (TMLR 2022) [18] дали наиболее чистое доказательство сходимости Adam/Adagrad для невыпуклого случая при ограниченных градиентах. Используем как теоретический baseline, от которого будем мерить деградацию при нарушении ограниченности.

arxiv.org/abs/2003.02395.

4.4. D. Нормированный и знаковый градиент

Cutkosky, Mehta (ICML 2020) [10] доказали, что Normalized-SGD with momentum достигает $O(1/\varepsilon^{3.5})$ без больших батчей. Прямо обосновывает выбор Normalized-SGD как четвёртого

оптимизатора в нашем сравнении.

arxiv.org/abs/2002.03305.

Bernstein и др. (ICML 2018) [19] – signSGD, предельный случай нормировки. Полезен как sanity-check: какой ценой полное игнорирование амплитуды шума.

arxiv.org/abs/1802.04434.

Hübler, Fatkhullin, He (AISTATS 2025) [6] показали, что Normalized-SGD достигает parameter-free сложности $O(\varepsilon^{-2p/(p-1)})$ при тяжёлом шуме, без необходимости огромных порогов клиппинга. *Самый прямой* теоретический аргумент в пользу Normalized-SGD против Clipped-SGD на финансовых данных.

arxiv.org/abs/2410.13849.

★ **Liu, Zhou (ICLR 2025)** [8] параллельно показали, что Batched Normalized SGD with Momentum (Batched NSGDM) достигает оптимальной скорости $O(T^{(1-p)/(3p-2)})$ при тяжёлом шуме *без клиппинга*, причём впервые – даже когда индекс хвоста p заранее неизвестен (получают $O(T^{(1-p)/(2p)})$). Усиливает аргумент [6] и важно для нашего бенчмарка: даёт нам теоретический baseline для безпараметрической версии Normalized-SGD на финансовых данных, где $\hat{p}$ может быть неточно оценён.

arxiv.org/abs/2412.19529.

Armacki, Yu, Sharma и др. (AISTATS 2025) [20] построили *единый* high-probability фреймворк для нелинейных модификаций SGD (Clipping, Sign, Quantization, Normalization) под тяжёлым шумом, где конкретная нелинейность трактуется как black-box. Получают для невыпуклых задач $\tilde{O}(t^{-1/4})$, не зависящую от p , и показывают, что clipping не всегда оптимален. Прямо мотивирует структуру нашего бенчмарка: четыре наших оптимизатора – частные случаи общей схемы $\varphi(g)$.

arxiv.org/abs/2310.18784.

4.5. Е. Стилизованные факты финансовых временных рядов

Cont (Quantitative Finance, 2001) [1] – канонический каталог 11 стилизованных фактов: тяжёлые хвосты доходностей, кластеризация волатильности, долговременная память абсолютных доходностей. Эмпирический фундамент нашей мотивации.

DOI 10.1080/713665670, PDF: rama.cont.perso.math.cnrs.fr.

Mandelbrot (Journal of Business, 1963) [21] – исторический аргумент в пользу α -устойчивых распределений с бесконечной дисперсией для цен. Концептуальный мост между α -стабильным шумом в DL и финансовыми наблюдениями.

PDF: e-m-h.org/Mand63.pdf.

Lux, Marchesi (Nature 397, 1999) [2] воспроизвели одновременно тяжёлые хвосты *и* долговременную волатильность в агентной модели рынка. Механистическое объяснение, почему градиенты, вычисленные на финансовых данных, будут демонстрировать одновременно $1/f$ -поведение и α -стабильные хвосты (наша модель шума N4).

nature.com/articles/17290.

4.6. F. α -стабильные / Lévy-методы и коррелированный шум

★ **Chandak, Yadav, Özgür, Bambos (arXiv 2603.19648, март 2026)** [9] – *ключевая* свежая работа: впервые получает finite-time оценки сходимости для стохастической аппроксимации (включая SGD) одновременно в двух неклассических режимах – (i) тяжёлохвостовом (p -й момент с $p \in (1, 2)$) и (ii) долговременно-зависимом (FARIMA(0, c , 0), fGn с показателем Хёрста $H \in (1/2, 1)$). Авторы используют noise-averaging аргумент, сглаживающий влияние корреляции *без* модификации алгоритма. Это прямой precedent нашей задачи; наша новизна теперь сужается до: (а) *смешанного* режима N4, где LRD-фильтр управляется α -устойчивыми инновациями

(Chandak рассматривает либо HT, либо LRD, но не их комбинацию), (б) явной специализации оценок на Adam / Clipped-SGD / Normalized-SGD, (в) реальных финансовых данных.

arxiv.org/abs/2603.19648.

Şimşekli (ICML 2017) [22] построил MCMC-сэмплеры на α -стабильных Lévy-SDE. Алгоритмический blueprint для дискретизации SDE при инъекции α -стабильного шума в наших симуляциях.

arxiv.org/abs/1706.03649.

Vivarelli, Mannella (2024) [23] – одна из немногих работ, прямо ослабляющих предположение белого шума в анализе SGD: исследуют, как временная корреляция меняет стационарное распределение весов. Прямо относится к нашему режиму $1/f$.

arxiv.org/abs/2306.05300.

4.7. G. Финансовый прикладной мост

Sirignano, Cont (Quantitative Finance, 2019) [24] обучили глубокую сеть на миллиардах событий стакана и показали универсальные закономерности price formation. Канонический real-world target для бенчмарка нашего сравнения оптимизаторов.

arxiv.org/abs/1803.06917.

Petrosyan (arXiv 2601.04490, январь 2026) [25] предлагает взвешенную метрику Колмогорова, восстанавливающую гауссовскую скорость сходимости $O(n^{-1/2})$ для эмпирических распределений с тяжёлыми хвостами ($\mathbb{E}|X|^2 < \infty$, но $\mathbb{E}|X|^3 = \infty$ – типичный режим high-frequency и crypto). Методологическая параллель нашему вопросу: как восстановить классические гарантии при нарушении предположений. Возможный downstream-инструмент для валидации моделей, обученных нашими оптимизаторами, на out-of-sample крипто-данных.

arxiv.org/abs/2601.04490.

Mishra, Kumar, Fida, Kalaš (Mathematics, 2025) [26] построили risk-sensitive RL-фреймворк (CVaR-objective) для портфельной оптимизации на NIFTY 50, доказали сходимость actor-critic при стандартных предположениях. Релевантно для нашего раздела о развитии проекта (RL-сеттинг): показывает, что в современной литературе RL-портфельная оптимизация делается *в предположении* классической сходимости – значит проверка этих предположений в наших трёх режимах шума – открытая ниша.

DOI: [10.3390/math14081334](https://doi.org/10.3390/math14081334).

4.8. Где наш проект на этом ландшафте

Существующие работы покрывают:

- *тяжёлый шум, независимый* (A, B, C, D) – богатая теория и практика, четвёрка наших оптимизаторов разобрана подробно;
- *коррелированный шум, гауссов* (F, частично) – мало, но появилось [23];
- *коррелированный + тяжёлый шум* – только Chandak et al. [9] (март 2026), и то для общей SA, без специализации на конкретные оптимизаторы и без α -стабильных LRD-инноваций;
- *финансовые стилизованные факты* (E, G) – развитая прикладная литература, но без связи с теорией оптимизации.

Никто из перечисленных *не предоставляет* единого эмпирического сравнения четырёх популярных оптимизаторов на финансовых данных с диагностикой полученного градиентного шума. Это и есть *эмпирическая* ниша, которую закрывает наша обязательная часть:

(E1) Конкретное эмпирическое сравнение *именно* четырёх baseline-оптимизаторов (SGD / Adam / Clipped-SGD / Normalized-SGD) на *одних и тех же* синтетических задачах при четырёх контролируемых режимах шума N1–N4.

(Е2) Реальные финансовые данные (S&P 500, LOBSTER NASDAQ) с *диагностикой* $\hat{\alpha}$, $\hat{H}$ *полученного* градиентного шума – сопоставление наблюдаемого режима с предсказаниями baseline-теории.

(Е3) Практическая шпаргалка по выбору оптимизатора для quant-finance.

Сверхнормативная (опциональная) задача: использовать noise-averaging аргумент [9] для расширения теории на смешанный N4-режим с α -устойчивыми инновациями (этого не делал никто, см. §«Возможные развития проекта»).

4.9. Воспроизводимый код

Существуют публичные репозитории по двум ключевым работам, которые мы используем как стартовый код:

- github.com/umutsimsekli/sgd_tail_index – оценка α градиентного шума;
- github.com/eduardgorbunov/accelerated_clipping – референс-имплементация Clipped-SGD с теоретически обоснованным шагом.

Финансовые датасеты будем брать из открытых источников: дневные доходности S&P 500 (Yahoo Finance, 30+ лет), high-frequency LOBSTER NASDAQ (пробный период), синтетические данные через GARCH(1,1) и модель Lux–Marchesi.

5. Детальный план работ

Этап	Задача	Срок	Ответств.
Е1	Реализация генератора шума: гауссов, FARIMA(0, d , 0), α -стабильный (Chambers–Mallows–Stuck), смешанный. Тесты на восстановление $\hat{\alpha}$, $\hat{d}$.	+1 нед.	Шадрин
Е2	Имплементация четырёх оптимизаторов в едином API (PyTorch): SGD, Adam, Clipped-SGD, Normalized-SGD. Каждый с поддержкой фиксированного и cosine-расписания шага, momentum, варьируемых порогов. Базовый smoke-test на квадратичной задаче.	+1 нед.	Дубовицкий
Е3	Синтетический эксперимент: квадратичная и логистическая задача, инъекция шумов N1–N4, измерение $T(\varepsilon)$ и 95-го перцентиля $\ \nabla f\ ^2$ по 50 запускам, построение кривых сходимости. Цель – <i>воспроизвести</i> baseline-результаты [5], [6], [8] на единой синтетической задаче, чтобы калибровать ожидания для реального эксперимента.	+2 нед.	Дубовицкий, Шадрин
Е4	Реальный эксперимент: предсказание знака доходности S&P 500 (1990–2020) и high-frequency LOBSTER NASDAQ, MLP/LSTM. Двунаправленный анализ: (а) обучить четыре оптимизатора с настройками по умолчанию; (б) собрать траектории градиента g_k , оценить $\hat{\alpha}$ по методу McCulloch и $\hat{H}$ через R/S-статистику и DFA, как в [7] и [13]; (в) сопоставить наблюдаемый режим с предсказаниями baseline-теории. Сравнение по out-of-sample test loss и Sharpe.	+2 нед.	Кортунов, Пастушенко

Этап	Задача	Срок	Ответств.
Е5	Анализ результатов и сборка: построить таблицу рекомендаций « $\hat{\alpha}, \hat{H} \rightarrow$ оптимизатор + порог τ »; формализовать наблюдаемые failure modes (Adam расходится при каких условиях? Clipped-SGD насколько чувствителен к τ ?); подготовка кода, README, шпаргалки.	+1.5 нед.	Все

Сверх нормы (опционально, если останется время в конце Е5): теоретический анализ для одного оптимизатора в режиме N4 через noise-averaging [9] и ablation L_p -Adam-семейства [3]; см. раздел «Возможные развития проекта».

6. Outcomes

В результате работы будет получено:

Обязательная часть проекта.

- Открытый репозиторий** (Python/PyTorch, MIT) с (а) реализацией четырёх оптимизаторов (SGD, Adam, Clipped-SGD, Normalized-SGD) в едином API; (б) генератором четырёх типов шума (gaussian, FARIMA, α -stable, mixed) с unit-тестами на восстановление $\hat{\alpha}, \hat{H}$; (в) воспроизводимыми скриптами `make experiments`, фиксированными seed.
- Синтетический бенчмарк:** таблица 4×4 «оптимизатор $\times$ режим шума» с метриками $T(\varepsilon)$, 95-й перцентиль $\|\nabla f(x_K)\|^2$, медиана и 90-й перцентиль кривых сходимости по 50 запускам. CSV + графики.
- Финансовый бенчмарк:** те же четыре оптимизатора на S&P 500 (предсказание знака доходности) и LOBSTER NASDAQ (forecasting спреда). Метрики: cross-entropy / MSE на validation, Sharpe ratio long/short стратегии на тесте. Диагностика $\hat{\alpha}, \hat{H}$ полученного градиентного шума.
- Практическая рекомендация:** одностраничная «шпаргалка» для квантовых ML-практиков: диагностический протокол ($\hat{\alpha} < 1.8?$ $\hat{H} > 0.6?$) $\rightarrow$ выбор оптимизатора и порога τ .
- Письменный отчёт** (≈ 10 –12 страниц, Typst) и презентация.

Сверх нормы (см. раздел «Возможные развития проекта»): теоретический анализ для одного оптимизатора в режиме N4 и эмпирический ablation L_p -Adam-семейства [3].

7. Возможные развития проекта

Эти задачи *не входят* в обязательную часть и оцениваются как сверхнормативные. Они опираются на результаты обязательной части (собранный бенчмарк + диагностика $\hat{\alpha}, \hat{H}$ на финансовых данных) и расширяют их в трёх направлениях: алгоритмическое расширение, теория, прикладные постановки. В порядке убывания перспективности:

- Эмпирический ablation L_p -Adam-семейства.** Kingma и Ba [3] в §7.1 оригинальной статьи об Adam написали обобщение со степенным моментом $v_t = \beta_2^p v_{t-1} + (1 - \beta_2^p)|g_t|^p$ и обновлением $m_t/v_t^{1/p}$, после чего сразу же специализировались на пределе $p \rightarrow \infty$ (это и есть Adamax). Промежуточный режим $p \in (1, 2)$ ими не исследован. *Гипотеза:* при α -устойчивом градиентном шуме оптимальный $p^* \approx \alpha$ (поскольку $\mathbb{E}|g|^p < \infty$ только при $p < \alpha$). Эксперимент: ablation по $p \in \{1.1, 1.3, 1.5, 1.7, 2.0\}$ на наших задачах из Е3–Е4, поиск зависимости $p^*(\hat{\alpha})$. Дополнительная идея: онлайн-оценка $\hat{\alpha}_t$ и адаптивный $p_t = (1 - \delta)\hat{\alpha}_t$ – этого нет ни в [3], ни в последующей литературе.

2. **Теоретический анализ для смешанного режима N4.** Применить noise-averaging аргумент [9] (март 2026, для общей стохастической аппроксимации) к одному из четырёх baseline-оптимизаторов. Конкретный таргет – получить оценку $\mathbb{E}\|\nabla f(x_K)\|^2 = O(K^{-r(\alpha, H)})$ для Clipped-SGD при FARIMA- α -стабильном шуме. Резерв: если общий случай не выйдет, доказать для квадратичной задачи или для упрощённой LRD-модели (FARIMA(0, d , 0) с малым d).
3. **Адаптивный клиппинг по оценке хвоста.** Вместо фиксированного τ оценивать $\hat{\alpha}_k$ онлайн (Hill по последним W норм градиента) и подбирать τ_k из теоретически оптимальной формулы [5]. Ожидаемая выгода: parameter-free алгоритм без перебора τ .
4. **Перенос на RL-сеттинг для портфельной оптимизации.** Reward-сигнал в финансовом RL экстремально шумный и тяжелохвостовой. Сравнить PPO+Adam vs PPO+Clipped-SGD vs PPO+Normalized-SGD на задаче optimal execution или market making (LOB-симулятор). [26] недавно построили risk-sensitive RL-фреймворк (CVaR-objective, NIFTY 50) и доказали сходимости в *классических* предположениях. Открытая ниша – проверить эти предположения в наших трёх режимах шума (N2–N4) и переоценить гарантии.
5. **Обобщение теории на немонотонный β_2 в Adam.** Несходимость Adam [4] связана с тем, что v_t может убывать. При тяжёлом шуме это происходит чаще. Можно попробовать вывести условие на $\beta_2(\alpha)$, гарантирующее сходимость. Связано с AMSGrad, но в новом режиме шума.
6. **Распределённый сеттинг.** Federated learning между банками: данные имеют тяжёлые хвосты у каждого участника, плюс асинхронность добавляет $1/f$ -корреляцию. Известно, что тяжёлый шум усиливает атаки Byzantine (ϵ -атакующий легко мимикрирует под «хвост»). Связь с [Nguyen et al., 2023](#) и литературой по robust aggregation.
7. **Связь с обобщающей способностью.** Гипотеза [7]: тяжёлые хвосты SGD – *причина* хорошей обобщающей способности. Если в финансовом сеттинге шум уже тяжёлый сам по себе, нужно ли применять регуляризацию через дополнительный шум? Эксперимент: сравнить Dropout + SGD vs no-Dropout + SGD на heavy-tailed задаче.
8. **Альтернативные модели шума.** Вместо α -стабильного – tempered stable (хвост заваливается на больших масштабах, что более реалистично для регулируемых рынков). Анализ сходимости в этом промежуточном режиме практически не сделан.
9. **Теоретико-информационная нижняя оценка.** Получить нижнюю оценку $T(\epsilon) \geq \Omega(\dots)$ для любого алгоритма первого порядка в режиме N4. Это покажет, насколько близко наши верхние оценки к оптимуму.
10. **Эмпирическое исследование «обратного эффекта».** Построить тест: можно ли по виду loss-curve (медленная сходимость, всплески) автоматически детектировать тип шума и переключать оптимизатор on-the-fly. По сути – meta-optimizer.
11. **Робастный backtesting на crypto/HFT-данных.** [25] предложил взвешенную метрику Колмогорова, восстанавливающую гауссовскую скорость сходимости при $\mathbb{E}X^3 = \infty$. Применить эту метрику к out-of-sample валидации моделей, обученных нашими оптимизаторами, на crypto-данных, где наша гипотеза о тяжёлых хвостах градиентов наиболее активна. Связывает оптимизационную часть проекта с прикладной валидацией.
12. **Расширение эксперимента на единый black-box фреймворк нелинейностей.** [20] рассматривают Clipping/Sign/Quantization/Normalization как частные случаи общего $\varphi(g)$. Систематически протестировать пространство нелинейностей (например, soft-clipping tanh, степенные нормировки $g/\|g\|^q$, $q \in [0, 1]$) и построить *кривую Парето* «скорость сходимости vs устойчивость к хвостам».

8. Личный вклад участников (планируемый)

Участник	Зона ответственности
Кортунов Дмитрий	Координация, теоретическая часть (E5), реальный эксперимент (E4), общая редакция отчёта.
Пастушенко Вадим	Сбор и предобработка финансовых данных, реальный эксперимент (E4), валидация tail-index estimator-ов.
Дубовицкий Алексей	Имплементация оптимизаторов (E2), синтетические эксперименты (E3), CI и repository hygiene.
Шадрин Андрей	Генератор шума (E1), оценка $\hat{H}$ и $\hat{\alpha}$, графики и визуализация, презентация.

9. Список литературы

- [1] R. Cont, «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues», *Quantitative Finance*, т. 1, вып. 2, сс. 223–236, 2001, doi: [10.1080/713665670](https://doi.org/10.1080/713665670).
- [2] T. Lux и M. Marchesi, «Scaling and Criticality in a Stochastic Multi-Agent Model of a Financial Market», *Nature*, т. 397, вып. 6719, сс. 498–500, 1999, doi: [10.1038/17290](https://doi.org/10.1038/17290).
- [3] D. P. Kingma и J. Ba, «Adam: A Method for Stochastic Optimization», в *International Conference on Learning Representations (ICLR)*, 2015. [Онлайн]. Доступно на: <https://arxiv.org/abs/1412.6980>
- [4] S. J. Reddi, S. Kale, и S. Kumar, «On the Convergence of Adam and Beyond», в *International Conference on Learning Representations (ICLR)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1904.09237>
- [5] E. Gorbunov, M. Danilova, и A. Gasnikov, «Stochastic Optimization with Heavy-Tailed Noise via Accelerated Gradient Clipping», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/2005.10785>
- [6] F. Hübler, I. Fatkhullin, и N. He, «From Gradient Clipping to Normalization for Heavy Tailed SGD», в *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2025. [Онлайн]. Доступно на: <https://arxiv.org/abs/2410.13849>
- [7] U. Şimşekli, L. Sagun, и M. Gürbüzbalaban, «A Tail-Index Analysis of Stochastic Gradient Noise in Deep Neural Networks», в *Proceedings of the 36th International Conference on Machine Learning (ICML)*, в PMLR, vol. 97. 2019, сс. 5827–5837. [Онлайн]. Доступно на: <https://arxiv.org/abs/1901.06053>
- [8] Z. Liu и Z. Zhou, «Nonconvex Stochastic Optimization under Heavy-Tailed Noises: Optimal Convergence without Gradient Clipping», в *International Conference on Learning Representations (ICLR)*, 2025. [Онлайн]. Доступно на: <https://arxiv.org/abs/2412.19529>
- [9] S. Chandak, A. K. Yadav, A. Özgür, и N. Bambos, «Heavy-Tailed and Long-Range Dependent Noise in Stochastic Approximation: A Finite-Time Analysis», в *arXiv preprint arXiv:2603.19648*, 2026. [Онлайн]. Доступно на: <https://arxiv.org/abs/2603.19648>
- [10] A. Cutkosky и H. Mehta, «Momentum Improves Normalized SGD», в *International Conference on Machine Learning (ICML)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/2002.03305>
- [11] M. Gürbüzbalaban, U. Şimşekli, и L. Zhu, «The Heavy-Tail Phenomenon in SGD», в *International Conference on Machine Learning (ICML)*, 2021. [Онлайн]. Доступно на: <https://arxiv.org/abs/2006.04740>
- [12] T. H. Nguyen, U. Şimşekli, M. Gürbüzbalaban, и G. Richard, «First Exit Time Analysis of Stochastic Gradient Descent Under Heavy-Tailed Gradient Noise», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2019. [Онлайн]. Доступно на: <https://arxiv.org/abs/1906.09069>
- [13] B. Battash и O. Lindenbaum, «Revisiting the Noise Model of Stochastic Gradient Descent», в *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2024. [Онлайн]. Доступно на: <https://arxiv.org/abs/2303.02749>
- [14] J. Zhang, T. He, S. Sra, и A. Jadbabaie, «Why Gradient Clipping Accelerates Training: A Theoretical Justification for Adaptivity», в *International Conference on Learning Representations (ICLR)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/1905.11881>
- [15] J. Zhang и др., «Why are Adaptive Methods Good for Attention Models?», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/1912.03194>
- [16] A. Koloskova, H. Hendrikx, и S. U. Stich, «Revisiting Gradient Clipping: Stochastic Bias and Tight Convergence Guarantees», в *International Conference on Machine Learning (ICML)*, 2023. [Онлайн]. Доступно на: <https://arxiv.org/abs/2305.01588>
- [17] T. D. Nguyen, A. Ene, и H. L. Nguyen, «High Probability Convergence of Clipped-SGD Under Heavy-tailed Noise», *arXiv preprint arXiv:2302.05437*, 2023, [Онлайн]. Доступно на: <https://arxiv.org/abs/2302.05437>

- [18] A. Défossez, L. Bottou, F. Bach, и N. Usunier, «A Simple Convergence Proof of Adam and Adagrad», *Transactions on Machine Learning Research (TMLR)*, 2022, [Онлайн]. Доступно на: <https://arxiv.org/abs/2003.02395>
- [19] J. Bernstein, Y.-X. Wang, K. Azizzadenesheli, и A. Anandkumar, «signSGD: Compressed Optimisation for Non-Convex Problems», в *International Conference on Machine Learning (ICML)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1802.04434>
- [20] A. Armacki и др., «High-Probability Convergence Bounds for Online Nonlinear Stochastic Gradient Descent under Heavy-Tailed Noise», в *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2025. [Онлайн]. Доступно на: <https://arxiv.org/abs/2310.18784>
- [21] B. Mandelbrot, «The Variation of Certain Speculative Prices», *Journal of Business*, т. 36, вып. 4, сс. 394–419, 1963, [Онлайн]. Доступно на: <http://www.e-m-h.org/Mand63.pdf>
- [22] U. Şimşekli, «Fractional Langevin Monte Carlo: Exploring Lévy Driven Stochastic Differential Equations for Markov Chain Monte Carlo», в *International Conference on Machine Learning (ICML)*, 2017. [Онлайн]. Доступно на: <https://arxiv.org/abs/1706.03649>
- [23] M. Vivarelli и R. Mannella, «Correlated Noise in Epoch-Based Stochastic Gradient Descent: Implications for Weight Variances», *arXiv preprint arXiv:2306.05300*, 2024, [Онлайн]. Доступно на: <https://arxiv.org/abs/2306.05300>
- [24] J. Sirignano и R. Cont, «Universal Features of Price Formation in Financial Markets: Perspectives from Deep Learning», *Quantitative Finance*, т. 19, вып. 9, сс. 1449–1459, 2019, [Онлайн]. Доступно на: <https://arxiv.org/abs/1803.06917>
- [25] A. Petrosyan, «Restoring Convergence in Heavy-Tailed Risk Models: A Weighted Kolmogorov Approach for Robust Backtesting», *arXiv preprint arXiv:2601.04490*, 2026, [Онлайн]. Доступно на: <https://arxiv.org/abs/2601.04490>
- [26] B. K. Mishra, M. Kumar, H. Fida, и B. Kalaš, «Risk-Sensitive Reinforcement Learning for Portfolio Optimization Under Stochastic Market Dynamics», *Mathematics*, т. 14, вып. 8, с. 1334, 2025, doi: [10.3390/math14081334](https://doi.org/10.3390/math14081334).