

Beyond Gaussian Noise: Optimizers under Correlated and Heavy-Tailed Financial Noise

Project Proposal · НИУ ВШЭ · 26 апреля 2026 г.

Кортунов Д., Пастушенко В., Дубовицкий А., Шадрин А.

Аннотация. Финансовые временные ряды содержат шум различной природы: гауссов, тяжёлохвостовый, коррелированный и их комбинации. Прямая подача таких данных в стандартные стохастические оптимизаторы нарушает базовые предположения теории сходимости. Мы исследуем альтернативный подход: перед оптимизацией применяется этап шумоподавления — скользящее среднее, фильтр Калмана, вейвлет-пороговая обработка или медианная фильтрация, — после чего ряд подаётся в SGD, Adam или AdamW. Основной вопрос: насколько выбор фильтра влияет на скорость сходимости и итоговое качество модели, и можно ли подобрать пару (фильтр, оптимизатор), устойчивую к нескольким типам шума одновременно?

1. Введение

В обучении на финансовых временных рядах стандартно фокусируются либо на выборе архитектуры модели, либо на модификациях оптимизатора. При этом сама структура входного шума часто остаётся «за кадром», хотя для финансовых данных именно она задаёт сложность обучения: тяжёлые хвосты, долгая память и выбросы нарушают предпосылки, при которых гарантируется стабильная работа классических стохастических методов.

В проекте мы рассматриваем шумоподавление не как вспомогательную технику визуализации, а как полноценную часть оптимизационного контура. Гипотеза состоит в том, что правильная предобработка может существенно изменить свойства градиентного шума и тем самым ускорить сходимость без усложнения самого оптимизатора.

Эмпирически мы сравниваем матрицу (тип шума) $\times$ (фильтр) $\times$ (оптимизатор) на синтетических и реальных финансовых данных и получаем ответ на практический вопрос: когда предобработка действительно помогает, а когда её эффект минимален или даже вреден из-за пересглаживания полезного сигнала.

2. Постановка

Минимизируем L -гладкую функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$ по параметрам модели. Наблюдаемый временной ряд $y_1, \dots, y_T$ задаётся как

$$y_t = s_t + \xi_t,$$

где s_t — «сигнал» (истинное движение цены), а ξ_t — шум. Мы рассматриваем четыре класса шума.

N1 (гауссов белый): $\xi_t \sim \mathcal{N}(0, \sigma^2)$ — контрольный режим, соответствующий стандартным допущениям теории.

N2 (розовый, $1/f$): $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$ с гауссовыми η_j и FARIMA(0, d , 0)-весами, $d \in (0, 1/2)$; дисперсия конечна, но есть долгая память.

N3 (тяжёлохвостовый): $\xi_t \sim S_{\alpha(\sigma, 0, 0)}$ покомпонентно, $\alpha \in (1, 2)$; конечен только p -й момент при $p < \alpha$.

N4 (смешанный): $\xi_t = \sum_{j \geq 0} \psi_j \zeta_{t-j}$, где ζ_j i.i.d. α -устойчивые, а ψ_j задают $1/f$ -спектр; тяжёлые хвосты и долгая память присутствуют одновременно.

Перед подачей в оптимизатор ряд $y_1, \dots, y_T$ обрабатывается одним из четырёх фильтров.

F1 (скользящее среднее, МА): $\hat{s}_t = (1/w) \sum_{i=0}^{w-1} y_{t-i}$; простейший линейный фильтр, смещает ряд на $w/2$ шагов.

F2 (фильтр Калмана): предполагает линейную модель состояния $s_t = As_{t-1} + w_t$; оценивает $\hat{s}_t$ рекуррентно, оптимален при гауссовом шуме [1].

F3 (вейвлет-пороговая обработка): разложение по базису Добеши, жёсткое или мягкое пороговое отсечение коэффициентов детализации, обратное преобразование [2], [3]. Хорошо справляется с локальными всплесками (тяжёлые хвосты).

F4 (медианная фильтрация): $\hat{s}_t = \text{median}(y_{t-\frac{w}{2}}, \dots, y_{t+\frac{w}{2}})$; не требует гауссовости, устойчив к выбросам [4].

Протокол сравнения начинается с baseline: каждый оптимизатор сначала запускается на исходном ряде без какой-либо фильтрации (режим F0), и только после этого тестируются режимы F1–F4. Это даёт прямую оценку вклада предобработки в сходимость и качество.

Технически мы реализуем предобработку как внутренний модуль оптимизации: внешне модель обучается на исходных наблюдениях, но на шаге обновления оптимизатор использует сглаженную версию входного ряда (или сглаженный градиентный сигнал) в зависимости от выбранной конфигурации. Такой дизайн позволяет корректно сравнить «без сглаживания» и «со сглаживанием» в одном API без изменения остального кода обучения.

После выбора режима (F0–F4) получаем ряд, по которому считаем градиенты и запускаем один из трёх оптимизаторов:

- SGD с постоянным шагом: $x_{k+1} = x_k - \eta \nabla f(x_k)$;
- Adam [5]: адаптивный шаг с моментами первого и второго порядка;
- AdamW [6]: Adam с корректным L_2 -регуляризатором.

Главная величина — эмпирическое время до ε -точности $T(\varepsilon; F, A, \mathcal{N}) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\}$ для каждой тройки (фильтр F , оптимизатор A , тип шума $\mathcal{N}$).

3. Метрики

По итогам экспериментов вычисляем следующие характеристики.

Кривая сходимости $\mathbb{E}\|\nabla f(x_k)\|^2$ от номера итерации: медиана и 90-й перцентиль по нескольким десяткам независимых запусков. Это основной результат для синтетических задач.

Качество на отложенной выборке (MSE или log-правдоподобие) для задач прогнозирования на реальных финансовых рядах.

Степень подавления шума: SNR до и после фильтрации для каждой пары (фильтр, тип шума). Позволяет понять, насколько хорошо фильтр «подготовил» ряд.

Искажение структуры ряда: оценка показателя Хёрста $\hat{H}$ и, при необходимости, индекса хвоста $\hat{\alpha}$ — до и после фильтрации. Слишком агрессивный фильтр может убрать вместе с шумом полезный сигнал.

Отрицательный результат тоже содержателен: если окажется, что все пары (фильтр, оптимизатор) дают схожую сходимость на реальных данных, это само по себе говорит о низкой чувствительности оптимизатора к предобработке — что является практически важным выводом.

4. Обзор литературы

Фильтрация временных рядов. Фильтр Калмана [1] — классический байесовский метод оценки состояния при линейной гауссовой модели; активно применяется в финансах для сглаживания цен и скрытых компонент [7]. Вейвлет-методы шумоподавления были систематизированы Donoho и Johnstone [2], которые показали оптимальность мягкого порога в классе кусочно-гладких функций; базисы Добеши [8] наиболее распространены на практике. Общую теорию вейвлет-разложений временных рядов описывает Mallat [3]. Медианная фильтрация и её обобщения разобраны у Yin и др. [4]; она устойчива к выбросам там, где линейные фильтры дают утечку. Скользящее среднее — простейший базовый случай; его свойства в контексте финансовых рядов обсуждают Hamilton [9] и Tsay [10].

Природа финансового шума и актуальность задачи. Cont [11] перечисляет одиннадцать «стилизированных фактов» финансовых доходностей — тяжёлые хвосты, кластеризация волатильности, долгая память абсолютных доходностей. Mandelbrot [12] ещё в 1963 году предлагал моделировать цены α -устойчивыми распределениями. Şimşekli, Sagun и Gürbüzbalaban [13] эмпирически показали, что градиентный шум при обучении нейросетей не гауссов, а близок к α -устойчивому. Chandak, Yadav, Özgür и Bambos [14] (март 2026) — единственная известная нам работа, в которой одновременно разбирается тяжёлохвостовый и долговременно-зависимый шум в стохастической аппроксимации.

Стохастические оптимизаторы и опорные результаты. Kingma и Ba [5] предложили Adam, обоснование его сходимости при ограниченных градиентах дано у Défossez и др. [15]. Reddi, Kale и Kumar [16] показали, что Adam может расходиться на выпуклых задачах, и предложили AMSGrad. Loshchilov и Hutter [6] уточнили, как правильно совмещать Adam с L_2 -регуляризацией. Классическая теория SGD изложена у Robbins и Monro [17]; современный анализ сходимости при тяжёлом шуме — у Gorbunov, Danilova и Gasnikov [18].

Что уже известно и почему этого недостаточно. В близких постановках достигнуты два сильных класса результатов: (i) для фильтрации хорошо понятны свойства отдельных методов (Калман, вейвлеты, медиана, скользящее среднее), (ii) для оптимизации есть теоретические оценки сходимости SGD/Adam-типов при разных предположениях о шуме. Более простые формулировки — это анализ «чисто гауссового» или независимого шума, а также изучение только одной стороны пайплайна (либо фильтр, либо оптимизатор). Наша задача сложнее: совместное влияние фильтрации и оптимизации при тяжёлохвостовом и коррелированном шуме.

Ключевые опорные источники для понимания постановки: Cont и Mandelbrot для феноменологии финансовых рядов, Donoho/Mallat/Daubechies для механики шумоподавления, Kingma-Reddi-Défossez-Loshchilov для поведения Adam-семейства, Robbins-Monro и Gorbunov et al. для базовой логики стохастической сходимости. По воспроизводимости: у части современных работ по оптимизации и heavy-tailed шуму доступны открытые реализации или неофициальные репозитории, но единого открытого benchmark-а вида (фильтр $\times$ шум $\times$ оптимизатор) на финансовых рядах мы не нашли. Это и определяет практическую ценность нашего эксперимента.

5. План работ

Работа разбивается на содержательные этапы.

Сначала реализуем генератор четырёх классов шума N1–N4 и проверяем, что обратные оценки $\hat{\alpha}$ и $\hat{H}$ восстанавливают заданные параметры. Затем строим модуль предобработки F1–F4 в едином API («сырые данные» $\rightarrow$ «очищенный ряд») и валидируем его на контролируемой синтетике через SNR и сохранение структуры.

После этого реализуем единый интерфейс оптимизаторов (SGD, Adam, AdamW) с внутренним переключаемым модулем сглаживания и проводим baseline- сравнение F0 (без фильтрации) против режимов F1–F4. Далее запускаем две серии экспериментов: синтетическую (квадратичная и логистическая задачи, полный факторный дизайн $5 \times 4 \times 3$, где F0–F4 $\times$ N1–N4 $\times$ оптимизатор) и прикладную (реальные финансовые ряды с той же процедурой).

Финальный этап — статистическое сравнение конфигураций, анализ устойчивости результатов и подготовка отчёта с практическими рекомендациями. Если отдельные сценарии окажутся слишком ресурсоёмкими, сохраняем ядро исследования: полный перебор по шумам и фильтрам на упрощённых моделях без потери сопоставимости.

6. Outcomes

По итогу ожидаем получить матрицу результатов сходимости и качества для всех комбинаций (фильтр, тип шума, оптимизатор); оценки SNR и степени искажения структуры ряда для каждого фильтра; практическую таблицу рекомендаций «при каком шуме какую пару использовать»; открытый воспроизводимый код и письменный отчёт.

Если результаты подтвердят положительный эффект предобработки, отдельным итогом станет библиотека оптимизационных пайплайнов для шумных финансовых рядов: набор унифицированных реализаций (фильтр + оптимизатор) с готовыми конфигурациями, которые в среднем обучаются стабильнее и быстрее на шумных данных.

7. Литература

- [1] R. E. Kalman, «A New Approach to Linear Filtering and Prediction Problems», *Journal of Basic Engineering*, т. 82, вып. 1, сс. 35–45, 1960, doi: [10.1115/1.3662552](https://doi.org/10.1115/1.3662552).
- [2] D. L. Donoho и I. M. Johnstone, «Ideal Spatial Adaptation by Wavelet Shrinkage», *Biometrika*, т. 81, вып. 3, сс. 425–455, 1994, doi: [10.1093/biomet/81.3.425](https://doi.org/10.1093/biomet/81.3.425).
- [3] S. Mallat, *A Wavelet Tour of Signal Processing*, 2nd изд. San Diego: Academic Press, 1999.
- [4] L. Yin, R. Yang, M. Gabbouj, и Y. Neuvo, «Weighted Median Filters: A Tutorial», *IEEE Transactions on Circuits and Systems II: Analog and Digital Signal Processing*, т. 43, вып. 3, сс. 157–192, 1996, doi: [10.1109/82.486465](https://doi.org/10.1109/82.486465).
- [5] D. P. Kingma и J. Ba, «Adam: A Method for Stochastic Optimization», в *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015. [Онлайн]. Доступно на: <https://arxiv.org/abs/1412.6980>
- [6] I. Loshchilov и F. Hutter, «Decoupled Weight Decay Regularization», в *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, 2019. [Онлайн]. Доступно на: <https://arxiv.org/abs/1711.05101>
- [7] A. C. Harvey, *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge: Cambridge University Press, 1990. doi: [10.1017/CBO9781107049994](https://doi.org/10.1017/CBO9781107049994).
- [8] I. Daubechies, *Ten Lectures on Wavelets*. Philadelphia: Society for Industrial, Applied Mathematics, 1992. doi: [10.1137/1.9781611970104](https://doi.org/10.1137/1.9781611970104).
- [9] J. D. Hamilton, *Time Series Analysis*. Princeton: Princeton University Press, 1994.
- [10] R. S. Tsay, *Analysis of Financial Time Series*, 3rd изд. Hoboken: John Wiley & Sons, 2010. doi: [10.1002/9780470644560](https://doi.org/10.1002/9780470644560).
- [11] R. Cont, «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues», *Quantitative Finance*, т. 1, вып. 2, сс. 223–236, 2001, doi: [10.1080/713665670](https://doi.org/10.1080/713665670).
- [12] B. Mandelbrot, «The Variation of Certain Speculative Prices», *The Journal of Business*, т. 36, вып. 4, сс. 394–419, 1963, doi: [10.1086/294632](https://doi.org/10.1086/294632).
- [13] U. Şimşekli, L. Sagun, и M. Gürbüzbalaban, «A Tail-Index Analysis of Stochastic Gradient Noise in Deep Neural Networks», в *Proceedings of the 36th International Conference on Machine Learning (ICML)*, в *Proceedings of Machine Learning Research*, vol. 97. PMLR, 2019, сс. 5827–5837. [Онлайн]. Доступно на: <https://arxiv.org/abs/1901.06053>
- [14] Y. Chandak, P. Yadav, A. Özgür, и N. Bambos, «Stochastic Approximation with Heavy-Tailed and Long-Range Dependent Noise». [Онлайн]. Доступно на: <https://arxiv.org/abs/2603.19648>
- [15] A. Défossez, L. Bottou, F. Bach, и N. Usunier, «A Simple Convergence Proof of Adam and Adagrad», *Transactions on Machine Learning Research*, 2022, [Онлайн]. Доступно на: <https://arxiv.org/abs/2003.02395>
- [16] S. J. Reddi, S. Kale, и S. Kumar, «On the Convergence of Adam and Beyond», в *Proceedings of the 6th International Conference on Learning Representations (ICLR)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1904.09237>
- [17] H. Robbins и S. Monro, «A Stochastic Approximation Method», *The Annals of Mathematical Statistics*, т. 22, вып. 3, сс. 400–407, 1951, doi: [10.1214/aoms/1177729586](https://doi.org/10.1214/aoms/1177729586).
- [18] E. Gorbunov, M. Danilova, и A. Gasnikov, «Stochastic Optimization with Heavy-Tailed Noise via Iterative Differentially Private Clipping», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020, сс. 15042–15053. [Онлайн]. Доступно на: <https://arxiv.org/abs/2005.10785>