

# Beyond Gaussian Noise: сходимость стохастических оптимизаторов при коррелированном и тяжёлохвостовом финансовом градиентном шуме

Project Proposal · НИУ ВШЭ · 26 апреля 2026 г.

Кортунов Д., Пастушенко В., Дубовицкий А., Шадрин А.

Аннотация. Почти вся теория сходимости стохастических методов оптимизации опирается на то, что градиентный шум имеет конечную дисперсию и независим по итерациям. При обучении на финансовых временных рядах оба предположения нарушаются: доходности активов тяжёлохвостовы и обладают долгой памятью, и градиент, посчитанный на таких данных, наследует эти свойства. Мы хотим эмпирически разобраться, как при таком шуме ведут себя четыре популярных оптимизатора — SGD, Adam, Clipped-SGD, Normalized-SGD — и какие из них остаются устойчивыми. Для этого подмешиваем к градиенту шум разных типов (от обычного гауссова до смеси  $\alpha$ -устойчивого с долгой памятью) и сравниваем кривые сходимости.

## 1. О чём проект

В обучении нейросетей по умолчанию используют Adam, и теоретические гарантии для него предполагают, что шум градиента ограничен по дисперсии и независим. На финансовых данных оба предположения ломаются, и непонятно, насколько это мешает на практике.

Идея простая: фиксируем четыре оптимизатора, фиксируем несколько параметрических классов градиентного шума и смотрим, как меняются кривые сходимости. Дальше сопоставляем наблюдаемое поведение с тем, что говорит теория для каждого метода. Важный момент: предположения теории формулируются для шума градиента, а не для исходных данных, поэтому и интересует нас именно градиентный шум.

## 2. Постановка

Минимизируем  $L$ -гладкую (в общем случае невыпуклую) функцию  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . На итерации  $k$  алгоритм получает стохастический градиент

$$g_k = \nabla f(x_k) + \xi_k,$$

где  $\xi_k$  — центрированный шум. Не накладываем ни ограниченности  $\mathbb{E}\|\xi_k\|^2$ , ни независимости  $\xi_k$  от прошлых итераций.

Для  $\xi_k$  рассматриваем четыре класса:

- белый гауссов  $\xi_k \sim \mathcal{N}(0, \sigma^2 I)$ , i.i.d. — контроль;
- розовый ( $1/f$ ):  $\xi_k = \sum_{j \geq 0} \psi_j \eta_{k-j}$  с гауссовыми  $\eta_j$  и коэффициентами FARIMA(0,  $d$ , 0),  $d \in (0, 1/2)$  — долгая память, конечная дисперсия;
- тяжёлохвостовой:  $\xi_k \sim S_\alpha(\sigma, 0, 0)$  покомпонентно,  $\alpha \in (1, 2)$ , конечен только  $p$ -й момент при  $p < \alpha$ ;
- смешанный (главный): тот же  $1/f$ -фильтр, но применённый к  $\alpha$ -устойчивым инновациям — тяжёлые хвосты и долгая память одновременно.

Сравниваем стандартные оптимизаторы с обновлением  $x_{k+1} = x_k - \eta_k \varphi(g_k)$ :

- SGD:  $\varphi(g) = g$ ;
- Adam [1]:  $\varphi(g_k) = m_k / (\sqrt{v_k} + \varepsilon)$ ;
- Clipped-SGD:  $\varphi(g) = \min(1, \tau/\|g\|)g$ ;
- Normalized-SGD with momentum [2]:  $\varphi(g_k) = m_k / \|m_k\|$ ;

— и другие (см. §«Обзор литературы»).

Главная величина — эмпирическая  $T(\varepsilon; A, \mathcal{N}) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\}$ , сколько итераций нужно методу  $A$  при шуме  $\mathcal{N}$ , чтобы дойти до малого градиента.

### 3. Метрики

Что считаем по результатам:

- кривая сходимости  $\mathbb{E}\|\nabla f(x_k)\|^2$  от номера итерации (медиана и 90-й перцентиль по нескольким десяткам запусков), чтобы видеть и типичное поведение, и разброс;
- индекс хвоста и показатель Хёрста собранного во время обучения градиентного шума — для проверки, что наблюдаемый режим соответствует заложенному.

Возможен и отрицательный исход — например, окажется, что все четыре метода ведут себя примерно одинаково. Это нормальный результат, и тогда содержательной частью становится сама диагностика градиента и объяснение, почему теоретические различия не проявились.

### 4. Обзор литературы

Литературу удобно разбить на несколько групп.

Тяжёлохвостовой градиентный шум как явление. Şimşekli, Sagun, Gürbüzbalaban [3] эмпирически показали, что градиентный шум в нейросетях не гауссов, а  $\alpha$ -устойчивый. Дальше Gürbüzbalaban, Şimşekli, Zhu [4] заметили, что даже при гауссовых данных стационарное распределение итераций SGD само получается тяжёлохвостовым, а Battash и Lindenbaum [5] добавили, что у разных параметров сети индексы хвоста заметно различаются. С этих работ начался интерес к тому, что классические условия на шум во многих задачах нарушаются. Ссылки: [arxiv 1901.06053](#), [2006.04740](#), [2303.02749](#).

Сходимость с обрезанием и нормировкой. Zhang, He, Sra и Jadbabaie [6] ввели условие  $(L_0, L_1)$ -гладкости, при котором обрезание градиента ускоряет обучение. Zhang и др. [7] формализуют наблюдение, что Adam эквивалентен покоординатному обрезанию. Главный для нас результат получили Gorbunov, Danilova и Gasnikov [8]: первые high-probability оценки для Clipped-SGD при ограниченном  $(1 + \alpha)$ -моменте шума; в [9] они доведены до оптимальных. У клиппинга есть обратная сторона: Koloskova, Hendrikx, Stich [10] показали, что обрезание вносит неустраняемое смещение. Альтернатива — нормировка: Cutkosky и Mehta [2] для Normalized-SGD с моментумом, а Hübler, Fatkhullin, He [11] и Liu, Zhou [12] недавно показали, что нормированные методы достигают оптимальной скорости при тяжёлом шуме вообще без обрезания. Ссылки: [1905.11881](#), [1912.03194](#), [2005.10785](#), [2302.05437](#), [2305.01588](#), [2002.03305](#), [2410.13849](#), [2412.19529](#).

Adam и его сходимость. Оригинальная статья Kingma и Ba [1] не предполагала тяжёлых хвостов. Reddi, Kale и Kumar [13] показали, что Adam может расходиться даже на простой выпуклой задаче, и предложили AMSGrad. Чистое доказательство сходимости Adam для ограниченных градиентов есть у Défossez и др. [14] — относительно него мы смотрим на деградацию. Loshchilov и Hutter [15] уточнили, как корректно прикручивать к Adam регуляризацию весов (AdamW). Ссылки: [1412.6980](#), [1904.09237](#), [2003.02395](#), [1711.05101](#).

Другие способы бороться с шумом. Помимо обрезания и нормировки есть несколько отдельных линий. Методы уменьшения дисперсии (SVRG [16], SAG [17], SAGA [18]) периодически используют полный градиент или историю прошлых градиентов; в их анализе тоже стоит предположение конечной дисперсии. Усреднение траектории по Поляку и Юдицкому [19] и его вариант SWA [20] уменьшают разброс итераций. Lookahead [21] периодически интерполирует медленные веса к быстрым. SAM [22] ищет плоские минимумы. Для больших батчей — линейное масштабирование шага у Goyal и др. [23] просто снижает дисперсию увеличением

батча. Lion [24] использует знак момента и близок к Normalized-SGD. В распределённом сеттинге используют робастные агрегации — Yin и др. [25], напрямую мотивированные тяжёлыми хвостами. В основной части мы их не разбираем, но они задают контекст. Ссылки: [1309.2388](#), [1407.0202](#), [1803.05407](#), [1907.08610](#), [2010.01412](#), [1706.02677](#), [2302.06675](#), [1803.01498](#).

Финансовые данные и коррелированный шум. Каноническая работа Cont [26] перечисляет одиннадцать стилизованных фактов финансовых доходностей: тяжёлые хвосты, кластеризация волатильности, долгая память абсолютных доходностей. Mandelbrot [27] ещё в 1963 предлагал моделировать цены  $\alpha$ -устойчивыми распределениями. Sirignano и Cont [28] обучили глубокую сеть на больших объёмах данных стакана — задача реалистичная. Vivarelli и Mannella [29] — одна из немногих работ, ослабляющих независимость шума в анализе SGD. И главное для нас: Chandak, Yadav, Özgür, Bambos [30] (март 2026) — единственная известная нам работа, разбирающая стохастическую аппроксимацию одновременно при тяжёлом и долговременно-зависимом шуме, в общем фреймворке, без привязки к конкретным оптимизаторам. Ссылки: [Cont 2001](#), [Mandelbrot 1963](#), [1803.06917](#), [2306.05300](#), [2603.19648](#).

Где наш проект на этом ландшафте. Тяжёлохвостовой шум разобран хорошо, но почти всегда в предположении независимости. Коррелированный гауссов шум разобран чуть-чуть. Одновременно тяжёлый и коррелированный — только в работе Chandak et al., и то для общей стохастической аппроксимации, без сравнения конкретных оптимизаторов и без финансовых данных. Эмпирического сравнения четырёх популярных методов на одних и тех же финансовых задачах с диагностикой полученного градиентного шума, насколько мы видим, никто не делал. Это и хочется заполнить.

## 5. План работ

Работа разбивается на несколько этапов. Сначала генератор шума: четыре класса, плюс тесты, что обратные оценки индекса хвоста и показателя Хёрста дают заложенное. Затем имплементация четырёх оптимизаторов в едином API на PyTorch со смок-тестами на квадратичной задаче. Дальше основной эксперимент: прогон оптимизаторов при разных типах шума, кривые сходимости и  $T(\epsilon)$  по нескольким десяткам запусков, сопоставление с известными теоретическими результатами для baseline-методов. На последнем этапе — анализ результатов, графики и отчёт. Если что-то пойдёт не по плану, есть запас: упростить или сократить набор задач.

## 6. Outcomes

По итогу — численные результаты сравнения четырёх оптимизаторов в нескольких режимах шума: кривые сходимости с разбросом, оценки индекса хвоста и показателя Хёрста, общие наблюдения о том, в каком режиме какой метод ведёт себя лучше. Плюс открытый код для воспроизведения экспериментов и письменный отчёт.

## 7. Литература

- [1] D. P. Kingma и J. Ba, «Adam: A Method for Stochastic Optimization», в *International Conference on Learning Representations (ICLR)*, 2015. [Онлайн]. Доступно на: <https://arxiv.org/abs/1412.6980>
- [2] A. Cutkosky и H. Mehta, «Momentum Improves Normalized SGD», в *International Conference on Machine Learning (ICML)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/2002.03305>
- [3] U. Şimşekli, L. Sagun, и M. Gürbüzbalaban, «A Tail-Index Analysis of Stochastic Gradient Noise in Deep Neural Networks», в *Proceedings of the 36th International Conference on Machine Learning (ICML)*, в PMLR, vol. 97. 2019, сс. 5827–5837. [Онлайн]. Доступно на: <https://arxiv.org/abs/1901.06053>
- [4] M. Gürbüzbalaban, U. Şimşekli, и L. Zhu, «The Heavy-Tail Phenomenon in SGD», в *International Conference on Machine Learning (ICML)*, 2021. [Онлайн]. Доступно на: <https://arxiv.org/abs/2006.04740>
- [5] B. Battash и O. Lindenbaum, «Revisiting the Noise Model of Stochastic Gradient Descent», в *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2024. [Онлайн]. Доступно на: <https://arxiv.org/abs/2303.02749>
- [6] J. Zhang, T. He, S. Sra, и A. Jadbabaie, «Why Gradient Clipping Accelerates Training: A Theoretical Justification for Adaptivity», в *International Conference on Learning Representations (ICLR)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/1905.11881>
- [7] J. Zhang и др., «Why are Adaptive Methods Good for Attention Models?», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/1912.03194>
- [8] E. Gorbunov, M. Danilova, и A. Gasnikov, «Stochastic Optimization with Heavy-Tailed Noise via Accelerated Gradient Clipping», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/2005.10785>
- [9] T. D. Nguyen, A. Ene, и H. L. Nguyen, «High Probability Convergence of Clipped-SGD Under Heavy-tailed Noise», *arXiv preprint arXiv:2302.05437*, 2023, [Онлайн]. Доступно на: <https://arxiv.org/abs/2302.05437>
- [10] A. Koloskova, H. Hendrikx, и S. U. Stich, «Revisiting Gradient Clipping: Stochastic Bias and Tight Convergence Guarantees», в *International Conference on Machine Learning (ICML)*, 2023. [Онлайн]. Доступно на: <https://arxiv.org/abs/2305.01588>
- [11] F. Hübler, I. Fatkhullin, и N. He, «From Gradient Clipping to Normalization for Heavy Tailed SGD», в *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2025. [Онлайн]. Доступно на: <https://arxiv.org/abs/2410.13849>
- [12] Z. Liu и Z. Zhou, «Nonconvex Stochastic Optimization under Heavy-Tailed Noises: Optimal Convergence without Gradient Clipping», в *International Conference on Learning Representations (ICLR)*, 2025. [Онлайн]. Доступно на: <https://arxiv.org/abs/2412.19529>
- [13] S. J. Reddi, S. Kale, и S. Kumar, «On the Convergence of Adam and Beyond», в *International Conference on Learning Representations (ICLR)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1904.09237>
- [14] A. Défossez, L. Bottou, F. Bach, и N. Usunier, «A Simple Convergence Proof of Adam and Adagrad», *Transactions on Machine Learning Research (TMLR)*, 2022, [Онлайн]. Доступно на: <https://arxiv.org/abs/2003.02395>
- [15] I. Loshchilov и F. Hutter, «Decoupled Weight Decay Regularization», в *International Conference on Learning Representations (ICLR)*, 2019. [Онлайн]. Доступно на: <https://arxiv.org/abs/1711.05101>
- [16] R. Johnson и T. Zhang, «Accelerating Stochastic Gradient Descent using Predictive Variance Reduction», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2013.
- [17] M. Schmidt, N. Le Roux, и F. Bach, «Minimizing Finite Sums with the Stochastic Average Gradient», *Mathematical Programming*, т. 162, сс. 83–112, 2017, [Онлайн]. Доступно на: <https://arxiv.org/abs/1309.2388>
- [18] A. Defazio, F. Bach, и S. Lacoste-Julien, «SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2014. [Онлайн]. Доступно на: <https://arxiv.org/abs/1407.0202>
- [19] B. T. Polyak и A. B. Juditsky, «Acceleration of Stochastic Approximation by Averaging», *SIAM Journal on Control and Optimization*, т. 30, вып. 4, сс. 838–855, 1992.
- [20] P. Izmailov, D. Podoprikin, T. Garipov, D. Vetrov, и A. G. Wilson, «Averaging Weights Leads to Wider Optima and Better Generalization», в *Conference on Uncertainty in Artificial Intelligence (UAI)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1803.05407>

- [21] M. R. Zhang, J. Lucas, G. Hinton, и J. Ba, «Lookahead Optimizer:  $k$  Steps Forward, 1 Step Back», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2019. [Онлайн]. Доступно на: <https://arxiv.org/abs/1907.08610>
- [22] P. Foret, A. Kleiner, H. Mobahi, и B. Neyshabur, «Sharpness-Aware Minimization for Efficiently Improving Generalization», в *International Conference on Learning Representations (ICLR)*, 2021. [Онлайн]. Доступно на: <https://arxiv.org/abs/2010.01412>
- [23] P. Goyal и др., «Accurate, Large Minibatch SGD: Training ImageNet in 1 Hour», *arXiv preprint arXiv:1706.02677*, 2017, [Онлайн]. Доступно на: <https://arxiv.org/abs/1706.02677>
- [24] X. Chen и др., «Symbolic Discovery of Optimization Algorithms», *arXiv preprint arXiv:2302.06675*, 2023, [Онлайн]. Доступно на: <https://arxiv.org/abs/2302.06675>
- [25] D. Yin, Y. Chen, K. Ramchandran, и P. Bartlett, «Byzantine-Robust Distributed Learning: Towards Optimal Statistical Rates», в *International Conference on Machine Learning (ICML)*, 2018. [Онлайн]. Доступно на: <https://arxiv.org/abs/1803.01498>
- [26] R. Cont, «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues», *Quantitative Finance*, т. 1, вып. 2, сс. 223–236, 2001, doi: [10.1080/713665670](https://doi.org/10.1080/713665670).
- [27] B. Mandelbrot, «The Variation of Certain Speculative Prices», *Journal of Business*, т. 36, вып. 4, сс. 394–419, 1963, [Онлайн]. Доступно на: <http://www.e-m-h.org/Mand63.pdf>
- [28] J. Sirignano и R. Cont, «Universal Features of Price Formation in Financial Markets: Perspectives from Deep Learning», *Quantitative Finance*, т. 19, вып. 9, сс. 1449–1459, 2019, [Онлайн]. Доступно на: <https://arxiv.org/abs/1803.06917>
- [29] M. Vivarelli и R. Mannella, «Correlated Noise in Epoch-Based Stochastic Gradient Descent: Implications for Weight Variances», *arXiv preprint arXiv:2306.05300*, 2024, [Онлайн]. Доступно на: <https://arxiv.org/abs/2306.05300>
- [30] S. Chandak, A. K. Yadav, A. Özgür, и N. Bambos, «Heavy-Tailed and Long-Range Dependent Noise in Stochastic Approximation: A Finite-Time Analysis», в *arXiv preprint arXiv:2603.19648*, 2026. [Онлайн]. Доступно на: <https://arxiv.org/abs/2603.19648>