

Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Gradient Noise

Дмитрий Кортунوف
НИУ ВШЭ
Москва, Россия
dvkortunov@edu.hse.ru

Вадим Пастушенко
НИУ ВШЭ
Москва, Россия
vapastushenko@edu.hse.ru

Алексей Дубовицкий
НИУ ВШЭ
Москва, Россия
andubovitskiy@edu.hse.ru

Андрей Шадрин
НИУ ВШЭ
Москва, Россия
arshadrin@edu.hse.ru

Аннотация—Финансовые временные ряды содержат шум различной природы: гауссов, тяжёлохвостовый, коррелированный и их комбинации. Прямая подача таких данных в стандартные стохастические оптимизаторы нарушает базовые предположения теории сходимости. Мы исследуем альтернативный подход: перед оптимизацией применяется этап шумоподавления — скользящее среднее, фильтр Калмана, вейвлет-пороговая обработка или медианная фильтрация, — после чего ряд подаётся в SGD, Adam или AdamW. Основной вопрос: насколько выбор фильтра влияет на скорость сходимости и итоговое качество модели, и можно ли подобрать пару (фильтр, оптимизатор), устойчивую к нескольким типам шума одновременно? Мы формализуем задачу как факторный эксперимент (тип шума) $\times$ (фильтр) $\times$ (оптимизатор), формулируем явные гипотезы из теоретических свойств методов и проверяем их на синтетических и реальных финансовых рядах. Ключевой результат: при α -устойчивом шуме ($\alpha \approx 1.2$) причинная медиана переводит расходящийся SGD в сходящийся режим (8/8 запусков) и снижает асимптотический уровень $\|\nabla f\|^2$ в 20–133 раза, тогда как линейные фильтры эффекта не дают; при гауссовом шуме фильтрация бесполезна или вредна.

Index Terms—шумоподавление, финансовые временные ряды, стохастическая оптимизация, фильтр Калмана, вейвлет-порог, медианная фильтрация, Adam, SGD, сходимость

I. Введение

В обучении на финансовых временных рядах стандартно фокусируются либо на выборе архитектуры модели, либо на модификациях оптимизатора. При этом сама структура входного шума часто остаётся «за кадром», хотя для финансовых данных именно она задаёт сложность обучения: тяжёлые хвосты, долгая память и выбросы нарушают предпосылки, при которых гарантируется стабильная работа классических стохастических методов.

В работе мы рассматриваем шумоподавление не как вспомогательную технику визуализации, а как полноценную часть оптимизационного процесса. Гипотеза состоит в том, что правильная предобработка может существенно изменить свойства градиентного шума и тем самым ускорить сходимость без усложнения самого оптимизатора.

Эмпирически мы сравниваем матрицу (тип шума) $\times$ (фильтр) $\times$ (оптимизатор) на синтетических и реальных финансовых данных и отвечаем на практический

вопрос: когда предобработка действительно помогает, а когда её эффект минимален или даже вреден из-за пересглаживания полезного сигнала. Короткий ответ, который мы получаем уже на первых экспериментах: при тяжёлых хвостах предобработка меняет сходимость, и сильно; при гауссовом шуме — нет.

Структура работы. Раздел II помещает работу в контекст литературы. Раздел III вводит модель ряда, классы шума, задачу прогноза и формализует исследовательскую задачу как факторный эксперимент с измеримыми метриками. Раздел IV даёт теоретический фон по фильтрам и оптимизаторам, формулирует предпосылки и явные гипотезы. Разделы V–VII описывают три эксперимента (синтетика, калибровка под реальные данные, реальные ряды) и проверяют гипотезы. Раздел VIII выводит практические критерии выбора пары (фильтр, оптимизатор) и явно указывает основание каждого из них. Раздел IX обсуждает ограничения, включая нерешённый случай смешанного шума.

II. Обзор литературы

II-A. Фильтрация временных рядов

Фильтр Калмана [1] для финансовых приложений подробно разобран у Harvey [2]. Теория вейвлет-порогового шумоподавления восходит к работе Donoho и Johnstone [3]; базисы Добеши [4] стали стандартом практики. Медианную фильтрацию и её взвешенные обобщения систематически изложили Yin et al. [6].

II-B. Природа финансового шума

Cont [7] зафиксировал набор устойчивых эмпирических фактов для доходностей: тяжёлые хвосты, кластеризация волатильности, медленное убывание автокорреляций абсолютных значений. Мандельброт [8] предложил α -устойчивые распределения в качестве модели ещё в 1963 году. Şimşekli et al. [9] показали, что стохастический градиент при обучении нейросетей демонстрирует те же признаки — α -устойчивость с α заметно меньше двух.

II-C. Стохастическая аппроксимация при нестандартном шуме

Asymptotic-уровень: Anantharam и Borkar [10] исследуют стохастическую аппроксимацию при одновременно тяжёлом и долгозависимом шуме методом предельного ОДУ. Первые конечновременные гарантии при обоих эффектах сразу получены в недавней работе Chandak et al. [11]. Направление робастной оптимизации через обрезание градиентов развито у Gorbunov et al. [14] и Zhang et al. [15]; вероятностные гарантии для невыпуклого случая — у Cutkosky и Mehta [16].

II-D. Место данной работы

Перечисленные работы либо анализируют поведение конкретного оптимизатора при заданном типе шума, либо изучают свойства фильтров как таковых. Совместное влияние выбора фильтра и оптимизатора при тяжёлохвостовом и коррелированном финансовом шуме эмпирически не измерялось. Открытого бенчмарка формата (фильтр $\times$ шум $\times$ оптимизатор) на финансовых рядах нам обнаружить не удалось.

III. Модель ряда и постановка задачи

В этом разделе мы вводим только то, что нужно для постановки исследовательской задачи: модель наблюдаемого ряда, классы шума, задачу прогноза и формальное описание изучаемого пространства экспериментов. Конкретные фильтры и оптимизаторы как алгоритмы описаны отдельно, в разделе IV.

III-A. Наблюдательная модель и классы шума

Наблюдаемый ряд $y_1, \dots, y_T \in \mathbb{R}$ описывается стандартной аддитивной моделью

$$y_t = s_t + \xi_t, \quad (1)$$

где s_t — полезный сигнал, ξ_t — шум. Цель преобработки — оценить s_t по доступным к моменту t наблюдениям, не используя будущее. Мы рассматриваем четыре класса шума, охватывающих основные режимы, встречающиеся в финансовых данных.

N1 — гауссов белый, $\xi_t \sim \mathcal{N}(0, \sigma^2)$. Это контрольный случай, при котором теория сходимости SGD работает в полную силу.

N2 — розовый ($1/f$): $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$ с гауссовыми инновациями η_j и коэффициентами FARIMA(0, d , 0), $d \in (0, 1/2)$. Дисперсия конечна, но корреляции убывают медленно (долгая память).

N3 — тяжёлохвостовый, $\xi_t \sim S_\alpha(\sigma, 0, 0)$, $\alpha \in (1, 2)$. Моменты порядка $p \geq \alpha$ бесконечны. Именно этот режим наиболее близок к реальным финансовым данным.

N4 — смешанный: α -устойчивые инновации, пропущенные через $1/f$ -фильтр. Тяжёлые хвосты и долгая память присутствуют одновременно.

III-B. Задача прогноза ряда

Центральная прикладная задача — краткосрочный одношаговый прогноз. Используем причинную AR(p)-модель. На шаге $t > p$ входом служит вектор последних p наблюдений

$$\phi_t = [\tilde{y}_{t-1}, \tilde{y}_{t-2}, \dots, \tilde{y}_{t-p}]^\top \in \mathbb{R}^p, \quad (2)$$

где $\tilde{y}$ — либо исходный ряд y , либо его версия, обработанная причинным фильтром. Выход модели — одношаговый прогноз

$$\hat{y}_t = x^\top \phi_t, \quad (3)$$

$x \in \mathbb{R}^p$ — вектор авторегрессионных коэффициентов. При обучении модель восстанавливает следующее значение того же ряда $\tilde{y}$, по которому построены признаки: каждый объект — пара $(\phi_t, \tilde{y}_t)$, а минимизируемая функция потерь квадратична:

$$f(x) = \frac{1}{n} \sum_{t=p+1}^{p+n} (x^\top \phi_t - \tilde{y}_t)^2. \quad (4)$$

Таким образом, фильтрация влияет и на входные признаки ϕ_t , и (при $F \neq F_0$) на обучающий таргет $\tilde{y}_t$. Качество же оценивается отдельно, на отложенной части ряда, по *исходному* будущему значению y_t : прогноз $x^\top \phi_t$ сравнивается с y_t , а не с его сглаженной версией. Именно сравнение с исходным рядом на holdout исключает ситуацию, в которой фильтр оценивался бы по им же сглаженному таргету.

III-C. Вспомогательные целевые функции

Чтобы изолированно измерить влияние шума на сходимость, не путая его с особенностями конкретной прогнозной модели, мы дополнительно используем две «чистые» задачи оптимизации, в которые шум ряда попадает прямо в признаки и тем самым в градиент. Они служат *диагностическим инструментом*, а не самостоятельной целью.

Квадратичная (при положительно определённой $A \in \mathbb{R}^{d \times d}$ и $b \in \mathbb{R}^d$):

$$f(x) = \frac{1}{2} x^\top A x - b^\top x, \quad (5)$$

с единственным минимумом $x^* = A^{-1}b$. Гладкий выпуклый ландшафт без нелинейностей позволяет приписать любое замедление сходимости именно шуму, а не геометрии потерь.

Логистическая регрессия (при наборе $\{(\phi_t, c_t)\}_{t=1}^n$, $\phi_t \in \mathbb{R}^d$ — лаговые признаки из ряда y , $c_t \in \{0, 1\}$ — метка):

$$f(x) = -\frac{1}{n} \sum_{t=1}^n [c_t \log \sigma(x^\top \phi_t) + (1 - c_t) \log(1 - \sigma(x^\top \phi_t))]. \quad (6)$$

Она добавляет к диагностике невырожденную, но по-прежнему выпуклую нелинейность.

Все три задачи — AR-прогноз (4), квадратичная и логистическая — объединены тем, что шум ряда y входит в них через признаки и, значит, через стохастический градиент.

III-D. Формализация исследовательской задачи

Перед оптимизацией весь ряд проходит через фильтр F : $\tilde{y} = F(y_1, \dots, y_T)$ (причём только причинно). Признаки строятся из $\tilde{y}$, а мини-батчевый градиент на итерации k равен

$$g_k = \frac{1}{|B_k|} \sum_{t \in B_k} \nabla_x \ell(x_k, \tilde{\phi}_t, c_t). \quad (7)$$

Параметры обновляются как $x_{k+1} = x_k - \eta \phi(g_k)$, где $\phi(\cdot)$ задаёт конкретный оптимизатор.

Исследуемое пространство. Исследовательская задача — измерить, как тройка

$$(\text{тип шума } \mathcal{N}) \times (\text{фильтр } F) \times (\text{оптимизатор } A)$$

влияет на сходимость и качество. Все три оси перебираются полным факторным дизайном (раздел V).

Метрики. Основная метрика — медианное (по 8 запускам) число итераций до ε -точности:

$$T(\varepsilon; F, A, \mathcal{N}) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\}. \quad (8)$$

Дополнительно измеряем *бинарную сходимость* — долю запусков, достигших 100-кратного снижения $\|\nabla f\|^2$, — и *асимптотический уровень* $\|\nabla f\|^2$ — медиану финального $\|\nabla f\|^2$ по последним 200 итерациям (в таблицах сокращаем до «асимпт.»). Бинарная сходимость отвечает на вопрос «сходится ли вообще», а асимптотический уровень — «насколько глубоко».

Важно, что три метрики дополняют друг друга и применимы в разных режимах. При α -устойчивом шуме итерация может вообще не иметь конечного предела (раздел IV-C); тогда $T(\varepsilon)$ не определено (формально равно горизонту), и информативны именно бинарная сходимость и асимптотический уровень. Поэтому для режима тяжёлых хвостов (H1) мы считаем первичными бинарную сходимость и этот уровень, а $T(\varepsilon)$ приводим там, где сходимость достигается; для уже сходящихся адаптивных методов (H2) первична скорость $T(\varepsilon)$.

IV. Теоретический фон, предпосылки и гипотезы

Здесь мы описываем сравниваемые методы как алгоритмы, кратко напоминаем их теоретические свойства и из этих свойств выводим явные гипотезы, которые затем проверяются экспериментально.

IV-A. Фильтры

Рассматриваем пять режимов предобработки; все причинные (при вычислении $\tilde{y}_t$ используются только $y_1, \dots, y_t$).

- **F0 — без фильтрации** ($\tilde{y}_t = y_t$), контроль.
- **F1 — скользящее среднее** по w последним наблюдениям. Линейный сглаживатель; оптимален в среднеквадратичном смысле для стационарного гауссова шума без памяти.
- **F2 — фильтр Калмана** с моделью случайного блуждания $s_t = s_{t-1} + w_t$; оптимальная линейная оценка при гауссовом шуме [1].

- **F3 — вейвлет-пороговая обработка** в базисе Добеши [3], [4]. Разреженно представляет кусочно-регулярный сигнал и эффективно подавляет коррелированный $(1/f)$ шум за счёт пороговой обрезки мелкомасштабных коэффициентов.
- **F4 — причинная медиана** по w последним наблюдениям. Единственный из рассматриваемых фильтров, устойчивый к выбросам [6]: одиночный экстремальный отсчёт не сдвигает медиану окна.

IV-B. Оптимизаторы

Обновление имеет общий вид $x_{k+1} = x_k - \eta \phi(g_k)$:

- **SGD**: $\phi(g) = g$ — базовый случай.
- **Clipped-SGD**: $\phi(g) = \min(1, \tau/\|g\|)g$ — обрезание ограничивает вклад редких больших градиентов.
- **Normalized-SGD**: $\phi(g) = g/\|g\|$ — полное удаление масштаба градиента.
- **Adam** [12] и **AdamW** [13] — адаптивные методы с покомпонентным масштабированием по вторым моментам.

IV-C. Предпосылки

Классический анализ SGD предполагает конечную дисперсию градиентного шума. При α -устойчивом шуме с $\alpha < 2$ это предположение нарушается: второй момент бесконечен, и редкие гигантские шаги не дают итерации стабилизироваться у минимума [9], [14]. Отсюда две принципиально разные стратегии борьбы: (i) подавить выбросы *на входе* робастным фильтром (F4), вернув градиентному шуму конечную дисперсию; (ii) ограничить выбросы *внутри* оптимизатора (обрезание, нормировка, адаптивные моменты). Долгая память $(1/f)$ дисперсию не ломает, но коррелирует последовательные градиенты; здесь помогает спектральное разреживание (вейвлет, F3) или адаптивное усреднение (Adam).

IV-D. Гипотезы

Из этих предпосылок мы формулируем четыре проверяемые гипотезы, по одной на каждый режим шума:

- **H1 (тяжёлые хвосты, N3).** Причинная медиана F4 переводит SGD из расходящегося режима в сходящийся и заметно снижает асимптотический уровень $\|\nabla f\|^2$; линейные фильтры (F1, F2, F3) этого не делают, так как не устойчивы к выбросам.
- **H2 (долгая память, N2).** Для адаптивных методов (Adam, AdamW) вейвлет-фильтр F3 ускоряет сходимость сильнее линейных сглаживателей.
- **H3 (смешанный шум, N4).** Ни один *простой* (одностадийный) фильтр не снижает асимптотический уровень: медиана видит одиночный выброс, но долгая память «растягивает» его в кластер, не помещающийся в окно.
- **H4 (гауссов контроль, N1).** Фильтрация в лучшем случае нейтральна, а медиана слегка проигрывает среднему, для которого гауссов шум оптимален.

V. Эксперимент 1: синтетика

V-A. Дизайн

Полный факторный эксперимент над тремя задачами (квадратичная регрессия $d = 20$, логистическая классификация $d = 15$, авторегрессия AR(5)), всеми четырьмя типами шума (N1, N2, N3 с $\alpha = 1.2$, N4) и пятью фильтрами (F0–F4). По 8 независимых запусков на каждую ячейку; гиперпараметры одинаковы для всех ячеек — никакого подбора под конкретный фильтр.

Оптимизаторы естественно делятся на две группы, поэтому факторный дизайн организован в два связанных блока (это разделение отвечает разным гипотезам):

- **Блок А** — SGD-семейство (SGD, Clipped-SGD, Normalized-SGD) на шумах N1/N3/N4. Здесь нас интересует, спасает ли фильтр *сходимость* при тяжёлых хвостах (H1) и нейтрален ли он на гауссиане (H4); основные метрики — бинарная сходимость и асимптотический уровень $\|\nabla f\|^2$.
- **Блок В** — адаптивные методы (Adam, AdamW) на шумах N2/N4. Здесь нас интересует *скорость*: ускоряет ли фильтр уже сходящийся оптимизатор при долгой памяти (H2) и помогает ли он на смешанном шуме (H3); основная метрика — $T(\varepsilon)$.

Розовый шум N2 проходит обе группы (с SGD-семейством в Блоке А и с адаптивными методами в Блоке В), так что все четыре режима шума присутствуют в дизайне как полноправные оси.

V-B. H1: тяжёлые хвосты

При шуме N3 ($\alpha = 1.2$) SGD без фильтра не сходится ни в одном из 8 запусков на квадратичной и логистической задачах — $\|\nabla f\|^2$ застревает на асимптотическом уровне и остаётся там, сколько бы итераций мы ни запускали. Фильтры F1, F2, F3 картину не меняют: для каждого из них результат тот же, 0/8. Единственный фильтр, который переводит задачу в сходящийся режим — причинная медиана F4: 8/8 на квадратичной и логистической задачах (табл. I, рис. 1). **Это прямо подтверждает H1.**

Таблица I: Тяжёлохвостовой шум N3, SGD: бинарная сходимость, число итераций T_{100} до 100-кратного снижения $\|\nabla f\|^2$ (то же определение, что у бинарной сходимости) и асимптотический уровень $\|\nabla f\|^2$ (столбцы «асимпт.») для исходного ряда (F0) и причинной медианы (F4). Запись « $> N$ » означает, что 100-кратное снижение не достигнуто за весь горизонт (N итераций).

Задача	бин. F0	бин. F4	T_{100} F0	T_{100} F4	асимпт. F0	асимпт. F4
квадратичная	0/8	8/8	>4000	416	0.540	0.0050
логистическая	0/8	8/8	>3000	1118	0.0658	0.00050
авторегрессия	8/8	8/8	109	75	0.0421	0.0021

Отношение асимптотических уровней F0/F4 составляет $108\times$ (квадратичная), $133\times$ (логистическая) и $20\times$ (авторегрессия).

Для авторегрессионной задачи сходимость формально достигается и без фильтра — слишком большой начальный $\|\nabla f_0\|^2$. Но асимптотический уровень с F4 ниже в 20 раз.




Рис. 1: Шум N3, SGD, 8 сидов. Слева — асимптотические уровни $\|\nabla f\|^2$ для F0–F4 (лог-шкала, полоса p10–p90). Справа — медианные кривые $\|\nabla f\|^2$: F0 и линейные фильтры застревают, F4 уходит вниз на 1–2 порядка.

V-C. H4: гауссов контроль

На гауссовом контроле N1 всё ровно наоборот: фильтры почти не различаются по асимптотическому уровню, а медиана F4 даже немного хуже F0 (отношение уровней 0.76–0.95). Это ожидаемо — медиана теряет немного точности на распределении, для которого оптимально среднее (рис. 2). **H4 подтверждается.**




Рис. 2: Гауссов шум N1, SGD, 8 сидов. Слева — асимптотические уровни $\|\nabla f\|^2$ для F0–F4 почти совпадают по задачам (лог-шкала, полоса p10–p90). Справа — медианные кривые $\|\nabla f\|^2$: F0, F1 и F4 идут вместе, выигрывают от фильтрации нет.

V-D. H2 и H3: долгая память и смешанный шум

H2 (долгая память N2). При шуме N2 ($1/f$) с Adam и AdamW вейвлет-фильтр F3 ускоряет сходимость в 11.2 раза: $T(\varepsilon)$ падает со 562 итераций (F0) до 50 (F3) на квадратичной задаче (табл. II, рис. 3). Фильтр Калмана F2 даёт $3.1\times$, линейное сглаживание F1 и медиана F4 — нет. Та же тенденция видна по *среднему логарифму нормы градиента* $\log_{10} \|\nabla f\|^2$ (усреднение по всей траектории; последний столбец табл. II, рис. 4). Эта величина отрицательна не «по площади», а потому что после сходимости $\|\nabla f\|^2 \ll 1$ и её десятичный логарифм отрицателен; *меньшее* (более отрицательное) значение отвечает более глубокой сходимости. У F3 оно наименьшее, -0.94 против -0.65 у F0. Эффект совпадает для Adam и AdamW.

Заметим, что в Блоке А с SGD-семейством линейная и медианная фильтрация при N2 асимптотический уровень почти не снижают (отношение $F0/F_k \approx 1.0\text{--}1.26$): выигрыш при долгой памяти — свойство связки «спектральное разреживание + адаптивный шаг», что и утверждает N2. **N2 подтверждается.**

Таблица II: Долгая память N2, квадратичная задача, Adam (AdamW — те же значения). Базовая строка — без фильтра (F0); ускорение считается относительно неё, ускор. = $T_\varepsilon^{F0}/T_\varepsilon^F$. Приведены число итераций до ε -точности T_ε , это ускорение, асимптотический уровень $\|\nabla f\|^2$ и средний логарифм нормы градиента $\log_{10} \|\nabla f\|^2$ (усреднён по траектории; отрицателен).

Фильтр	T_ε	ускор. vs F0	асимпт. $\ \nabla f\ ^2$	$\log_{10} \ \nabla f\ ^2$
F0 (без фильтра)	562	$1.0\times$ (база)	0.234	-0.65
F1 (скользя. средн.)	719	$0.8\times$	0.267	-0.59
F2 (Калман)	180	$3.1\times$	0.169	-0.78
F3 (вейвлет)	50	$11.2\times$	0.120	-0.94
F4 (медиана)	560	$1.0\times$	0.266	-0.59




Рис. 3: Долгая память N2, Adam, 8 сидов. Слева — медианные кривые $\|\nabla f\|^2$ (квадратичная задача): F3 уходит вниз заметно раньше F2 и F0. Справа — ускорение $T(\varepsilon)$ относительно F0 по фильтрам: только вейвлет F3 даёт $\sim 11\times$, линейные фильтры — нет.




Рис. 4: Та же конфигурация (N2, Adam). Слева — кривые $\log_{10} \|\nabla f\|^2$, пунктир — их среднее по траектории ($\log_{10} \|\nabla f\|^2$). Справа — это среднее по фильтрам: оно отрицательно, потому что $\|\nabla f\|^2 < 1$ даёт отрицательный логарифм; у F3 оно наименьшее (наилучшее).

N3 (смешанный шум N4). На смешанном N4 ни один простой фильтр асимптотический уровень не снижает: отношение уровней F0/Fk близко к единице для всех

фильтров и всех задач (табл. III). Для адаптивных методов на N4 разницы между F0 и фильтрами тоже нет — Adam сам справляется с коррелированным градиентным шумом, а избыточное сглаживание уровень не улучшает. **Это согласуется с N3.**

Таблица III: Смешанный шум N4, SGD: отношение асимптотических уровней $\|\nabla f\|^2$ для F0/Fk. Везде ≈ 1 — ни один простой фильтр его не снижает.

Задача	F1	F2	F3	F4
квадратичная	1.00	0.99	1.00	1.07
логистическая	1.00	1.00	1.00	1.00
авторегрессия	1.00	1.06	1.04	1.02

V-E. Статистическая значимость

До сих пор мы сравнивали фильтры по точечным сводкам (медианный асимптотический уровень, число сходящихся запусков). Чтобы убедиться, что наблюдаемые различия не случайны, мы проверяем их формальным критерием. Ключевая особенность дизайна, которая это позволяет, — *парность*: сид s задаёт одну и ту же реализацию шума для F0 и для каждого F_k , поэтому межсидовый разброс «сложности задачи» можно вынести за скобки и работать с попарными разностями. Это переводит нас от двухвыборочного критерия к более мощному *парному*.

V-E0a. Модель и гипотезы критерия. Для каждой ячейки (задача, шум, оптимизатор) и каждого фильтра F_k берём попарную разность логарифмов асимптотических уровней

$$d_s = \log_{10} \|\nabla f\|_{F0,s}^2 - \log_{10} \|\nabla f\|_{Fk,s}^2, \quad s = 1, \dots, 8.$$

Работаем в логарифмической шкале сознательно: отношение уровней (во сколько раз фильтр снижает шумовой пол) на исходной шкале превращается в *разность* в лог-шкале, а именно разности и моделирует t -критерий; вдобавок лог-преобразование стабилизирует дисперсию тяжёлохвостовой величины $\|\nabla f\|^2$. Проверяем одностороннюю гипотезу

$$H_0 : \mathbb{E}[d_s] \leq 0 \quad \text{против} \quad H_1 : \mathbb{E}[d_s] > 0 \quad (\text{фильтр снижает пол}),$$

статистикой $t = \bar{d}/(s_d/\sqrt{n})$ с $n - 1 = 7$ степенями свободы. Рядом приводим размер эффекта — парный d Коэна = $\bar{d}/s_d$, — 95%-й доверительный интервал для $\bar{d}$ и распределение независимую проверку знаковым ранговым критерием Уилкоксона. Поскольку семейство сравнений велико, односторонние p корректируются по нисходящей процедуре Холма; в таблице приведены сырые p , в тексте — вывод после поправки.

V-E0b. Результат. В режиме тяжёлых хвостов N3 причинная медиана F4 снижает асимптотический уровень в 21–135 раз, и эффект колоссален по любым меркам: t от 12.5 до 31.4, односторонние p от 2.4×10^{-6} до 4.3×10^{-9} , d Коэна от 4.4 до 11.1 (для сравнения, $d > 0.8$ уже считается «большим»). После поправки Холма по всему семейству из 192 сравнений все три остаются значимы на

уровне $p_{\text{Холм}} < 10^{-3}$. В режиме долгой памяти N2 вейвлет F3 с Adam ускоряет достижение ε -точности в 7–12 раз на квадратичной и авторегрессионной задачах ($t = 6.4$ и 7.8 , $p < 2 \times 10^{-4}$, $d > 2.2$; значимо и после Холма). На логистической задаче ускорение F3 статистически не подтверждается ($p = 0.17$) — там выигрыш в скорости меньше, и мы это честно отмечаем.

Таблица IV: Парные односторонние t -критерии для двух подтверждаемых гипотез. Сверху — снижение асимптотического уровня $\|\nabla f\|^2$ причинной медианой F4 при тяжёлых хвостах N3 (SGD); снизу — ускорение $T(\varepsilon)$ вейвлетом F3 при долгой памяти N2 (Adam). 8 спаренных сидов на ячейку, $df = 7$. «Эффект» — отношение уровней (во сколько раз ниже) либо ускорение (во сколько раз быстрее); d Козна — парный размер эффекта. Все приведённые p — сырые односторонние; после поправки Холма по семейству из 192 сравнений строки N3 сохраняют $p_{\text{Холм}} < 10^{-3}$, обе значимые строки N2 — $p_{\text{Холм}} < 0.035$.

Режим	Задача	эффект	t	p (одност.)	d Козна
N3 (хвосты), F4	квадратичная	106× ниже	31.4	4.3×10^{-9}	11.1
N3 (хвосты), F4	авторегрессия	21× ниже	28.6	8.2×10^{-9}	10.12
N3 (хвосты), F4	логистическая	135× ниже	12.5	2.4×10^{-6}	4.47
N2 (память), F3	квадратичная	12.2× быстрее	7.8	5.2×10^{-5}	2.77
N2 (память), F3	авторегрессия	7.2× быстрее	6.4	0.0002	2.26
N2 (память), F3	логистическая	1.4× быстрее	1.0	0.1742	0.83

V-E0c. Контроль ложноположительности. Чтобы критерий не превратился в генератор «значимых» эффектов там, где их нет, мы прогоняем тот же парный t на гауссовом контроле N1 и на смешанном шуме N4. На N1 медиана F4 пол не снижает (односторонний $p > 0.96$ на всех трёх задачах, $d < 0$ — эффект в обратную сторону, как и предсказывает N4: на гауссиане среднее эффективнее медианы). На N4 слабые номинальные эффекты ($p \in [0.004, 0.05]$) не переживают поправку Холма ($p_{\text{Холм}} > 0.6$), что согласуется с N3 — простого фильтра для смешанного режима нет. Таким образом, критерий «зажигается» ровно там, где теория предсказывает выигрыш, и молчит на контролях; это и есть нужная картина.

VI. Эксперимент 2: калибровка под реальные ряды

VI-A. Откуда взялось $\alpha = 1.2$

Прежде чем интерпретировать синтетические результаты, стоит проверить, насколько $\alpha = 1.2$ соответствует реальным финансовым данным. Мы оценили индекс хвоста $\hat{\alpha}$ методом Маккаллоха и показатель Хёрста $\hat{H}$ методом DFA (по модулю доходности) для корзины из 9 инструментов за 2018–2025 гг. по дневным логдоходностям (источник: Yahoo Finance). Полные оценки по всем 9 инструментам приведены в табл. V.

Таблица V: Оценки тяжести хвоста $\hat{\alpha}$ (Маккаллох) и памяти $\hat{H}$ (DFA) по всем 9 инструментам корзины, дневные логдоходности.

Инструмент	$\hat{\alpha}$	$\hat{H}$
SPY	1.05	0.86
QQQ	1.07	0.82
AAPL	1.09	0.77
MSFT	1.09	0.77
JPM	1.12	0.79
EUR/USD	1.19	0.69
GBP/USD	1.24	0.70
BTC	1.36	0.79
ETH	1.41	0.73
медиана	1.12	0.77

Медиана по этим 9 дневным инструментам: $\hat{\alpha} = 1.12$, $\hat{H} = 0.77$ (что соответствует $\hat{d} = \hat{H} - 0.5 = 0.27$); индекс хвоста лежит в диапазоне 1.05–1.41, и выбранное в эксперименте 1 значение $\alpha = 1.2$ попадает в его середину. При калибровке эксперимента 2 (ниже) мы используем медиану по расширенной корзине (дневные + 5-минутные несезонный сенсорный ряд), где более тяжёлые внутридневные хвосты сдвигают медиану до $\hat{\alpha} = 1.21$, $\hat{d} = 0.29$.

VI-B. Эксперимент при $\hat{\alpha} = 1.21$

При синтетическом шуме, откалиброванном под медиану реальных данных (N3cal, $\hat{\alpha} = 1.21$), основной эффект сохраняется: асимптотический уровень $\|\nabla f\|^2$ SGD с F4 ниже F0 в 91 раз (квадратичная), 120 раз (логистическая), 17 раз (авторегрессия).

Для смешанного режима N4cal ($\hat{d} = 0.29$, $\hat{\alpha} = 1.21$) простые фильтры асимптотический уровень не снижают — отношение F0/F4 около единицы. По всей видимости, медиана видит единичные выбросы, но долгая память «растягивает» выброс по времени, и скользящее окно медианы его уже не захватывает. Это эмпирическое подтверждение N3 уже на калиброванных данных.




Рис. 5: Синтетика, откалиброванная под реальные $\hat{\alpha}$ и $\hat{d}$. При тяжёлохвостовом N3cal разрыв F0/F4 сохраняется (91–120×). При смешанном N4cal разрыва нет.

VII. Эксперимент 3: реальные финансовые ряды

VII-A. Дизайн

Эксперимент проводится по четырём доменам (финансовые 15-минутные и дневные доходности, несезонный сенсорный ряд ETT, макроряды FRED). В каждом домене берётся по 4 представительных инструмента и по 4 сида,

то есть на каждую пару (фильтр, оптимизатор) приходится $4 \times 4 = 16$ ячеек; разбиение train/holdout — 70/30, только причинные фильтры, holdout — исходные будущие значения, одинаковые для всех фильтров. На каждой ячейке обучается AR(5)-модель оптимизатором Adam.

Метрики (агрегируются медианой по 16 ячейкам):

- T — число итераций до сходимости, где «сходимость» означает 100-кратное относительное падение $\|\nabla f\|^2$ от начального значения (та же бинарная сходимость, что в разделе III-D; абсолютный порог ε здесь не используется, так как масштаб градиента различается по доменам);
- доля сошедшихся ячеек из 16;
- causal holdout MSE (на исходном таргете).

VII-B. Результаты

Таблица VI: Реальные ряды, Adam. T — медиана числа итераций до 100-кратного относительного падения $\|\nabla f\|^2$ по 16 ячейкам (4 инструмента $\times$ 4 сйда); «сошл. F0» — доля сошедшихся ячеек без фильтра; «ускор.» = $T_{F0}/T_{\text{лучш.}}$; «holdout» — медианный causal holdout MSE в формате лучший/F0.

Домен	T_{F0}	сошл. F0	$T_{\text{лучш.}}$	ускор.	holdout (лучш./F0)
фин. 15-мин	4000	7/16	F2 52	$78\times$	0.528/0.522
фин. дневные	554	13/16	F2 57	$10\times$	0.634/0.626
сенсор ETT	43	16/16	F1 20	$2.1\times$	0.653/0.488
макро FRED	20	16/16	F0 20	—	F0 лучший

На 15-минутных доходностях (SPY, QQQ и др.) Adam без фильтра сходится в 7 прогонах из 16; медиана T упирается в потолок 4000 итераций. С фильтром Калмана (F2) сходятся все 16, за 52 итерации в среднем. Это примерно 78-кратное ускорение. Holdout MSE при этом практически не меняется: 0.528 против 0.522.

На дневных доходностях ускорение есть (примерно 10-кратное), но оно значительно скромнее. На сенсорных данных ETT фильтр ускоряет сходимость, однако снижает точность на holdout — очевидно, пересглаживает полезную структуру в ряде. На макроэкономических данных FRED лучший вариант — F0 без фильтра.

Общий вывод: фильтр помогает там, где шум тяжёлый и домен близок к финансовому. Там, где данные ведут себя «аккуратнее», фильтр в лучшем случае нейтрален. Это переносит подтверждённые на синтетике гипотезы N1/N4 на реальные ряды.

VII-C. Сводка проверки гипотез

Таблица VII: Итог проверки гипотез из раздела IV-D.

Гип.	Статус	Где подтверждена
N1	подтв.	Э1 (табл. I, t -крит. IV: $p < 10^{-3}$), Э2, Э3 (15-мин)
N2	подтв.	Э1 (N2, Adam/AdamW: $11.2\times$, t -крит. IV)
N3	подтв.	Э1 (N4), Э2 (N4cal: F0/F4 $\approx$ 1)
N4	подтв.	Э1 (N1), Э3 (FRED, дневные)

VIII. Практические критерии выбора фильтра и оптимизатора

Критерии ниже построены из трёх источников, и для каждого пункта мы явно указываем основание: [Т] — теоретическое свойство метода (раздел IV-C), [Э] — прямое эмпирическое подтверждение в наших экспериментах, [Эв] — эвристика, не проверенная напрямую и предлагаемая лишь как отправная точка.

VIII-A. Диагностика типа шума

Тип шума оценивается по обучающей части ряда до начала обучения, без заглядывания в будущее. Две характеристики — индекс хвоста $\hat{\alpha}$ (метод Маккаллоха или Хилла) и показатель Хёрста $\hat{H}$ (DFA) — делят пространство на четыре случая, в точности соответствующие режимам N1–N4 и гипотезам N1–N4.

VIII-B. Решающая таблица

- $\hat{\alpha} \approx 2$, $\hat{H} \approx 0.5$ (близко к N1): шум близок к гауссову белому — фильтрация не нужна, **F0**. Основание: [Т] медиана/сглаживание лишь теряют точность на гауссиане; [Э] подтверждено на N1 и на FRED/дневных (табл. VI).
- $\hat{\alpha} \approx 2$, $\hat{H} > 0.6$ (близко к N2): долгая память при лёгком хвосте — **вейвлет F3 с Adam**. Основание: [Т] вейвлет разреживает $1/f$ -спектр; [Э] ускорение $11.2\times$ в Э1.
- $\hat{\alpha} < 1.9$, $\hat{H} \approx 0.5$ (близко к N3): тяжёлый хвост без памяти — **причинная медиана F4 с SGD**. Основание: [Т] медиана возвращает конечную дисперсию градиента; [Э] перевод $0/8 \rightarrow 8/8$ и асимптотический уровень ниже в $20\text{--}133\times$ (табл. I, Э2, 15-мин в Э3).
- $\hat{\alpha} < 1.9$, $\hat{H} > 0.6$ (близко к N4): оба эффекта сразу — ни один простой фильтр пока не работает стабильно; пробуем **F4+SGD** и **F2+Adam** и выбираем по валидации. Основание: [Э] отсутствие эффекта простых фильтров на N4 подтверждает, что готового рецепта нет; [Эв] F2+Adam — лишь кандидат, не проверенный напрямую.

Таким образом, три из четырёх рекомендаций имеют прямое экспериментальное подтверждение [Э] поверх теоретической мотивации [Т]; единственный случай, держащийся на эвристике [Эв], — смешанный шум N4, который и остаётся открытой проблемой.

VIII-C. Процедура финального выбора

Диагностика задаёт стартовый список из 2–3 кандидатов. Финальный выбор делается по causal walk-forward валидации: обучение на train-части, оценка на исходном holdout. Рекомендации из таблицы — не истина в последней инстанции, а отправная точка для поиска.

IX. Проблемы, ограничения и следующие шаги

В ходе работы мы столкнулись с двумя неожиданными ситуациями, которые изменили дизайн экспериментов.

Артефакт заглядывания вперёд. Центрированная (не причинная) медиана давала ложный прирост в точности прогноза направления на 7 п.п. Когда мы заменили её на причинную медиану, эффект исчез. Это стандартная проблема look-ahead bias, но она легко проскальзывает при небрежной реализации. Теперь все фильтры в экспериментах строго причинные.

Нерешённый смешанный режим N4. Ни один из простых фильтров не снижает там асимптотический уровень $\|\nabla f\|^2$. Интуиция: медиана работает с отдельными выбросами, но долгая память превращает выброс в аномальный кластер, который в окно медианы не помещается. Это и есть подтверждённая гипотеза H3, и одновременно открытый вопрос.

Ограничения. Выводы по реальным данным опираются на корзину из 9 инструментов и одну прогнозную модель (AR(5)); практические критерии выбора подтверждены в основном на финансовых доходностях. Перенос на другие домены и модели требует отдельной проверки.

Следующие шаги.

- **Каскадный фильтр для N4.** Двухстадийная предобработка, адресующая оба дефекта смешанного шума по отдельности: робастная стадия против выбросов (причинная медиана F4), затем память-ориентированная стадия против остаточной $1/f$ -корреляции (вейвлет F3 или Калман F2). Цель — закрыть единственный режим (N4), где ни один простой фильтр пока не снижает асимптотический уровень $\|\nabla f\|^2$.
- **Статистические тесты.** Перевод сравнений пар (фильтр, оптимизатор) на формальную основу: тесты значимости различий в $T(\varepsilon)$, асимптотическом уровне $\|\nabla f\|^2$ и holdout MSE (например, тест Уилкоксона по сидам и поправка на множественные сравнения) вместо качественного сопоставления медиан.

X. Заключение

Главное, что мы наблюдаем: при α -устойчивом шуме с $\alpha \approx 1.2$ SGD без фильтра не достигает целевой точности ни в одном из восьми запусков — и это не вопрос количества итераций, а вопрос наличия конечного предела. Причинная медиана переводит задачу в сходящийся режим (8/8) и снижает асимптотический уровень $\|\nabla f\|^2$ в 20–133 раза. Линейные фильтры этого не делают. Тот же эффект воспроизводится на реальных 15-минутных доходностях.

При гауссовом шуме и на дневных доходностях фильтр не помогает. Это не случайное исключение, а следствие того, что медиана оптимальна для тяжёлых хвостов, но проигрывает среднему там, где хвосты лёгкие. Все четыре сформулированные заранее гипотезы (H1–H4) подтвердились (табл. VII).

Практическое следствие: перед обучением на финансовых данных имеет смысл оценить $\hat{\alpha}$ и $\hat{H}$ и выбрать пару (фильтр, оптимизатор) исходя из этих оценок по решающей таблице раздела VIII, а не запускать один и тот же

конвейер на всех рядах без разбора. Единственный случай, для которого готового рецепта пока нет, — смешанный шум N4 (тяжёлый хвост и долгая память одновременно); он остаётся открытой проблемой.

Список литературы

- [1] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *J. Basic Eng.*, vol. 82, no. 1, pp. 35–45, 1960.
- [2] A. C. Harvey, *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge: Cambridge Univ. Press, 1990.
- [3] D. L. Donoho and I. M. Johnstone, “Ideal spatial adaptation by wavelet shrinkage,” *Biometrika*, vol. 81, no. 3, pp. 425–455, 1994.
- [4] I. Daubechies, *Ten Lectures on Wavelets*. Philadelphia: SIAM, 1992.
- [5] S. Mallat, *A Wavelet Tour of Signal Processing*. San Diego: Academic Press, 1999.
- [6] L. Yin, R. Yang, M. Gabbouj, and Y. Neuvo, “Weighted median filters: a tutorial,” *IEEE Trans. Circuits Syst. II*, vol. 43, no. 3, pp. 157–192, 1996.
- [7] R. Cont, “Empirical properties of asset returns: stylized facts and statistical issues,” *Quant. Finance*, vol. 1, no. 2, pp. 223–236, 2001.
- [8] B. B. Mandelbrot, “The variation of certain speculative prices,” *J. Business*, vol. 36, no. 4, pp. 394–419, 1963.
- [9] U. Şimşekli, L. Sagun, and M. Gürbüzbalaban, “A tail-index analysis of stochastic gradient noise in deep neural networks,” in *Proc. ICML*, 2019, pp. 5827–5837.
- [10] V. Anantharam and V. S. Borkar, “Stochastic approximation with long-range dependent and heavy-tailed noise,” *Queueing Syst.*, vol. 71, no. 1–2, pp. 221–242, 2012.
- [11] P. Chandak, A. Yadav, A. Özgür, and N. Bambos, “Heavy-Tailed and Long-Range Dependent Noise in Stochastic Approximation: A Finite-Time Analysis” arXiv:2503.19648, Mar. 2026.
- [12] D. P. Kingma and J. Ba, “Adam: a method for stochastic optimization,” in *Proc. ICLR*, 2015.
- [13] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *Proc. ICLR*, 2019.
- [14] E. Gorbunov, M. Danilova, and A. Gasnikov, “Stochastic optimization with heavy-tailed noise via Accelerated Gradient Clipping,” in *Proc. NeurIPS*, 2020.
- [15] J. Zhang, T. He, S. Sra, and A. Jadbabaie, “Why gradient clipping accelerates training: a theoretical justification for adaptivity,” in *Proc. ICLR*, 2020.
- [16] A. Cutkosky and H. Mehta, “High-probability bounds for non-convex stochastic optimization with heavy tails,” in *Proc. NeurIPS*, 2021.