


Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Gradient Noise

Д. КОРТУНОВ В. ПАСТУШЕНКО А. ДУБОВИЦКИЙ А. ШАДРИН НИИ ВШЭ, Москва

Мотивация и гипотезы

Градиентный шум на финансовых рядах тяжёлохвостый (α -устойчивый, $\alpha < 2$, бесконечная дисперсия) и долгопамятный — предпосылки сходимости SGD нарушены. Идея: до обучения прогнать ряд через причинный фильтр $\hat{y} = F(y)$ и учить AR(p) на нём. **Вопрос:** какая пара (фильтр, оптимизатор) под какой шум, и можно ли выбрать её по диагностике ряда $(\hat{\alpha}, \hat{H})$?



Четыре класса шума N1–N4. Медиана F_4 срезает α -устойчивые выбросы (N3, N4); линейный F_1 и вейвлет F_3 тянутся за ними.


Фильтры (причинные): F_0 нет, F_1 скользящее, F_2 Калман, F_3 вейвлет, F_4 медиана, F_5 каскад $F_4 \rightarrow F_3$. **Оптимизаторы:** SGD-семейство, Adam/AdamW. Дизайн *блочный*: SGD $\times$ N1–N4 (сходимость), Adam $\times$ N2/N4 (скорость); по 100 запусков на ячейку.

Гипотезы (заданы до экспериментов): **H1** — при тяжёлых хвостах (N3) медиана F_4 спасает сходимость; **H2** — при долгой памяти (N2) вейвлет F_3 +Adam ускоряет; **H3** — смешанный N4 не лечится простым фильтром; **H4** — на гауссиане (N1) фильтр не нужен.

Спасает ли фильтр сходимость при тяжёлых хвостах? (N3)

Да. Медиана F_4 даёт 100/100 сходимостей, пол $\|\nabla f\|^2$ ниже в 22–161 $\times$; линейные фильтры и вейвлет — нет.

Задача	бин. F_0	бин. F_4	асимпт. F_0	асимпт. F_4
квадратичная	2/100	100/100	0.456	0.0047
логистическая	0/100	100/100	0.0767	0.00048
авторегрессия	100/100	100/100	0.0479	0.0022




F_0 и линейные фильтры застревают; F_4/F_5 уходят на 1–2 порядка ниже.


Строго: парный $t - d$ Коэна 4.8–7.7, $p_{\text{Холм}} < 10^{-60}$, Стоуффер $Z=32.8$; точный критерий **Макнемара** $0 \rightarrow 100/100$, $p \approx 8 \times 10^{-31}$; эффект держится и под Clipped-SGD (3.2–5.2 $\times$).

Ускоряет ли фильтр при долгой памяти? (N2)

Да. Вейвлет F_3 +Adam ускоряет в $4.9 \times (T_{\varepsilon} \text{ 814} \rightarrow 165)$; Калман 1.9 $\times$; линейные, медиана и каскад F_5 (0.9 $\times$) — нет.




Контроль N1 (гаусс): фильтрация нейтральна, F_4 чуть хуже среднего (TOST: $F_4 \equiv F_0$ в пределах фактора 2) — гипотеза 4.



Лечится ли смешанный режим N4 каскадом?

Нет. Каскад $F_5 = F_4 \rightarrow F_3$ на N3 даже *сильнее* простой медианы (136/168/36 $\times$), но N4 не покрывает: отношение уровней 1.0–1.2 (TOST: $F_4, F_5 \equiv F_0$). Долгая память размывает выброс в кластер шире окна медианы — остаётся открытым вопросом.




Калибровка под реальные хвосты ($\hat{\alpha}=1.21$): на N3cal разрыв F_0/F_k сохраняется (91–129 $\times$), на N4cal — нет.

Переносится ли эффект на реальные ряды?

Скорость — да, точность — нет. На реальных рядах фильтр Калмана F_2 резко ускоряет Adam:

Домен	сошл. F_0	лучший	ускор.	holdout
фин. 15-мин	109/200	F_2	51 $\times$	0.529/0.522
фин. дневные	322/400	F_2	11 $\times$	0.635/0.626
сенсор ETT	100/100	F_1	2.2 $\times$	0.641/0.488
макро FRED	300/300	F_0	—	F_0 лучший

Но **кластерный бутстрап** holdout-MSE (ресэмпл рядов): прогноз фильтр *не* улучшает — ДИ выше нуля на всех доменах. Фильтр кондиционирует *оптимизацию*, а не прогноз.



Результаты и выводы

- Робастная медиана возвращает градиенту конечную дисперсию — линейные фильтры этого не дают.
- Тяжёлый хвост сам по себе не повод фильтровать: на гауссе лучший выбор — F_0 .
- На реальных рядах фильтр ускоряет оптимизацию, но прогноз не улучшает (и может ухудшить).
- Каскад F_5 усиливает N3, но N4 остаётся открытым.

Правило $(\hat{\alpha}, \hat{H}) \rightarrow \text{фильтр}$: тяжёлый хвост $\Rightarrow F_4$ +SGD; долгая память $\Rightarrow F_3$ +Adam; гаусс $\Rightarrow F_0$; N4 $\Rightarrow$ нет рецепта. **Все четыре гипотезы подтверждены на 100 сиах формальными критериями.**

Код и данные: github.com/Poogee/momo_proj