

Beyond Gaussian Noise

Сходимость стохастических оптимизаторов под коррелированным и тяжёлохвостовым градиентным шумом

Д. Картунов В. Пастушенко А. Дубовицкий А. Шадрин • НИУ ВШЭ, Москва

Причинная медиана возвращает SGD конечную дисперсию градиента и спасает сходимость при α -устойчивом шуме; на реальных рядах фильтр ускоряет оптимизацию, но не улучшает прогноз.

Задача


Наблюдаемый ряд — сигнал плюс шум, $y_t = s_t + \xi_t$. Перед обучением весь ряд проходит через причинный фильтр F : $\tilde{y} = F(y)$, и из сглаженного ряда строятся признаки. Прогнозную модель (AR(p)) учим методом первого порядка

$$x_{k+1} = x_k - \eta \phi(g_k), \quad g_k = \frac{1}{|\mathcal{B}_k|} \sum_{t \in \mathcal{B}_k} \nabla_x \ell(x_k, \tilde{\phi}_t, c_t).$$

Признаки и таргет — из $\tilde{y}$; качество меряем на holdout по *исходному* будущему y_t . На финансовых рядах шум тяжёлохвостый (α -устойчивый, $\alpha < 2$, бесконечная дисперсия) и долгопамятный — базовые предпосылки сходимости SGD нарушены.

Вопрос. Как тройка (шум) $\times$ (фильтр) $\times$ (оптимизатор) влияет на сходимость, и можно ли по диагностике ряда заранее выбрать удачную пару?

Шумы и фильтрация: как это выглядит



Сверху вниз — четыре класса шума; причинная медиана срезает α -устойчивые выбросы, линейные фильтры — нет.

Шумы

N1 гаусс (контроль)
N2 $1/f$ (память)
N3 α -устойч. (хвост)
N4 смешанный

Фильтры (причинные)

F_0 без фильтра
 F_1 скольз. среднее
 F_2 Калман
 F_3 вейвлет-порог
 F_4 медиана
 F_5 каскад $F_4 \rightarrow F_3$

Дизайн — блочный (не полный перебор). **Блок А:** SGD-семейство (SGD, Clipped-, Normalized-SGD) на всех шумах N1–N4 — спасение *сходимости*. **Блок В:** Adam/AdamW на N2/N4 — *скорость*. По **100** независимых запусков на ячейку.

Теория и гипотезы


Гипотезы выведены из теории и зафиксированы до экспериментов. При $\alpha < 2$ второй момент градиентного шума бесконечен — редкие гигантские шаги не дают SGD стабилизироваться. Хвост медианы окна w имеет порядок $\alpha \lceil w/2 \rceil$: при $w=9$ конечная дисперсия уже при $\alpha > 0.4$. Линейные фильтры α -устойчивость не убирают.

- H1** (N3): медиана F_4 переводит SGD в сходящийся режим.
- H2** (N2): вейвлет F_3 +Adam ускоряет сильнее линейных.
- H3** (N4): простого фильтра, снижающего пол, нет.
- H4** (N1): фильтрация нейтральна, медиана чуть хуже среднего.

Главный результат: спасение сходимости (N3, $\alpha=1.2$, SGD)

Без фильтра и с линейными $F_1 - F_3$ SGD почти не сходится; причинная медиана F_4 — **100/100**, асимптотический уровень $\|\nabla f\|^2$ **ниже в 22–161** $\times$.


Задача	бин. F_0	бин. F_4	асимпт. F_0	асимпт. F_4
квадратичная	2/100	100/100	0.456	0.0047
логистическая	0/100	100/100	0.0767	0.00048
авторегрессия	100/100	100/100	0.0479	0.0022



F_0 и линейные фильтры застревают; F_4/F_5 уходят на 1–2 порядка ниже (6 фильтров, 100 сидов).

Строгие критерии: размеры эффекта и ДИ


Парный односторонний t на $\log_{10} \|\nabla f\|^2$: d Коэна 4.8–7.7, $p_{\text{Холм}} < 10^{-60}$, Стоуффер $Z=32.8$. Бинарную сходимость проверяем точным критерием **Макнемара** ($0 \rightarrow 100/100$, $p \approx 8 \times 10^{-31}$).



Лесовидная диаграмма: 95% бутстрэп-интервалы снижения пола целиком правее $\times 1$ и на синтетике ($\alpha=1.2$), и на калиброванном шуме ($\alpha=1.21$).

Долгая память (N2) и гауссов контроль (N1)


N2, Adam: вейвлет F_3 ускоряет в **4.9** $\times$ (T_{ε} 814 $\rightarrow$ 165), Калман — 1.9 $\times$; линейные, медиана и даже каскад F_5 (0.9 $\times$) — нет.



N1: фильтрация нейтральна, F_4 чуть хуже среднего (TOST: $F_4 \equiv F_0$ в пределах фактора 2).

Каскад F_5 для смешанного N4

Двухстадийный каскад $F_5 = F_4 \rightarrow F_3$ (медиана против выбросов, затем вейвлет против $1/f$ -памяти) проган как полноправный фильтр. **На N3** каскад даже *сильнее* простой медианы (136/168/36 $\times$). **Но N4 он не закрывает:** отношение уровней 1.0–1.2, как и у простых фильтров (TOST: $F_4, F_5 \equiv F_0$). Долгая память размывает выброс в кластер шире окна медианы.




Калибровка под реальные хвосты ($\hat{\alpha}=1.21$): на N3cal разрыв F_0/F_k сохраняется (91–129 $\times$), на N4cal — нет.

Реальные ряды: скорость $\neq$ точность

Фильтр Калмана F_2 резко ускоряет сходимость Adam, доля сошедшихся ячеек растёт. Но **кластерный бутстреп** по holdout-MSE (ресэмпл рядов): прогноз **не** улучшается — наоборот, ДИ *выше нуля* на всех доменах.

Домен	сошл. F_0	ускор. (F_2)	holdout (лучш./ F_0)
фин. 15-мин	109/200	51 $\times$	0.529/0.522
фин. дневные	322/400	11 $\times$	0.635/0.626
сенсор ETT	100/100	2.2 $\times$	0.641/0.488
макро FRED	300/300	—	F_0 лучший



Фильтр — инструмент кондиционирования *оптимизации*, не улучшения прогноза.

Итог проверки гипотез и выводы

Гипотеза	Подтв.	Критерий
H1 — медиана спасает (N3)	✓	Макнемар + парный t
H2 — вейвлет ускоряет (N2)	✓	two-stage
H3 — для N4 рецепта нет	✓	TOST (и каскад F_5)
H4 — на N1 не помогает	✓	TOST, $d < 0$
Фильтр улучшает прогноз	✗	кластерный бутстреп

Правило ($\hat{\alpha}, \hat{H}$) $\rightarrow$ **фильтр**: тяжёлый хвост без памяти $\Rightarrow F_4$ +SGD; лёгкий хвост, долгая память $\Rightarrow F_3$ +Adam; гаусс $\Rightarrow F_0$; смешанный N4 — открытый вопрос.

Выводы. Робастная медиана возвращает градиенту конечную дисперсию (линейные фильтры — нет); тяжёлый хвост сам по себе не повод фильтровать (на гауссе лучший выбор F_0); на реальных рядах фильтр ускоряет оптимизацию, но прогноз *не* улучшает; каскад F_5 усиливает N3, но N4 остаётся открытым. **Все четыре гипотезы подтвердились на 100 сидах с формальными стат-критериями.**