

Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Gradient Noise

Д. КОРТУНОВ В. ПАСТУШЕНКО А. ДУБОВИЦКИЙ А. ШАДРИН НИУ ВШЭ, Москва

Постановка

Наблюдаемый ряд — сигнал плюс шум. Перед обучением мы сглаживаем его фильтром F и учим модель $AR(p)$ на сглаженном ряде, а качество меряем на holdout по исходному y_t :

$$y_t = s_t + \xi_t, \quad \tilde{y} = F(y).$$

Вопрос работы — какой фильтр F и какой оптимизатор подходят под какой шум ξ .


Четыре класса шума ξ_t

- **N1, гаусс** — $\xi_t \sim \mathcal{N}(0, \sigma^2)$, конечная дисперсия
- **N2, долгая память** — $(1-L)^d \xi_t = e_t$, спектр $\sim |f|^{-2d}$, показатель Хёрста $H > \frac{1}{2}$
- **N3, тяжёлый хвост** — $\xi_t \sim S_\alpha, \alpha < 2, \Pr(|\xi| > t) \sim t^{-\alpha}, \mathbb{E} \xi^2 = \infty$
- **N4, смешанный** — α -устойчивые инновации с долгой памятью

Шесть фильтров F

- F_0 — без фильтра, $\tilde{y}_t = y_t$
- F_1 — скользящее среднее, $\tilde{y}_t = \frac{1}{w} \sum_{i=0}^{w-1} y_{t-i}$
- F_2 — Калман, оптимальная линейная оценка уровня
- F_3 — вейвлет, мягкий порог коэффицентов Добеши
- F_4 — медиана, $\tilde{y}_t = \text{med}(y_{t-w+1}, \dots, y_t)$
- F_5 — каскад: сначала F_4 , затем F_3

Оптимизаторы: SGD, Clipped-SGD, Normalized-SGD, Adam, AdamW.




Гипотезы и выводы

Проверка гипотез

Гипотеза	Тест	Итог
N1 — медиана даёт сходимость (N3)	Макнемар, t	✓
N2 — вейвлет ускоряет (N2)	two-stage	✓
N3 — для N4 фильтра нет	TOST	✓
N4 — на гауссе фильтр не нужен	TOST	✓
фильтр улучшает прогноз	бутстрап	✗


Помогает ли фильтр сходимости при тяжёлых хвостах?

Да. Под α -устойчивым шумом обычный SGD почти не сходится, а медиана F_4 доводит до сходимости все 100 запусков из 100 и снижает асимптотический уровень $\|\nabla f\|^2$ в 22–161 раз. Линейные фильтры и вейвлет этого не дают.




Ускоряет ли фильтр обучение при долгой памяти?

Да, но только вейвлет с адаптивным оптимизатором. Под розовым шумом $1/f$ вейвлет F_3 с Adam достигает заданной точности в 4.9 раза быстрее (за 165 итераций вместо 814), тогда как линейные фильтры, медиана и каскад выигрыша не дают. На гауссовом шуме фильтрация ожидаемо нейтральна.



Справляется ли каскад со смешанным шумом?

Нет. Каскад $F_5 = F_4 \rightarrow F_3$ на тяжёлых хвостах даже сильнее простой медианы (снижение в 136, 168 и 36 раз), но смешанный режим N4 он не решает — уровень почти не меняется, как и у простых фильтров. Долгая память растягивает выброс в кластер, который не помещается в окно медианы, поэтому N4 остаётся открытым.



Калибровка под реальные хвосты ($\hat{\alpha}=1.21$): на тяжёлохвостовом N3cal эффект сохраняется (91–129 раз), на смешанном N4cal его нет.

Переносится ли эффект на реальные данные?

Частично. На реальных финансовых рядах фильтр Калмана F_2 ускоряет обучение Adam в десятки раз, но точность прогноза при этом не растёт. Кластерный бутстрап подтверждает, что ошибка на отложенной выборке с фильтром и без него совпадает. Фильтр улучшает оптимизацию, а не сам прогноз.

Таблица VII. Реальные ряды, Adam

Домен	T	F_0	сошл. F_0	лучш. ускор.	holdout (n/F_0)
фин. 15-мин	3030	109/200	F_3 59	$51\times$	0.529/0.522
фин. дневные	640	322/400	F_2 60	$11\times$	0.635/0.626
сенсор ETT	44	100/100	F_1 20	$2.2\times$	0.641/0.488
макро FRED	20	300/300	F_0 20	—	F_0 лучший

Ускорение большое, а ошибка на holdout с фильтром и без него практически одинакова.

Как выбрать фильтр

По обучающей части ряда оцениваем индекс хвоста $\hat{\alpha}$ (Маккаллох или Хилл) и память $\hat{H}$ (DFA по $|\Delta y_t|$), затем по четырём случаям:

Диагностика	Связка
$\hat{\alpha} \approx 2, \hat{H} \approx 0.5$	без фильтра F_0
$\hat{\alpha} \approx 2, \hat{H} > 0.6$	вейвлет F_3 , Adam
$\hat{\alpha} < 1.9, \hat{H} \approx 0.5$	медиана F_4 , SGD
$\hat{\alpha} < 1.9, \hat{H} > 0.6$	Калман F_2 , Adam

Какой фильтр выбрать

Шум ряда	Связка
тяжёлый хвост	F_4 , SGD
долгая память	F_3 , Adam
гауссов шум	F_0
смешанный (N4)	F_2 , Adam