

Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Gradient Noise

Д. КОРТУНОВ В. ПАСТУШЕНКО А. ДУБОВИЦКИЙ А. ШАДРИН НИУ ВШЭ, Москва

Постановка

Наблюдаемый ряд — сигнал плюс шум. Перед обучением мы сглаживаем его фильтром F и учим модель $\text{AR}(p)$ на сглаженном ряде, а качество меряем на holdout по исходному y_t :

$$y_t = s_t + \xi_t, \quad \tilde{y} = F(y).$$

Вопрос работы — какой фильтр F и какой оптимизатор подходят под какой шум ξ .


Четыре класса шума ξ_t

- **N1, гаусс** — $\xi_t \sim \mathcal{N}(0, \sigma^2)$, конечная дисперсия
- **N2, долгая память** — $(1-L)^d \xi_t = e_t$, спектр $\sim |f|^{-2d}$, показатель Хёрста $H > \frac{1}{2}$
- **N3, тяжёлый хвост** — $\xi_t \sim S_\alpha, \alpha < 2, \Pr(|\xi|>t) \sim t^{-\alpha}, \mathbb{E} \xi^2 = \infty$
- **N4, смешанный** — α -устойчивые инновации с долгой памятью

Шесть фильтров F


- F_0 — без фильтра, $\tilde{y}_t = y_t$
- F_1 — скользящее среднее, $\tilde{y}_t = \frac{1}{w} \sum_{i=0}^{w-1} y_{t-i}$
- F_2 — Калман, оптимальная линейная оценка уровня
- F_3 — вейвлет, мягкий порог коэффициентов Добеши
- F_4 — медиана, $\tilde{y}_t = \text{med}(y_{t-w+1}, \dots, y_t)$
- F_5 — каскад: сначала F_4 , затем F_3

Оптимизаторы: SGD, Clipped-SGD, Normalized-SGD, Adam, AdamW.




Помогает ли фильтр сходимости при тяжёлых хвостах?

Да. Под α -устойчивым шумом обычный SGD почти не сходится, а медиана F_4 доводит до сходимости все 100 запусков из 100 и снижает асимптотический уровень $\|\nabla f\|^2$ в 22–161 раз. Линейные фильтры и вейвлет этого не дают.




Ускоряет ли фильтр обучение при долгой памяти?

Да, но только вейвлет с адаптивным оптимизатором. Под розовым шумом $1/f$ вейвлет F_3 с Adam достигает заданной точности в 4.9 раза быстрее (за 165 итераций вместо 814), тогда как линейные фильтры, медиана и каскад выигрыша не дают. На гауссовом шуме фильтрация ожидаемо нейтральна.



Справляется ли каскад со смешанным шумом?


Нет. Каскад $F_5 = F_4 \rightarrow F_3$ на тяжёлых хвостах даже сильнее простой медианы (снижение в 136, 168 и 36 раз), но смешанный режим N4 он не решает — уровень почти не меняется, как и у простых фильтров. Долгая память растягивает выброс в кластер, который не помещается в окно медианы, поэтому N4 остаётся открытым.



Калибровка под реальные хвосты ($\hat{\alpha}=1.21$): на тяжёлохвостовом N3cal эффект сохраняется (91–129 раз), на смешанном N4cal его нет.

Переносится ли эффект на реальные данные?

Частично. На реальных финансовых рядах фильтр Калмана F_2 ускоряет обучение Adam в десятки раз, но точность прогноза при этом не растёт. Кластерный бутстреп подтверждает, что ошибка на отложенной выборке с фильтром и без него совпадает. Фильтр улучшает оптимизацию, а не сам прогноз.



Гипотезы и выводы

Проверка гипотез

Гипотеза	Стат-тест	Итог
N1 — медиана возвращает сходимость (N3)	Макнемар, t	✓
N2 — вейвлет ускоряет обучение (N2)	two-stage	✓
N3 — для смешанного N4 фильтра нет	TOST	✓
N4 — на гауссовом шуме фильтр не нужен	TOST	✓
фильтр улучшает прогноз на реальных данных	бутстреп	✗

Какой фильтр выбрать

Шум ряда	Связка
тяжёлый хвост	медиана F_4 с SGD
долгая память	вейвлет F_3 с Adam
гауссов шум	без фильтра, F_0
смешанный (N4)	готового рецепта пока нет

Главное. Медиана возвращает градиенту конечную дисперсию, чего линейные фильтры не дают. Тяжёлый хвост сам по себе не повод фильтровать. На реальных данных фильтр ускоряет обучение, но не улучшает прогноз, а смешанный режим N4 пока остаётся нерешённым.