


Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Gradient Noise

Д. КОРТУНОВ В. ПАСТУШЕНКО А. ДУБОВИЦКИЙ А. ШАДРИН НИУ ВШЭ, Москва

Зачем фильтровать ряд перед обучением

На финансовых рядах градиентный шум тяжёлохвостый (α -устойчивый, $\alpha < 2$, с бесконечной дисперсией) и обладает долгой памятью, поэтому классические условия сходимости SGD перестают выполняться. Мы предлагаем перед обучением сглаживать ряд фильтром, $\hat{y} = F(y)$, и обучать модель $AR(p)$ уже на нём. Главный вопрос работы — какой фильтр и какой оптимизатор подходят под каждый тип шума, и можно ли выбрать их заранее по диагностике ряда $(\hat{\alpha}, \hat{H})$.




Четыре класса шума и действие фильтров. Медиана F_4 срезает редкие выбросы тяжёлого хвоста, тогда как скользящее среднее F_1 и вейвлет F_3 следуют за ними.

Мы сравниваем шесть фильтров — F_0 без фильтрации, F_1 скользящее среднее, F_2 Калман, F_3 вейвлет, F_4 медиана и F_5 каскад $F_4 \rightarrow F_3$ — в паре с оптимизаторами SGD, Clipped-SGD, Normalized-SGD, Adam и AdamW. Каждая задача прогоняется по 100 раз.

Помогает ли фильтр сходимости при тяжёлых хвостах?


Да. Под α -устойчивым шумом обычный SGD почти не сходится, а медиана F_4 доводит до сходимости все 100 запусков из 100 и снижает асимптотический уровень $\|\nabla f\|^2$ в 22–161 раз. Линейные фильтры и вейвлет этого не дают.



Без фильтра и с линейными фильтрами уровень остаётся высоким, а медиана F_4 и каскад F_5 опускают его на один-два порядка.


Ускоряет ли фильтр обучение при долгой памяти?

Да, но только вейвлет с адаптивным оптимизатором. Под розовым шумом $1/f$ вейвлет F_3 с Adam достигает заданной точности в 4.9 раза быстрее (за 165 итераций вместо 814), тогда как линейные фильтры, медиана и каскад выигрыша не дают. На гауссовом шуме фильтрация ожидаемо нейтральна.



Справляется ли каскад со смешанным шумом?


Нет. Каскад $F_5 = F_4 \rightarrow F_3$ на тяжёлых хвостах даже сильнее простой медианы (снижение в 136, 168 и 36 раз), но смешанный режим N4 он не решает — уровень почти не меняется, как и у простых фильтров. Долгая память растягивает выброс в кластер, который не помещается в окно медианы, поэтому N4 остаётся открытым.



Калибровка под реальные хвосты ($\hat{\alpha}=1.21$): на тяжёлохвостовом N3cal эффект сохраняется (91–129 раз), на смешанном N4cal его нет.

Переносится ли эффект на реальные данные?

Частично. На реальных финансовых рядах фильтр Калмана F_2 ускоряет обучение Adam в десятки раз, но точность прогноза при этом не растёт. Кластерный бутстрап подтверждает, что ошибка на отложенной выборке с фильтром и без него совпадает. Фильтр улучшает оптимизацию, а не сам прогноз.



Гипотезы и выводы

Гипотеза	Проверка	Итог
N1 — медиана восстанавливает сходимости (N3)	Макнемар, парный t	✓
N2 — вейвлет ускоряет обучение (N2)	двухэтапный тест	✓
N3 — для смешанного N4 простого фильтра нет	TOST (эквивалентность)	✓
N4 — на гауссовом шуме фильтр не нужен	TOST (эквивалентность)	✓
фильтр улучшает прогноз на реальных данных	кластерный бутстрап	✗

Практическое правило выбора простое. При тяжёлом хвосте берём медиану с SGD, при долгой памяти — вейвлет с Adam, при чистом гауссовом шуме фильтр не нужен, а для смешанного режима готового рецепта пока нет.

- Медиана возвращает градиенту конечную дисперсию, чего линейные фильтры не дают
- Тяжёлый хвост сам по себе не повод фильтровать
- На реальных рядах фильтр ускоряет обучение, но не улучшает прогноз
- Смешанный режим N4 остаётся нерешённым