

Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Gradient Noise

Д. Картунов В. Пастушенко А. Дубовицкий А. Шадрин

НИУ ВШЭ, Москва

Постановка

Наблюдаемый ряд — сигнал плюс шум, $y_t = s_t + \xi_t$. Перед обучением весь ряд проходит через причинный фильтр F : $\tilde{y} = F(y)$, и уже из сглаженного ряда строятся признаки $\tilde{\phi}_t$. Обучаем прогнозную модель (AR(p)) минимизацией риска методом первого порядка

$$g_k = \frac{1}{|B_k|} \sum_{t \in B_k} \nabla_x \ell(x_k, \tilde{\phi}_t, c_t), \quad x_{k+1} = x_k - \eta \phi(g_k).$$

Признаки и обучающий таргет — из ряда $\tilde{y}$; качество же оценивается на holdout по исходному будущему значению y_t .

На финансовых рядах шум тяжёлохвостый (α -устойчивый, $\alpha < 2$, бесконечная дисперсия) и долгопамятный. Тогда базовые предпосылки теории сходимости SGD нарушаются.

Вопрос. Как тройка (тип шума) $\times$ (фильтр) $\times$ (оптимизатор) влияет на сходимость, и можно ли по диагностике ряда заранее выбрать удачную пару?

Четыре класса шума

- N1 гауссов белый (контроль)
- N2 розовый $1/f$ (долгая память)
- N3 α -устойчивый (тяжёлый хвост)
- N4 смешанный (хвост $\cap$ память)

Фильтры F_0 – F_5 (все причинные)

- F_0 без фильтрации (контроль)
- F_1 скользящее среднее (линейный)
- F_2 фильтр Калмана (линейный)
- F_3 вейвлет-порог (Добеши)
- F_4 причинная медиана (робастный)
- F_5 каскад $F_4 \rightarrow F_3$ (для N4)

Оптимизаторы: SGD, Clipped-SGD, Normalized-SGD, Adam, AdamW. Дизайн — **блочный** (не полный перебор): Блок А (SGD-семейство, все шумы N1–N4; спасение сходимости) и Блок В (Adam/AdamW, N2/N4; скорость). Шумы N2 и N4 проходят оба блока. По **100** независимых запусков на ячейку.


Предпосылки и гипотезы

Гипотезы выведены из теории и зафиксированы *до* экспериментов. При $\alpha < 2$ второй момент градиентного шума бесконечен — редкие гигантские шаги не дают SGD стабилизироваться. Хвост выборочной медианы окна w имеет порядок $\alpha \lceil w/2 \rceil$: при $w=9$ конечная дисперсия уже при $\alpha > 0.4$. Линейные фильтры α -устойчивость не убирают; долгую память лечит спектральное разреживание (вейвлет) или адаптивный шаг (Adam).

- Гипотеза 1 (N3): медиана F_4 переводит SGD в сходящийся режим; линейные фильтры — нет.
- Гипотеза 2 (N2): для Adam/AdamW вейвлет F_3 ускоряет сходимость сильнее линейных фильтров.
- Гипотеза 3 (N4): ни один простой фильтр не снижает асимптотический уровень $\|\nabla f\|^2$.
- Гипотеза 4 (N1): фильтрация нейтральна, медиана чуть хуже среднего.

Эксперимент 1: тяжёлые хвосты ($\alpha=1.2$, SGD)

Без фильтра и с линейными F_1, F_2, F_3 — почти нет сходимостей; причинная медиана F_4 — 100/100, асимптотический уровень $\|\nabla f\|^2$ ниже в 22–161 $\times$.




F_0 и линейные фильтры застревают на асимптотическом уровне; F_4/F_5 уходят вниз на 1–2 порядка (6 фильтров, 100 сидов).


Строгие критерии: парный t на $\log_{10} \|\nabla f\|^2 - d$ Коэна 4.8–7.7, $p_{\text{Холм}} < 10^{-60}$, Стоуффер $Z=32.8$. Бинарную сходимость проверяет точный критерий **Макнемара** ($0 \rightarrow 100/100$, $p \approx 8 \times 10^{-31}$). Спасение устойчиво и под Clipped-SGD (3.2–5.2 $\times$).

Долгая память, смешанный шум, гауссов контроль

N2, Adam: вейвлет F_3 ускоряет сходимость в $4.9 \times$ (T_{ε} 814 $\rightarrow$ 165), Калман F_2 — 1.9 $\times$; линейные, медиана и даже каскад F_5 (0.9 $\times$) — нет.



N4: отношение асимптотических уровней $F_0/F_k \approx 1$ для всех простых фильтров *и* двухстадийного каскада F_5 — мешанный режим не закрывается (гипотеза 3). N1: фильтрация нейтральна, F_4 слегка проигрывает среднему (гипотеза 4); TOST подтверждает эквивалентность F_0 :




Каскад F_5 для N4

Двухстадийный каскад $F_5 = F_4 \rightarrow F_3$ (медиана против выбросов, затем вейвлет против $1/f$ -памяти) прогнан как полноправный фильтр. На N3 он даже *сильнее* простой медианы (136/168/36 $\times$), но **N4 не закрывает** (отношение уровней 1.0–1.2, TOST: $F_4, F_5 \equiv F_0$).

Эксперименты 2–3: калибровка и реальные ряды

Медиана хвостов по корзине реальных инструментов: $\hat{\alpha} \approx 1.21$, $\hat{d} \approx 0.29$. На калиброванной синтетике спасение сходимости сохраняется (91–129 $\times$):



На реальных рядах (Adam) фильтр Калмана F_2 резко ускоряет сходимость:

Домен	сошл. F_0	лучший	ускор.	holdout (лучш./ F_0)
фин. 15-мин	109/200	F_2	51 $\times$	0.529/0.522
фин. дневные	322/400	F_2	11 $\times$	0.635/0.626
сенсор ETT	100/100	F_1	2.2 $\times$	0.641/0.488
макро FRED	300/300	F_0	—	F_0 лучший

Но скорость $\neq$ точность: кластерный бутстреп по holdout-MSE (ресэмпл рядов) показывает, что прогноз фильтр *не* улучшает — доверительный интервал выше нуля на всех доменах. Фильтр — инструмент кондиционирования оптимизации, а не улучшения прогноза.

Правило $(\hat{\alpha}, \hat{H}) \rightarrow$ фильтр

Режим $(\hat{\alpha}, \hat{H})$	связка	основание
$\hat{\alpha} \approx 2, \hat{H} \approx 0.5$	F_0	теория+опыт
$\hat{\alpha} \approx 2, \hat{H} > 0.6$	F_3 +Adam	теория+опыт
$\hat{\alpha} < 1.9, \hat{H} \approx 0.5$	F_4 +SGD	теория+опыт
$\hat{\alpha} < 1.9, \hat{H} > 0.6$ (N4)	нет рецепта	открытый вопрос

Выводы

- Робастная медиана восстанавливает конечную дисперсию градиента — линейные фильтры этого не дают.
- Тяжёлый хвост сам по себе не повод фильтровать: если узкое место не в сходимости (гаусс, светлый хвост), лучший выбор — F_0 .
- На реальных рядах фильтр ускоряет оптимизацию, но прогноз на holdout не улучшает (и может ухудшить).
- Каскад F_5 усиливает эффект на N3, но смешанный N4 остаётся открытым.
- Все четыре гипотезы подтвердились на 100 сидах формальными стат-критериями.

Код и данные: github.com/Poogee/momo_proj