

# Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Gradient Noise

Д. КОРТУНОВ   В. ПАСТУШЕНКО   А. ДУБОВИЦКИЙ   А. ШАДРИН   НИУ ВШЭ, Москва

## Постановка

Наблюдаемый ряд — сигнал плюс шум. Перед обучением мы сглаживаем его фильтром  $F$  и учим модель  $AR(p)$  на сглаженном ряде, а качество меряем на holdout по исходному  $y_t$ :

$$y_t = s_t + \xi_t, \quad \tilde{y} = F(y).$$

Вопрос работы — какой фильтр  $F$  и какой оптимизатор подходят под какой шум  $\xi$ .


## Четыре класса шума $\xi_t$

- **N1, гаусс** —  $\xi_t \sim \mathcal{N}(0, \sigma^2)$ , конечная дисперсия
- **N2, долгая память** —  $(1-L)^d \xi_t = e_t$ , спектр  $\sim |f|^{-2d}$ , показатель Хёрста  $H > \frac{1}{2}$
- **N3, тяжёлый хвост** —  $\xi_t \sim S_\alpha, \alpha < 2, \Pr(|\xi| > t) \sim t^{-\alpha}, \mathbb{E} \xi^2 = \infty$
- **N4, смешанный** —  $\alpha$ -устойчивые инновации с долгой памятью

## Шесть фильтров $F$

- $F_0$  — без фильтра,  $\tilde{y}_t = y_t$
- $F_1$  — скользящее среднее,  $\tilde{y}_t = \frac{1}{w} \sum_{i=0}^{w-1} y_{t-i}$
- $F_2$  — Калман, оптимальная линейная оценка уровня
- $F_3$  — вейвлет, мягкий порог коэффицентов Добеши
- $F_4$  — медиана,  $\tilde{y}_t = \text{med}(y_{t-w+1}, \dots, y_t)$
- $F_5$  — каскад: сначала  $F_4$ , затем  $F_3$

Оптимизаторы: SGD, Clipped-SGD, Normalized-SGD, Adam, AdamW.




## Гипотезы и выводы

### Проверка гипотез

| Гипотеза                          | Тест          | Итог |
|-----------------------------------|---------------|------|
| N1 — медиана даёт сходимость (N3) | Макнемар, $t$ | ✓    |
| N2 — вейвлет ускоряет (N2)        | two-stage     | ✓    |
| N3 — для N4 фильтра нет           | TOST          | ✓    |
| N4 — на гауссе фильтр не нужен    | TOST          | ✓    |
| фильтр улучшает прогноз           | бутстрап      | ✗    |


## Помогает ли фильтр сходимости при тяжёлых хвостах?

**Да.** Под  $\alpha$ -устойчивым шумом обычный SGD почти не сходится, а медиана  $F_4$  доводит до сходимости все 100 запусков из 100 и снижает асимптотический уровень  $\|\nabla f\|^2$  в 22–161 раз. Линейные фильтры и вейвлет этого не дают.




## Ускоряет ли фильтр обучение при долгой памяти?

**Да, но только вейвлет с адаптивным оптимизатором.** Под розовым шумом  $1/f$  вейвлет  $F_3$  с Adam достигает заданной точности в 4.9 раза быстрее (за 165 итераций вместо 814), тогда как линейные фильтры, медиана и каскад выигрыша не дают. На гауссовом шуме фильтрация ожидаемо нейтральна.



## Справляется ли каскад со смешанным шумом?

**Нет.** Каскад  $F_5 = F_4 \rightarrow F_3$  на тяжёлых хвостах даже сильнее простой медианы (снижение в 136, 168 и 36 раз), но смешанный режим N4 он не решает — уровень почти не меняется, как и у простых фильтров. Долгая память растягивает выброс в кластер, который не помещается в окно медианы, поэтому N4 остаётся открытым.



Калибровка под реальные хвосты ( $\hat{\alpha}=1.21$ ): на тяжёлохвостовом N3cal эффект сохраняется (91–129 раз), на смешанном N4cal его нет.

## Переносится ли эффект на реальные данные?

**Частично.** На реальных финансовых рядах фильтр Калмана  $F_2$  ускоряет обучение Adam в десятки раз, но точность прогноза при этом не растёт. Кластерный бутстрап подтверждает, что ошибка на отложенной выборке с фильтром и без него совпадает. Фильтр улучшает оптимизацию, а не сам прогноз.

| Домен        | $T$  | $F_0$   | сошл. $F_0$ | лучш. | ускор.      | holdout ( $\mu/F_0$ ) |
|--------------|------|---------|-------------|-------|-------------|-----------------------|
| фин. 15-мин  | 3030 | 109/200 | $F_2$       | 59    | $51\times$  | 0.529/0.522           |
| фин. дневные | 640  | 322/400 | $F_2$       | 60    | $11\times$  | 0.635/0.626           |
| сенсор ETT   | 44   | 100/100 | $F_1$       | 20    | $2.2\times$ | 0.641/0.488           |
| макро FRED   | 20   | 300/300 | $F_0$       | 20    | —           | $F_0$ лучший          |

Ускорение большое, а ошибка на holdout с фильтром и без него практически одинакова.

## Тип шума на реальных данных

| Диагностика                                   | Шум               |
|-----------------------------------------------|-------------------|
| $\hat{\alpha} \approx 2, \hat{H} \approx 0.5$ | N1, гаусс         |
| $\hat{\alpha} \approx 2, \hat{H} > 0.6$       | N2, долгая память |
| $\hat{\alpha} < 1.9, \hat{H} \approx 0.5$     | N3, тяжёлый хвост |
| $\hat{\alpha} < 1.9, \hat{H} > 0.6$           | N4, смешанный     |

Считаем по обучающей части:  $\hat{\alpha}$  — метод Маккаллоха или Хилла,  $\hat{H}$  — DFA по  $|\Delta y_t|$ .

## Какой фильтр выбрать

| Шум ряда       | Связка       |
|----------------|--------------|
| тяжёлый хвост  | $F_4$ , SGD  |
| долгая память  | $F_3$ , Adam |
| гауссов шум    | $F_0$        |
| смешанный (N4) | $F_2$ , Adam |