

Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Gradient Noise

Д. КОРТУНОВ В. ПАСТУШЕНКО А. ДУБОВИЦКИЙ А. ШАДРИН НИИ ВШЭ, Москва

Постановка

Наблюдаемый ряд — сигнал плюс шум. Перед обучением мы сглаживаем его фильтром F и учим модель $AR(p)$ на сглаженном ряде, а качество меряем на holdout по исходному y_t :

$$y_t = s_t + \xi_t, \quad \tilde{y} = F(y).$$

Вопрос работы — какой фильтр F и какой оптимизатор подходят под какой шум ξ .


Четыре класса шума ξ_t

- **N1, гаусс** — $\xi_t \sim \mathcal{N}(0, \sigma^2)$, конечная дисперсия
- **N2, долгая память** — $(1-L)^d \xi_t = e_t$, спектр $\sim |f|^{-2d}$, показатель Хёрста $H > \frac{1}{2}$
- **N3, тяжёлый хвост** — $\xi_t \sim S_\alpha, \alpha < 2, \Pr(|\xi|>t) \sim t^{-\alpha}, \mathbb{E} \xi^2 = \infty$
- **N4, смешанный** — α -устойчивые инновации с долгой памятью

Шесть фильтров F

- F_0 — без фильтра, $\tilde{y}_t = y_t$
- F_1 — скользящее среднее, $\tilde{y}_t = \frac{1}{w} \sum_{i=0}^{w-1} y_{t-i}$
- F_2 — Калман, оптимальная линейная оценка уровня
- F_3 — вейвлет, мягкий порог коэффициентов Добеши
- F_4 — медиана, $\tilde{y}_t = \text{med}(y_{t-w+1}, \dots, y_t)$
- F_5 — каскад: сначала F_4 , затем F_3


Оптимизаторы: SGD, Clipped-SGD, Normalized-SGD, Adam, AdamW.



Медиана F_4 срезает редкие выбросы тяжёлого хвоста (N3, N4), скользящее среднее F_1 и вейвлет F_3 следуют за ними.

Помогает ли фильтр сходимости при тяжёлых хвостах?


Да. Под α -устойчивым шумом обычный SGD почти не сходится, а медиана F_4 доводит до сходимости все 100 запусков из 100 и снижает асимптотический уровень $\|\nabla f\|^2$ в 22–161 раз. Линейные фильтры и вейвлет этого не дают.



Без фильтра и с линейными фильтрами уровень остаётся высоким, а медиана F_4 и каскад F_5 опускают его на один-два порядка.


Ускоряет ли фильтр обучение при долгой памяти?

Да, но только вейвлет с адаптивным оптимизатором. Под розовым шумом $1/f$ вейвлет F_3 с Adam достигает заданной точности в 4.9 раза быстрее (за 165 итераций вместо 814), тогда как линейные фильтры, медиана и каскад выигрыша не дают. На гауссовом шуме фильтрация ожидаемо нейтральна.



Справляется ли каскад со смешанным шумом?


Нет. Каскад $F_5 = F_4 \rightarrow F_3$ на тяжёлых хвостах даже сильнее простой медианы (снижение в 136, 168 и 36 раз), но смешанный режим N4 он не решает — уровень почти не меняется, как и у простых фильтров. Долгая память растягивает выброс в кластер, который не помещается в окно медианы, поэтому N4 остаётся открытым.



Калибровка под реальные хвосты ($\hat{\alpha}=1.21$): на тяжёлохвостовом N3cal эффект сохраняется (91–129 раз), на смешанном N4cal его нет.

Переносится ли эффект на реальные данные?

Частично. На реальных финансовых рядах фильтр Калмана F_2 ускоряет обучение Adam в десятки раз, но точность прогноза при этом не растёт. Кластерный бутстрап подтверждает, что ошибка на отложенной выборке с фильтром и без него совпадает. Фильтр улучшает оптимизацию, а не сам прогноз.



Гипотезы и выводы

Гипотеза	Проверка	Итог
N1 — медиана восстанавливает сходимостью (N3)	Макнемар, парный t	✓
N2 — вейвлет ускоряет обучение (N2)	двухэтапный тест	✓
N3 — для смешанного N4 простого фильтра нет	TOST (эквивалентность)	✓
N4 — на гауссовом шуме фильтр не нужен	TOST (эквивалентность)	✓
фильтр улучшает прогноз на реальных данных	кластерный бутстрап	✗

Практическое правило выбора простое. При тяжёлом хвосте берём медиану с SGD, при долгой памяти — вейвлет с Adam, при чистом гауссовом шуме фильтр не нужен, а для смешанного режима готового рецепта пока нет.

- Медиана возвращает градиенту конечную дисперсию, чего линейные фильтры не дают
- Тяжёлый хвост сам по себе не повод фильтровать
- На реальных рядах фильтр ускоряет обучение, но не улучшает прогноз
- Смешанный режим N4 остаётся нерешённым

Код и данные: github.com/Poogee/momo_proj