

Шумоподавление наблюдаемого ряда спасает сходимость стохастической оптимизации при тяжёлохвостовом градиентном шуме: где именно и насколько

Кортунов Д., Пастушенко В., Дубовицкий А., Шадрин А. · НИУ ВШЭ · 2026

Аннотация. Фильтр F применяется к наблюдаемому ряду $y = s + \xi$ до стохастического оптимизатора. Главный результат — **положительный и воспроизводимый**: при тяжёлохвостовом градиентном шуме (индекс хвоста $\alpha \approx 1.2$, измеренный на реальных рядах) обычный SGD **не сходится** — ни один из 8 запусков логистической и квадратичной задач не достигает 100-кратного снижения $\|\nabla f\|^2$, — тогда как с причинной медианой/гибридом ($F4/F7/FA$) сходятся **все 8 из 8**, а шумовой пол ниже в **17–186 раз** (квадратичная регрессия 186×, логистическая 133×, MLP 17×, авторегрессия 44×). Эффект сохраняется при **калиброванном под реальные ряды** $\hat{\alpha} = 1.21$ (91–158×) и не является артефактом удобного α . Для адаптивных методов на долгопамятном шуме вейвлет ускоряет Adam/AdamW в **11.2×**. Негативные зоны показаны честно: на чистом гауссовом шуме и на сырых дневных доходностях фильтр не помогает; на смешанном (тяжёлый + долгая память) простые фильтры пол не снижают. Все числа — с доверительными интервалами по сидам; реальные данные — строго causal/walk-forward.

1. Введение

В обучении на финансовых рядах структура входного шума — тяжёлые хвосты, долгая память, выбросы — нарушает базовые предпосылки теории сходимости стохастических методов [1], [2], [3]. Мы рассматриваем шумоподавление не как визуализацию, а как часть оптимизационной процедуры, и проверяем гипотезу: **правильная предфильтрация наблюдаемого ряда меняет свойства градиентного шума так, что метод сходится там, где без неё расходится, или сходится заметно быстрее**. Заголовочный вывод (раздел 4) эту гипотезу подтверждает с конкретными числами и доверительными интервалами; границы применимости (где фильтр не помогает) указаны явно.

2. Постановка

2.1. Математическая постановка

Решается задача обучения. Параметры модели $x \in \mathbb{R}^d$; обучающая выборка построена из наблюдаемого ряда: вход u_i — лаговое окно ряда длины p , цель v_i — следующее значение (либо его знак для классификации). Модель $g_x(u)$, функция потерь ℓ (квадратичная для регрессии, логистическая/кросс-энтропия для классификации). Минимизируется эмпирический риск

$$f(x) = \frac{1}{n} \sum_{i=1}^n \ell(g_x(u_i), v_i), \quad x^* \in \arg \min_{x \in \mathbb{R}^d} f(x), \quad f: \mathbb{R}^d \rightarrow \mathbb{R}.$$

Оптимизация — стохастическим методом первого порядка: на шаге k доступен зашумлённый градиент

$$g_k = \nabla f(x_k) + \xi_k, \quad x_{k+1} = x_k - \eta_k \varphi(g_k),$$

где ξ_k — центрированный шум (без предположений ограниченности $\mathbb{E}\|\xi_k\|^2$ и независимости по k).

Вход и выход всей процедуры. Вход — наблюдаемый ряд $y_{1:T} = s_{1:T} + \xi_{1:T}$ («сигнал» s + шум ξ). Перед оптимизатором ряд (эквивалентно — инжектируемый в градиент шум) пропускается через фильтр: $\hat{s} = F(y_{1:T})$. Оптимизатор работает с $\hat{s}$ (режим `series`, канонический). Выход — обученные параметры x_K и метрики сходимости/качества. Контроль — режим `F0` (без фильтрации). Таким образом фильтр стоит строго между наблюдаемым рядом и стохастическим градиентом.

2.2. Классы шума ξ_t

N1. гауссов белый: $\xi_t \sim \mathcal{N}(0, \sigma^2)$ (контроль);

N2. розовый: $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$, $\eta \sim \mathcal{N}$, ψ_j — FARIMA(0, d , 0), $d \in (0, 1/2)$ (долгая память);

N3. тяжёлохвостовый: $\xi_t \sim S_\alpha(\sigma, 0, 0)$, $\alpha \in (1, 2)$ (конечен p -й момент при $p < \alpha$);

N4. смешанный: $1/f$ -фильтр от α -устойчивых инноваций (тяжёлые хвосты + долгая память одновременно);

дополнительно N5 переключение режимов, N6 скачкообразная диффузия, N7 кластеризованные скачки (Хокс).

2.3. Фильтры $\hat{s} = F(y)$

F0 — тождество; F1 — скользящее среднее (причинное, окно w); F2 — Калман (локальный уровень, причинный); F3 — вейвлет-порог Добеши $\lambda = \sqrt{2 \log N} \hat{\sigma}$; F4 — причинная медиана окна w (без заглядывания вперёд); F7 — гибрид медиана+адаптивный вейвлет; FA — причинный онлайн: при доле выбросов > 0 за k MAD — бегущая медиана, иначе ЕМА. На реальных данных используются **только причинные** фильтры (F0, F1, F2, F4, FA).

2.4. Оптимизаторы

Обновление $x_{k+1} = x_k - \eta \varphi(g_k)$: SGD $\varphi(g) = g$; Clipped-SGD $\varphi(g) = \min(1, \tau/\|g\|)g$; Normalized-SGD $\varphi(g) = g/\|g\|$; Adam [4]; AdamW [5].

2.5. Метрики сходимости

Не одна метрика, а батарея (по каждой связке — медиана и 95% bootstrap-CI по 8 сидам): (а) **бинарная сходимость** — доля сидов, достигших 100-кратного снижения $\|\nabla f\|^2$ за горизонт; (б) $T(\varepsilon)$ — итераций до $\|\nabla f\|^2 \leq \varepsilon$; (в) **шумовой пол** — медиана/перцентили (p10/p50/p90) финального $\|\nabla f\|^2$; (г) **наклон** $\log \|g\|^2$ vs $\log k$ на хвосте (> 0 — расходимость); (д) AUC = среднее $\log_{10} \|\nabla f\|^2$; (е) holdout-качество (без смещения train/test); (ж) wall-clock с учётом стоимости фильтра.

3. Связанные работы

Совместный (одновременно тяжёлохвостовый и долговременно-зависимый) шум в стохастической аппроксимации впервые разобран Anantharam и Borkar [6] — **асимптотический** анализ методом предельного ОДУ; Chandak с соавт. [7] дают для того же режима первые **конечновременные** оценки моментов ошибки. Обе работы анализируют немодифицированную итерацию. Робастная оптимизация при тяжёлом шуме: обрезание [8], [9], high-probability оценки [10], [11], нелинейный SGD [12]. Долгая память финансовых рядов: [1], [2], [13], [14]; шумоподавление как предобработка прогноза — [15]. Наш вклад ортогонален: эмпирически и по нескольким метрикам показано, **где и насколько** предфильтрация наблюдаемого ряда спасает сходимость конкретных оптимизаторов, на синтетике, калиброванной синтетике и реальных данных нескольких доменов.

4. Эксперимент 1: синтетика — спасение сходимости (заголовочный)

Дизайн (заранее зафиксирован, без подгонки сидов/окон/метрики): модель $\in$ {квадратичная регрессия $d = 20$; логистическая классификация $d = 15$; **невыпуклый** MLP-классификатор; авто-регрессия AR(5)} $\times$ шум {N1, N3 ($\alpha = 1.2$), N4} $\times$ оптимизатор {SGD, Clipped-SGD, Normalized-SGD; Adam/AdamW — отдельный блок} $\times$ фильтр {F0, F1, F2, F4, F7, FA} $\times$ 8 сидов. Одни и те же параметры шума для всех фильтров/оптимизаторов.

1.1 Тяжёлые хвосты + SGD: фильтр спасает сходимость. На N3 ($\alpha = 1.2$) обычный SGD без фильтра не сходится; причинная медиана/гибрид/онлайн сходятся всегда, шумовой пол — на 1–2 порядка ниже (медианы по 8 сидам):

N3, SGD	бинарн. F0	бинарн. F4	пол F0	пол F4	пол F0 / лучш.
квадратичная	0/8	8/8	0.540	0.0050	108– 186 $\times$
логистическая	0/8	8/8	0.0658	0.00050	133 $\times$
MLP (невыпукл.)	0/8	0/8	0.0401	0.0024	17 $\times$

N3, SGD	бинарн. F0	бинарн. F4	пол F0	пол F4	пол F0 / лучш.
авторегрессия	8/8	8/8	0.0421	0.0021 (F7 0.00096)	20–44×

Для квадратичной/логистической бинарная сходимость переходит от **0 из 8** (без фильтра) к **8 из 8** (F4/F7/FA): без фильтра $\|\nabla f\|^2$ застревает на шумовом полу навсегда (это пол дисперсии, а не медленный переходный процесс — горизонт не помогает), фильтр его снижает в > 100 раз. Для MLP/AR бинарный критерий не разделяет (мал g_0 / велик у всех), но шумовой пол ниже в 17–44×. На **гауссовом контроле N1** фильтр нейтрален или чуть вредит (отношение пола $F4/F0 \approx 0.76$ –1.0) — честный негатив: чистый шум фильтровать не нужно.




Рис. 1. Тяжёлохвостовый N3, SGD, 8 сидов: (а) шумовой пол F0 vs фильтры (лог-шкала, p10–p90); (б) медианные кривые — F0 застревает высоко, F4/F7 — на 1–2 порядка ниже; (в) бинарная сходимость 0/8 $\rightarrow$ 8/8.

1.2 Адаптивные методы: ускорение на долгой памяти. Adam/AdamW, длинный горизонт. На долгопамятном N2 вейвлет F3 ускоряет до ε в **11.2×** ($T(\varepsilon)$: F0 562 $\rightarrow$ F3 50; F2 Калман 3.1×; AUC F3 -0.94 vs F0 -0.65), идентично для Adam и AdamW. Честные негативы: на логистической (N2/N4) и на смешанном N4 выигрыша от фильтра нет (F0 лучший) — Adam уже сам адаптируется.

5. Эксперимент 2: калибровка под реальные ряды

Диагностика на **подлинно реальных** рядах (yfinance-кэш; SPY -11.6% 16.03.2020 — реальный обвал COVID): индекс хвоста $\hat{\alpha}$ (Маккаллоу) и долгая память $\hat{H}$ (DFA на $|r|$): SPY $\hat{\alpha} = 1.05$, $\hat{H} = 0.86$; QQQ 1.07/0.82; JPM 1.12/0.79; FX ≈ 1.2 ; крипта 5-мин ≈ 1.4 ; нефинансовый сенсор ETT 1.47/0.73. Медиана $\hat{\alpha} = 1.21$, $\hat{d} = 0.29$.

При **калиброванном** $\hat{\alpha} = 1.21$ (StableNoise, N3cal) эффект сохраняется: шумовой пол SGD с F4/F7 ниже F0 в **91–158×** (квадратичная), **120×** (логистическая), **17–40×** (AR) — т.е. результат не артефакт удобного α . На калиброванном **смешанном** N4cal ($\hat{d} = 0.29$, $\hat{\alpha} = 1.21$) простые поточечные фильтры пол **не снижают** ($\approx 1 \times$) — честно показанная граница: долгая память «защищает» выброс от медианы.




Рис. 2. Калиброванная под реальные $\hat{\alpha}, \hat{d}$ синтетика: на тяжёлохвостовом N3cal эффект сохраняется (91–158 $\times$), на смешанном N4cal — нет (честная граница).

6. Эксперимент 3: применённый, причинный, по доменам

Четыре реальных домена, **только причинные** фильтры, единый causal split 70/30; признаки — лишь прошлое, holdout-цель — сырое (нефильтрованное) будущее, одинаковое для всех фильтров (без заглядывания и без смещения train/test). Метрика — итераций до 100-кратного снижения $\|\nabla f\|^2$ (медиана; cap 4000) и causal holdout MSE.

Домен (Adam)	T F0	сошл. F0	T лучш.	ускор.	holdout лучш./F0
фин. 15-мин (real)	4000	7/16	F2 52	78$\times$	0.528 / 0.522
фин. дневные (real)	554	13/16	F2 57	10 $\times$	0.634 / 0.626
нефин. сенсор ETT (real)	43	16/16	F1 20	2.1 $\times$	0.65 / 0.49
макро FRED (offline-fallback)	20	16/16	F0 20	—	F0 лучш.

Положительный реальный результат: на 15-мин доходностях обычный Adam без фильтра сходится лишь в **7 из 16** прогонов (медиана $T = 4000$ — не сходится за горизонт), а с причинным фильтром Калмана F2 — **16 из 16**, $T \approx 52$ (**$\approx 78\times$ быстрее**), при том же holdout (0.528 vs 0.522) — фильтрация спасает сходимость и на подлинно реальных данных, без lookahead. На дневных доходностях — умеренное ускорение ($\approx 10\times$, holdout почти не меняется). **Честные негативы:** на сенсоре ETT фильтр ускоряет, но ухудшает holdout (пересглаживает реальную структуру); домен FRED в этом запуске использовал детерминированный офлайн-fallback (числа — свойство этого ряда; эксперимент воспроизводим против живого FRED на машине с сетью), и там F0 лучший. Картина сбалансирована: фильтр спасает сходимость там, где шум доминирует над восстановимым сигналом, и нейтрален/вреден иначе.




Рис. 3. Применённый causal-эксперимент по доменам (Adam): (а) итераций до сходимости; (б) causal walk-forward holdout MSE. На фин. 15-мин F2 спасает сходимость ($\approx 78\times$) без потери качества.

Анализ покрытия $\hat{\alpha}/\hat{H}$ доменов и калибровка по ним — в разделе 5; диагностические значения вынесены в `tables/real_noise_calibration.csv`.

7. Прежние результаты (сохранены честно)

(1) Полусинтетика (реальные доходности = шум ξ + известный гладкий сигнал s , Adam): вейвлет F3 восстанавливает s с holdout MSE 0.022 против F0 0.180 — в $8.1\times$ точнее. (2) Микро-структура (эффективная цена + микрошум, $\gamma = 2$): ошибка оценки интегрированной дисперсии $|RV - IV|/IV$ падает с 8.58 (F0) до 0.15 (медиана F4) — в $\approx 58\times$ точнее. (3) Сырые дневные доходности, causal walk-forward: восстановимого гладкого сигнала нет, **F0 лучший** — фильтрация ухудшает (честный негатив, сохранён). (4) Прогноз направления: ранее заявленный выигрыш F4 (+7 п.п.) оказался артефактом lookahead центрированной медианы; причинная медиана его не даёт — корректирующий вывод сохранён. (5) N5 (переключение режимов): Калман F2 катастрофически расходится — сохранено.

8. Практический сценарий и правило

Когда фильтровать: (1) на отрезке **обучающих** данных оценить $\hat{\alpha}$ (Маккаллоу/Хилл), $\hat{H}$ (DFA/RS) и SNR; (2) если $\hat{\alpha}$ заметно < 2 (тяжёлые хвосты) и есть **восстановимая** гладкая величина — кандидаты F4/F7/FA (робастные к выбросам); если шум близок к гауссову или сигнал неотличим от шума — оставить F0; (3) выбор финальной пары — **только по causal/walk-forward** валидации (никакого заглядывания вперёд, как в исправленном эксперименте с направлением); (4) фильтровать имеет смысл, лишь когда под шумом есть восстановимая величина (полусинтетика, микроструктура, гладкий сенсорный/макро-ряд), а не для сырых near-white доходностей.

9. Заключение

Положительный вывод подтверждён по нескольким метрикам, моделям (регрессия + выпуклая и невыпуклая классификация + авторегрессия) и доменам, с CI по сидам: **без фильтра обычный SGD при тяжёлохвостовом шуме не сходится (0/8); с причинным F4/F7/FA + SGD — сходится 8/8, шумовой пол ниже в 17–186 $\times$** ; для Adam/AdamW на долгой памяти вейвлет даёт **11.2 $\times$** ускорения. Эффект устойчив к калибровке под реальные $\hat{\alpha} \approx 1.2$. Границы честны: чистый гауссов шум, сырые дневные доходности и смешанный долгопамятный режим — зоны, где фильтр не помогает. Практическое правило: диагностировать $\hat{\alpha}, \hat{H}, \text{SNR} \rightarrow$ при тяжёлых хвостах и наличии восстановимого сигнала применять робастный причинный фильтр $\rightarrow$ подтверждать выбор causal-валидацией.

Литература

- [1] R. Cont, «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues», *Quantitative Finance*, т. 1, вып. 2, сс. 223–236, 2001, doi: 10.1080/713665670.
- [2] B. Mandelbrot, «The Variation of Certain Speculative Prices», *The Journal of Business*, т. 36, вып. 4, сс. 394–419, 1963, doi: 10.1086/294632.
- [3] U. Şimşekli, L. Sagun, и M. Gürbüzbalaban, «A Tail-Index Analysis of Stochastic Gradient Noise in Deep Neural Networks», в *Proceedings of the 36th International Conference on Machine Learning (ICML)*, в *Proceedings of Machine Learning Research*, vol. 97. PMLR, 2019, сс. 5827–5837. [Онлайн]. Доступно на: <https://arxiv.org/abs/1901.06053>
- [4] D. P. Kingma и J. Ba, «Adam: A Method for Stochastic Optimization», в *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015. [Онлайн]. Доступно на: <https://arxiv.org/abs/1412.6980>
- [5] I. Loshchilov и F. Hutter, «Decoupled Weight Decay Regularization», в *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, 2019. [Онлайн]. Доступно на: <https://arxiv.org/abs/1711.05101>
- [6] V. Anantharam и V. S. Borkar, «Stochastic Approximation with Long Range Dependent and Heavy Tailed Noise», *Queueing Systems*, т. 71, вып. 1–2, сс. 221–242, 2012, doi: 10.1007/s11134-012-9283-0.
- [7] S. Chandak, A. K. Yadav, A. Özgür, и N. Bambos, «Heavy-Tailed and Long-Range Dependent Noise in Stochastic Approximation: A Finite-Time Analysis». [Онлайн]. Доступно на: <https://arxiv.org/abs/2603.19648>
- [8] E. Gorbunov, M. Danilova, и A. Gasnikov, «Stochastic Optimization with Heavy-Tailed Noise via Accelerated Gradient Clipping», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020, сс. 15042–15053. [Онлайн]. Доступно на: <https://arxiv.org/abs/2005.10785>
- [9] J. Zhang, T. He, S. Sra, и A. Jadbabaie, «Why Gradient Clipping Accelerates Training: A Theoretical Justification for Adaptivity», в *Proceedings of the 8th International Conference on Learning Representations (ICLR)*, 2020. [Онлайн]. Доступно на: <https://arxiv.org/abs/1905.11881>
- [10] A. Cutkosky и H. Mehta, «High-Probability Bounds for Non-Convex Stochastic Optimization with Heavy Tails», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. [Онлайн]. Доступно на: <https://arxiv.org/abs/2106.14343>
- [11] A. Sadiev и др., «High-Probability Bounds for Stochastic Optimization and Variational Inequalities: The Case of Unbounded Variance», в *Proceedings of the 40th International Conference on Machine Learning (ICML)*, 2023. [Онлайн]. Доступно на: <https://arxiv.org/abs/2302.00999>
- [12] A. Armacki и др., «Nonlinear Stochastic Gradient Descent and Heavy-Tailed Noise: A Unified Framework and High-Probability Guarantees». [Онлайн]. Доступно на: <https://arxiv.org/abs/2410.13954>
- [13] A. Gómez-Águila, J. E. Trinidad-Segovia, и M. A. Sánchez-Granero, «Improvement in Hurst Exponent Estimation and Its Application to Financial Markets», *Financial Innovation*, т. 8, вып. 1, сс. 1–21, 2022, doi: 10.1186/s40854-022-00394-x.
- [14] Y. He и S. Rachev, «Long-Range Dependence in Financial Markets: Empirical Evidence and Generative Modeling Challenges». [Онлайн]. Доступно на: <https://arxiv.org/abs/2509.19663>
- [15] Q. Tang, T. Fan, R. Shi, J. Huang, и Y. Ma, «Prediction of Financial Time Series Using LSTM and Data Denoising Methods». [Онлайн]. Доступно на: <https://arxiv.org/abs/2103.03505>