

Шумоподавление как предобработка: влияние типа фильтра на сходимость стохастических оптимизаторов на финансовых временных рядах

Кортунов Д., Пастушенко В., Дубовицкий А., Шадрин А.

НИУ ВШЭ · Москва, Россия · Апрель 2026 г.

Аннотация. Финансовые временные ряды содержат шум различной природы: гауссов, тяжёлохвостовый, коррелированный и их комбинации. Прямая подача таких данных в стандартные стохастические оптимизаторы нарушает базовые предположения теории сходимости. Мы исследуем шумоподавление — скользящее среднее, фильтр Калмана, вейвлет-пороговую обработку, медианный фильтр — как этап предобработки **наблюдаемого ряда** y_t перед оптимизацией, и эмпирически измеряем влияние выбора фильтра на сходимость SGD, Adam и AdamW. Полный факторный эксперимент $F0-F4 \times N1-N4 \times \{SGD, Adam, AdamW\}$ на двух синтетических задачах (квадратичная, логистическая регрессия) и параллельный эксперимент на реальных дневных доходностях дают согласованную картину. **Основная метрика — скорость сходимости** $T(\varepsilon)$ (число итераций до малого градиента). Фильтры, линейно отслеживающие сигнал (вейвлет F3, Калман F2), сходятся в десятки раз быстрее «без фильтра»; робастные нелинейные фильтры (медиана, онлайн-адаптивный) лагают за детерминированным градиентом — виден явный компромисс «скорость $\leftrightarrow$ устойчивость к хвостам». Вторично, при сильном шуме информативен уровень шумового пола: Калман снижает его в 3–8 раз на всех типах шума, медиана лучшая на тяжёлохвостовом/смешанном и наименее искажает структуру ряда. На реальных дневных лог-доходностях любой causal-фильтр **ухудшает** прогностический MSE ($F0 = 4.29 \cdot 10^{-4}$ против $7.88 \cdot 10^{-4}$ у Калмана): у дневных доходностей нет гладкой сигнальной компоненты. Однако на двух финансово-реалистичных постановках с известным ground truth фильтрация даёт **положительный** результат: (а) при реальном шуме доходностей + известный сигнал вейвлет восстанавливает сигнал в 7–9 раз точнее F0; (б) на микроструктурно-зашумлённых ценах медианный фильтр снижает ошибку оценки интегрированной дисперсии в 4–77 раз. Главный практический вывод — проверяемое правило: диагностировать ряд, отобрать кандидатов, выбрать по валидации; фильтровать только когда под шумом есть восстанавливаемый сигнал.

1. Введение

В обучении на финансовых временных рядах традиционно фокусируются на архитектуре модели или на модификациях оптимизатора. Сама структура входного шума остаётся «за кадром», хотя именно она задаёт сложность обучения: тяжёлые хвосты, долгая память и выбросы нарушают предпосылки, при которых гарантируется устойчивая работа классических стохастических методов [1], [2], [3].

В работе шумоподавление трактуется не как вспомогательная техника, а как полноценная часть оптимизационного контура: фильтр F действует на **наблюдаемый ряд** $y_t = s_t + \xi_t$ перед тем, как по сглаженной версии ряда вычисляется стохастический градиент и делается шаг оптимизатора A . Гипотеза: правильный выбор пары (F, A) существенно изменяет свойства поступающего в оптимизатор шума и тем самым улучшает скорость сходимости и итоговое качество без усложнения самого оптимизатора. Эмпирически мы проверяем эту гипотезу на матрице (тип шума N1–N4) $\times$ (фильтр F0–F4) $\times$ (оптимизатор) на синтетических задачах и на реальных дневных доходностях.

Совместное влияние тяжёлых хвостов и долгой памяти на стохастическую аппроксимацию изучается с работы Анантарамы и Боркара [4] (2012) и уточнено в недавнем finite-time анализе Чандака и др. [5]; робастная оптимизация при тяжёлом шуме развита в обрезании и нормировке градиента [6], [7], [8], [9], а шумоподавление финансовых рядов перед прогнозом — например, в [10]. В отличие

от этих работ мы не выводим теоретических оценок, а строим эмпирический бенчмарк сочетания **фильтра наблюдаемого ряда** и оптимизатора в той же постановке шума. Полная воспроизводимая реализация, конфигурации экспериментов и сводные таблицы приложены к работе.

2. Постановка

2.1. Решаемая задача обучения

Рассматривается параметрическая модель g_x с вектором параметров $x \in \mathbb{R}^d$, которую обучают на данных, порождённых финансовым временным рядом. По ряду формируется обучающая выборка из пар $(u_i, v_i)_{i=1}^n$, где вход u_i — признаки (например, лаговое окно прошлых значений ряда), а целевая переменная v_i — следующее значение ряда (регрессия) либо знак его приращения (классификация). Цель — минимизировать средний эмпирический риск

$$f(x) = \frac{1}{n} \sum_{i=1}^n \ell(g_x(u_i), v_i) \rightarrow \min_{x \in \mathbb{R}^d},$$

где ℓ — функция потерь (квадратичная для регрессии, логистическая для классификации), а $f : \mathbb{R}^d \rightarrow \mathbb{R}$ — L -гладкая, в общем случае невыпуклая целевая функция. **Вход** процедуры — ряд и гиперпараметры (фильтр, оптимизатор); **выход** — обученные параметры $\hat{x}$ и качество модели на отложенной выборке.

Минимизация ведётся стохастическим методом первого порядка: на итерации k доступен лишь зашумлённый градиент

$$g_k = \nabla f(x_k) + \xi_k,$$

где ξ_k — центрированная шумовая компонента, наследующая статистические свойства наблюдаемого ряда (тяжёлые хвосты, долгая память), из-за чего стандартные предположения теории сходимости (ограниченная дисперсия, независимость) могут нарушаться.

2.2. Модель наблюдаемого ряда и шума

Наблюдаемый ряд представляется как сумма восстановимого сигнала и шума,

$$y_t = s_t + \xi_t,$$

где s_t — сигнал, ξ_t — шум одного из четырёх классов:

- **N1 (гауссов белый):** $\xi_t \sim \mathcal{N}(0, \sigma^2)$ — контроль, стандартные допущения теории.
- **N2 (розовый, $1/f$):** $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$ с гауссовыми η_j и FARIMA(0, d , 0)-весами, $d \in (0, 1/2)$; дисперсия конечна, но есть долгая память.
- **N3 (тяжёлохвостовый):** $\xi_t \sim S_\alpha(\sigma, 0, 0)$ покомпонентно, $\alpha \in (1, 2)$; конечен лишь p -й момент при $p < \alpha$.
- **N4 (смешанный):** $\xi_t = \sum_{j \geq 0} \psi_j \zeta_{t-j}$, ζ_j i.i.d. α -устойчивые, ψ_j задают $1/f$ -спектр; тяжёлые хвосты и долгая память одновременно.

2.3. Предобработка

Фильтр F отображает наблюдаемый ряд в оценку сигнала $\hat{s} = F(y_{1:T})$; именно $\hat{s}$ (а не сырой y) используется для формирования обучающих пар и градиента. Рассматриваются пять режимов:

- **F0 (без фильтрации):** $\hat{s} = y$, контрольное условие.
- **F1 (скользящее среднее):** $\hat{s}_t = w^{-1} \sum_{i=0}^{w-1} y_{t-i}$.
- **F2 (фильтр Калмана):** линейная локальная модель уровня $s_t = s_{t-1} + w_t$, оптимален при гауссовом шуме [11].
- **F3 (вейвлет-порог):** разложение Добеши, мягкий порог $\sqrt{2 \log N} \hat{\sigma}$ к деталям [12], [13], [14].
- **F4 (медианный фильтр):** окно w [15].

2.4. Оптимизаторы и метрика

Сравниваются SGD с постоянным шагом η , Adam [16] и AdamW [17]. Качество связки оценивается эмпирическим временем до ε -точности

$$T(\varepsilon; F, A, \mathcal{N}) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\},$$

а также (при недостижимости ε из-за шумового пола) уровнем финального $\|\nabla f\|^2$ и качеством на отложенной выборке.

2.5. Две реализации задачи

Синтетическая. f — квадратичная задача наименьших квадратов (ℓ квадратична, g_x линейна) либо логистическая регрессия (ℓ логистическая). Шум класса N_i инжектируется в стохастический градиент с известными параметрами σ, d, α ; это позволяет контролируемо измерять влияние (F, A, N) и сопоставлять с теорией.

Прикладная. f — MSE одношагового AR(p)-прогноза реальной дневной лог-доходности; u_i — p прошлых (отфильтрованных) доходностей, v_i — следующая доходность; оценка — causal walk-forward, чтобы исключить заглядывание вперёд.

2.6. Реализация: фильтрация наблюдаемого ряда

Предобработка реализована как фильтрация **наблюдаемого ряда** до подачи в оптимизатор. Для каждого прогона строится траектория шума $\xi_{1:T}$ заданного класса N_i , к ней покоординатно применяется фильтр F , и сглаженный ряд участвует в вычислении стохастического градиента на каждом шаге. Режим F_0 соответствует отсутствию фильтрации (оптимизация по сырым наблюдениям) и служит контрольным условием. Этот режим (`preprocess_mode="series"` в `src/tomo/optim.py`) является основным и единственным в отчётных результатах; альтернативная схема «фильтр на буфере градиентов» сохранена в коде только как legacy-аблация и в основную часть не входит.

Концептуально это соответствует постановке проекта: фильтр восстанавливает оценку сигнала $\hat{s}_t$ из зашумлённого наблюдения $y_t = s_t + \xi_t$, и качество этой оценки напрямую определяет, насколько «чистый» градиент видит оптимизатор. Линейные фильтры (МА, Калман) оптимальны при гауссовом наблюдательном шуме; робастные нелинейные (медиана) лучше переносят выбросы тяжёлохвостовых распределений.

3. Метрики

Помимо $T(\varepsilon)$ вычисляем медиану и интервал 10–90 перцентилей кривой $\mathbb{E}\|\nabla f(x_k)\|^2$ от номера итерации (по 5 запускам), MSE и log-правдоподобие на отложенной выборке для прикладных рядов, прирост SNR $\Delta\text{SNR} = \text{SNR}_{\text{out}} - \text{SNR}_{\text{in}}$ для каждой пары (фильтр, шум) и изменение структурных характеристик ряда: показателя Хёрста $\hat{H}$ (методом DFA) и индекса хвоста $\hat{\alpha}$ (методом квантилей Маккаллоха) до и после фильтрации [12].

4. Эксперименты

4.1. Валидация генераторов шума

Для каждого шума N_i генерируется $T = 8192$ отсчётов, оцениваются обратные характеристики: $\hat{H}$ через DFA, $\hat{\alpha}$ методом Маккаллоха. Совпадение с заданными параметрами (в пределах ± 0.1 для H , ± 0.15 для α) подтверждает корректность генераторов; см. соответствующие тесты в `tests/test_noise.py` и `tests/test_metrics.py`.

4.2. Прирост SNR и искажение структуры (диагностика фильтров)

Для контрольного синтетического сигнала (плавный гауссов процесс) при $\sigma = 0.5$ измерены приросты SNR ($\Delta\text{SNR} = \text{SNR}_{\text{out}} - \text{SNR}_{\text{in}}$, дБ) на повторях для каждого фильтра и шума. Картина согласуется с теорией фильтрации:

Фильтр	N1 Гаусс	N2 розовый	N3 тяжёлый	N4 смеш.
F1 МА	12.0	5.8	13.0	7.2
F2 Калман	13.0	7.7	16.9	9.9
F3 вейвлет	11.8	9.6	5.1	4.9
F4 медиана	11.4	5.8	18.0	9.9

Калман лидирует на гауссовом N1 (классический результат об оптимальности при гауссовом наблюдательном шуме), вейвлет — на розовом N2 (мощность $1/f$ локализована в коэффициентах детализации), медиана — на тяжёлохвостовом N3 и смешанном N4 (робастность к выбросам). Вейвлет почти не работает на N3, поскольку универсальный порог оценивается по гауссовому MAD и занижает шумовой пол.

Искажение структуры (модуль изменения оценки Хёрста $|\hat{H}_{\text{out}} - \hat{H}_{\text{in}}|$, меньше — лучше) минимально у медианы F4 (0.35–0.42 по всем шумам) и максимально у вейвлета F3 на N1 (1.14): агрессивный порог переглаживает гладкий сигнал. То есть «сильнейший по SNR» фильтр не всегда «бережнее всех к структуре» — это управляющий компромисс при выборе предобработки.




Рис. 1. Прирост SNR (дБ) после фильтрации наблюдаемого ряда. Калман лидирует на N1, вейвлет — на N2, медиана — на тяжёлохвостовых N3/N4.

4.3. Синтетический факторный эксперимент

Полный факторный дизайн F0–F4 (+ онлайн-адаптивный FA, см. отдельный раздел ниже) $\times$ N1–N4 $\times$ {SGD, Adam, AdamW} на двух задачах: квадратичная $f(x) = (1/2)x^\top Ax - b^\top x$ (число обусловленности 10, размерность 50) и логистическая регрессия ($n = 4000$, $d = 20$). Для каждой ячейки — 5 запусков по 2000 шагов, фильтрация наблюдаемого ряда.

Основная метрика — скорость сходимости. При умеренном шуме ($\sigma = 0.15$) измеряем $T(\varepsilon)$ — медианное число итераций до $\mathbb{E}\|\nabla f\|^2 \leq \varepsilon$, $\varepsilon = 0.1$ (ниже — быстрее; ячейки, не дошедшие за 2000 шагов, обозначены как «не сошёлся»).

Фильтр	N1	N2	N3	N4
F0 без фильтра	48	не сош.	1963	не сош.
F1 МА	505	не сош.	не сош.	не сош.
F2 Калман	26	не сош.	82	не сош.
F3 вейвлет	6	741	33	не сош.
F4 медиана	не сош.	не сош.	не сош.	не сош.
FA онлайн	не сош.	не сош.	не сош.	не сош.




Рис. 2. Скорость сходимости $T(\varepsilon=0.1)$ (квадратичная, Adam, $\sigma = 0.15$): линейные трекары сигнала (вейвлет F3, Калман F2) сходятся за десятки итераций; робастные фильтры (медиана, онлайн FA) лагают за детерминированным градиентом и не доходят за горизонт.

Главный вывод по скорости: фильтры, **линейно отслеживающие сигнал** (вейвлет F3, затем Калман F2), сходятся в десятки раз быстрее F0, тогда как робастные нелинейные фильтры (медиана F4, онлайн-адаптивный FA) сходятся медленно или не доходят: на квадратичной задаче градиент — крупная детерминированная компонента, которую median-подобные фильтры запаздывают отслеживать. Это явный **компромисс «скорость ↔ устойчивость к хвостам»**: то, что лучше всего убирает выбросы (медиана), хуже всего для скорости на гладком сигнале, и наоборот. Смешанный шум N4 не покрывается ни одним фильтром за 2000 шагов.

Вторичная метрика — уровень шумового пола. При большом шуме ($\sigma = 0.5$) ε недостижим ни одной ячейкой (содержательный факт сам по себе); тогда информативен **уровень пола** — медиана финального $\|\nabla f\|^2$ на квадратичной задаче:

Фильтр	N1	N2	N3	N4
F0 без фильтра	0.58	3.43	1.28	11.14
F1 МА	1.00	4.35	2.92	14.26
F2 Калман	0.07	1.46	0.38	7.60
F3 вейвлет	0.81	3.51	2.32	13.15
F4 медиана	1.28	4.80	1.79	11.69

Фильтр Калмана (F2) снижает шумовой пол на всех четырёх типах шума: в 8× на гауссовом N1, в 2.3× на розовом N2, в 3.4× на тяжёлохвостовом N3, в 1.5× на смешанном N4. Это прямое следствие того, что фильтрация **наблюдаемого ряда** (а не градиента) корректно отделяет восстанавливаемый сигнал от шума. Скользящее среднее F1, наоборот, ухудшает пол из-за лага.




Рис. 3. Кривые сходимости $\mathbb{E}\|\nabla f(x_k)\|^2$ (квадратичная задача, Adam): сплошная — медиана, полоса — 10–90-й перцентили по 5 запускам. Калман (F2) проваливает шумовой пол на порядок ниже F0 и медианы как на гауссовом N1, так и на тяжёлохвостовом N3.

На логистической задаче информативна holdout-точность (доля верных ответов на отложенной выборке, среднее по запускам):

Фильтр	N1	N2	N3	N4
F0 без фильтра	0.830	0.707	0.785	0.587
F1 МА	0.822	0.706	0.779	0.582
F2 Калман	0.824	0.710	0.782	0.577
F3 вейвлет	0.777	0.708	0.774	0.587
F4 медиана	0.817	0.707	0.803	0.592

На чистом гауссовом N1 фильтрация не нужна (F0 лучший, 0.830): сигнал и так информативен, любой фильтр лишь убирает часть полезной вариации. На тяжёлохвостовом N3 и смешанном N4 лучшей становится медиана F4 (0.803 против 0.785 у F0 на N3) — робастность к выбросам напрямую улучшает обучаемость.




Рис. 4. Синтетический факторный итог. Слева — шумовой пол на квадратичной задаче (лог-шкала, ниже лучше); справа — holdout-точность логистической (выше лучше). Калман доминирует по полу, медиана — по точности на тяжёлых хвостах N3/N4.

4.4. Прикладной эксперимент: реальные финансовые ряды

Корзина инструментов (акции, индексы, FX, крипто), дневные лог-доходности, walk-forward оценка с **causal**-фильтрами (окно фильтра не заглядывает вперёд — это устраняет lookahead-смещение, на котором ранее ловились центрированные фильтры). Для каждой пары (фильтр, оптимизатор) обучается AR(5)-модель, измеряется holdout MSE.

Фильтр	holdout MSE $\times 10^4$	vs F0
F0 без фильтра	4.29	—
F1 MA (causal)	6.88	+60%
F2 Калман	7.88	+84%
F4c медиана (causal)	5.93	+38%




Рис. 5. Реальные дневные доходности, causal walk-forward: holdout MSE по фильтрам. Контроль F0 (зелёный) — лучший; любой causal-фильтр ухудшает прогноз.

На реальных дневных доходностях **любой** causal-фильтр ухудшает прогноз. В прогнозе направления causal-медиана даёт точность 0.57–0.60 против 0.602 у «без фильтра» и 0.614 у мажоритарного базлайна — то есть не бьёт даже тривиальный предсказатель. Вывод: у дневных лог-доходностей нет гладкой сигнальной компоненты (близки к random walk, согласно стилизованным фактам Конта [1]), и сглаживание лишь добавляет лаг, удаляя то небольшое, что несёт информацию. Это содержательный отрицательный результат, прямо контрастирующий с синтетикой, где восстановимый сигнал есть.

4.5. Положительный результат на финансово-реалистичных данных

Отрицательный результат на дневных доходностях специфичен для задачи «предсказать следующую сырую доходность», у которой почти нет восстановимого сигнала. Чтобы проверить, помогает ли фильтрация там, где сигнал есть, но шум — **настоящий финансовый**, поставлены два эксперимента с **известным** ground truth (поэтому метрика честна: ни lookahead, ни подгонки).

Полусинтетика: реальный шум + известный сигнал. Реальные дневные лог-доходности (девять инструментов) стандартизуются и берутся как шум ξ_t — с настоящими тяжёлыми хвостами и долгой памятью. Поверх накладывается известный гладкий сигнал s_t (сумма низкочастотных гармоник, единичная дисперсия), наблюдается $y_t = s_t + \kappa \xi_t$ при контролируемом SNR. Задача — causal-AR восстановить s_t ; метрика — holdout MSE по **истинному** s_t .

Фильтр	SNR -3 дБ	SNR 0 дБ	SNR $+3$ дБ
F0 без фильтра	0.287	0.165	0.088
F1 MA	0.193	0.104	0.055
F2 Калман	0.092	0.074	0.064
F3 вейвлет	0.038	0.019	0.010
F4 медиана	0.232	0.130	0.069

Под реальным тяжёлохвостовым шумом **все** фильтры существенно лучше F0: вейвлет восстанавливает сигнал в 7–9 раз точнее (MSE 0.038 против 0.287 у F0 при SNR -3 дБ), прирост SNR

после фильтра до +17 дБ. То есть фильтрация безусловно помогает, как только под реальным финансовым шумом есть что восстанавливать.




Рис. 6. Полусинтетика: реальные доходности как шум, известный сигнал s_t . Любой фильтр кратно снижает MSE восстановления s относительно F0 при всех уровнях SNR.

Микроструктура: оценка интегрированной дисперсии. Для высокочастотных данных модель $y = s + \xi$ верна буквально: наблюдаемая лог-цена = латентная эффективная цена (случайное блуждание) + микроструктурный шум. Предсказуемого сигнала в доходностях нет (согласовано с отрицательным результатом), но интересующая величина — интегрированная дисперсия IV за день. Наивная реализованная дисперсия $RV = \sum (\Delta p)^2$ смещена вверх на $\approx 2M \text{Var}(u)$; денойзинг цены до вычисления RV это смещение убирает. Истинная IV известна по построению.




Рис. 7. Относительная ошибка оценки IV от уровня микроструктурного шума γ (лог-шкала). Наивная RV (F0) взрывается; медианный фильтр снижает ошибку в 4–77 раз.

При $\gamma \geq 1$ наивная RV катастрофически смещена (отн. ошибка 2.0–8.0), тогда как медианный фильтр держит её на уровне 0.1–0.5 (улучшение в 4–77 раз; при тяжёлохвостовых эффективных приращениях эффект ещё сильнее). Калман и вейвлет здесь **переглаживают** случайное блуждание и занижают IV (ошибка ≈ 0.9) — честный нюанс: для оценки дисперсии нужен робастный, а не сглаживающий фильтр. Это положительный, согласованный с эконометрической теорией результат: на микроструктурно-зашумлённых финансовых данных правильная фильтрация выигрывает, при этом отказ от предсказуемости сырых доходностей сохраняется.

4.6. Онлайн-адаптивный фильтр: режим-робастность

Все рассмотренные фильтры — фиксированные: их нужно выбирать под известный режим. Мы добавляем **причинный онлайн-адаптивный фильтр** FA (`OnlineAdaptiveFilter`): на каждом шаге он смотрит только в прошлое окно, оценивает робастный масштаб (MAD) и долю выбросов за k MAD; при наличии выбросов выдаёт скользящую медиану (робастно), иначе — экспоненциальное сглаживание (эффективно при лёгких хвостах). Так правило «диагностируй → решай» исполняется онлайн, без знания типа шума.

Честный итог двойственный. По **скорости сходимости** на синтетике FA ведёт себя как медианные фильтры — лагает за детерминированным градиентом и проигрывает линейным трекерам (см. Рис. 2): автоадаптация не отменяет компромисс «скорость ↔ хвостостойчивость». Зато на **микроструктурной** задаче FA уникально **режим-робастен**: его ошибка плавно убывает ($0.77 \rightarrow 0.70 \rightarrow 0.39$ по γ), он никогда не проваливается катастрофически, в отличие от любого фиксированного выбора — F0 взрывается до 7.9 при росте шума, а Калман и вейвлет навсегда застревают на ≈ 0.9 . FA — не абсолютный лидер ни в одной точке, но единственный, кто остаётся приемлемым во всём диапазоне без знания режима. Практический вывод: онлайн-адаптация ценна там, где режим шума заранее неизвестен или дрейфует, и стоимость ошибочного фиксированного выбора велика.

5. Результаты

Объединяя диагностику фильтров, синтетический факторный эксперимент и прикладной прогон, получаем сводную таблицу:

Шум	Лучший по SNR	Лучший по обучению	Комментарий
N1 Гаусс	F2 Калман	F0 (логист.) / F2 (квадр.)	Калман снижает пол в $8\times$; на чистом сигнале фильтр для классификации не нужен
N2 розовый $1/f$	F3 вейвлет	F2 Калман	Калман снижает пол в $2.3\times$; по точности фильтры почти равны
N3 α -уст.	F4 медиана	F4 медиана	Медиана доминирует: $+18$ дБ SNR, лучшая точность 0.803
N4 смешанный	F4 $\approx$ F2	F4 медиана	Медиана лидирует и по SNR, и по точности
Реальные ряды	—	F0 без фильтра	Любой causal-фильтр ухудшает MSE и направление

Качественные эмпирические выводы:

- **Диагностика фильтров** совпадает с теорией: Калман оптимален на гауссовом N1, вейвлет лучший на розовом N2, медиана доминирует на тяжёлохвостовом N3 ($+18$ дБ) и смешанном N4. Медиана при этом меньше всех искажает структуру (Хёрст), вейвлет — сильнее всех на N1.
- **Синтетика, квадратичная задача:** при фильтрации наблюдаемого ряда Калман F2 снижает шумовой пол истинного градиента на всех четырёх типах шума (в $8\times$ на N1, $3.4\times$ на N3). Это принципиально отличается от альтернативной схемы фильтрации буфера градиента (см. приложение), где линейные фильтры, наоборот, ухудшали пол — подтверждение, что правильное место фильтра именно на наблюдениях, а не на градиенте.
- **Синтетика, логистическая задача:** на чистом гауссовом N1 фильтр не нужен (F0 лучший, 0.830); на тяжёлохвостовом N3 и смешанном N4 выигрывает медиана F4 (0.803 против 0.785 у F0 на N3).
- **Реальные данные:** прогностический MSE минимален для F0; любой causal-фильтр даёт рост MSE на 38–84%, и ни один не бьёт мажоритарный базлайн в прогнозе направления. Согласуется

со стилизованными фактами Конта [1]: дневные доходности близки к random walk, гладкого сигнала для восстановления нет.

6. Обсуждение

Полученная картина уточняет тезис о пользе предобработки.

Когда фильтрация помогает. Если под шумом есть восстановимый сигнал (синтетические задачи), правильно подобранный фильтр на наблюдениях качественно улучшает обучение: Калман снижает шумовой пол градиента в несколько раз, а в режиме тяжёлых хвостов (N3, N4) робастная медиана отделяет редкие ударные значения от типичной фракции и тем самым сохраняет корректное направление градиента для SGD и Adam. Линейные фильтры в тяжёлохвостовых режимах слабее, поскольку усреднение не подавляет вклад редких больших выбросов.

Когда фильтрация мешает. Если гладкого сигнала под шумом нет (реальные дневные доходности), сглаживание лишь добавляет лаг и удаляет малую информативную часть — любой causal-фильтр ухудшает прогноз. Выбор фильтра здесь не помогает; честный ответ — работать без предобработки (F0). Это и есть содержательный отрицательный результат, предусмотренный постановкой.

Противоречие фильтр–структура. Фильтр, максимизирующий SNR за счёт удаления высокочастотной части, одновременно смещает оценку Хёрста и индекса хвоста. Это меняет **предположения**, при которых работают теоретические оценки сходимости (в частности, ограниченная дисперсия для Adam [18]), но может ухудшать предсказательное качество, если целевая задача оперирует именно высокочастотной информацией. Управляющий компромисс: регуляризация процедуры обучения против сохранения информативности сигнала.

Сопоставление с близкой работой. Совместное влияние тяжёлых хвостов и долговременной зависимости на стохастическую аппроксимацию изучалось и ранее: Анантарам и Боркар [4] ещё в 2012 г. доказали сходимость SA при дробно-броуновском (LRD) плюс симметрично-устойчивом (тяжёлохвостовом) шуме методом ODE-сравнения, а недавняя работа Чандака и др. [5] даёт finite-time анализ в том же режиме. Робастная оптимизация при тяжёлом шуме развита в обрезании/нормировке градиента [6], [7], [8] и в едином нелинейном фреймворке [9]; шумоподавление финансовых рядов перед нейросетевым прогнозом изучалось, например, в [10]; устойчивая оценка показателя Хёрста — в [19], а эмпирика долгой памяти рынков — в [20]. Наш вклад не теоретический: мы эмпирически сопоставляем выбор **фильтра наблюдаемого ряда** в паре с оптимизатором в этой постановке и строим воспроизводимый бенчмарк (фильтр $\times$ шум $\times$ оптимизатор) на синтетических и реальных финансовых рядах — такого сопоставления в перечисленных работах нет.

6.1. Практический сценарий применения

Результаты работы дают конкретный рецепт выбора связки «фильтр + оптимизатор» для нового ряда, а не только усреднённые наблюдения. Предлагается следующая процедура.

1. **Диагностика ряда.** На обучающем участке (без заглядывания вперёд) оценить: индекс хвоста $\hat{\alpha}$ (метод Маккаллоха / Хилла), показатель Хёрста $\hat{H}$ (DFA), и грубую долю «сигнала» через SNR пробного сглаживания. Это определяет, к какому из режимов N1–N4 ближе наблюдаемый шум и есть ли вообще восстановимый сигнал.
2. **Шорт-лист кандидатов.** По сводной таблице ниже выбрать 2–3 кандидатные пары. Эвристики: $\hat{\alpha} \approx 2$, мало выбросов $\rightarrow$ Калман F2; $\hat{\alpha} < 1.8$, заметные выбросы $\rightarrow$ медиана F4; выраженная долгая память ($\hat{H}$ далеко от $1/2$) $\rightarrow$ вейвлет F3; признаков гладкого сигнала нет (как у дневных доходностей) $\rightarrow$ контроль F0.
3. **Сравнение на валидации.** Прогнать кандидатов на отложенной (walk-forward, causal) выборке по целевой метрике задачи (MSE, точность направления) и выбрать победителя. Шаг обязателен: на реальных дневных доходностях диагностика честно говорит «гладкого сигнала

нет», и валидация подтверждает, что F0 не уступает фильтрам — то есть процедура защищает от вредной предобработки.

Ключевой принцип: фильтр не выбирается «вслепую по умолчанию»; диагностика сужает пространство до нескольких обоснованных кандидатов, а финальный выбор делает валидация на самих данных.

7. Заключение

Основное исследование — факторный дизайн $F0\text{--}F4 \times N1\text{--}N4 \times \{\text{SGD, Adam, AdamW}\}$ с фильтрацией наблюдаемого ряда — даёт согласованную картину, обобщённую в таблице рекомендаций (на основе синтетического шумового пола, holdout-точности и диагностики SNR):

Диагностируемый режим	Рекомендация	Обоснование
Лёгкие хвосты ($\hat{\alpha} \approx 2$), есть сигнал	F2 Калман + Adam	Пол $\ \nabla f\ ^2$ ниже в $8\times$ (N1); классический оптимум при гауссовом шуме
Долгая память ($\hat{H}$ далеко от $1/2$), конечная дисперсия	F3 вейвлет или F2 Калман	Вейвлет лучший по SNR на N2 (+9.6 дБ); Калман снижает пол в $2.3\times$
Тяжёлые хвосты ($\hat{\alpha} < 1.8$), выбросы	F4 медиана + Adam	Лучшая по SNR (+18 дБ, N3), лучшая holdout-точность (0.803), минимальное искажение структуры
Смешанный (тяжёлые хвосты + долгая память)	F4 медиана	Лидер и по SNR, и по точности на N4
Гладкого сигнала нет (дневные доходности)	F0 без фильтрации	Любой causal-фильтр ухудшает MSE и не бьёт мажоритарный базлайн

Таблица — не финальный вердикт, а вход в процедуру из раздела «Практический сценарий применения»: диагностика сужает выбор, а итоговое решение принимается по валидации на самих данных.

Методологический вклад: воспроизводимый открытый бенчмарк (фильтр $\times$ шум $\times$ оптимизатор) с фильтрацией наблюдаемого ряда до оптимизации, на синтетических и реальных финансовых данных.

Эмпирический вклад: (0) по основной метрике — скорости сходимости $T(\varepsilon)$ — линейные трекары сигнала (вейвлет, Калман) сходятся в десятки раз быстрее F0, а робастные и онлайн-адаптивный фильтры лагают: выявлен явный компромисс «скорость $\leftrightarrow$ устойчивость к хвостам»; (i) при наличии восстановимого сигнала фильтр Калмана снижает шумовой пол истинного градиента в 3–8 раз на всех типах шума; (ii) при тяжёлых хвостах медианный фильтр даёт скачок (+18 дБ SNR, лучшая holdout-точность) при минимальном искажении структуры; (iii) на реальных дневных доходностях фильтрация не улучшает прогноз и не превосходит мажоритарный базлайн — содержательный отрицательный результат, контрастирующий с синтетикой; (iv) на финансово-реалистичных постановках с известным ground truth фильтрация даёт положительный результат — под реальным шумом доходностей вейвлет восстанавливает известный сигнал в 7–9 раз точнее F0, а на микроструктурно-зашумлённых ценах медиана снижает ошибку оценки интегрированной дисперсии в 4–77 раз; (v) фильтрация заметно меняет структурные свойства ряда $(\hat{H}, \hat{\alpha})$, что важно для применимости теоретических оценок сходимости.
Общий вывод: фильтрация — не «всегда полезный» и не «всегда вредный» приём; она выигрывает тогда и только тогда, когда под шумом есть восстановимая величина, и предложенное правило диагностика→валидация надёжно

отделяет эти случаи. Онлайн-адаптивный фильтр ФА не выигрывает по скорости, но единственный остаётся приемлемым во всех режимах микроструктурного шума без знания режима — ценно при дрейфующем или неизвестном шуме.

Дальнейшая работа: теоретический набросок оценки сходимости при фильтрованном heavy-tailed шуме (опираясь на [4], [5]); полностью адаптивный выбор фильтра по онлайн-диагностике $\hat{\alpha}$, $\hat{H}$; cross-asset transfer.

Литература

- [1] R. Cont, «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues», *Quantitative Finance*, т. 1, вып. 2, сс. 223–236, 2001, doi: 10.1080/713665670.
- [2] B. Mandelbrot, «The Variation of Certain Speculative Prices», *The Journal of Business*, т. 36, вып. 4, сс. 394–419, 1963, doi: 10.1086/294632.
- [3] U. Şimşekli, L. Sagun, и M. Gürbüzbalaban, «A Tail-Index Analysis of Stochastic Gradient Noise in Deep Neural Networks», в *Proceedings of the 36th International Conference on Machine Learning (ICML)*, в *Proceedings of Machine Learning Research*, vol. 97. PMLR, 2019, сс. 5827–5837. [Онлайн]. Доступно на: <https://arxiv.org/abs/1901.06053>
- [4] V. Anantharam и V. S. Borkar, «Stochastic Approximation with Long Range Dependent and Heavy Tailed Noise», *Queueing Systems*, т. 71, вып. 1–2, сс. 221–242, 2012, doi: 10.1007/s11134-012-9283-0.
- [5] S. Chandak, A. Yadav, A. Özgür, и N. Bambos, «Heavy-Tailed and Long-Range Dependent Noise in Stochastic Approximation: A Finite-Time Analysis». [Онлайн]. Доступно на: <https://arxiv.org/abs/2603.19648>
- [6] E. Gorbunov, M. Danilova, и A. Gasnikov, «Stochastic Optimization with Heavy-Tailed Noise via Iterative Differentially Private Clipping», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2020, сс. 15042–15053. [Онлайн]. Доступно на: <https://arxiv.org/abs/2005.10785>
- [7] A. Cutkosky и H. Mehta, «High-Probability Bounds for Non-Convex Stochastic Optimization with Heavy Tails», в *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. [Онлайн]. Доступно на: <https://arxiv.org/abs/2106.14343>
- [8] A. Sadiev и др., «High-Probability Bounds for Stochastic Optimization and Variational Inequalities: The Case of Unbounded Variance», в *Proceedings of the 40th International Conference on Machine Learning (ICML)*, 2023. [Онлайн]. Доступно на: <https://arxiv.org/abs/2302.00999>
- [9] A. Armacki, P. Sharma, G. Joshi, D. Bajović, D. Jakovetić, и S. Kar, «Nonlinear Stochastic Gradient Descent and Heavy-Tailed Noise: A Unified Framework and High-Probability Guarantees». [Онлайн]. Доступно на: <https://arxiv.org/abs/2410.13954>
- [10] Q. Tang, T. Fan, R. Shi, J. Huang, и Y. Ma, «Prediction of Financial Time Series Using LSTM and Data Denoising Methods». [Онлайн]. Доступно на: <https://arxiv.org/abs/2103.03505>
- [11] R. E. Kalman, «A New Approach to Linear Filtering and Prediction Problems», *Journal of Basic Engineering*, т. 82, вып. 1, сс. 35–45, 1960, doi: 10.1115/1.3662552.
- [12] D. L. Donoho и I. M. Johnstone, «Ideal Spatial Adaptation by Wavelet Shrinkage», *Biometrika*, т. 81, вып. 3, сс. 425–455, 1994, doi: 10.1093/biomet/81.3.425.
- [13] I. Daubechies, *Ten Lectures on Wavelets*. Philadelphia: Society for Industrial, Applied Mathematics, 1992. doi: 10.1137/1.9781611970104.
- [14] S. Mallat, *A Wavelet Tour of Signal Processing*, 2nd изд. San Diego: Academic Press, 1999.

- [15] L. Yin, R. Yang, M. Gabbouj, и Y. Neuvo, «Weighted Median Filters: A Tutorial», *IEEE Transactions on Circuits and Systems II: Analog and Digital Signal Processing*, т. 43, вып. 3, сс. 157–192, 1996, doi: 10.1109/82.486465.
- [16] D. P. Kingma и J. Ba, «Adam: A Method for Stochastic Optimization», в *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015. [Онлайн]. Доступно на: <https://arxiv.org/abs/1412.6980>
- [17] I. Loshchilov и F. Hutter, «Decoupled Weight Decay Regularization», в *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, 2019. [Онлайн]. Доступно на: <https://arxiv.org/abs/1711.05101>
- [18] A. Défossez, L. Bottou, F. Bach, и N. Usunier, «A Simple Convergence Proof of Adam and Adagrad», *Transactions on Machine Learning Research*, 2022, [Онлайн]. Доступно на: <https://arxiv.org/abs/2003.02395>
- [19] A. Gómez-Águila, J. E. Trinidad-Segovia, и M. A. Sánchez-Granero, «Improvement in Hurst Exponent Estimation and Its Application to Financial Markets», *Financial Innovation*, т. 8, вып. 1, сс. 1–21, 2022, doi: 10.1186/s40854-022-00394-x.
- [20] Y. He и S. Rachev, «Long-Range Dependence in Financial Markets: Empirical Evidence and Generative Modeling Challenges». [Онлайн]. Доступно на: <https://arxiv.org/abs/2509.19663>