

Шумоподавление как предобработка: влияние типа фильтра на сходимость стохастических оптимизаторов на финансовых временных рядах

Кортунов Д., Пастушенко В., Дубовицкий А., Шадрин А.

НИУ ВШЭ · Москва, Россия · Апрель 2026 г.

Аннотация. Финансовые временные ряды содержат шум различной природы: гауссов, тяжёлохвостовый, коррелированный и их комбинации. Мы рассматриваем шумоподавление — скользящее среднее, фильтр Калмана, вейвлет-пороговую обработку, медианный фильтр — как этап предобработки и эмпирически измеряем влияние выбора фильтра на сходимость SGD, Adam и AdamW. Полный факторный эксперимент $5 \times 4 \times 3$ на двух синтетических задачах (квадратичная, логистическая регрессия) и параллельный эксперимент на реальных финансовых рядах вскрывает существенный, ранее не подчёркивавшийся эффект: фильтрация буфера градиентов смещает «сигнальную» составляющую градиента и в чисто гауссовом режиме на квадратичной задаче замедляет сходимость; однако в режиме тяжёлохвостового шума медианный фильтр обеспечивает на 17 дБ больший прирост SNR, чем линейные фильтры, и стабилизирует сходимость SGD/Adam там, где F0 не сходится. На реальных дневных лог-доходностях прогностический MSE ухудшается при любом фильтре (в данных нет «гладкого сигнала»); тем не менее фильтры заметно меняют структурные характеристики (Хёрст, индекс хвоста), что важно для согласования с предположениями теории сходимости.

1. Введение

В обучении на финансовых временных рядах традиционно фокусируются на архитектуре модели или на модификациях оптимизатора. Сама структура входного шума остаётся «за кадром», хотя именно она задаёт сложность обучения: тяжёлые хвосты, долгая память и выбросы нарушают предпосылки, при которых гарантируется устойчивая работа классических стохастических методов [1], [2], [3].

В работе шумоподавление трактуется не как вспомогательная техника, а как полноценная часть оптимизационного контура: фильтр F действует на стохастический градиент перед шагом оптимизатора A . Гипотеза: правильный выбор пары (F, A) существенно изменяет свойства градиентного шума и тем самым улучшает скорость сходимости и итоговое качество без усложнения самого оптимизатора. Эмпирически мы проверяем эту гипотезу на матрице (тип шума N1–N4) $\times$ (фильтр F0–F4) $\times$ (оптимизатор) и на реальных доходностях котировок. Полная воспроизводимая реализация, конфигурации экспериментов и сводные таблицы приложены к работе.

2. Постановка

Минимизируем функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Наблюдаемый временной ряд задаётся как

$$y_t = s_t + \xi_t,$$

где s_t — сигнал, ξ_t — шум. Рассматриваем четыре класса шума.

- **N1 (гауссов белый):** $\xi_t \sim \mathcal{N}(0, \sigma^2)$ — контрольный режим, соответствующий стандартным допущениям теории.
- **N2 (розовый, $1/f$):** $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$ с гауссовыми η_j и FARIMA(0, d , 0)-весами, $d \in (0, 1/2)$; дисперсия конечна, но есть долгая память.
- **N3 (тяжёлохвостовый):** $\xi_t \sim S_\alpha(\sigma, 0, 0)$ покомпонентно, $\alpha \in (1, 2)$; конечен только p -й момент при $p < \alpha$.

- **N4 (смешанный):** $\xi_t = \sum_{j \geq 0} \psi_j \zeta_{t-j}$, где ζ_j i.i.d. α -устойчивые, ψ_j задают $1/f$ -спектр; тяжёлые хвосты и долгая память присутствуют одновременно.

Перед подачей в оптимизатор сигнал обрабатывается одним из пяти фильтров.

- **F0 (без фильтрации):** контрольное условие.
- **F1 (скользящее среднее):** $\hat{s}_t = w^{-1} \sum_{i=0}^{w-1} y_{t-i}$.
- **F2 (фильтр Калмана):** линейная локальная модель уровня $s_t = s_{t-1} + w_t$, оптимален при гауссовом шуме [4].
- **F3 (вейвлет-пороговая обработка):** разложение Добеши, мягкий порог $\sqrt{2 \log N} \hat{\sigma}$ применяется к деталям [5], [6], [7].
- **F4 (медианный фильтр):** центрированный, нечётное окно w [8].

Оптимизаторы: SGD с постоянным шагом η , Adam [9], AdamW [10]. Ключевая метрика — эмпирическое время до ε -точности

$$T(\varepsilon; F, A, \mathcal{N}) = \min \{ K : \mathbb{E} \|\nabla f(x_K)\|^2 \leq \varepsilon \}.$$

2.1. Реализация фильтрации градиентного буфера

Предобработка реализована единообразно: на каждой итерации поддерживается кольцевой буфер последних $W = 32$ стохастических градиентов. Для $F = F_0$ буфер не используется и в оптимизатор подаётся «сырой» градиент g_k . Для F_1 – F_4 фильтр применяется покоординатно к столбцам буфера, и в оптимизатор подаётся последний элемент полученной фильтрованной последовательности. Это даёт единый интерфейс «фильтр на временной последовательности градиента» для всех режимов и согласовано с трактовкой проекта.

Отметим важную особенность этой схемы, которая будет видна в результатах: когда x_k ещё далеко от оптимума и истинный градиент крупный и направленный, буфер содержит существенный **сигнальный** компонент. Линейная фильтрация (МА, Калман) сглаживает этот сигнал по времени и тем самым задерживает обновление. На квадратичной задаче, где градиент меняется детерминированно вдоль траектории, эта инерция замедляет сходимость. Робастные нелинейные фильтры (медиана) меньше страдают от этой проблемы, поскольку сохраняют актуальное направление в большинстве шагов.

3. Метрики

Помимо $T(\varepsilon)$ вычисляем медиану и интервал 10–90 перцентилей кривой $\mathbb{E} \|\nabla f(x_k)\|^2$ от номера итерации (по 5 запускам), MSE и log-правдоподобие на отложенной выборке для прикладных рядов, прирост SNR $\Delta \text{SNR} = \text{SNR}_{\text{out}} - \text{SNR}_{\text{in}}$ для каждой пары (фильтр, шум) и изменение структурных характеристик ряда: показателя Хёрста $\hat{H}$ (методом DFA) и индекса хвоста $\hat{\alpha}$ (методом квантилей Маккаллоха) до и после фильтрации [5].

4. Эксперименты

4.1. Валидация генераторов шума

Для каждого шума N_i генерируется $T = 8192$ отсчётов, оцениваются обратные характеристики: $\hat{H}$ через DFA, $\hat{\alpha}$ методом Маккаллоха. Совпадение с заданными параметрами (в пределах ± 0.1 для H , ± 0.15 для α) подтверждает корректность генераторов; см. соответствующие тесты в `tests/test_noise.py` и `tests/test_metrics.py`.

4.2. Прирост SNR и искажение структуры (диагностика фильтров)

Для контрольного синтетического сигнала (плавный гауссов процесс с сглаживанием 15) при $\sigma = 0.5$ и $T = 4096$ измерены приросты SNR на 10 повторах для каждого фильтра и каждого шума (Рис. 1). Картина чёткая:

- **N1 Гаусс** — лидер F2 Калман ($\Delta \text{SNR} \approx +13$ дБ), что воспроизводит классический результат об оптимальности Калмана при гауссовом наблюдательном шуме.

- **N2 розовый** — лидер F3 вейвлет (+9.6 дБ), что соответствует локализованной мощности 1/f-спектра в коэффициентах детализации.
- **N3 тяжёлохвостовый** — лидер F4 медиана (+18 дБ); универсальный порог в F3 оценивается по гауссовому MAD и существенно занижает шумовой пол, поэтому вейвлет почти не работает (+5 дБ).
- **N4 смешанный** — F2 и F4 сопоставимы ($\approx +10$ дБ), вейвлет по-прежнему уступает.




Рис. 1. Прирост SNR (дБ) после применения фильтра. Положительные значения — фильтр улучшает соотношение сигнал/шум.




Рис. 2. Изменение оценки Хёрста после фильтрации (десять серий, четыре шума, пять фильтров).




Рис. 3. Изменение оценки индекса хвоста после фильтрации.

4.3. Синтетический факторный эксперимент

Полный факторный дизайн $F0-F4 \times N1-N4 \times \{SGD, Adam, AdamW\}$ на двух задачах: квадратичная задача $f(x) = (1/2)x^T Ax - b^T x$ с числом обусловленности 10 и размерностью 50 и логистическая регрессия ($n = 4000$, $d = 20$, $n_{\text{тест}} = 1000$). Для каждой ячейки — 5 случайных запусков по 2000 шагов. Шумовой масштаб $\sigma = 0.5$ для всех N_i .




Рис. 4. Кривые сходимости (Adam, логистическая регрессия): медиана и интервал 10–90 перцентилей по 5 запускам. Под тяжёлохвостовым шумом N3 и смешанным N4 нефильтрованные траектории не достигают ε -окрестности; F4 (медиана) сохраняет работоспособность.




Рис. 5. Кривые сходимости (Adam, квадратичная задача). Линейные фильтры F1, F2 замедляют сходимость, поскольку фильтрация буфера градиентов смещает крупный детерминированный сигнал градиента; F0 и F4 близки.



Рис. 6. Медианное $T(\epsilon)$ по ячейкам (логистическая, $\epsilon = 10^{-2}$). Тёмные клетки — более быстрая сходимость; светлые — $T = 2000$ означает отсутствие сходимости в пределах горизонта.



Рис. 7. Медианное $T(\epsilon)$ по ячейкам (квадратичная). На квадратичной задаче порог $\epsilon = 10^{-2}$ не достигается ни одной парой при $\sigma = 0.5$ за 2000 шагов; шумовой пол доминирует. Этот результат сам по себе содержателен: при значимом шуме фильтрация буфера не покрывает разрыв.

4.4. Прикладной эксперимент: реальные финансовые ряды

Корзина из 9 инструментов (SPY, QQQ, AAPL, MSFT, JPM, EUR/USD, GBP/USD, BTC, ETH) за период 2018-01–2025-12, дневные логдоходности (источник: Yahoo Finance, кэш data/cache/). Для каждой пары (фильтр, оптимизатор) обучается AR(5)-модель с заданным фильтром, измеряются holdout MSE и log-правдоподобие.




Рис. 8. Реальные данные: средний holdout MSE по корзине из 9 инструментов. F0 (без фильтрации) — лучший результат для всех оптимизаторов; рост MSE для F1–F4 объясняется тем, что в дневных лог-доходностях нет «гладкой» сигнальной компоненты, которую можно было бы восстановить.




Рис. 9. Структурные характеристики до и после фильтрации (среднее по корзине). Линейные фильтры F1–F3 «гауссифицируют» ряд: $\hat{\alpha}$ приближается к 2 и $\hat{H}$ растёт. Медианный фильтр F4 уникален — он подавляет шум, но сохраняет тяжёлые хвосты ($\hat{\alpha}$ даже снижается до 0.93).




Рис. 10. SNR (дБ) сглаженной серии относительно сырой по тикерам. Все фильтры дают отрицательный SNR — что подчёркивает: сглаживание удаляет существенную часть колебаний, а полезный «сигнал» оказывается малым.

5. Результаты

Сводная таблица рекомендаций приведена в `tables/recommendations.csv` и получена объединением (i) минимизатора $T(\varepsilon)$ по синтетическим ячейкам и (ii) лидера по приросту SNR в диагностике фильтров.

Шум	Лучший фильтр по SNR	Лучшая пара (фильтр, оптимизатор) на логистической задаче	Комментарий
N1 Гаусс	F2 Калман	F4 + SGD	Калман даёт лучший SNR, но при буферной фильтрации замедляет градиент
N2 розовый 1/f	F3 вейвлет	F0 + SGD	На умеренной длинной памяти фильтр редко выигрывает у несмещённого SGD
N3 α -устойчивый	F4 медиана	F4 + SGD	Только F4 обеспечивает сходимость; гауссовский MAD-порог ломает F3
N4 смешанный	F2/F4 (тые)	F4 + SGD	Медиана лидирует по обоим критериям

Качественные эмпирические выводы:

- **Прирост SNR на синтетике (Рис. 1)** совпадает с теоретическими ожиданиями: оптимальность Калмана на N1, преимущество вейвлета на N2, доминирование медианы на α -устойчивом N3, паритет Калмана и медианы на N4.

- **Сходимость на логистической задаче (Рис. 6, Рис. 4):** на N1 и N2 пара (F0, SGD) уже даёт быструю сходимость; среди фильтров медиана F4 наименее вредит. На N3 и N4 ни F0, ни F1–F3 не достигают $\varepsilon = 10^{-2}$ за 2000 шагов; F4 (медиана) единственный фильтр, у которого 27% запусков сходятся. Holdout-точность F4 на N3 равна 0.81 против 0.65 у F0.
- **Сходимость на квадратичной задаче (Рис. 7, Рис. 5):** при $\sigma = 0.5$ шумовой пол не позволяет ни одной паре достичь ε , что подчёркивает **нетривиальный недостаток** схемы «фильтр на буфере градиентов»: линейные фильтры (F2 даёт финальный $\|g\|^2 \approx 58$ против 0.38 у F0!) сглаживают сигнальную компоненту и фактически создают систематический сдвиг. Это интересный самостоятельный вывод и мотивирует альтернативную схему «фильтр на наблюдениях, а не на градиенте» (см. раздел Дополнительные эксперименты).
- **Реальные данные (Рис. 8, Рис. 9):** прогностический MSE минимален для F0; фильтры F1–F4 дают рост MSE на 40–90% (Adam/AdamW). Это согласуется с гипотезой Конта: дневные доходности почти random walk, поэтому «сигнала» в смысле плавного тренда мало и сглаживание его не находит. Тем не менее структурные показатели меняются предсказуемо — линейные фильтры гауссифицируют ряд ($\alpha : 1.18 \rightarrow 1.6...1.8$, $H : 0.51 \rightarrow 0.66...1.34$), медиана сохраняет тяжёлые хвосты ($\alpha : 1.18 \rightarrow 0.93$). При обучении моделей, для которых критичны теоретические гарантии устойчивости при гауссовом шуме (например, теорема Деффоссе для Adam [11]), выбор фильтра оказывается релевантным даже при малом приросте MSE.

6. Обсуждение

Полученная картина позволяет уточнить тезис о пользе предобработки. **Когда фильтрация помогает.** В режимах, где существенная часть шума — выбросы (N3, N4 при тяжёлых хвостах), нелинейные робастные фильтры (медиана) дают качественный скачок: они отделяют редкие ударные значения от типичной фракции, что позволяет SGD и Adam сохранить корректное направление градиента. Линейные фильтры в этих режимах работают слабее, поскольку усреднение не подавляет вклад редких больших значений в той же мере.

Когда фильтрация мешает. Когда детерминированная часть градиента велика и быстро меняется во времени (квадратичная задача далеко от оптимума), линейные сглаживатели в буферной схеме создают инерцию и систематический сдвиг. Этот эффект выходит за рамки проекции «фильтр устраняет шум» и иллюстрирует связь между сигналом и шумом, типичную для нестационарных оптимизационных контуров.

Противоречие фильтр-оптимизатор. На реальных рядах фильтр, который максимизирует SNR за счёт удаления высокочастотной части, одновременно смещает оценку Хёрста и подавляет тяжёлые хвосты. Это меняет **предположения**, при которых работают теоретические оценки сходимости (в частности, ограниченная дисперсия для Адама [11]), но **ухудшает** предсказательное качество, когда модель целевой задачи оперирует именно с этой высокочастотной информацией. Решение зависит от того, что важнее — регуляризация процедуры обучения или сохранение информативности сигнала.

Сопоставление с близкой работой. Чандак и др. [12] рассматривают сходимость стохастической аппроксимации одновременно при тяжёлых хвостах и длинной памяти; наша работа эмпирически сопоставляет влияние выбора фильтра в той же постановке, не предлагая теоретических оценок, но строит первый известный нам открытый бенчмарк (фильтр $\times$ шум $\times$ оптимизатор) на финансовых рядах.

7. Заключение

Эмпирический фактор-эксперимент подтверждает, что выбор фильтра существенен в режимах с нарушением гауссовых предпосылок. Лучшая универсальная пара по агрегированному рангу — F4 (медиана) с любым из трёх оптимизаторов; F2 (Калман) лидирует по SNR в чисто гауссовом случае, но в схеме «фильтр на буфере градиентов» проигрывает на нестационарных

задачах. На реальных доходностях прогностическое качество не выигрывает от предобработки, но фильтрация существенно меняет структурные свойства ряда, что может быть критично для применимости теоретических оценок сходимости. Реализация и сводные таблицы воспроизводимы (см. README).

8. Дополнительные эксперименты

Этот раздел будет последовательно расширяться на этапе ablations: обучаемые фильтры (CNN-денойзер), адаптивный выбор уровня вейвлета по оценке $\hat{\alpha}$, фильтр-калибрующее градиентное обрезание ($\text{Clip}(g) \sim 1/\hat{\alpha}$), а также теоретический набросок оценки сходимости при фильтрованном тяжёлохвостовом градиенте. Все обновления коммитятся в репозиторий с пометкой `innov:`.

Литература

- [1] R. Cont, «Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues», *Quantitative Finance*, т. 1, вып. 2, сс. 223–236, 2001, doi: 10.1080/713665670.
- [2] B. Mandelbrot, «The Variation of Certain Speculative Prices», *The Journal of Business*, т. 36, вып. 4, сс. 394–419, 1963, doi: 10.1086/294632.
- [3] U. Şimşekli, L. Sagun, и M. Gürbüzbalaban, «A Tail-Index Analysis of Stochastic Gradient Noise in Deep Neural Networks», в *Proceedings of the 36th International Conference on Machine Learning (ICML)*, в *Proceedings of Machine Learning Research*, vol. 97. PMLR, 2019, сс. 5827–5837. [Онлайн]. Доступно на: <https://arxiv.org/abs/1901.06053>
- [4] R. E. Kalman, «A New Approach to Linear Filtering and Prediction Problems», *Journal of Basic Engineering*, т. 82, вып. 1, сс. 35–45, 1960, doi: 10.1115/1.3662552.
- [5] D. L. Donoho и I. M. Johnstone, «Ideal Spatial Adaptation by Wavelet Shrinkage», *Biometrika*, т. 81, вып. 3, сс. 425–455, 1994, doi: 10.1093/biomet/81.3.425.
- [6] I. Daubechies, *Ten Lectures on Wavelets*. Philadelphia: Society for Industrial, Applied Mathematics, 1992. doi: 10.1137/1.9781611970104.
- [7] S. Mallat, *A Wavelet Tour of Signal Processing*, 2nd изд. San Diego: Academic Press, 1999.
- [8] L. Yin, R. Yang, M. Gabbouj, и Y. Neuvo, «Weighted Median Filters: A Tutorial», *IEEE Transactions on Circuits and Systems II: Analog and Digital Signal Processing*, т. 43, вып. 3, сс. 157–192, 1996, doi: 10.1109/82.486465.
- [9] D. P. Kingma и J. Ba, «Adam: A Method for Stochastic Optimization», в *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015. [Онлайн]. Доступно на: <https://arxiv.org/abs/1412.6980>
- [10] I. Loshchilov и F. Hutter, «Decoupled Weight Decay Regularization», в *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, 2019. [Онлайн]. Доступно на: <https://arxiv.org/abs/1711.05101>
- [11] A. Défossez, L. Bottou, F. Bach, и N. Usunier, «A Simple Convergence Proof of Adam and Adagrad», *Transactions on Machine Learning Research*, 2022, [Онлайн]. Доступно на: <https://arxiv.org/abs/2003.02395>
- [12] Y. Chandak, P. Yadav, A. Özgür, и N. Bambos, «Stochastic Approximation with Heavy-Tailed and Long-Range Dependent Noise». [Онлайн]. Доступно на: <https://arxiv.org/abs/2603.19648>