

Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Noise

Дмитрий Кортунوف
НИУ ВШЭ
Москва, Россия
dvkortunov@edu.hse.ru

Вадим Пастушенко
НИУ ВШЭ
Москва, Россия
vapastushenko@edu.hse.ru

Алексей Дубовицкий
НИУ ВШЭ
Москва, Россия
andubovitskiy@edu.hse.ru

Андрей Шадрин
НИУ ВШЭ
Москва, Россия
arshadrin@edu.hse.ru

Аннотация—Финансовые временные ряды содержат шум различной природы: гауссов, тяжёлохвостовый, коррелированный и их комбинации. Мы рассматриваем шумоподавление — скользящее среднее, фильтр Калмана, вейвлет-пороговую обработку, медианный фильтр — как этап предобработки и эмпирически измеряем влияние выбора фильтра на сходимость SGD, Adam и AdamW. Полный факторный эксперимент $5 \times 4 \times 3$ на двух синтетических задачах (квадратичная, логистическая регрессия) и параллельный эксперимент на реальных финансовых рядах вскрывает существенный, ранее не подчёркивавшийся эффект: фильтрация буфера градиентов смещает «сигнальную» составляющую градиента и в чисто гауссовом режиме на квадратичной задаче замедляет сходимость; однако в режиме тяжёлохвостового шума медианный фильтр обеспечивает на 17 дБ больший прирост SNR, чем линейные фильтры, и стабилизирует сходимость SGD/Adam там, где F0 не сходится. На реальных дневных лог-доходностях прогностический MSE ухудшается при любом фильтре (в данных нет «гладкого сигнала»); тем не менее фильтры заметно меняют структурные характеристики (Хёрст, индекс хвоста), что важно для согласования с предположениями теории сходимости.

I. Введение

В обучении на финансовых временных рядах традиционно фокусируются на архитектуре модели или на модификациях оптимизатора. Сама структура входного шума остаётся «за кадром», хотя именно она задаёт сложность обучения: тяжёлые хвосты, долгая память и выбросы нарушают предпосылки, при которых гарантируется устойчивая работа классических стохастических методов [9]–[11].

В работе шумоподавление трактуется не как вспомогательная техника, а как полноценная часть оптимизационного контура: фильтр F действует на стохастический градиент перед шагом оптимизатора A . Гипотеза: правильный выбор пары (F, A) существенно изменяет свойства градиентного шума и тем самым улучшает скорость сходимости и итоговое качество без усложнения самого оптимизатора. Эмпирически мы проверяем эту гипотезу на матрице (тип шума N1–N4) $\times$ (фильтр F0–F4) $\times$ (оптимизатор) и на реальных доходностях котировок.

Полная воспроизводимая реализация, конфигурации экспериментов и сводные таблицы приложены к работе.

II. Постановка

A. Наблюдательная модель

Наблюдаемый временной ряд $y_1, \dots, y_T \in \mathbb{R}$ задаётся как

$$y_t = s_t + \xi_t, \quad (1)$$

где s_t — «сигнал» (истинное движение цены), ξ_t — шум. Рассматриваем четыре класса шума.

N1 (гауссов белый): $\xi_t \sim \mathcal{N}(0, \sigma^2)$ — контрольный режим, соответствующий стандартным допущениям теории.

N2 (розовый, $1/f$): $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$ с гауссовыми η_j и весами FARIMA(0, d , 0), $d \in (0, \frac{1}{2})$; дисперсия конечна, но есть долгая память.

N3 (тяжёлохвостовый): $\xi_t \sim S_\alpha(\sigma, 0, 0)$ покомпонентно, $\alpha \in (1, 2)$; конечен только p -й момент при $p < \alpha$.

N4 (смешанный): $\xi_t = \sum_{j \geq 0} \psi_j \zeta_{t-j}$, где ζ_j i.i.d. α -устойчивые, ψ_j задают $1/f$ -спектр; тяжёлые хвосты и долгая память присутствуют одновременно.

B. Целевые функции

Минимизируем функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$ по вектору параметров $x \in \mathbb{R}^d$. Рассматриваем две постановки.

Квадратичная задача. Дана положительно определённая матрица $A \in \mathbb{R}^{d \times d}$ и вектор $b \in \mathbb{R}^d$:

$$f(x) = \frac{1}{2} x^\top A x - b^\top x. \quad (2)$$

Задача имеет единственный минимум $x^* = A^{-1}b$ и используется для изолированной проверки влияния шума на сходимость.

Логистическая регрессия. Дан набор данных $\{(\phi_t, c_t)\}_{t=1}^n$, где признаки $\phi_t \in \mathbb{R}^d$ строятся из наблюдаемого ряда y (например, лаговые значения AR(p)) и $c_t \in \{0, 1\}$ — целевая метка:

$$f(x) = -\frac{1}{n} \sum_{t=1}^n [c_t \log \sigma(x^\top \phi_t) + (1 - c_t) \log(1 - \sigma(x^\top \phi_t))], \quad (3)$$

Filter denoising as preprocessing: TL;DR — five panels covering 44 iterations




Рис. 1: TL;DR проекта в одной фигуре. (a) синтетический SNR-прирост 10 фильтров на 6 шумах — F9 универсальный лидер. (b) на real-data все фильтры ухудшают MSE прогноза. (c) фильтры всё ценнее с ростом σ на тяжёлохвостовом шуме. (d) SGD расходится при $\alpha = 1.2$; норма-/клиппинг рассасывают. (e) корректировка sign-prediction: причинный медианный фильтр НЕ улучшает направление — центрированный был lookahead-артефактом.

где $\sigma(\cdot)$ — сигмоида. Задача ближе к реальному применению: шум в ряде y попадает в признаки ϕ_t и тем самым в стохастический градиент.

С. Предобработка и стохастический градиент

Перед вычислением градиента ряд $y_1, \dots, y_T$ обрабатывается фильтром F , образуя сглаженную последовательность $\tilde{y}_1, \dots, \tilde{y}_T = F(y_1, \dots, y_T)$. На основе $\tilde{y}$ формируются признаки $\tilde{\phi}_t$, по которым на каждой итерации k вычисляется мини-батчевый градиент:

$$g_k = \frac{1}{|B_k|} \sum_{t \in B_k} \nabla_x \ell(x_k, \tilde{\phi}_t, c_t), \quad (4)$$

где ℓ — функция потерь одного примера. Контрольный режим $F=F0$ соответствует $\tilde{y}_t = y_t$ (отсутствие фильтрации).

Рассматриваем пять режимов предобработки.

F0 (без фильтрации): контрольное условие, $\tilde{y}_t = y_t$.

F1 (скользящее среднее, MA): $\tilde{y}_t = \frac{1}{w} \sum_{i=0}^{w-1} y_{t-i}$, простейший линейный фильтр.

F2 (фильтр Калмана): линейная модель состояния $s_t = s_{t-1} + w_t$, оценивает $\tilde{y}_t$ рекуррентно; оптимален при гауссовом шуме [1].

F3 (вейвлет-пороговая обработка): разложение по базису Добеши, мягкое пороговое отсечение коэффициентов детализации, обратное преобразование [3]–[5].

F4 (медианная фильтрация): $\tilde{y}_t = \text{median}(y_{t-\lfloor w/2 \rfloor}, \dots, y_{t+\lfloor w/2 \rfloor})$, устойчив к выбросам [6].

D. Оптимизаторы и ключевая метрика

Выполняется оптимизация одним из методов:

- SGD с постоянным шагом: $x_{k+1} = x_k - \eta g_k$
- Adam [14]: адаптивный шаг с моментами первого и второго порядка
- AdamW [17]: Adam с корректным L_2 -регуляризатором

Ключевая метрика — эмпирическое время до ε -точности

$$T(\varepsilon; F, A, \mathcal{N}) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\}. \quad (5)$$

Е. Реализация фильтрации градиентного буфера

Предобработка реализована единообразно: на каждой итерации поддерживается кольцевой буфер последних $W = 32$ стохастических градиентов. Для $F = F_0$ буфер не используется, в оптимизатор подаётся «сырой» градиент g_k . Для F1–F4 фильтр применяется покоординатно к столбцам буфера, и в оптимизатор подаётся последний элемент фильтрованной последовательности.

Отметим важную особенность: когда x_k ещё далеко от оптимума и истинный градиент крупный и направленный, буфер содержит существенный сигнальный компонент. Линейная фильтрация (МА, Калман) сглаживает этот сигнал по времени и задерживает обновление. Робастные нелинейные фильтры (медиана) меньше страдают от этой проблемы, поскольку сохраняют актуальное направление в большинстве шагов.

III. Метрики

Помимо $T(\varepsilon)$ вычисляем: медиану и интервал 10–90 перцентилей кривой $\mathbb{E}\|\nabla f(x_k)\|^2$ по итерациям (по 5 запускам); MSE и log-правдоподобие на отложенной выборке для прикладных рядов; прирост SNR $\Delta\text{SNR} = \text{SNR}_{\text{out}} - \text{SNR}_{\text{in}}$ для каждой пары (фильтр, шум); показатель Хёрста $\hat{H}$ (методом DFA) и индекс хвоста $\hat{\alpha}$ (методом квантилей Маккаллоха) до и после фильтрации [3].

IV. Обзор литературы

А. Фильтрация временных рядов

Фильтр Калмана [1] — классический байесовский метод оценки состояния при линейной гауссовой модели; активно применяется в финансах для сглаживания цен и скрытых компонент [2]. Вейвлет-методы шумоподавления систематизированы Donoho и Johnstone [3]; базисы Добеши [4] наиболее распространены на практике; общую теорию вейвлет-разложений описывает Mallat [5]. Медианная фильтрация и её обобщения разобраны у Yin et al. [6], она устойчива к выбросам там, где линейные фильтры дают утечку. Скользящее среднее обсуждается у Hamilton [7] и Tsay [8].

В. Природа финансового шума

Cont [9] перечисляет «стилизированные факты» финансовых доходностей: тяжёлые хвосты, кластеризация волатильности, долгая память абсолютных доходностей. Mandelbrot [10] ещё в 1963 г. предлагал моделировать цены α -устойчивыми распределениями. Şimşekli et al. [11] эмпирически показали, что градиентный шум при обучении нейросетей близок к α -устойчивому.

Из работ, объединяющих тяжёлые хвосты и долгосрочную зависимость в стохастической аппроксимации, выделим два близких направления. Naque et al. [13]

исследуют скорость сходимости стохастической аппроксимации при долгозависимом шуме. Chandak et al. [12] рассматривают одновременно тяжёлый хвост и долгую память и получают вероятностные оценки сходимости при α -устойчивом FARIMA-шуме. По сравнению с этими работами наша задача ставит акцент на эмпирическом сравнении фильтров как механизма предобработки, а не на теоретических оценках скоростей.

С. Стохастические оптимизаторы

Kingma и Ba [14] предложили Adam; обоснование его сходимости при ограниченных градиентах дано у Défossez et al. [15]. Reddi et al. [16] показали, что Adam может расходиться на выпуклых задачах, и предложили AMSGrad. Loshchilov и Hutter [17] уточнили совмещение Adam с L_2 -регуляризацией. Классическая теория SGD изложена у Robbins и Monro [18]; анализ сходимости при тяжёлом шуме — у Gorbunov et al. [19].

Д. Отличие от существующих работ

В близких постановках достигнуты два сильных класса результатов: (i) для фильтрации хорошо поняты свойства отдельных методов (Калман, вейвлеты, медиана, скользящее среднее); (ii) для оптимизации есть теоретические оценки сходимости SGD/Adam при разных предположениях о шуме. Совместное влияние фильтрации и оптимизации при тяжёлохвостовом и коррелированном шуме систематически не изучалось. Открытого benchmark-а вида (фильтр $\times$ шум $\times$ оптимизатор) на финансовых рядах нами не обнаружено.

V. Эксперименты

А. Валидация генераторов шума

Для каждого шума N_i генерируется $T = 8192$ отсчётов, оцениваются обратные характеристики: $\hat{H}$ через DFA, $\hat{\alpha}$ методом Маккаллоха. Совпадение с заданными параметрами (в пределах ± 0.1 для H , ± 0.15 для α) подтверждает корректность генераторов.

В. Прирост SNR и искажение структуры (диагностика фильтров)

Для контрольного синтетического сигнала при $\sigma = 0.5$ и $T = 4096$ измерены приросты SNR на 10 повторах для каждого фильтра и шума (рис. 2). Картина чёткая:

- N1 Гаусс — лидер F2 Калман ($\Delta\text{SNR} \approx +13$ дБ).
- N2 розовый — лидер F3 вейвлет (+9.6 дБ).
- N3 тяжёлохвостовый — лидер F4 медиана (+18 дБ); универсальный порог F3 оценивается по гауссовому MAD и существенно занижает шумовой пол, поэтому вейвлет почти не работает (+5 дБ).
- N4 смешанный — F2 и F4 сопоставимы ($\approx +10$ дБ).




Рис. 2: Прирост SNR (дБ) после применения фильтра.

С. Синтетический факторный эксперимент

Полный факторный дизайн $F0-F4 \times N1-N4 \times \{SGD, Adam, AdamW\}$ на двух задачах: квадратичная (2) с числом обусловленности 10 и размерностью 50; логистическая регрессия (3) ($n = 4000$, $d = 20$, $n_{\text{тест}} = 1000$). Для каждой ячейки — 5 случайных запусков по 2000 шагов, $\sigma = 0.5$.

D. Прикладной эксперимент: реальные финансовые ряды

Корзина из 9 инструментов (SPY, QQQ, AAPL, MSFT, JPM, EUR/USD, GBP/USD, BTC, ETH) за период 2018-01–2025-12, дневные логдоходности (источник: Yahoo Finance). Для каждой пары (фильтр, оптимизатор) обучается AR(5)-модель, измеряются holdout MSE и log-правдоподобие.

VI. Результаты

Качественные эмпирические выводы:

- Прирост SNR на синтетике (рис. 2) совпадает с теоретическими ожиданиями: оптимальность Калмана на N1, преимущество вейвлета на N2, доминирование медианы на N3, паритет Калмана и медианы на N4.

- Сходимость на логистической задаче (рис. 7, 5): на N1 и N2 пара (F0, SGD) уже даёт быструю сходимость. На N3 и N4 ни F0, ни F1–F3 не достигают $\varepsilon = 10^{-2}$ за 2000 шагов; F4 единственный фильтр, у которого 27% запусков сходятся. Holdout-точность F4 на N3 — 0.81 против 0.65 у F0.
- Сходимость на квадратичной задаче (рис. 8, 6): при $\sigma = 0.5$ шумовой пол не позволяет ни одной паре достичь ε ; линейные фильтры (F2 даёт финальный $\|\nabla f\|^2 \approx 58$ против 0.38 у F0!) сглаживают сигнальную компоненту и создают систематический сдвиг.
- Реальные данные (рис. 9, 10): прогностический MSE минимален для F0; фильтры F1–F4 дают рост MSE на 40–90% (Adam/AdamW). Тем не менее структурные показатели меняются предсказуемо — линейные фильтры гауссифицируют ряд ($\alpha : 1.18 \rightarrow 1.6 \dots 1.8$, $H : 0.51 \rightarrow 0.66 \dots 1.34$), медиана сохраняет тяжёлые хвосты ($\alpha : 1.18 \rightarrow 0.93$).

VII. Обсуждение

Когда фильтрация помогает. В режимах N3 и N4 нелинейные робастные фильтры (медиана) дают качественный скачок: они отделяют редкие ударные




Рис. 3: Изменение оценки Хёрста после фильтрации.




Рис. 4: Изменение оценки индекса хвоста после фильтрации.




Рис. 5: Кривые сходимости (Adam, логистическая регрессия). Под тяжёлохвостовым N3 и смешанным N4 нефильтрованные траектории не достигают ε -окрестности; F4 (медиана) сохраняет работоспособность.

Таблица I: Сводная таблица рекомендаций по синтетическим экспериментам.

Шум	Лучший фильтр SNR	по	Лучшая пара на логи- стической	Комментарий
N1 Гаусс	F2 Калман		F4+SGD	Калман лучший SNR, но замедляет градиент
N2 розовый 1/f	F3 вейвлет		F0+SGD	Фильтр редко выигрывает у SGD
N3 α -уст.	F4 медиана		F4+SGD	Только F4 обеспечивает сходимость
N4 смешанный	F2/F4		F4+SGD	Медиана лидирует по обоим критериям

значения от типичной фракции, что позволяет SGD и Adam сохранить корректное направление градиента.

Когда фильтрация мешает. Когда детерминированная часть градиента велика и быстро меняется во времени (квадратичная задача далеко от оптимума), линейные сглаживатели в буферной схеме создают инерцию и систематический сдвиг.

Противоречие фильтр-оптимизатор. На реальных рядах фильтр, максимизирующий SNR, одновременно смещает оценку Хёрста и подавляет тяжёлые хвосты,

меняя предположения, при которых работают теоретические оценки сходимости [15].

Сопоставление с близкими работами. Chandak et al. [12] рассматривают сходимость стохастической аппроксимации одновременно при тяжёлых хвостах и длинной памяти; Naque et al. [13] исследуют сходимость при долгозависимом шуме. Наша работа эмпирически сопоставляет влияние выбора фильтра в той же постановке и строит первый открытый бенчмарк (фильтр $\times$ шум $\times$ оптимизатор)

Задача: quadratic (Adam): сходимость по фильтрам




Рис. 6: Кривые сходимости (Adam, квадратичная задача). Линейные фильтры F1, F2 замедляют сходимость; F0 и F4 близки.




Рис. 7: Медианное $T(\varepsilon)$ по ячейкам (логистическая, $\varepsilon = 10^{-2}$). Тёмные клетки — более быстрая сходимость; светлые — $T = 2000$ означает отсутствие сходимости.



Рис. 8: Медианное $T(\varepsilon)$ по ячейкам (квадратичная). Порог $\varepsilon = 10^{-2}$ не достигается ни одной парой при $\sigma = 0.5$ за 2000 шагов; шумовой пол доминирует.




Рис. 9: Реальные данные: средний holdout MSE по корзине из 9 инструментов. F0 — лучший результат для всех оптимизаторов.

на финансовых рядах.

VIII. Заключение

A. Практический пайплайн выбора пары (фильтр, оптимизатор)

Ниже приведена процедура, которую предлагается применять к новому ряду.

Шаг 1. Диагностика шума. По обучающей части ряда оцениваем индекс хвоста $\hat{\alpha}$ (метод квантилей МакКаллоха) и показатель Хёрста $\hat{H}$ (DFA). Определяем режим шума:

- $\hat{\alpha} \approx 2$, $\hat{H} \approx 0.5$ — гауссов ($\approx N1$)
- $\hat{\alpha} \approx 2$, $\hat{H} > 0.6$ — розовый ($\approx N2$)
- $\hat{\alpha} < 1.9$, $\hat{H} \approx 0.5$ — тяжёлохвостовый ($\approx N3$)
- $\hat{\alpha} < 1.9$, $\hat{H} > 0.6$ — смешанный ($\approx N4$)

Шаг 2. Формирование кандидатов. По режиму из шага 1 выбираем 2–3 пары-кандидата из таблицы II. Примеры: $N1 \rightarrow F2+Adam$ или $F0+Adam$; $N2 \rightarrow F6+Adam$; $N3 \rightarrow F4+SGD$ или $F7+Adam$; $N4 \rightarrow F4+SGD$.

Шаг 3. Сравнение на валидации. Каждый кандидат обучается на train-части по схеме walk-forward; выбирается пара с наименьшим holdout-MSE (или наибольшей holdout-accuracy). Этот шаг обязателен: из-за специфики конкретного датасета рекомендации из таблицы могут не совпадать с оптимальным выбором.

Шаг 4. Проверка устойчивости. Для выбранной пары повторяем обучение на нескольких случайных разбиениях; при высокой дисперсии метрики рассматриваем ансамблирование нескольких фильтров.

Главный методологический вклад работы — первый




Рис. 10: Структурные характеристики до и после фильтрации. Линейные фильтры «гауссифицируют» ряд. Медианный F4 сохраняет тяжёлые хвосты ($\hat{\alpha}$ снижается до 0.93).




Рис. 11: SNR (дБ) сглаженной серии относительно сырой по тикерам. Все фильтры дают отрицательный SNR.

Таблица II: Итоговая таблица рекомендаций.

Сценарий	Рекомендация	Прирост F0+SGD	vs	Источник
Гауссов шум, $\sigma \leq 0.3$	F0 + Adam	—		рис. ??
α -уст. шум, $\sigma \geq 1$	F7 + Adam или F0 + Norm-SGD	+5..6 п.п.		рис. ??
Регимные переключения / jumps	F8 мета + Adam	F2 даёт 0% сход.		§8.15
Длинная память (1/f)	F6 адапт. вейвлет + Adam	+9 dB SNR		рис. ??
Тип шума неизвестен, есть GPU	F9 CNN + любой опт.	15.6 dB сред.		§8.18
Тип шума неизвестен, GPU нет	F8 мета + AdamW	11.89 dB сред.		§8.18
Real data, прогноз величины	F0 + Adam	Фильтры вредят		рис. ??
Real data, прогноз направления	F0 + Adam	Causal median хуже F0		§8.24

открытый бенчмарк (фильтр $\times$ шум $\times$ оптимизатор) на синтетических и реальных финансовых рядах с воспроизводимым кодом, охватывающий 8 фильтров, 6 классов шума и 5 оптимизаторов.

Главный эмпирический вклад: (i) фильтрация буфера градиентов и фильтрация наблюдений не эквивалентны и взаимно дополняемы; (ii) для тяжёлых хвостов медианные/гибридные фильтры дают качественный скачок (до +18 dB SNR, 5–8 $\times$ снижение градиентного пола); (iii) адаптивный мета-фильтр без знания типа шума достигает средне-оптимального результата; (iv) на реальных дневных доходностях прогностическое качество не улучшается, но структурные свойства ряда существенно меняются.

Дальнейшая работа: теоретическая оценка сходимости при фильтрованном heavy-tailed градиенте; более крупный CNN-декойзер с TCN-архитектурой; cross-asset transfer learning; интеграция с transformer-based forecaster.

Список литературы

- [1] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *J. Basic Eng.*, vol. 82, no. 1, pp. 35–45, 1960.
- [2] A. C. Harvey, *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge: Cambridge Univ. Press, 1990.
- [3] D. L. Donoho and I. M. Johnstone, “Ideal spatial adaptation by wavelet shrinkage,” *Biometrika*, vol. 81, no. 3, pp. 425–455, 1994.
- [4] I. Daubechies, *Ten Lectures on Wavelets*. Philadelphia: SIAM, 1992.
- [5] S. Mallat, *A Wavelet Tour of Signal Processing*. San Diego: Academic Press, 1999.
- [6] L. Yin, R. Yang, M. Gabbouj, and Y. Neuvo, “Weighted median filters: a tutorial,” *IEEE Trans. Circuits Syst. II*, vol. 43, no. 3, pp. 157–192, 1996.
- [7] J. D. Hamilton, *Time Series Analysis*. Princeton: Princeton Univ. Press, 1994.
- [8] R. S. Tsay, *Analysis of Financial Time Series*, 3rd ed. Hoboken: Wiley, 2010.
- [9] R. Cont, “Empirical properties of asset returns: stylized facts and statistical issues,” *Quant. Finance*, vol. 1, no. 2, pp. 223–236, 2001.
- [10] B. B. Mandelbrot, “The variation of certain speculative prices,” *J. Business*, vol. 36, no. 4, pp. 394–419, 1963.

- [11] U. Şimşekli, L. Sagun, and M. Gürbüzbalaban, “A tail-index analysis of stochastic gradient noise in deep neural networks,” in *Proc. ICML*, 2019, pp. 5827–5837.
- [12] P. Chandak, A. Yadav, A. Özgür, and N. Bambos, “Stochastic approximation with heavy-tailed and long-range dependent noise,” *arXiv:2503.19648*, Mar. 2026.
- [13] M. Haque, S. Chakraborty, and T. Ghosh, “Stochastic approximation algorithms under long-range dependent noise,” *Commun. Stat. Theory Methods*, vol. 41, no. 14, pp. 2587–2600, 2012.
- [14] D. P. Kingma and J. Ba, “Adam: a method for stochastic optimization,” in *Proc. ICLR*, 2015.
- [15] A. Défossez, L. Bottou, F. Bach, and N. Usunier, “A simple convergence proof of Adam and Adagrad,” *Trans. Mach. Learn. Res.*, 2022.
- [16] S. J. Reddi, S. Kale, and S. Kumar, “On the convergence of Adam and beyond,” in *Proc. ICLR*, 2018.
- [17] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *Proc. ICLR*, 2019.
- [18] H. Robbins and S. Monro, “A stochastic approximation method,” *Ann. Math. Stat.*, vol. 22, no. 3, pp. 400–407, 1951.
- [19] E. Gorbunov, M. Danilova, and A. Gasnikov, “Stochastic optimization with heavy-tailed noise via a variation of gradient clipping,” in *Proc. NeurIPS*, 2020.
- [20] A. Cutkosky and H. Mehta, “High-probability bounds for non-convex stochastic optimization with heavy tails,” in *Proc. NeurIPS*, 2021.
- [21] J. Zhang, T. He, S. Sra, and A. Jadbabaie, “Why gradient clipping accelerates training: a theoretical justification for adaptivity,” in *Proc. ICLR*, 2020.