

Домашнее задание: ускоренные методы — разделы 1–5

Сопряжённые градиенты · Ньютон/квази-Ньютон · Условный градиент · Субградиентный · Проксимальный

Источник: hse26.fmin.xyz/homework.html. Все ссылки — на конспекты hse26.fmin.xyz/program.html (занятия 10–14).

Код: каталог `notebooks/`, рисунки воспроизводимы.

Содержание

1	Сопряжённые градиенты	3
1.1	Рандомизированные предобуславливатели для CG (20)	3
2	Метод Ньютона и квазиньютоновские методы	5
2.1	Проблема сходимости Ньютона (10)	5
2.2	Hessian-Free метод Ньютона (20)	5
3	Условные градиентные методы	7
3.1	Проекция на многогранник Биркгофа методом Франк–Вульфа (20)	7
3.2	Минимизация квадратичной функции на симплексе (20)	7
4	Субградиентный метод	9
4.1	Точка в пересечении выпуклых множеств (30)	9
4.2	Субградиентные методы для LASSO (10)	10
5	Проксимальный градиентный метод	11
5.1	Проксимальный метод для разреженной softmax-регрессии (20)	11

1 Сопряжённые градиенты

1.1 Рандомизированные предобуславливатели для CG (20)

Задача наименьших квадратов $f(x) = \frac{1}{2} \|\hat{A}x - \hat{b}\|_2^2$, $\hat{A} \in R^{m \times n}$, $m \gg n$. Минимум $\Rightarrow$ нормальные уравнения

$$Ax = b, \quad A := \hat{A}^\top \hat{A} \in R^{n \times n}, \quad b := \hat{A}^\top \hat{b} \in R^n. \quad (1)$$

Лекция 10 Теорема 2 (сходимость CG как итерационного метода):

$$\|x_k - x^*\|_A \leq 2 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k \|x_0 - x^*\|_A, \quad \kappa(A) = \lambda_1(A)/\lambda_n(A). \quad (2)$$

Поскольку $\kappa(\hat{A}^\top \hat{A}) = \kappa^2(\hat{A})$, обусловленность возводится в квадрат, поэтому нужен предобуславливатель: переход $Ax = b \rightarrow MAx = Mb$ при $\kappa(MA) \ll \kappa(A)$; спектр MA совпадает со спектром $T^\top AT$

Лекция 10. Идеал $M = A^{-1}$ недостижим, ищем дешёвый $M \approx A^{-1}$.

Сэмплирующая матрица $\Phi = RH_m^{\text{norm}}S \in R^{(n+p) \times m}$ ($S = \text{diag}(\pm 1)$, R — выбор строк, $H_m^{\text{norm}} = m^{-\frac{1}{2}}H_m$), и

$$M^{-1} = \hat{A}^\top \Phi^\top \Phi \hat{A} = (\Phi \hat{A})^\top (\Phi \hat{A}), \quad W := \Phi \hat{A} \in R^{(n+p) \times n}. \quad (3)$$

1.1.1 (2) FLOP-ы для M^{-1} и M

Строим $W = RH_m^{\text{norm}}S\hat{A}$ по столбцам (n столбцов):

- $S\hat{A}$: домножение на диагональ — $O(mn)$;
- $H_m^{\text{norm}}(S\hat{A})$: быстрое преобразование Адамара ($\text{matvec } H_m v$ за $m \log m$) к каждому из n столбцов плюс масштаб $m^{-\frac{1}{2}}$ — $O(nm \log m)$;
- $R(\cdot)$: выбор $n + p$ строк — $O((n + p)n)$ копирований (без умножений).

Итого W : $O(nm \log m)$. Далее $M^{-1} = W^\top W$: $(n + p) \times n$ на $n \times (n + p)$ — $O(n^2(n + p))$. Обращение $M = (M^{-1})^{-1}$ (или фактор Холецкого $M^{-1} = LL^\top$): $O(n^3)$.

$$\text{FLOPs}(M^{-1}) = O(nm \log m + n^2(n + p)), \quad \text{FLOPs}(M) = O(n^3). \quad (5)$$

1.1.2 (2) FLOP-ы наивного $\hat{A}^\top \hat{A}$

$(\hat{A}^\top \hat{A})_{ij} = \sum_{k=1}^m \hat{A}_{ki} \hat{A}_{kj}$ — n^2 скалярных произведений длины m , симметрия даёт фактор $\frac{1}{2}$:

$$\text{FLOPs}(\hat{A}^\top \hat{A}) = n^2(2m - 1) \approx 2mn^2 = O(mn^2). \quad (6)$$

1.1.3 (2) FLOP-ы $\hat{A}^\top \hat{A}v$ через $u = \hat{A}v$

$u = \hat{A}v$: $m \times n$ на вектор — $\approx 2mn$. Затем $\hat{A}^\top u$: $\approx 2mn$.

$$\text{FLOPs}(\hat{A}^\top (\hat{A}v)) \approx 4mn = O(mn) \ll O(mn^2). \quad (7)$$

Поэтому в CG матрица A никогда не формируется явно.

1.1.4 (4) PCG за k итераций против прямого решения

Предобработка PCG: построение M — $O(nm \log m + n^3)$ (п. 1.1.1). Одна итерация PCG: один $Ap = \hat{A}^\top (\hat{A}p)$ — $O(mn)$; применение предобуславливателя $z = Mr$ через факторы Холецкого $M^{-1} = LL^\top$ — $O(n^2)$; векторные операции $O(n)$. Итого

$$T_{\text{PCG}}(k) = O\left(\underbrace{nm \log m + n^3}_{\text{setup}} + k(mn + n^2)\right). \quad (8)$$

Прямое решение $Ax = b$: формирование $\hat{A}^\top \hat{A} — O(mn^2)$; Холецкий — $O(n^3/3)$; обратная подстановка — $O(n^2)$:

$$T_{\text{direct}} = O(mn^2 + n^3). \quad (9)$$

При $\log m \ll n$ (здесь $\log_2 4096 = 12 \ll 400$) setup PCG $O(nm \log m) \ll O(mn^2)$, дешевле формирования $\hat{A}^\top \hat{A}$. Сравнивая ведущие члены $k \cdot mn$ и mn^2 :

$$k \cdot mn \gtrsim mn^2 \implies k \gtrsim n. \quad (11)$$

CG медленнее прямого метода при $k = O(n)$ (здесь $n = 400$). В точной арифметике CG сходится за $\leq n$ шагов (Лекция 10 Теорема 1: за r — число различных собственных значений), смысл предобуславливания — добиться $k \ll n$.

1.1.5 (10) Реализация (notebooks/01_cg_preconditioned.ipynb)

$m = 2^{12} = 4096$, $n = 400$, $p = 20$; столбцы $\hat{A}$ масштабированы логарифмически $\implies$ большое κ . Быстрое Адамара проверено против рекурсивного определения H_m (порядок 8). Предобусловленный CG (Лекция 10, алгоритм):

$$r_0 = b - Ax_0, \quad z_0 = Mr_0, \quad d_0 = z_0; \quad \alpha_k = \frac{r_k^\top z_k}{d_k^\top A d_k}, \quad \beta_k = \frac{r_{k+1}^\top z_{k+1}}{r_k^\top z_k}. \quad (12)$$

Полученные числа:

$$\kappa(\hat{A}^\top \hat{A}) \approx 1.20 \cdot 10^6, \quad \kappa(M^{\frac{1}{2}} \hat{A}^\top \hat{A} M^{\frac{1}{2}}) \approx 1.45 \cdot 10^5 \quad (\approx 8.2 \times \text{меньше}). \quad (13)$$

Невязка после 400 итераций: $7.0 \cdot 10^{-5}$ (без M) против $2.8 \cdot 10^{-6}$ (с M). При предписанном малом $p = 20$ эскиз SRHT лишь слабо переопределён ($n + p = 420 < n \log n$), поэтому спектр кластеризуется умеренно — но CG с предобуславливателем всё равно сходится заметно быстрее.




Рис. 1. Относительная невязка $\|\hat{A}^\top \hat{b} - \hat{A}^\top \hat{A} x_k\|_2 / \|\hat{A}^\top \hat{b}\|_2$.

2 Метод Ньютона и квазиньютоновские методы

2.1 Проблема сходимости Ньютона (10)

$$f(x, y) = \frac{x^4}{4} - x^2 + 2x + (y - 1)^2, \quad \nabla f = \begin{pmatrix} x^3 - 2x + 2 \\ 2(y - 1) \end{pmatrix}, \quad \nabla^2 f = \begin{pmatrix} 3x^2 - 2 & 0 \\ 0 & 2 \end{pmatrix}. \quad (14)$$

Переменные разделяются. По y : f квадратична, Ньютон попадает в $y^* = 1$ за один шаг при любом старте.

По x : $g(x) = \frac{x^4}{4} - x^2 + 2x$, $g'(x) = x^3 - 2x + 2$, $g''(x) = 3x^2 - 2$. Единственный вещественный корень g' : $x^* \approx -1.7693$, $g''(x^*) \approx 7.39 > 0$ — глобальный минимум (g коэрцитивна, x^4 доминирует).

Итерации Ньютона из $x_0 = 0$. $x_{k+1} = x_k - g'(x_k)/g''(x_k)$:

$$\begin{aligned} x_0 = 0 : \quad & g'(0) = 2, g''(0) = -2 \rightarrow x_1 = 0 - \frac{2}{-2} = 1, \\ x_1 = 1 : \quad & g'(1) = 1, g''(1) = 1 \rightarrow x_2 = 1 - \frac{1}{1} = 0, \Rightarrow \{x_k\} = \{0, 1, 0, 1, \dots\}. \end{aligned} \quad (15)$$

Метод Ньютона **зацикливается** в 2-цикле $\{0, 1\}$ и не сходится к $x^* \approx -1.77$.

Объяснение Лекция 11: локальная квадратичная сходимость гарантируется лишь при $\mu I_n \preceq \nabla^2 f \preceq LI_n$ и хорошей инициализации $\|x_0 - x^*\| < 2\mu/M$ (M — константа Липшица гессиана). Здесь в $x_0 = 0$ гессиан $g''(0) = -2 < 0$ — **индефинитен**, направление Ньютона не является направлением спуска, предположение $\nabla^2 f \succeq \mu I$ нарушено (ср. Лекция 11 «Отсутствие квадратичной сходимости, если предположения нарушаются», «Проблемы метода Ньютона»).

Градиентный спуск $\alpha = 0.01$. $x_{k+1} = x_k - 0.01(x_k^3 - 2x_k + 2)$. Малый шаг $\Rightarrow$ монотонное убывание f (т.к. $\alpha < 2/L$ локально); f коэрцитивна и имеет единственный минимум $\Rightarrow$ сходимость к $(x^*, 1) \approx (-1.7693, 1)$, медленно (линейно).

Наискорейший спуск (точный линейный поиск, Лекция 10). Тоже метод спуска: $f(x_{k+1}) \leq f(x_k)$, на коэрцитивной функции с единственным минимумом сходится к $(x^*, 1)$; направления соседних шагов ортогональны (Лекция 10), на овражной части возможен зигзаг.

2.2 Hessian-Free метод Ньютона (20)

Бинарная логистическая регрессия, $p(y = 1|x; w) = \sigma(w^\top x)$, $\sigma(t) = \frac{1}{1+e^{-t}}$:

$$f(w) = \sum_{i=1}^m [\log(1 + e^{w^\top x_i}) - y_i w^\top x_i] + \frac{\mu}{2} \|w\|_2^2. \quad (16)$$

$$\nabla f(w) = X^\top (\sigma(Xw) - y) + \mu w, \quad \nabla^2 f(w) = X^\top DX + \mu I, \quad D = \text{diag}(\sigma_i(1 - \sigma_i)). \quad (17)$$

Так как $0 < \sigma(1 - \sigma) \leq \frac{1}{4}$:

$$\mu I \preceq \nabla^2 f(w) \preceq LI, \quad L = \frac{1}{4} \lambda_{\max}(X^\top X) + \mu, \quad (18)$$

т.е. f есть L -гладкая и (при $\mu > 0$) μ -сильно выпуклая (Лекция 11, L -гладкость и сильная выпуклость; $\kappa = L/\mu$). Данные: $m = 1000$, $d = 100$, $y_i = \mathbb{1}[\sigma(x_i^\top w^*) > 0.5] \Rightarrow$ **линейно разделимы**. Эксперименты — notebooks/02_newton_logreg.ipynb; $\lambda_{\max}(X^\top X) \approx 1.70 \cdot 10^3$.

(a) **GD**, $\mu = 1$. $L \approx 426.2$, теоретический максимальный шаг $2/L \approx 4.69 \cdot 10^{-3}$. Шаги $0.5/L, 1/L, 1.9/L$ дают линейную сходимость (сильная выпуклость), шаг $2.05/L$ расходится — граница $2/L$ точна.

(b) **Ньютон**, $\mu = 1$. Все предположения Лекция 11 выполнены ($\mu I \preceq \nabla^2 f \preceq LI$, гессиан липшицев) $\Rightarrow$ локальная квадратичная сходимость $\|w_{k+1} - w^*\| \leq (M/2\mu)\|w_k - w^*\|^2$; численно $f - f^* < 10^{-3}$ за ≈ 6 итераций ($f^* = 97.3743$).

(с) **Демпфированный Ньютон.** Шаг $w_{k+1} = w_k - t_k [\nabla^2 f]^{-1} \nabla f$ с backtracking (условие Армихо). Глобальная сходимость из любой точки + переход к $t_k = 1$ и квадратичной фазе вблизи w^* — устраняет «дикие» шаги чистого Ньютона.

(d) **GD, $\mu = 0$.** Разделимость $\Rightarrow \inf f = 0$ не достигается ($\|w_k\| \rightarrow \infty$); нет сильной выпуклости $\Rightarrow$ только $O(1/k)$. $L_0 = \frac{1}{4} \lambda_{\max}(X^\top X)$; шаг $1/L_0$ убывает f сублинейно (численно f застревает ≈ 35.5 за 400 итераций). ε -точность по f достижима (т.к. $f^* = 0$), но по $\|\nabla f\|$ — крайне медленно (минимум на бесконечности).

(е) **Ньютон, $\mu = 0$.** При w с уверенными предсказаниями $D = \sigma(1 - \sigma) \rightarrow 0 \Rightarrow \nabla^2 f = X^\top DX$ почти вырожден, нарушено $\mu I \preceq \nabla^2 f$ (Лекция 11) $\Rightarrow$ огромные шаги, нет квадратичной сходимости. Демпфированный вариант остаётся устойчив: численно $f \rightarrow 8.6 \cdot 10^{-10}$ (приближение к 0).

(f) **Ньютон–CG.** $\nabla^2 f(w_k) d_k = -\nabla f(w_k)$ решается CG (`jax.scipy.sparse.linalg.cg`, Лекция 10); затем $w_{k+1} = w_k + \alpha d_k$. Тот же квадратичный профиль, что у точного Ньютона, при неточном (CG) решении системы.

(g) **Hessian-Free Newton.** Произведение гессиан-вектор через автодифф $\nabla^2 f(w)v = \nabla_w[\langle \nabla f(w), v \rangle]$ (forward-over-reverse, `jax.jvp(jax.grad f)`), гессиан не хранится. Память $O(d)$ против $O(d^2)$. Замеры (15 итераций, $\mu = 1$, $f - f^*$): явный Ньютон ≈ 141 мс, Ньютон–CG (плотный H) ≈ 386 мс, HFN ≈ 561 мс. При малом $d = 100$ плотный гессиан ($d^2 = 10^4$ чисел) дешевле; преимущество HFN — память $O(d)$ и масштабируемость на большие d , где формирование $\nabla^2 f$ невозможно.




Рис. 2. (а) GD, $\mu = 1$: граница $2/L$.




Рис. 3. (b,c) Ньютон vs демпфированный, $\mu = 1$.




Рис. 4. (d,e) $\mu = 0$: $\inf f = 0$ недостижим.




Рис. 5. (f,g) Ньютон / Ньютон–CG / HFN.

3 Условные градиентные методы

3.1 Проекция на многогранник Биркгофа методом Франк–Вульфа (20)

$$\min_{X \in B_n} f(X) = \frac{1}{2} \|X - Y\|_F^2, \quad B_n = \{X \geq 0, X\mathbb{1} = \mathbb{1}, X^\top \mathbb{1} = \mathbb{1}\}.$$

3.1.1 (5) Градиент и оракул LMO

$$\nabla f(X) = X - Y. \quad (19)$$

Шаг LMO (Лекция 12, идея Франк–Вульфа: $y_k = \arg \min_{x \in S} \langle \nabla f(x_k), x \rangle$, $x_{k+1} = \gamma_k x_k + (1 - \gamma_k) y_k$):

$$S_k = \arg \min_{S \in B_n} \langle \nabla f(X_k), S \rangle = \arg \min_{S \in B_n} \langle X_k - Y, S \rangle. \quad (20)$$

Линейная функция на многограннике достигает минимума в вершине. **Теорема Биркгофа–фон Неймана:** вершины B_n — в точности матрицы перестановок. Поэтому

$$\min_{S \in B_n} \langle G, S \rangle = \min_{\pi \in S_n} \sum_{i=1}^n G_{i, \pi(i)} \quad (21)$$

— **линейная задача о назначениях**; решается венгерским алгоритмом (`scipy.optimize.linear_sum_assignment`). S_k — матрица перестановки.

3.1.2 (10–5) Реализация (`notebooks/03_fw_birkhoff.ipynb`)

Точный линейный поиск для квадратичной f : $\varphi(\gamma) = f(X_k + \gamma(S_k - X_k))$, $\varphi'(\gamma) = \langle X_k - Y + \gamma(S_k - X_k), S_k - X_k \rangle = 0 \Rightarrow$

$$\gamma_k = \frac{\langle X_k - Y, X_k - S_k \rangle}{\|X_k - S_k\|_F^2} \quad (\text{отсечение в } [0, 1]) \quad \text{— совпадает с заданным.} \quad (22)$$

Старт $X_0 = I$ (перестановка). Итерации — выпуклые комбинации матриц перестановок $\Rightarrow X_k \in B_n$ **точно** на каждом шаге: численно $\max_j |\sum_i X_{ij} - 1| \approx 9 \cdot 10^{-16}$, $\max_i |\sum_j X_{ij} - 1| \approx 7 \cdot 10^{-16}$, отрицательных элементов нет; $f(X_{200}) \approx 6.413$. Сходимость $O(1/k)$ (Лекция 12, $f(x_k) - f^* \leq 2LR^2/(k+1)$).




Рис. 6. Франк–Вульф на B_5 , LMO = венгерский алгоритм, скорость $O(1/k)$.

3.2 Минимизация квадратичной функции на симплексе (20)

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} x^\top Q x + c^\top x, \quad Q \in \mathbb{S}_{++}^n, \quad \nabla f(x) = Qx + c.$$

3.2.1 (5) Данные

$n = 20$; $Q = U \operatorname{diag}(s) U^\top$ со спектром $s \subset [\mu, L] = [1, 100]$ (U ортогональна); $x^* \sim \operatorname{Dirichlet}(\mathbb{1}) \in \operatorname{ri}(\Delta_n)$; $c = -Qx^*$. Тогда безусловный минимум $-Q^{-1}c = x^*$ лежит в $\Delta_n \Rightarrow x^*$ — и условный минимум, $f^* = f(x^*)$. Старты: вершина e_1 и барицентр $\mathbb{1}/n$.

3.2.2 (7) Франк–Вульф

ЛМО на симплексе: $\min_{s \in \Delta_n} \langle g, s \rangle = e_{i^*}$, $i^* = \arg \min_i g_i$ (линейная функция на Δ_n — в вершине). Точный линейный поиск (квадратичная f , направление $d = s - x$):

$$\gamma_k = \text{clip} \left(-\frac{\langle g, d \rangle}{d^\top Q d}, 0, 1 \right). \quad (23)$$

3.2.3 (8) Проекционный градиентный спуск

$$x_{k+1} = \text{proj}_{\Delta_n} \left(x_k - \frac{1}{L} \nabla f(x_k) \right), \quad L = \lambda_{\max}(Q). \quad (24)$$

Проекция на симплекс (Duchi и др., 2008) — решение $\min_z \frac{1}{2} \|z - v\|_2^2$ при $\mathbf{1}^\top z = 1$, $z \geq 0$. ККТ: $z_i = (v_i - \theta)_+$, θ — множитель условия $\sum z_i = 1$. Сортируем $u = \text{sort}_\downarrow(v)$, $\rho = \max\{j : u_j - (1/j)(\sum_{r \leq j} u_r - 1) > 0\}$, $\theta = (1/\rho)(\sum_{r \leq \rho} u_r - 1)$, $z = (v - \theta)_+$. Оператор проекции нестягивающий (неравенство Бурбаки–Чейни–Гольдштейна, Лекция 12). Шаг $1/L$ обоснован Лекция 12: для гладкого выпуклого $f(x_k) - f^* \leq L\|x_0 - x^*\|^2/(2k)$; для μ -сильно выпуклого ($Q \succeq \mu I$) — линейная скорость.

3.2.4 Сравнение (notebooks/04_fw_simplex.ipynb)

$\kappa(Q) = L/\mu = 100$. Численно: PGD сходится **линейно** (зазор $\approx 10^{-12}$ при старте e_1 , $\approx 10^{-10}$ из барицентра) — сильная выпуклость. FW **сублинейно** $O(1/k)$ (зазор $\approx 2.4 \cdot 10^{-3}$): оптимум $x^* \in \text{ri}(\Delta_n)$ не вершина, FW зигзагует — это проявление нижней оценки $\min(n/2, LR^2/16\epsilon)$ для методов с оракулом ЛМО (Лекция 12).




Рис. 7. Квадратичная задача на Δ_{20} : FW $O(1/k)$ против линейного PGD.

4 Субградиентный метод

4.1 Точка в пересечении выпуклых множеств (30)

$U = \{\|A(x - y)\|_2 \leq 1\}$ (эллипсоид), $V = \{\|\Sigma x\|_\infty \leq 1\}$ (брус).

4.1.1 (10) Постановка и алгоритм

$$\phi(x) = \max\{\text{dist}(x, U), \text{dist}(x, V)\}, \quad \text{dist}(x, C) = \min_{z \in C} \|x - z\|_2. \quad (25)$$

$\text{dist}(\cdot, C)$ выпукла (Лекция 12, проекция на выпуклое корректна; $\frac{1}{2} \text{dist}^2(x, C)$ дифференцируема с градиентом $x - \text{proj}_{C(x)}$). Максимум выпуклых — выпуклая (Лекция 13). $\phi \geq 0$ и

$$\phi(x) = 0 \Leftrightarrow x \in U \cap V. \quad (26)$$

Субградиент $\text{dist}(\cdot, C)$ при $x \notin C$: $\nabla \text{dist}(x, C) = (x - \text{proj}_{C(x)}) / \|x - \text{proj}_{C(x)}\|$ (из критерия проекции Лекция 12). Субдифференциал максимума — теорема Дубовицкого–Миллутина (Лекция 13):

$$\partial\phi(x) = \text{conv} \bigcup_{i \in I(x)} \partial f_{i(x)}, \quad I(x) = \{i : f_{i(x)} = \phi(x)\}, \quad (27)$$

берём субградиент **активной** (большей) дистанции. Так как $\phi^* = 0$ известно — **шаг Поляка**

$$x_{k+1} = x_k - \frac{\phi(x_k) - \phi^*}{\|g_k\|_2^2} g_k, \quad g_k \in \partial\phi(x_k), \quad (28)$$

сходится к $U \cap V$ (Лекция 13, базовое неравенство и сходимости при $\sum \alpha_k = \infty$, $\sum \alpha_k^2 < \infty$; Поляк удовлетворяет условиям).

Проекция. $\text{proj}_{V(x)_i} = \text{clip}(x_i, -1/\sigma_i, 1/\sigma_i)$ (брус, покоординатно). proj_U : при $\|A(x - y)\| \leq 1$ — тождество; иначе ККТ для $\min_w \frac{1}{2} \|w - c\|^2, \|Aw\|^2 \leq 1$ ($w = z - y$, $c = x - y$): $w = (I + \lambda A^\top A)^{-1} c$, $\lambda \geq 0$ из $\|Aw\|^2 = 1$; в собственном базисе $A^\top A = Q\Lambda Q^\top$ функция $\sum_i \lambda_i \tilde{c}_i^2 / (1 + \lambda \lambda_i)^2$ монотонна по $\lambda \Rightarrow$ бисекция.

4.1.2 (15) Реализация (notebooks/05_subgrad_intersection.ipynb)

$n = 2$, $y = (3, 2)$, $\sigma = (0.5, 1)$, $A = \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix}$. Старт $x_0 = (1, 2)$ сходится в $(2, 1)$ с $\phi = 0$ **точно** и быстрее всех (точка уже почти в одном множестве, активная дистанция мгновенно зануляется). Старты $(2, -1)$ и $(0, 0)$ медленнее: $x \rightarrow (2, 0.97)$, $\phi \rightarrow 4.4 \cdot 10^{-4}$ за 2000 итераций.

4.1.3 (5) Обсуждение

- **Выпуклость:** ϕ выпукла (max выпуклых дистанций), задача выпукла.
- **Гладкость:** ϕ негладкая — изломы там, где $\text{dist}(x, U) = \text{dist}(x, V)$, и в точках границы (где dist не дифференцируема). Скорость $O(1/\sqrt{k})$ (Лекция 13).
- **Единственность:** решение не единственно — всё множество $U \cap V$ оптимально.
- **Скорость:** зависит от геометрии и старта; ближайший к $U \cap V$ / лежащий внутри одного множества старт сходится быстрее, старт «по диагонали» от тонкого пересечения — медленнее.




Рис. 8. Субградиентный метод (шаг Поляка), $\phi^* = 0$; разные старты.

4.2 Субградиентные методы для LASSO (10)

$$f(x) = \frac{1}{2}\|Ax - b\|_2^2 + \lambda\|x\|_1. \quad (29)$$

Субдифференциал (теорема Моро–Рокафеллара, Лекция 13: $\partial(\sum f_i) = \sum \partial f_i$, $\partial(g(Ax + b)) = A^\top \partial g$):

$$\partial f(x) = A^\top (Ax - b) + \lambda \partial \|x\|_1, \quad [\partial \|x\|_1]_i = \begin{cases} \{\text{sign}(x_i)\}, & x_i \neq 0 \\ [-1, 1], & x_i = 0. \end{cases} \quad (30)$$

Канонический субградиент $g = A^\top (Ax - b) + \lambda \text{sign}(x)$.

Стратегии шага и оценки (Лекция 13, базовое неравенство $f_k^{\text{best}} - f^* \leq \frac{R^2 + G^2 \sum \alpha_k^2}{2 \sum \alpha_k}$):

пост.: $\frac{R^2}{2\alpha k} + \frac{\alpha G^2}{2}$; пост. длины: $\frac{GR^2}{2\gamma k} + \frac{G\gamma}{2}$; $\alpha_k = \frac{R}{G\sqrt{k+1}} : \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$; $\alpha_k \sim \frac{1}{k}$; Поляк: $\alpha_k = \frac{f(x_k) - f^*}{\|g_k\|^2}$.

Реализация (notebooks/06_subgrad_lasso.ipynb): $n = 1000$, $m = 200$, $\lambda = 0.01$, разреженный x^* (20 ненулей). Эталон $f^* = 0.18252$ получен FISTA ($2 \cdot 10^4$ итераций, Лекция 14). Среди правил шага Поляк сходится быстрее всех; правила $1/k$ и постоянный шаг — медленно ($O(1/\sqrt{k})$). **Тяжёлый шар** $x_{k+1} = x_k - \alpha g_k + \beta(x_k - x_{k-1})$: настройка β даёт зазор $f_k^{\text{best}} - f^*$: $0.30(\beta = 0)$, $0.25(0.5)$, $0.17(0.8)$, **$2.9 \cdot 10^{-2}(\beta = 0.95)$** — импульс существенно ускоряет.




Рис. 9. LASSO: правила выбора шага (слева) и тяжёлый шар (справа).

5 Проксимальный градиентный метод

5.1 Проксимальный метод для разреженной softmax-регрессии (20)

$$\min_{W \in \mathbb{R}^{c \times d}} \underbrace{-\sum_{i=1}^N \log P(y_i | x_i; W)}_{f(W)} + \lambda \|W\|_1, \quad P(y = j | x; W) = e^{W_j^\top x} / \sum_{l=1}^c e^{W_l^\top x}. \quad (32)$$

Датасет «Predicting Students' Dropout and Academic Success» (UCI 697), 3 класса {Dropout, Enrolled, Graduate}, $N = 4424$, $d = 37$ (с bias), стандартизация. Эксперименты: `notebooks/07_prox_softmax.ipynb`.

5.1.1 (4) Точные правила обновления

$$\nabla f(W) = (P - Y)^\top X, \quad P_{ij} = \text{softmax}(XW^\top)_{ij}, \quad Y \text{ — one-hot.} \quad (33)$$

Субградиентный метод:

$$W_{k+1} = W_k - \alpha (\nabla f(W_k) + \lambda \text{sign}(W_k)). \quad (34)$$

Проксимальный градиентный (ISTA) — из условий оптимальности $0 \in \nabla f(W^*) + \partial r(W^*)$ (Лекция 14):

$$W^* = \text{prox}_{\alpha r}(W^* - \alpha \nabla f(W^*)) \Rightarrow W_{k+1} = \text{prox}_{\alpha \lambda \|\cdot\|_1}(W_k - \alpha \nabla f(W_k)). \quad (35)$$

Прокс ℓ_1 — **мягкий порог** (Лекция 14, вывод по трём случаям $x_i > 0$, $x_i < 0$, $x_i = 0$ из $0 \in \partial h(x_i)$):

$$\left[\text{prox}_{\tau \|\cdot\|_1}(v) \right]_i = \text{sign}(v_i) [|v_i| - \tau]_+, \quad \tau = \alpha \lambda. \quad (36)$$

Итого $W_{k+1} = \mathcal{S}_{\alpha \lambda}(W_k - \alpha \nabla f(W_k))$. Скорость Лекция 14: $\phi(W_k) - \phi^* \leq L \|W_0 - W^*\|^2 / (2k) = O(1/k)$ при $\alpha = 1/L$; ускоренный (FISTA) — $O(1/k^2)$. Критерий оптимальности — градиентное отображение $G_\alpha(W) = \frac{1}{\alpha(W - \text{prox}_{\alpha r}(W - \alpha \nabla f(W)))}$, $G_\alpha = 0 \Leftrightarrow W$ оптимальна (Лекция 14).

Граница гладкости softmax-кросс-энтропии: $\nabla^2 f \preceq \frac{1}{2} X^\top X \Rightarrow L = \frac{1}{2} \lambda_{\max}(X^\top X) \approx 1.16 \cdot 10^4$, шаг $1/L \approx 8.6 \cdot 10^{-5}$.

5.1.2 (6) $\lambda = 0$

Прокс с $\tau = 0$ — тождество $\Rightarrow \text{ISTA} \equiv \text{GD}$; максимальный шаг $< 2/L$ (Лекция 11, L -гладкость). Численно: NLL $\rightarrow 1951.39$, тест-точность 0.765, разреженность 0% (нет ℓ_1). Субградиент с $\alpha_k \sim 1/\sqrt{k}$ медленнее ($O(1/\sqrt{k})$ против $O(1/k)$), Лекция 13 – Лекция 14).




Рис. 10. $\lambda = 0$: проксимальный (= GD, $O(1/k)$) против субградиента ($O(1/\sqrt{k})$).

5.1.3 (10) Таблица сходимости

Чистый ISTA, шаг $1/L$; критерий — относительный зазор $(\phi(W_k) - \phi^*)/(\phi(W_0) - \phi^*) \leq \varepsilon$, эталон ϕ^* на каждое λ — FISTA ($4 \cdot 10^4$ итераций, Лекция 14).

λ	ε	итераций	разреженность	тест-точность
10^{-3}	10^{-1}	30	2.70%	0.7582
10^{-3}	10^{-2}	310	2.70%	0.7672
10^{-3}	10^{-3}	970	2.70%	0.7627
10^{-3}	10^{-4}	2180	2.70%	0.7661
10^{-3}	10^{-5}	3910	2.70%	0.7650
10^{-2}	10^{-1}	30	2.70%	0.7582
10^{-2}	10^{-2}	310	2.70%	0.7672
10^{-2}	10^{-3}	970	2.70%	0.7627
10^{-2}	10^{-4}	2250	2.70%	0.7661
10^{-2}	10^{-5}	38930	10.81%	0.7650
10^{-1}	10^{-1}	30	2.70%	0.7582
10^{-1}	10^{-2}	310	3.60%	0.7672
10^{-1}	10^{-3}	1000	3.60%	0.7638
10^{-1}	10^{-4}	4760	13.51%	0.7661
10^{-1}	10^{-5}	139350	34.23%	0.7650
1	10^{-1}	30	4.50%	0.7582
1	10^{-2}	300	9.01%	0.7638
1	10^{-3}	1330	21.62%	0.7638
1	10^{-4}	13250	36.04%	0.7627
1	10^{-5}	19260	36.04%	0.7627

Выводы: рост $\lambda \Rightarrow$ рост разреженности (до $\approx 36\%$ нулей при $\lambda = 1$) — soft-thresholding порождает точные нули (Лекция 14); более жёсткое ε требует больше итераций ($O(1/\varepsilon)$ для ISTA); тест-точность устойчива ≈ 0.76 (мажоритарный базис ≈ 0.50).




Рис. 11. Проксимальный градиент (ISTA), $\phi(W_k) - \phi^*$, скорость $O(1/k)$.