

Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Noise

(Project Proposal)

Дмитрий Кортунوف
НИУ ВШЭ
Москва, Россия
dvkortunov@edu.hse.ru

Вадим Пастушенко
НИУ ВШЭ
Москва, Россия
vpastushenko@edu.hse.ru

Алексей Дубовицкий
НИУ ВШЭ
Москва, Россия
andubovitskiy@edu.hse.ru

Андрей Шадрин
НИУ ВШЭ
Москва, Россия
arshadrin@edu.hse.ru

Аннотация—Финансовые ряды содержат шум различной природы — гауссов, тяжёлохвостовый, коррелированный. Прямая подача в стандартные стохастические оптимизаторы нарушает предпосылки теории сходимости. Мы рассматриваем шумоподавление наблюдаемого ряда как явный этап оптимизационной процедуры и формулируем проверяемую гипотезу: нелинейная порядковая статистика (оконная медиана) восстанавливает конечную эффективную дисперсию градиентного шума там, где линейные фильтры этого сделать не могут, и тем самым спасает сходимость SGD при α -устойчивом шуме. Этот документ — план работ; полный вывод механизма, доказательства и численные результаты вынесены в сопутствующую статью того же формата (paper.pdf / paper_ru.pdf), которую настоящий план дополняет.

Index Terms—шумоподавление, финансовые ряды, стохастическая оптимизация, α -устойчивый шум, медианная фильтрация, фильтр Калмана, вейвлет-порог, сходимость.

I. Введение

При обучении на финансовых рядах фокусируются обычно на архитектуре модели или модификации оптимизатора, оставляя структуру входного шума «за кадром». Между тем именно она — тяжёлые хвосты, долгая память, выбросы — определяет сложность обучения: нарушаются предпосылки ($\mathbb{E}\|\xi\|^2 < \infty$, независимость), при которых гарантирована стабильная работа классических методов [5]–[7]. Мы рассматриваем шумоподавление не как вспомогательную визуализацию, а как полноценную часть процедуры вычисления градиентного шага, и проверяем, может ли корректная предобработка изменить свойства градиентного шума так, чтобы метод сходился там, где без неё расходится. Ключевой тезис, который проект формулирует и проверяет: разделение фильтров на линейные (скользящее среднее, Калман — замкнуты относительно α -устойчивого закона и потому бессильны против тяжёлых хвостов) и нелинейные порядковые (медиана — отображает окно с бесконечной дисперсией в выход с конечной).

II. Постановка

A. Математическая постановка

Решается задача обучения. Параметры $x \in \mathbb{R}^d$; из наблюдаемого ряда $y_{1:T}$ строятся пары $(u_i, v_i)_{i=1}^n$, где вход $u_i \in \mathbb{R}^p$ — лаговое окно, цель v_i — следующее значение (или его знак). При модели g_x и потере ℓ (квадратичной для регрессии, логистической для классификации) минимизируется эмпирический риск

$$f(x) = \frac{1}{n} \sum_{i=1}^n \ell(g_x(u_i), v_i), \quad x^* \in \arg \min_{x \in \mathbb{R}^d} f(x). \quad (1)$$

Оптимизация — стохастическим методом первого порядка: на шаге k доступен зашумлённый градиент

$$g_k = \nabla f(x_k) + \xi_k, \quad x_{k+1} = x_k - \eta_k \phi(g_k), \quad (2)$$

ξ_k — центрированный шум, без предположений ограниченности $\mathbb{E}\|\xi_k\|^2$ и независимости. Вход всей процедуры — наблюдаемый ряд $y_t = s_t + \xi_t$ (s — сигнал, ξ — шум); перед оптимизатором он пропускается через фильтр $\hat{s} = F(y_{1:T})$, оптимизатор работает с $\hat{s}$; выход — параметры x_K и метрики. Контроль — $F_0 = \text{Id}$. Фильтр стоит строго между наблюдением и стохастическим градиентом (2).

B. Классы шума

N1 гауссов белый $\xi_t \sim \mathcal{N}(0, \sigma^2)$ (контроль). N2 розовый: $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$, $\psi_j \sim \text{FARIMA}(0, d, 0)$, $d \in (0, \frac{1}{2})$ (конечная дисперсия, долгая память). N3 тяжёлохвостовый $\xi_t \sim \mathcal{S}_\alpha(\sigma, 0, 0)$, $\alpha \in (1, 2)$ (конечен лишь p -й момент при $p < \alpha$; дисперсия бесконечна). N4 смешанный: $1/f$ -фильтр от α -устойчивых инноваций (тяжёлые хвосты и долгая память одновременно). Определяющее свойство: у N3/N4 второй момент бесконечен, у N1/N2 — конечен.

С. Фильтры

Рассматриваются только F0–F4. F0 тождество. F1 причинное скользящее среднее $\hat{s}_t = \frac{1}{w} \sum_{i=0}^{w-1} y_{t-i}$ (линейно; конечная линейная комбинация α -устойчивых снова α -устойчива). F2 Калман (локальный уровень) — линейная БИХ-рекурсия, оптимальная при гауссовом шуме [1]. F3 мягкий вейвлет-порог Добеши $\lambda = \hat{\sigma}\sqrt{2\ln N}$ [2], [3]. F4 причинная медиана окна w — единственный нелинейный, порядковая статистика, устойчива к выбросам [4]. На реальных данных — только причинные F0, F1, F2, F4 (без заглядывания вперёд).

D. Оптимизаторы

SGD (постоянный шаг $\phi(g) = g$); Clipped-SGD; Normalized-SGD; Adam [9]; AdamW [10]. Опорный факт: для SGD с постоянным шагом на L -гладкой μ -сильно выпуклой f при $\mathbb{E}\|\xi_k\|^2 \leq \sigma^2$ возникает конечное плато $\mathbb{E}\|\nabla f\|^2 \rightarrow \Theta(\eta L \sigma^2)$ [8]; при $\sigma^2 = \infty$ плато не определено — мотив всей работы.

E. Метрики

Не одна метрика, а батарея (медиана и 95% bootstrap-CI по сидам): бинарная сходимость (доля сошедшихся прогонов), $T(\varepsilon) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\}$, шумовой пол (перцентили), наклон $\log\|g\|^2$ vs $\log k$, AUC кривой, holdout-качество (без смещения train/test), искажение $\hat{H}, \hat{\alpha}$, wall-clock с учётом стоимости фильтра.

III. Гипотеза и ожидаемый механизм

Центральная гипотеза: при N3 ($\alpha < 2$) выборочная медиана окна w имеет конечную дисперсию $\frac{1}{4wh(0)^2} + o(1/w)$ для любого α (ЦПТ медианы использует лишь $h(0) > 0$, не моменты), тогда как любая линейная комбинация α -устойчивых остаётся α -устойчивой с бесконечной дисперсией. Отсюда предсказания, которые проект должен подтвердить или опровергнуть: (i) SGD без фильтра и с F1/F2/F3 не сходится при тяжёлых хвостах; (ii) с F4 сходится, шумовой пол падает на 1–2 порядка; (iii) на чистом гауссовом N1 медиана вредит (потеря эффективности $\pi/2$); (iv) на смешанном N4 медиана не спасает (зависимость окна ломает аргумент). Эти предсказания и их проверка — содержание сопутствующей статьи.

IV. Обзор литературы

Совместный тяжёлохвостовой/долгопамятный шум в стохастической аппроксимации впервые разобран Anantharam и Borkar [13] — асимптотический анализ через предельное ОДУ; Chandak и др. [14] дают первые конечновременные оценки моментов для того же режима. Обе работы анализируют немодифицированную итерацию. Робастность к тяжёлым хвостам со стороны оптимизатора: обрезание [11], high-probability оценки [12]. Классические операторы шумоподавления — Калман [1], вейвлет-порог [2], [3], медиана [4]; шумоподавление как предобработка прогноза — эмпирически

[15]; тяжёлый градиентный шум нейросетей — [7]. Наш вопрос ортогонален: при фиксированном оптимизаторе — где и насколько предобработка наблюдаемого ряда спасает сходимость, с явным механизмом.

V. План работ

Этап 1. Генераторы N1–N4; проверка, что обратные оценки $\hat{\alpha}, \hat{H}$ восстанавливают заданные параметры. Этап 2. Реализация F0–F4 как причинных отображений; валидация по SNR и сохранению структуры. Этап 3. Фиксированный набор оптимизаторов; контрольное сравнение F0 с F1–F4 по батарее метрик. Этап 4. Две серии: (а) синтетика (квадратичная, логистическая, AR) — факторный дизайн (F0–F4) $\times$ (N1–N4) $\times$ (оптимизатор), 8 сидов; (б) реальные ряды нескольких доменов и частот при той же причинной процедуре (walk-forward, без lookahead). Этап 5. Калибровка синтетики под измеренные на реальных рядах $\hat{\alpha}, \hat{H}$; статистическое сопоставление; вывод механизма; отчёт и сопутствующая статья.

VI. Ожидаемые результаты

Ожидается (и в сопутствующей статье подтверждено с CI по сидам): матрица сходимости/качества для всех (F0–F4, N1–N4, оптимизатор); доказанный механизм спасения сходимости медианой и его границы; практическая таблица «при каком шуме что применять»; воспроизводимый код. Положительным итогом является связка (причинная медиана + SGD) как процедура, делающая обучение при тяжёлохвостовом шуме сходящимся там, где без предобработки оно не сходится; негативные зоны (чистый гаусс, смешанный долгопамятный режим, сырые near-white доходности) сообщаются честно.

Список литературы

- [1] R. E. Kalman, “A new approach to linear filtering and prediction problems,” J. Basic Eng., vol. 82, no. 1, pp. 35–45, 1960.
- [2] D. L. Donoho and I. M. Johnstone, “Ideal spatial adaptation by wavelet shrinkage,” Biometrika, vol. 81, no. 3, pp. 425–455, 1994.
- [3] S. Mallat, A Wavelet Tour of Signal Processing, 2nd ed. San Diego: Academic Press, 1999.
- [4] L. Yin, R. Yang, M. Gabbouj, and Y. Neuvo, “Weighted median filters: a tutorial,” IEEE Trans. Circuits Syst. II, vol. 43, no. 3, pp. 157–192, 1996.
- [5] R. Cont, “Empirical properties of asset returns: stylized facts and statistical issues,” Quant. Finance, vol. 1, no. 2, pp. 223–236, 2001.
- [6] B. B. Mandelbrot, “The variation of certain speculative prices,” J. Business, vol. 36, no. 4, pp. 394–419, 1963.
- [7] U. Şimşekli, L. Sagun, and M. Gürbüzbalaban, “A tail-index analysis of stochastic gradient noise in deep neural networks,” in Proc. ICML, 2019, pp. 5827–5837.
- [8] H. Robbins and S. Monro, “A stochastic approximation method,” Ann. Math. Stat., vol. 22, no. 3, pp. 400–407, 1951.
- [9] D. P. Kingma and J. Ba, “Adam: a method for stochastic optimization,” in Proc. ICLR, 2015.
- [10] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in Proc. ICLR, 2019.
- [11] E. Gorbunov, M. Danilova, and A. Gasnikov, “Stochastic optimization with heavy-tailed noise via accelerated gradient clipping,” in Proc. NeurIPS, vol. 33, 2020, pp. 15042–15053.

- [12] A. Cutkosky and H. Mehta, “High-probability bounds for non-convex stochastic optimization with heavy tails,” in Proc. NeurIPS, 2021.
- [13] V. Anantharam and V. S. Borkar, “Stochastic approximation with long range dependent and heavy tailed noise,” *Queueing Syst.*, vol. 71, no. 1–2, pp. 221–242, 2012, doi: 10.1007/s11134-012-9283-0.
- [14] S. Chandak, A. K. Yadav, A. Özgür, and N. Bambos, “Heavy-tailed and long-range dependent noise in stochastic approximation: a finite-time analysis,” arXiv:2603.19648, Mar. 2026.
- [15] Q. Tang, T. Fan, R. Shi, J. Huang, and Y. Ma, “Prediction of financial time series using LSTM and data denoising methods,” arXiv:2103.03505, 2021.