

Beyond Gaussian Noise: Convergence of Stochastic Optimizers under Correlated and Heavy-Tailed Financial Noise

Дмитрий Кортунوف
НИУ ВШЭ
Москва, Россия
dvkortunov@edu.hse.ru

Вадим Пастушенко
НИУ ВШЭ
Москва, Россия
vapastushenko@edu.hse.ru

Алексей Дубовицкий
НИУ ВШЭ
Москва, Россия
andubovitskiy@edu.hse.ru

Андрей Шадрин
НИУ ВШЭ
Москва, Россия
arshadrin@edu.hse.ru

Аннотация—Финансовые временные ряды содержат шум различной природы: гауссов, тяжёлохвостовый, коррелированный и их комбинации. Прямая подача таких данных в стандартные стохастические оптимизаторы нарушает базовые предположения теории сходимости. Мы исследуем альтернативный подход: перед оптимизацией применяется этап шумоподавления — скользящее среднее, фильтр Калмана, вейвлет-пороговая обработка или медианная фильтрация, — после чего ряд подаётся в SGD, Adam или AdamW. Основной вопрос: насколько выбор фильтра влияет на скорость сходимости и итоговое качество модели, и можно ли подобрать пару (фильтр, оптимизатор), устойчивую к нескольким типам шума одновременно?

Index Terms—шумоподавление, финансовые временные ряды, стохастическая оптимизация, фильтр Калмана, вейвлет-порог, медианная фильтрация, Adam, SGD, сходимость

I. Введение

В обучении на финансовых временных рядах стандартно фокусируются либо на выборе архитектуры модели, либо на модификациях оптимизатора. При этом сама структура входного шума часто остаётся «за кадром», хотя для финансовых данных именно она задаёт сложность обучения: тяжёлые хвосты, долгая память и выбросы нарушают предпосылки, при которых гарантируется стабильная работа классических стохастических методов.

В проекте мы рассматриваем шумоподавление не как вспомогательную технику визуализации, а как полноценную часть оптимизационного процесса. Гипотеза состоит в том, что правильная предобработка может существенно изменить свойства градиентного шума и тем самым ускорить сходимость без усложнения самого оптимизатора.

Эмпирически мы сравниваем матрицу (тип шума) $\times$ (фильтр) $\times$ (оптимизатор) на синтетических и реальных финансовых данных и получаем ответ на практический вопрос: когда предобработка действительно помогает, а когда её эффект минимален или даже вреден из-за пересглаживания полезного сигнала.

II. Постановка

A. Математическая постановка

Решается задача обучения. Параметры модели $x \in \mathbb{R}^d$; обучающая выборка строится из наблюдаемого ряда: вход u_i — лаговое окно ряда длины p , цель v_i — следующее значение (или его знак для классификации). Модель $g_x(u)$, функция потерь ℓ (квадратичная для регрессии, логистическая кросс-энтропия для классификации). Минимизируется эмпирический риск

$$f(x) = \frac{1}{n} \sum_{i=1}^n \ell(g_x(u_i), v_i), \quad x^* \in \arg \min_{x \in \mathbb{R}^d} f(x), \quad (1)$$

$f : \mathbb{R}^d \rightarrow \mathbb{R}$. Оптимизация — стохастическим методом первого порядка: на итерации k доступен зашумлённый градиент

$$g_k = \nabla f(x_k) + \xi_k, \quad x_{k+1} = x_k - \eta_k \phi(g_k), \quad (2)$$

где ξ_k — центрированный шум (без предположений ограниченности $\mathbb{E}\|\xi_k\|^2$ и независимости по k).

Вход и выход всей процедуры. Вход — наблюдаемый ряд

$$y_t = s_t + \xi_t, \quad (3)$$

где s_t — сигнал, ξ_t — шум. Перед оптимизатором ряд (эквивалентно — инжектируемый в градиент шум) пропускается через фильтр $\hat{s} = F(y_{1:T})$; оптимизатор работает с $\hat{s}$. Выход — обученные параметры x_K и метрики сходимости/качества. Контроль — режим F0 (без фильтрации). Таким образом фильтр стоит строго между наблюдаемым рядом и стохастическим градиентом (2).

B. Классы шума ξ_t

N1 (гауссов белый): $\xi_t \sim \mathcal{N}(0, \sigma^2)$ — контрольный режим. N2 (розовый, $1/f$): $\xi_t = \sum_{j \geq 0} \psi_j \eta_{t-j}$ с гауссовыми η_j и весами FARIMA(0, d , 0), $d \in (0, \frac{1}{2})$ (конечная дисперсия, долгая память). N3 (тяжёлохвостовый): $\xi_t \sim S_\alpha(\sigma, 0, 0)$, $\alpha \in (1, 2)$ (конечен лишь p -й момент при $p < \alpha$). N4 (смешанный): $1/f$ -фильтр от α -устойчивых

инноваций — тяжёлые хвосты и долгая память одновременно.

С. Фильтры $\hat{s} = F(y)$

F0 — тождество (контроль). F1 (МА): $\hat{s}_t = \frac{1}{w} \sum_{i=0}^{w-1} y_{t-i}$, причинное. F2 (Калман): локальный уровень $s_t = As_{t-1} + w_t$, рекуррентная (причинная) оценка, оптимален при гауссовом шуме [1]. F3 (вейвлет-порог): базис Добеши, мягкое отсечение коэффициентов детализации [3], [5]. F4 (медиана): причинная медиана окна w , устойчива к выбросам [6]. На реальных данных используются только причинные фильтры (нет заглядывания вперёд).

Д. Оптимизаторы

Обновление (2) с ϕ : SGD $\phi(g) = g$; Adam [14] (моменты 1-го и 2-го порядка); AdamW [17] (корректный L_2); дополнительно Clipped-SGD и Normalized-SGD как робастные базлайны.

Е. Метрики

Ключевая — эмпирическое время до ε -точности

$$T(\varepsilon, F, A, \mathcal{N}) = \min\{K : \mathbb{E}\|\nabla f(x_K)\|^2 \leq \varepsilon\} \quad (4)$$

для каждой связки (фильтр F , оптимизатор A , тип шума $\mathcal{N}$). Дополнительно: бинарная сходимость (доля сошедшихся прогнозов по сидам), шумовой пол (перцентили финального $\|\nabla f\|^2$), наклон $\log \|g\|^2$ vs $\log k$ (диагностика расходимости), AUC кривой сходимости, holdout-качество (MSE / log-правдоподобие, без смешения train/test), ΔSNR и искажение $\hat{H}, \hat{\alpha}$ до/после фильтра, wall-clock с учётом стоимости фильтра. Все величины — с доверительными интервалами по сидам. Отрицательный результат тоже содержателен: схожая сходимость всех пар означала бы низкую чувствительность к предобработке — практически важный вывод.

III. Обзор литературы

А. Фильтрация временных рядов

Фильтр Калмана [1] — классический байесовский метод оценки состояния при линейной гауссовой модели. Активно применяется в финансах для сглаживания цен и скрытых компонент [2]. Вейвлет-методы шумоподавления были систематизированы Donoho и Johnstone [3], которые показали оптимальность мягкого порога в классе кусочно-гладких функций. Базисы Добеши [4] наиболее распространены на практике. Общую теорию вейвлет-разложений временных рядов описывает Mallat [5]. Медианная фильтрация и её обобщения разобраны у Yin et al. [6], она устойчива к выбросам там, где линейные фильтры дают утечку. Скользящее среднее — простейший базовый случай, его свойства в контексте финансовых рядов обсуждают Hamilton [7] и Tsay [8].

В. Природа финансового шума

Cont [9] перечисляет одиннадцать «стилизированных фактов» финансовых доходностей — тяжёлые хвосты, кластеризация волатильности, долгая память абсолютных доходностей. Mandelbrot [10] ещё в 1963 г. предлагал моделировать цены α -устойчивыми распределениями. Şimşekli et al. [11] эмпирически показали, что градиентный шум при обучении нейросетей не гауссов, а близок к α -устойчивому. Совместный (одновременно тяжёлохвостовый и долговременно-зависимый) шум в стохастической аппроксимации впервые разобран Anantharam и Borkar [12]: они дают асимптотический анализ методом сравнения с предельным ОДУ (долгая память — через дробное броуновское движение, тяжёлые хвосты — через симметричный устойчивый процесс). Недавняя работа Chandak et al. [13] даёт для этого же режима первые конечновременные (finite-time) оценки моментов ошибки. Обе работы анализируют немодифицированную итерацию; наш вопрос ортогонален: меняет ли картину предварительное шумоподавление наблюдаемого ряда и как это взаимодействует с конкретными оптимизаторами на финансовых данных.

С. Стохастические оптимизаторы

Kingma и Ba [14] предложили Adam, обоснование его сходимости при ограниченных градиентах дано у Défossez et al. [15]. Reddi et al. [16] показали, что Adam может расходиться на выпуклых задачах, и предложили AMSGrad. Loshchilov и Hutter [17] уточнили, как правильно совмещать Adam с L_2 -регуляризацией. Классическая теория SGD изложена у Robbins и Monro [18], современный анализ сходимости при тяжёлом шуме — у Gorbunov et al. [19].

Д. Отличие от существующих работ

В близких постановках достигнуты два сильных класса результатов: (i) для фильтрации хорошо понятны свойства отдельных методов (Калман, вейвлеты, медиана, скользящее среднее), (ii) для оптимизации есть теоретические оценки сходимости SGD/Adam-типов при разных предположениях о шуме. Наша задача сложнее: совместное влияние фильтрации и оптимизации при тяжёлохвостовом и коррелированном шуме. Единого открытого benchmark-а вида (фильтр $\times$ шум $\times$ оптимизатор) на финансовых рядах нами не обнаружено.

IV. План работ

Работа разбивается на содержательные этапы.

Этап 1. Задаём процедуры генерации четырёх классов шума N1–N4 и проверяем, что обратные оценки $\hat{\alpha}$ и $\hat{H}$ корректно восстанавливают заданные параметры.

Этап 2. Определяем четыре режима предобработки F1–F4 как отображения наблюдаемого ряда и валидируем их на контролируемой синтетике по SNR и по степени сохранения структурных характеристик.

Этап 3. Фиксируем набор оптимизаторов (SGD, Adam, AdamW) и проводим контрольное сравнение режима F0 (без фильтрации) с режимами F1–F4.

Этап 4. Две серии экспериментов:

- синтетическая — квадратичная и логистическая задачи, полный факторный дизайн $5 \times 4 \times 3$ (F0–F4) $\times$ (N1–N4) $\times$ (оптимизатор)
- прикладная — реальные финансовые ряды при той же процедуре сравнения.

Этап 5. Статистическое сопоставление режимов, анализ устойчивости выводов, подготовка отчёта с практическими рекомендациями. Если отдельные сценарии окажутся ресурсоёмкими, сохраняем ядро исследования: полный перебор по шумам и фильтрам на упрощённых моделях без потери сопоставимости.

V. Ожидаемые результаты

По итогу ожидаем получить:

- матрицу результатов сходимости и качества для всех комбинаций (фильтр, тип шума, оптимизатор)
- оценки SNR и степени искажения структуры ряда для каждого фильтра
- практическую таблицу рекомендаций «при каком шуме какую пару использовать»
- воспроизводимые материалы экспериментов и письменный отчёт

Если результаты подтвердят положительный эффект предобработки, отдельным итогом станет набор унифицированных процедур вида (фильтр + оптимизатор) для шумных финансовых рядов, обеспечивающих в среднем более стабильное и быстрое обучение.

Список литературы

- [1] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *J. Basic Eng.*, vol. 82, no. 1, pp. 35–45, 1960.
- [2] A. C. Harvey, *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge: Cambridge Univ. Press, 1990.
- [3] D. L. Donoho and I. M. Johnstone, “Ideal spatial adaptation by wavelet shrinkage,” *Biometrika*, vol. 81, no. 3, pp. 425–455, 1994.
- [4] I. Daubechies, *Ten Lectures on Wavelets*. Philadelphia: SIAM, 1992.
- [5] S. Mallat, *A Wavelet Tour of Signal Processing*. San Diego: Academic Press, 1999.
- [6] L. Yin, R. Yang, M. Gabbouj, and Y. Neuvo, “Weighted median filters: a tutorial,” *IEEE Trans. Circuits Syst. II*, vol. 43, no. 3, pp. 157–192, 1996.
- [7] J. D. Hamilton, *Time Series Analysis*. Princeton: Princeton Univ. Press, 1994.
- [8] R. S. Tsay, *Analysis of Financial Time Series*, 3rd ed. Hoboken: Wiley, 2010.
- [9] R. Cont, “Empirical properties of asset returns: stylized facts and statistical issues,” *Quant. Finance*, vol. 1, no. 2, pp. 223–236, 2001.
- [10] B. B. Mandelbrot, “The variation of certain speculative prices,” *J. Business*, vol. 36, no. 4, pp. 394–419, 1963.
- [11] U. Şimşekli, L. Sagun, and M. Gürbüzbalaban, “A tail-index analysis of stochastic gradient noise in deep neural networks,” in *Proc. ICML*, 2019, pp. 5827–5837.

- [12] V. Anantharam and V. S. Borkar, “Stochastic approximation with long range dependent and heavy tailed noise,” *Queueing Syst.*, vol. 71, no. 1–2, pp. 221–242, 2012, doi: 10.1007/s11134-012-9283-0.
- [13] S. Chandak, A. K. Yadav, A. Özgür, and N. Bambos, “Heavy-tailed and long-range dependent noise in stochastic approximation: a finite-time analysis,” *arXiv:2603.19648*, Mar. 2026.
- [14] D. P. Kingma and J. Ba, “Adam: a method for stochastic optimization,” in *Proc. ICLR*, 2015.
- [15] A. Défossez, L. Bottou, F. Bach, and N. Usunier, “A simple convergence proof of Adam and Adagrad,” *Trans. Mach. Learn. Res.*, 2022.
- [16] S. J. Reddi, S. Kale, and S. Kumar, “On the convergence of Adam and beyond,” in *Proc. ICLR*, 2018.
- [17] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *Proc. ICLR*, 2019.
- [18] H. Robbins and S. Monro, “A stochastic approximation method,” *Ann. Math. Stat.*, vol. 22, no. 3, pp. 400–407, 1951.
- [19] E. Gorbunov, M. Danilova, and A. Gasnikov, “Stochastic optimization with heavy-tailed noise via accelerated gradient clipping,” in *Proc. NeurIPS*, vol. 33, 2020, pp. 15042–15053.